Apuntes · Clase 41 · Detección de anomalías

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **Una alerta es una pista.** Indica qué revisar; no demuestra un error. Se investiga antes de eliminar.
2. **Cada método define «inusual» distinto.** Extremo (RIC, z), combinación (Mahalanobis), vecindario (kNN, LOF, DBSCAN), reconstrucción (PCA), aislamiento (Isolation Forest).
3. **z puede no alertar.** Con n pequeño $|z| \le (n-1)/\sqrt{n}$; el extremo infla la media y la desviación.
4. **Escala y covarianza.** kNN, LOF y DBSCAN piden estandarizar; Mahalanobis ya corrige escala y correlación, pero su covarianza es sensible a extremos.
5. **El corte decide las alertas.** Un cuantil fija cuántas alertas; se elige con validación o con la capacidad de revisión, no con la prueba.
6. **Clase escasa: no mires la exactitud.** Compara con «todo normal» y con la prevalencia; usa sensibilidad, precisión y PR.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C41_Anomalias.ipynb` o el cuaderno `C41_Ejercicios_Cuaderno_Anomalias.pdf`.

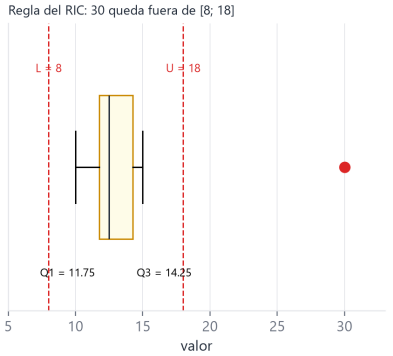
1 RIC y puntaje z

El RIC marca los valores fuera de [Q1 − 1.5·RIC, Q3 + 1.5·RIC]; usa cuartiles, así que no depende de una normal ni de los extremos. El puntaje z = (x − media)/s marca $|z| > 3$, pero la media y la desviación incluyen al propio extremo. Con n datos y desviación muestral, $|z|$ nunca supera $(n-1)/\sqrt{n}$.

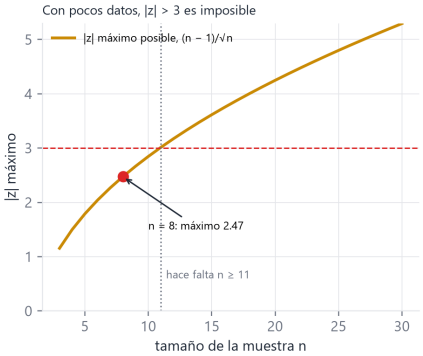
Ejemplo resuelto · ocho valores: 4, 5, 5, 6, 7, 8, 9 y 40

Paso	Cálculo	Resultado
Cuartiles	interpolación lineal, posiciones 1.75 y 5.25	Q1 = 5.00, Q3 = 8.25
RIC y límites	RIC = 3.25; Q1 − 1.5·RIC; Q3 + 1.5·RIC	0.12 y 13.12
Alerta RIC	40 > límite superior	sí (solo el 40)
Media y desviación	con el 40 incluido	10.500 y 12.036
z del 40	(40 − 10.500)/12.036	2.451
Cota para n = 8	(8 − 1)/√8	2.475 < 3

Lectura: el RIC marca el 40 y el z no (aunque 40 es más de 4 veces el segundo mayor). **Error común**: concluir «no hay atípicos» porque $|z| < 3$; con n = 8 ese resultado es inevitable.







Pista para la Parte A del notebook (A1 y A2) y el Bloque 1 del cuaderno

Calcula límites y z con NumPy, dibuja el boxplot y grafica $(n-1)/\sqrt{n}$.

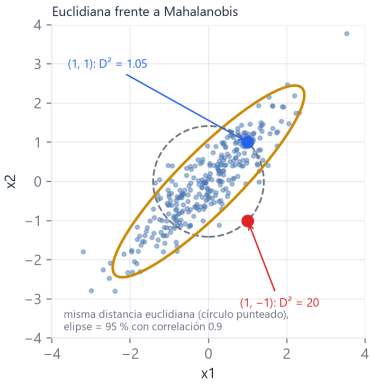
2 Distancia de Mahalanobis

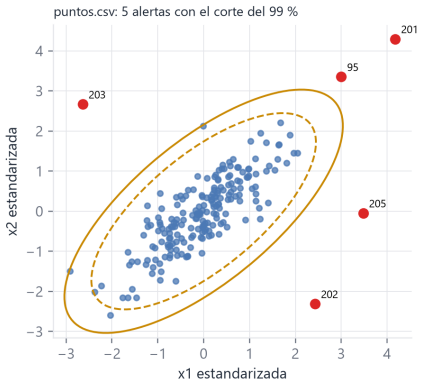
$D^2 = (x - m)^T S^{-1} (x - m)$ con m el centro y S la covarianza. Si las variables están correlacionadas, un punto contrario a la correlación queda lejos aunque sus coordenadas sean moderadas. El corte orientativo es $\chi^2(p; 0.99)$; R devuelve D^2, no D.

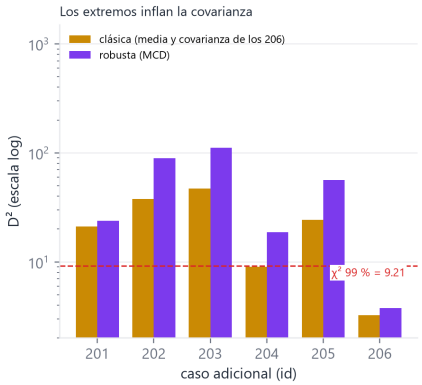
Ejemplo resuelto · centro (50, 30), S = [[25, 12], [12, 16]]; puntos (58, 26) y (58, 34)

Paso	Cálculo	Resultado
Determinante	$25 \cdot 16 - 12^2$	256
Inversa	$(1/256) \cdot [[16, -12], [-12, 25]]$	—
(58, 26): d = (8, −4)	$(16 \cdot 64 + 2 \cdot (-12) \cdot 8 \cdot (-4) + 25 \cdot 16)/256 = 2\,192/256$	$D^2 = 8.562$
(58, 34): d = (8, 4)	$(16 \cdot 64 + 2 \cdot (-12) \cdot 8 \cdot 4 + 25 \cdot 16)/256 = 656/256$	$D^2 = 2.562$
Corte	$\chi^2(2; 0.99)$	9.210

Lectura: ambos puntos están a la misma distancia euclidiana ($\sqrt{80} \approx 8.94$) del centro, pero (58, 26) contradice la correlación positiva ($D^2 = 8.56$, cerca del corte) y (58, 34) la sigue ($D^2 = 2.56$). **Error común**: tomar D^2 como D al compararlo con χ^2.







Pista para la Parte A del notebook (A3) y el Bloque 2 del cuaderno
Calcula D^2 con NumPy y con `MinCovDet`, y compara cuántas alertas da cada covarianza con los seis casos añadidos.

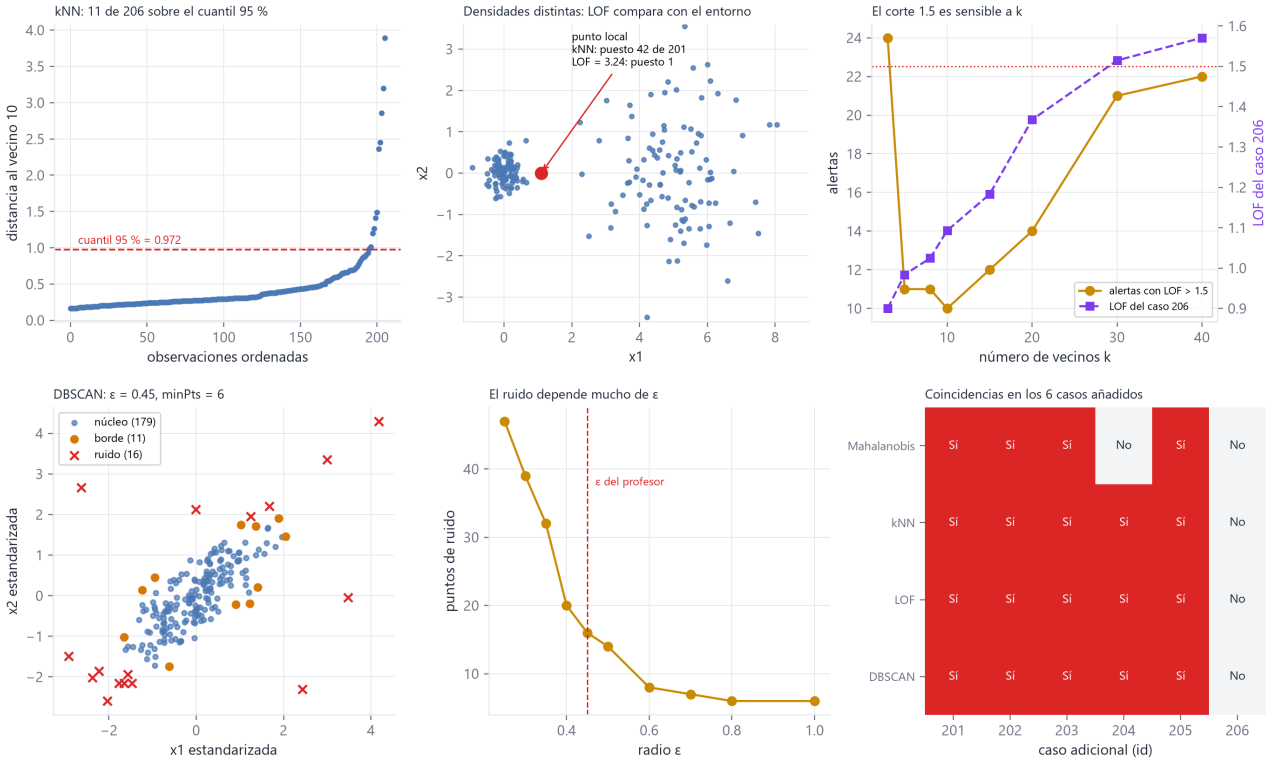
3 kNN y LOF en un conjunto pequeño

El puntaje kNN es la distancia al vecino k (sin contar el propio punto). LOF compara la densidad local con la de los vecinos: reach(i, j) = max{d(i, j), k-dist(j)}, lrd(i) = 1/promedio de reach y LOF(i) = promedio de lrd de los vecinos / lrd(i). Cerca de 1: normal; mucho mayor: candidato a revisión.

Ejemplo resuelto · seis valores en una recta: 1, 2, 3, 4, 6 y 15, con k = 2

Valor	Vecinos	k-dist	lrd	LOF
1	2, 3	2	0.667	1.000
2	1, 3	1	0.667	1.000
3	2, 4	1	0.667	1.000
4	3, 2	2	0.667	1.000
6	4, 3	3	0.400	1.667
15	6, 4	11	0.100	5.333

Lectura: el 15 tiene el mayor k-dist (11) y el mayor LOF (5.33); el 6, con k-dist 3, queda solo moderado (1.67). Ejemplo de reach: reach(15, 6) = max{9, k-dist(6) = 3} = 9. **Error común**: usar 1.5 como regla universal; el LOF depende de k.



Pista para la Parte A del notebook (A4 y A5) y el Bloque 3 del cuaderno
Calcula k-distancias con `NearestNeighbors`, LOF con `LocalOutlierFactor` y compara ε de DBSCAN.

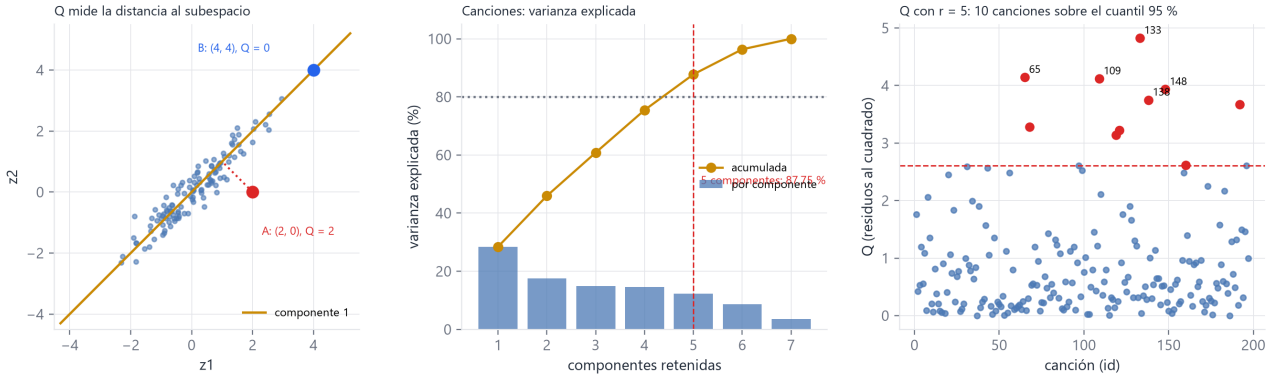
4 PCA: Q y T^2

Con las cargas P de las r componentes, la coordenada de un caso es t = z·P, su reconstrucción es $\hat{z} = t \cdot P^T$ y el error Q = $\Sigma(z - \hat{z})^2$. Q detecta combinaciones que el subespacio no representa; $T^2 = \Sigma\, t^2/\lambda$ detecta casos extremos dentro del subespacio.

Ejemplo resuelto · una componente p = (0.8, 0.6) y el caso z = (3, 1); λ = 4

Paso	Cálculo	Resultado
Coordenada	t = 3·0.8 + 1·0.6	3.00
Reconstrucción	$\hat{z}$ = t·p	(2.40, 1.80)
Error	e = z − $\hat{z}$	(0.60, -0.80)
Q	$0.60^2 + (-0.80)^2$	1.00
T^2	$t^2/\lambda = 3.0^2/4$	2.25

Lectura: Q = 1 dice que el caso se aparta del plano de la componente; T^2 = 2.25 que está moderadamente lejos del centro dentro de él. **Error común**: usar todas las componentes (Q ≈ 0 para todos) o mezclar variables sin estandarizar.



Pista para la Parte B del notebook (B1 y B2)
Reproduce las 10 canciones con mayor Q y compara con T^2.

5 Isolation Forest: longitud de camino y puntaje

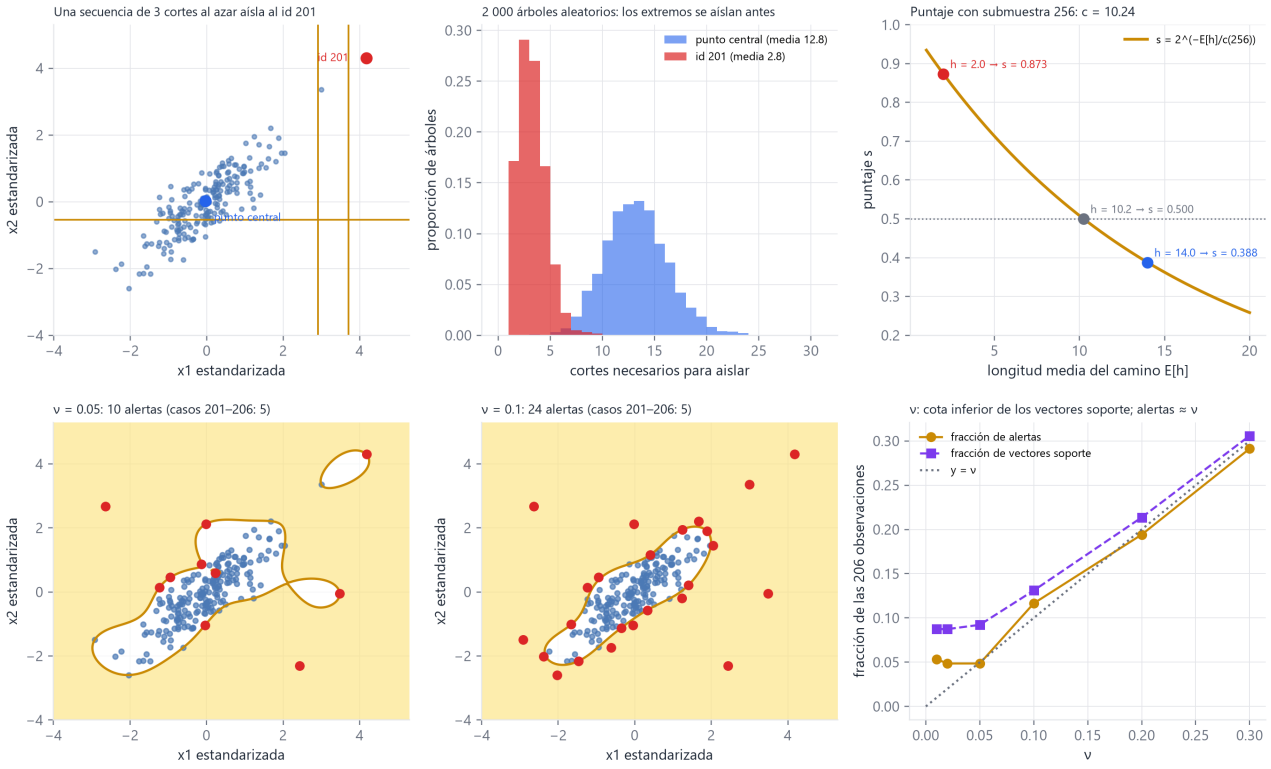
Cada árbol corta al azar hasta aislar los puntos de su submuestra de tamaño ψ. Los casos extremos necesitan pocos cortes. El puntaje s = 2^(−E[h]/c(ψ)), con c(ψ) = 2(ln(ψ − 1) + 0.5772) − 2(ψ − 1)/ψ, vale 0.5 cuando E[h] = c(ψ) y se acerca a 1 con caminos muy cortos. No es una probabilidad. scikit-learn devuelve −s en `score_samples`.

Ejemplo resuelto · submuestra ψ = 64: c(64) = 2(ln 63 + 0.5772) − 2·63/64

Concepto	Cálculo	Resultado
c(64)	2(4.1431 + 0.5772) − 1.9688	7.472

Caso	E[h]	E[h]/c	s
extremo	3.00	0.402	0.757
típico	7.47	1.000	0.500
muy central	12.00	1.606	0.329

Lectura: un caso aislado en 3 cortes tiene s = 0.757; uno que necesita 7.47 (el promedio) tiene 0.5. **Error común**: leer 0.76 como «76 % de probabilidad»; solo ordena.



Pista para la Parte B del notebook (B3) y el Bloque 4 del cuaderno
Verifica la fórmula con las profundidades de los árboles de scikit-learn y mide la variación por semilla.

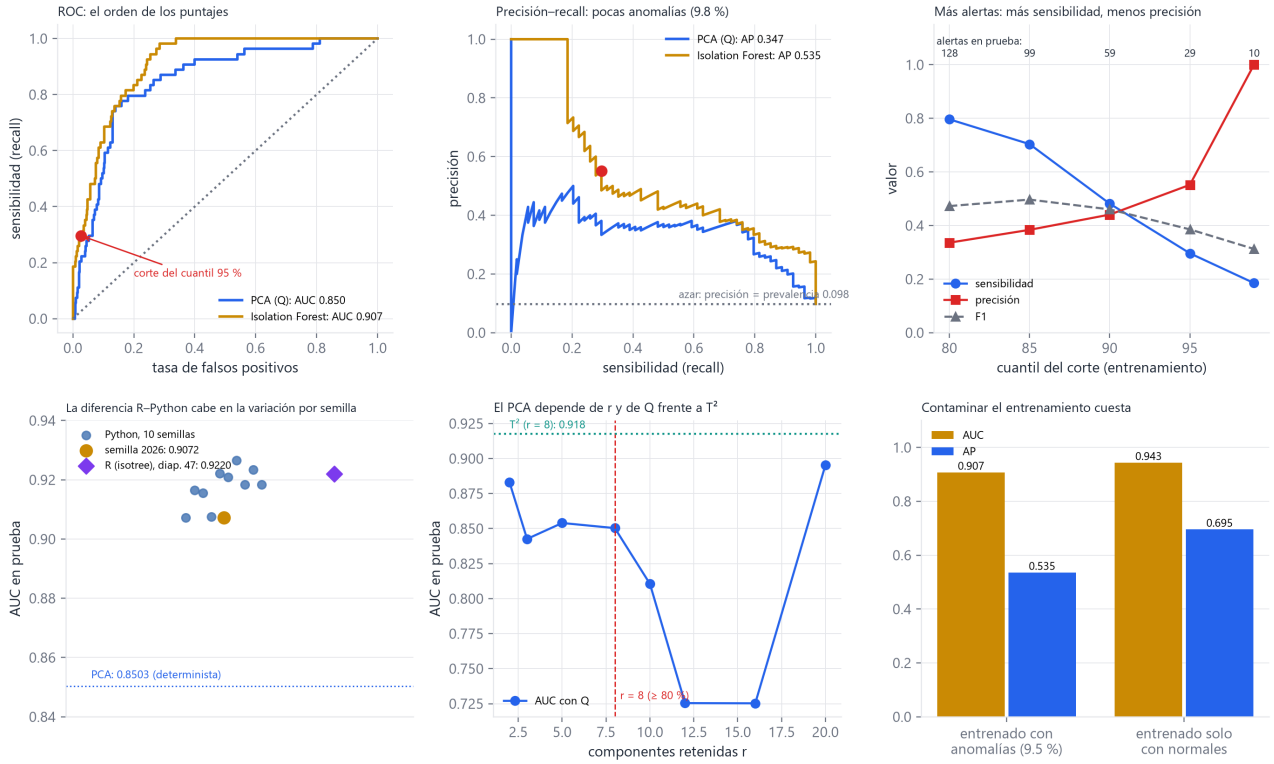
6 Elegir el corte y evaluar con una clase escasa

Un cuantil q del puntaje de entrenamiento fija ≈ (1 − q) de alertas. Con etiquetas, cada corte da una matriz de confusión; con pocas anomalías conviene comparar con la prevalencia: un detector al azar tiene precisión igual a la prevalencia. La exactitud de «todo normal» es 1 − prevalencia.

Ejemplo resuelto · 1 000 registros con 40 anomalías; el detector marca 40 (VP = 20, FP = 20)

Métrica	Cálculo	Resultado
Prevalencia	40/1000	4.0 %
Exactitud	(940 + 20)/1000	96.0 %
«Todo normal»	960/1000	96.0 %
Sensibilidad	20/(20 + 20)	0.500
Precisión	20/(20 + 20)	0.500
Mejora sobre el azar	precisión / prevalencia	12.5 veces

Lectura: la exactitud (96 %) **empata** con no hacer nada, pero el detector acierta la mitad de sus alertas, 12.5 veces mejor que el azar (4 %). **Error común**: celebrar la exactitud o descartar el modelo porque su sensibilidad es 50 %.



Pista para la Parte C del notebook y el Bloque 5 del cuaderno

Calcula la tabla de cuantiles y elige el corte con validación cruzada en entrenamiento, no con la prueba.

Lo que debes recordar

- Una alerta indica qué revisar; investiga el contexto antes de eliminar o corregir.
- Usa varios métodos y mira dónde coinciden; ajusta escala, componentes, bosque y corte solo con entrenamiento.
- El corte fija cuántas alertas; la prevalencia fija la referencia de precisión.
- Orden sugerido: apuntes → Bloques 1–3 del cuaderno → Partes A–B del notebook → Bloques 4–6 → Parte C → ejercicio de cierre.