Ejercicios para el cuaderno · Clase 41 · Detección de anomalías

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: RIC = Q3 − Q1 · límites Q1 − 1.5·RIC y Q3 + 1.5·RIC · $z = (x - \text{media})/s$ · $|z| \le (n-1)/\sqrt{n}$ · $D^2 = (x-m)^T S^{-1}(x-m)$ · reach(i, j) = max{d(i, j), k-dist(j)} · LOF = prom. lrd vecinos / lrd(i) · $s = 2^{-E[h]/c(\psi)}$ · precisión = VP/(VP + FP) · sensibilidad = VP/(VP + FN).
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 RIC y z a mano ★★

Ocho tiempos de respuesta (ms): 50, 52, 53, 55, 56, 58, 60 y 95.

1. Calcula Q1, Q3, RIC y los límites del RIC (interpolación lineal). ¿Qué valor se marca?
2. Calcula la media, la desviación muestral y el z del 95. ¿Lo marca $|z| > 3$?
3. Calcula $(n-1)/\sqrt{n}$. ¿Podría algún valor de estos ocho marcarse con $|z| > 3$?
4. Calcula el z modificado $0.6745 \cdot (x - \text{mediana})/\text{MAD}$ del 95 y compáralo con 3.5.

Bloque 2 Mahalanobis con una covarianza 2×2 ★★★

Centro m = (10, 20) y S = [[9, 6], [6, 16]]. Puntos P1 = (13, 16), P2 = (13, 24) y P3 = (10, 30).

1. Calcula la correlación entre las dos variables y la inversa de S.
2. Calcula D^2 de P1 y P2. ¿Qué tienen en común sus distancias euclidianas?
3. Calcula D^2 de P3 y compara los tres con $\chi^2(2;\ 0.99) = 9.21$.
4. ¿Por qué P1 y P2 tienen D^2 distintos si están a la misma distancia euclidiana?

Bloque 3 k-distancia y LOF ★★★

Cinco valores en una recta: 0, 1, 2, 3 y 9, con k = 2.

1. Escribe los dos vecinos más cercanos y la k-distancia de cada valor.
2. ¿Qué valor marcaría un corte basado en la distancia al vecino 2? Calcula su puntaje.
3. Calcula las distancias de accesibilidad, lrd y LOF del valor 9 (usa lrd(2) = lrd(3) = 0.667).
4. ¿Qué diría LOF de un valor 9 si el resto estuviera igual de disperso (0, 3, 6, 9, 12)?

Bloque 4 Isolation Forest: razonar el aislamiento ★★

Valores 0, 1, 2, 3, 4, 5, 6 y 20. Un corte se elige uniforme entre el mínimo y el máximo del nodo.

1. En el primer corte (uniforme entre 0 y 20), ¿qué probabilidad hay de aislar el 20? ¿Y el 0?
2. ¿Por qué el valor 3 no puede aislarse en un solo corte?
3. Con $\psi = 16$, $c(16) = 2(\ln 15 + 0.5772) - 2 \cdot 15/16$. Calcula c(16) y el puntaje s para E[h] = 2 y E[h] = 8.
4. ¿Qué puntaje corresponde a $E[h] = c(\psi)$? ¿Y qué indica un valor 0.8?

Bloque 5 Elegir la contaminación y el corte ★★

Un sistema procesa 4 000 registros y se espera ≈ 2 % de anomalías (prevalencia). El equipo solo puede revisar 60 alertas.

1. ¿Cuántas anomalías hay? ¿Qué cuantil del puntaje de entrenamiento produce ≈ 60 alertas?
2. Con ese corte, ¿cuál es la sensibilidad máxima posible?
3. Si el corte se fijara con el cuantil 98 % (contamination = 0.02), ¿cuántas alertas esperas y cuál sería el máximo de VP?
4. ¿Por qué no se elige el corte mirando la prueba y qué se hace en su lugar?

Bloque 6 Precisión y sensibilidad con clase escasa ★★★

5 000 casos con 100 anomalías. Corte A: 150 alertas con 40 VP. Corte B: 300 alertas con 60 VP.

1. Para cada corte calcula sensibilidad, precisión y exactitud. ¿Cuál es la exactitud de «todo normal»?
2. Compara la precisión de cada corte con la prevalencia. ¿Cuántas veces mejora al azar?
3. Calcula F1 de A y B. ¿Qué corte prefieres si cada FN cuesta 10 y cada FP cuesta 1?
4. ¿Qué falta para decidir si el modelo es útil: ROC-AUC, PR o ambos? Justifica.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Posiciones 1.75 y 5.25: Q1 = 52 + 0.75·1 = 52.75; Q3 = 58 + 0.25·2 = 58.50; RIC = 5.75. Límites: 52.75 − 1.5·5.75 = 44.125 y 58.50 + 8.625 = 67.125. Se marca el 95.
2	Media = 59.875; s = 14.555; z(95) = (95 − 59.875)/14.555 = 2.413. No supera 3: no alerta.
3	(8 − 1)/√8 = 2.475 < 3: con 8 datos ningún valor puede tener |z| > 3; el z no sirve para este tamaño.
4	Mediana = 55.5; desviaciones absolutas: 5.5, 3.5, 2.5, 0.5, 0.5, 2.5, 4.5, 39.5 → MAD = 3.0. z modificado = 0.6745·39.5/3.0 = 8.88 > 3.5: alerta.

Bloque 2

#	Solución
1	r = 6/(3·4) = 0.50. det = 9·16 − 36 = 108; S^{-1} = (1/108)·[[16, −6], [−6, 9]].
2	P1: d = (3, −4): (16·9 + 2·(−6)·3·(−4) + 9·16)/108 = 432/108 = 4.000. P2: d = (3, 4): (144 − 144 + 144)/108 = 1.333. Ambos están a √25 = 5 del centro.
3	P3: d = (0, 10): 9·100/108 = 8.333. Frente a 9.21: P1 = 4.0 y P2 = 1.33 no alertan; P3 = 8.33 tampoco (cerca del corte).
4	Con correlación positiva (0.5), moverse hacia el mismo lado en ambas variables (P2) es «natural» y moverse en direcciones opuestas (P1) es inusual: Mahalanobis pesa por la dirección de la nube, no solo por la distancia.

Bloque 3

#	Solución
1	0: vecinos 1 y 2, k-dist 2. 1: vecinos 0 y 2, k-dist 1. 2: vecinos 1 y 3, k-dist 1. 3: vecinos 2 y 1, k-dist 2. 9: vecinos 3 y 2, k-dist 7.
2	El 9, con puntaje 7 (el siguiente mayor es 2). Por kNN se marcaría el 9.
3	reach(9, 3) = max{6, k-dist(3) = 2} = 6; reach(9, 2) = max{7, 1} = 7; promedio 6.5; lrd(9) = 1/6.5 = 0.154. LOF(9) = ((0.667 + 0.667)/2)/0.154 = 4.33. Alerta clara (mucho mayor que 1.5).
4	Con 0, 3, 6, 9, 12 los vecinos del 9 están a 3 y las densidades son parecidas: LOF = 1.25 (menor que 1.5) y no alerta, aunque la distancia al vecino sea 3 (kNN sí lo vería alto). LOF mide densidad relativa.

Bloque 4

#	Solución
1	Aislar el 20: basta un corte en (6, 20): 14/20 = 0.70. Aislar el 0: corte en (0, 1): 1/20 = 0.05.
2	Porque cualquier corte deja al menos otro valor al mismo lado (hay valores a ambos lados del 3); hacen falta varios cortes.
3	c(16) = 2(2.708 + 0.5772) − 1.875 = 4.696. E[h] = 2: s = 2^(−2/4.696) = 0.744; E[h] = 8: s = 2^(−8/4.696) = 0.307.
4	E[h] = c(ψ) → s = 2^{-1} = 0.5 (caso típico). 0.8 indica aislamiento más rápido que el típico (candidato a revisar), pero no es una probabilidad.

Bloque 5

#	Solución
1	0.02·4 000 = 80 anomalías. 60/4 000 = 1.5 % de alertas → cuantil 98.5 % del puntaje de entrenamiento.
2	Con 60 alertas se detectan como máximo 60 anomalías de 80: sensibilidad ≤ 60/80 = 0.75 (y solo si todas las alertas fueran anomalías).
3	Cuantil 98 % → 2 % de alertas = 80 alertas, máximo 80 VP (sensibilidad 1) solo en el caso ideal; pero supera la capacidad de revisión (60).
4	Porque la prueba debe medir el resultado final sin haber influido en él. El corte se elige con validación cruzada en entrenamiento o con la capacidad de revisión, y la prueba se consulta una vez.

Bloque 6

#	Solución
1	A: VP 40, FP 110, FN 60, VN 4790: sensibilidad 40/100 = 0.40, precisión 40/150 = 0.267, exactitud 0.9660. B: VP 60, FP 240, FN 40, VN 4660: sensibilidad 0.60, precisión 60/300 = 0.20, exactitud 0.9440. «Todo normal»: 4 900/5 000 = 0.98.
2	Prevalencia 100/5 000 = 0.02. A: 13.3 veces; B: 10.0 veces. Ambas bastante mejores que el azar, aunque las exactitudes (0.966 y 0.944) están por debajo de 0.98.
3	F1(A) = 80/(80 + 110 + 60) = 0.320; F1(B) = 120/(120 + 240 + 40) = 0.300. Costos: A = 10·60 + 110 = 710; B = 10·40 + 240 = 640 → se prefiere B (F1 prefiere A: F1 no usa los costos).
4	Ambos: la ROC-AUC resume el orden pero con 2 % de anomalías puede verse optimista; la PR (con la línea base en 0.02) muestra la precisión que se logra para cada sensibilidad. El corte final se fija con costos o capacidad de revisión.