Apuntes · Clase 43 · Evaluación estadística y bootstrap

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **Una cifra de prueba es una estimación.** Cambia con los casos de evaluación; el SE y el IC dicen cuánto.
2. **Seleccionar ≠ evaluar.** Receta con entrenamiento y validación; prueba una vez; sin fuga.
3. **Bootstrap = remuestrear con reposición.** Misma n; ≈ 63.2 % de los casos distintos; percentiles = IC.
4. **Modelos fijos, casos remuestreados.** No se reentrena: log loss por filas, AUC por clase.
5. **Compara la diferencia, no los dos IC.** Mismos IDs en ambos modelos; IC de Δ; si contiene 0, no hay evidencia clara.
6. **Conoce el alcance.** El IC no incluye reentrenar, cambios de población ni sesgos de diseño.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C43_EvaluacionBootstrap.ipynb` o el cuaderno `C43_Ejercicios_Cuaderno_EvaluacionBootstrap.pdf`.

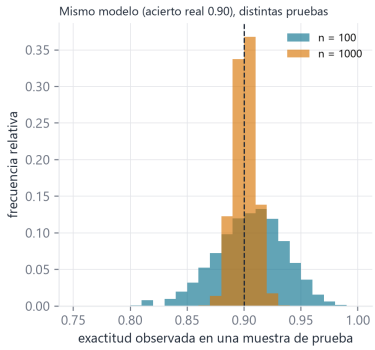
1 Una métrica es una estimación: el error estándar

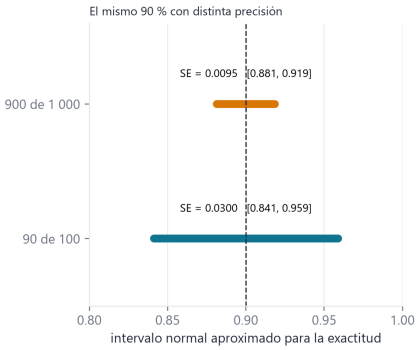
Si un clasificador fijo acierta con probabilidad p en cada caso independiente, la exactitud observada en n casos tiene error estándar $\sqrt{p(1-p)/n}$, que se estima con $\hat{a}$. Aproximadamente, $\hat{a} \pm 1.96$ SE contiene a p en el 95 % de los experimentos.

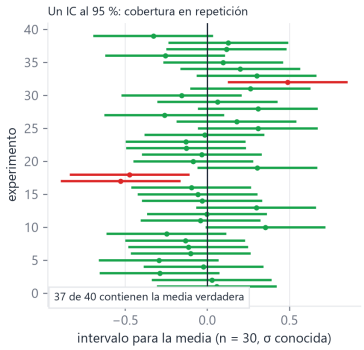
Ejemplo resuelto · un filtro acierta 170 de 200 casos (0.85); otro, 680 de 800 (0.85)

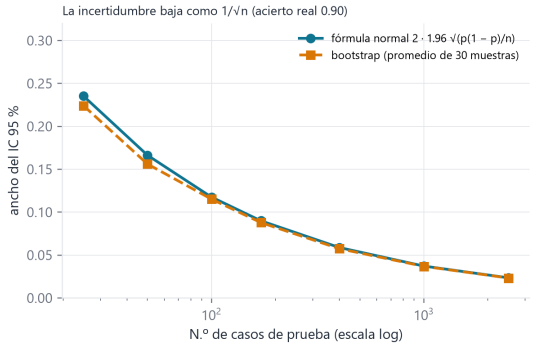
Concepto	Cálculo	Resultado
SE con n = 200	$\sqrt{(0.85 \times 0.15/200)}$	0.0252
IC normal	$0.85 \pm 1.96 \times$ SE	[0.801; 0.899]
SE con n = 800	$\sqrt{(0.85 \times 0.15/800)}$	0.0126
IC normal	$0.85 \pm 1.96 \times$ SE	[0.825; 0.875]

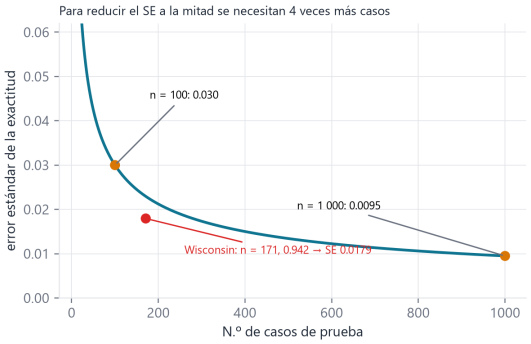
Lectura: el mismo 0.85 es más preciso con 800 casos; con 4 veces más casos el SE se reduce a la mitad (2.00 veces). **Error común**: confundir la desviación de los datos con el error estándar de la estimación, o creer que «95 %» es la probabilidad de que este intervalo contenga a p (es la cobertura del procedimiento).











Pista para la Parte A del notebook (A1 y A2) y los Bloques 1 y 3 del cuaderno
Simula exactitudes con n = 100 y n = 1 000 y compara su desviación con √(p(1 − p)/n).

2 Bootstrap a mano: remuestra, estadística e IC percentil

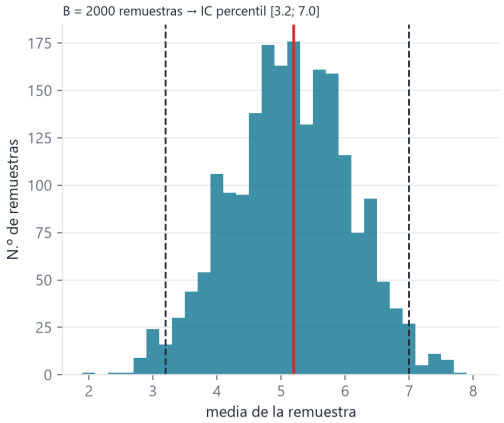
Se parte de la muestra observada. Se sortean n IDs con reposición (la remuestra tiene el mismo tamaño); se calcula la estadística; se repite B veces. Con los B valores ordenados, el IC percentil al 95 % usa los cuantiles 2.5 % y 97.5 %. En un ejemplo pequeño a mano se usa un nivel de 90 %: con B = 20 se descarta 1 valor en cada cola.

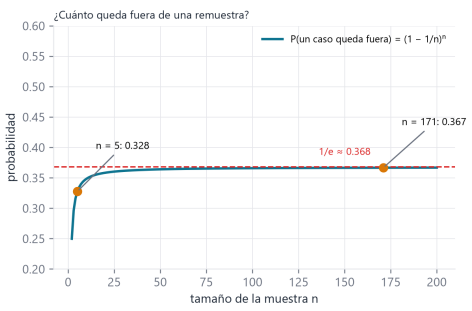
Ejemplo resuelto · cinco tiempos: 3, 5, 6, 9 y 12 minutos (media 7.0)

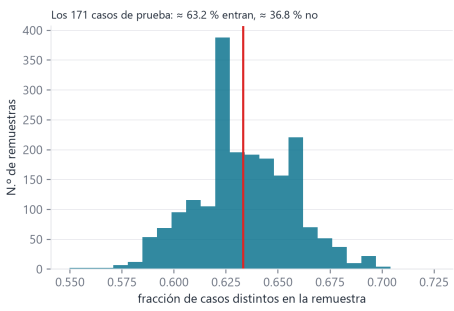
Paso	Cálculo	Resultado
Remuestra con IDs 4, 1, 4, 5 y 2	9, 3, 9, 12 y 5	media 7.6
Se repite B = 20 veces	20 medias ordenadas	4.0, 4.4, 5.4, 5.6, 6.0, 6.2, 6.2, 6.2, 6.4, 6.6, 6.8, 6.8, 7.0, 7.4, 7.6, 7.8, 7.8, 7.8, 7.8, 9.4
IC del 90 % (sin la 1.ª ni la 20.ª)	2.º menor y 2.º mayor	[4.4; 7.8]
Error estándar bootstrap	desviación de las 20 medias	1.263

Lectura: la distribución de las medias remuestreadas da una idea de cuánto cambiaría la media con otra muestra. Con B = 20 y n = 5 es solo para entender la cuenta; en la práctica B = 2 000 o más. **Error común**: remuestrear sin reposición (daría siempre la misma muestra), o creer que más remuestras dan más información sobre los datos.









Pista para la Parte A del notebook (A3 a A5) y los Bloques 1, 2 y 7 del cuaderno
Reproduce 5.2, SE 0.9306 e IC [3.2; 7.0] con la semilla 20261012 y compáralos con las 3 125 remuestras exactas.

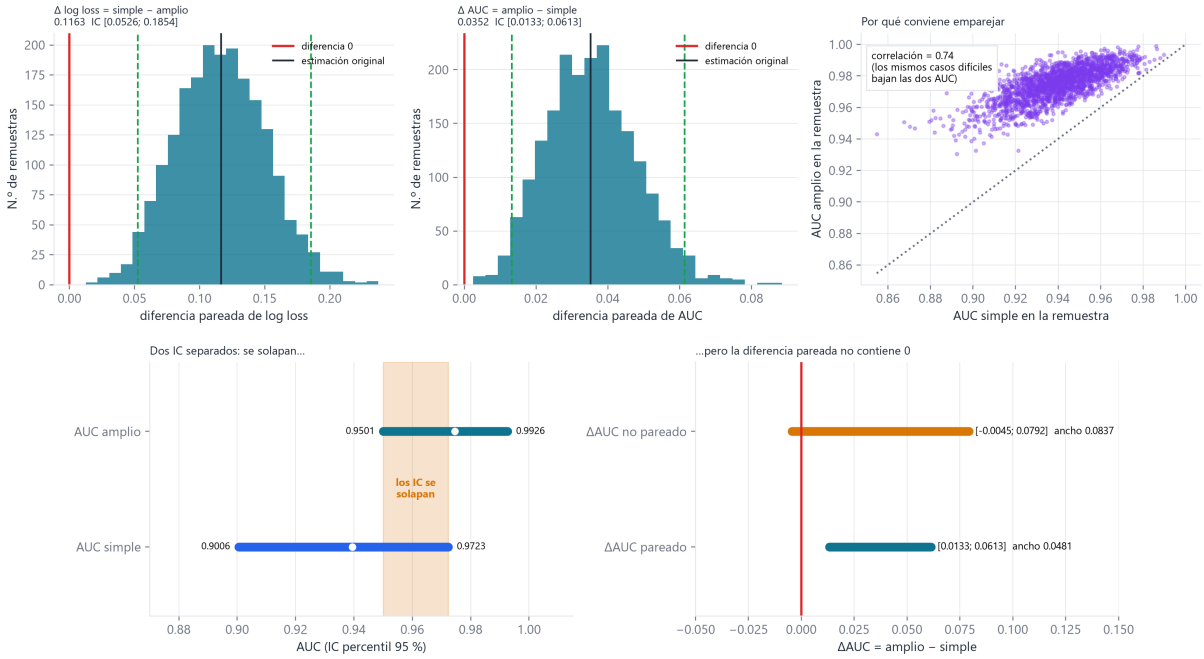
3 Modelos fijos, diferencia pareada y por qué no basta solapar

Se ajustan los modelos una vez; con sus predicciones fijas se remuestrean los casos de prueba (log loss por filas, AUC por clase) y se recalcula la métrica. Para comparar, se usa la **misma** remuestra en ambos modelos y se toman los percentiles de la **diferencia**.

Ejemplo resuelto · pérdidas de dos modelos en los mismos 8 casos (A y B)

Concepto	Cálculo	Resultado
Diferencias A − B	caso por caso	0.2, 0.0, 0.1, 0.3, 0.0, 0.1, 0.0, 0.2
Media y desviación de las diferencias	media; desviación (n − 1)	0.1125 y 0.1126
SE pareado	desviación/√8	0.0398
SE sin emparejar	$\sqrt{(sA^2/8 + sB^2/8)}$	0.1658
Cociente	SE no pareado / SE pareado	4.16

Lectura: los dos modelos sufren los mismos casos difíciles (la pérdida del caso 4 es alta para ambos), así que las diferencias varían poco y el SE pareado es mucho menor. **Error común**: tratar las dos columnas como muestras independientes, o concluir «no hay diferencia» porque los IC de cada modelo se solapan.



Pista para la Parte C del notebook (C1 a C5) y los Bloques 4 y 6 del cuaderno
Remuestrea los mismos IDs para los dos modelos y compara el IC pareado con el no pareado.

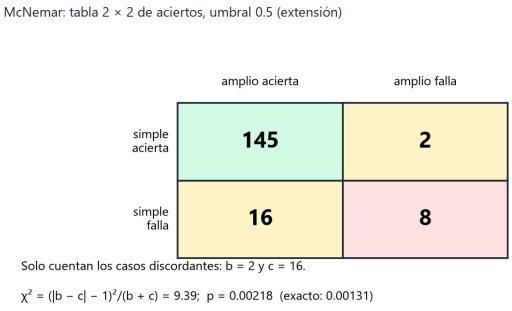
4 McNemar: comparar exactitudes con casos discordantes (extensión)

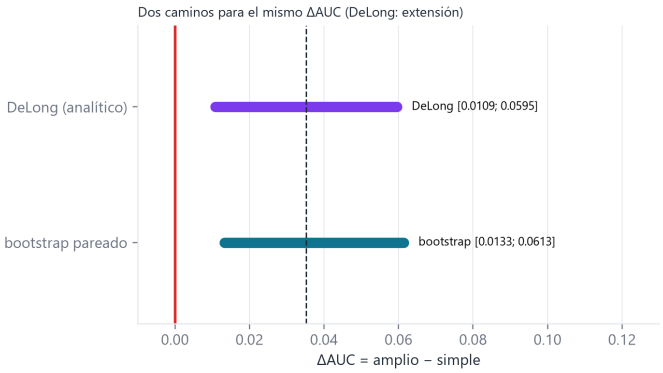
Con las predicciones de dos clasificadores en los mismos casos se arma una tabla 2 × 2 de aciertos. Solo cuentan los casos **discordantes**: b (solo A acierta) y c (solo B acierta). Si no hay diferencia, b y c deberían ser parecidos: $\chi^2 = (|b - c| - 1)^2/(b + c)$, con 1 grado de libertad.

Ejemplo resuelto · 100 casos: ambos aciertan 70; solo A, 12; solo B, 4; ambos fallan 14

Concepto	Cálculo	Resultado
Exactitudes	(70 + 12)/100 y (70 + 4)/100	0.82 y 0.74
Discordantes	b = 12; c = 4	b + c = 16
Estadístico	$(\|12 - 4\| - 1)^2/16 = 49/16$	3.0625
Valor p (χ^2, 1 gl)	$P(\chi^2 \geq 3.06)$	0.0801
Valor p exacto	2 P(X ≤ 4), X ~ Binomial(16; 0.5)	0.0768

Lectura: con 0.82 frente a 0.74 no se rechaza «sin diferencia» al 5 % (p ≈ 0.08). **Error común**: usar los 100 casos en vez de los discordantes, o olvidar que McNemar compara exactitudes con un umbral fijo, no AUC ni log loss.





Pista para la Parte D del notebook (D1 y D2) y el Bloque 5 del cuaderno

Calcula la tabla con los aciertos de los dos modelos de Wisconsin y compara con DeLong y con el bootstrap.

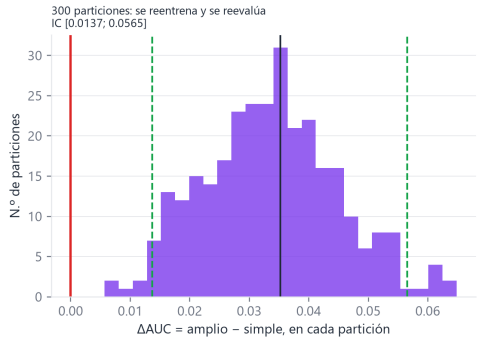
5 Qué cubre el intervalo y qué no

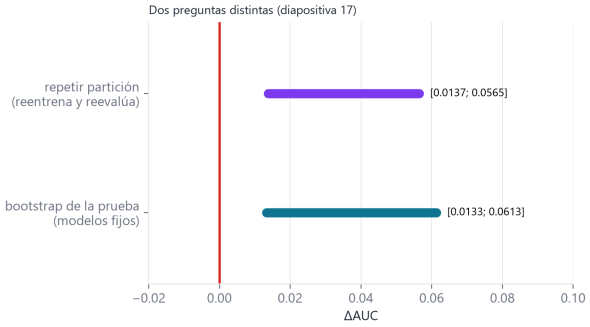
El bootstrap de la prueba con modelos fijos responde «¿cuánto varía la evaluación de **este** modelo si cambian los casos?». No responde «¿cuánto varía el modelo si lo vuelvo a entrenar?». Tampoco corrige una fuga de datos previa ni cambios futuros de población.

Ejemplo resuelto · tres diferencias hipotéticas de log loss con la mejora relevante fijada en 0.010

Δ̂	IC 95 %	Lectura
0.010	[−0.004; 0.024]	no hay evidencia clara de superioridad; no prueba equivalencia
0.002	[0.001; 0.003]	positiva, pero menor que la mejora relevante
0.030	[0.020; 0.050]	positiva y por encima de la mejora relevante

Lectura: excluir 0 no basta; hay que compararlo con el tamaño relevante. **Error común**: decir «equivalentes» porque el IC contiene 0.





Pista para la Parte D del notebook (D3 y D4)

Repite 300 particiones (reentrenando) y compara el ancho del intervalo con el del bootstrap de la prueba.

Lo que debes recordar

- Una métrica de prueba es una estimación; el IC dice cuánto podría variar.
- Bootstrap: remuestras del mismo tamaño, con reposición; ≈ 63.2 % de casos distintos; percentiles 2.5 y 97.5.
- Con modelos fijos: no se reentrena. Log loss por filas; AUC por clase; mismos IDs en ambos modelos.
- Compara la diferencia pareada, no los dos IC por separado; excluir 0 no es lo mismo que una mejora relevante.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.