Ejercicios para el cuaderno · Clase 43 · Evaluación y bootstrap

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: SE(â) = √(â(1 − â)/n) · â ± 1.96 SE · IC percentil = cuantiles 2.5 % y 97.5 % de las estadísticas bootstrap · P(caso fuera) = $(1 - 1/n)^n$ · SE pareado = desv(diferencias)/√n · McNemar: $\chi^2 = (|b - c| - 1)^2/(b + c)$.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Una remuestra bootstrap a mano ★

Un clasificador se evalúa en 8 casos. Verdadero y predicho (IDs 1 a 8): 1: y = 1, pred = 1; 2: y = 0, pred = 0; 3: y = 1, pred = 0; 4: y = 1, pred = 1; 5: y = 0, pred = 0; 6: y = 0, pred = 1; 7: y = 1, pred = 1; 8: y = 0, pred = 0.

1. Calcula la exactitud original.
2. Remuestra A, con los IDs 3, 3, 6, 1, 8, 2, 3, 5: calcula su exactitud. ¿Cuántos IDs distintos hay y cuáles no aparecen?
3. Remuestra B, con los IDs 7, 7, 1, 4, 2, 8, 5, 1: calcula su exactitud. ¿Qué enseña sobre la variación de la métrica?

Bloque 2 Intervalo percentil desde valores ordenados ★★

Se hicieron B = 40 remuestras y se ordenaron las AUC de menor a mayor: 0.840, 0.849, 0.851, 0.857, 0.859, 0.861, 0.863, 0.864, 0.867, 0.869, 0.869, 0.872, 0.873, 0.875, 0.875, 0.875, 0.876, 0.876, 0.878, 0.879, 0.881, 0.882, 0.886, 0.886, 0.886, 0.887, 0.888, 0.892, 0.892, 0.893, 0.895, 0.895, 0.899, 0.899, 0.901, 0.902, 0.904, 0.911, 0.913, 0.914. La AUC original fue 0.884.

1. Construye el IC percentil del 90 % descartando 5 % en cada cola (2 valores de cada lado).
2. ¿Contiene la AUC original? ¿Y el valor 0.85, que alguien propone como referencia?
3. Si con B = 400 el IC casi no cambiara, ¿qué conclusión es correcta y cuál no?

Bloque 3 Error estándar de una exactitud ★★

Un modelo acierta 54 de 60 casos de prueba. El bootstrap de esa prueba dio un SE de 0.040.

1. Calcula â y el SE con la fórmula normal. Compáralo con el SE bootstrap.
2. Construye el IC normal del 95 %. ¿Por qué un IC exacto o de Wilson sería preferible aquí?
3. ¿Cuántos casos habría que evaluar para reducir el SE a la mitad (con la misma exactitud)?

Bloque 4 Comparación pareada frente a no pareada ★★★

Pérdida (log loss por caso) de dos modelos en los mismos 6 casos. A: 0.6, 0.9, 0.3, 1.1, 0.4, 0.8. B: 0.5, 0.7, 0.3, 0.9, 0.3, 0.7.

1. Calcula las diferencias A − B, su media y su desviación (n − 1).
2. Calcula el SE pareado y el SE como si A y B fueran muestras independientes.
3. Explica con una frase por qué el SE pareado es menor y qué supone emparejar.

Bloque 5 McNemar a mano ★★

Dos clasificadores se evalúan en 120 casos: ambos aciertan 80; solo A acierta 15; solo B acierta 5; ambos fallan 20.

1. Calcula las exactitudes de A y B.
2. Calcula el estadístico de McNemar con corrección de continuidad y compáralo con 3.84.
3. Calcula el valor p aproximado (χ^2, 1 gl). ¿Qué concluyes?

Bloque 6 Interpretar intervalos que se solapan ★★★

AUC del modelo 1: IC [0.84; 0.92]; AUC del modelo 2: IC [0.88; 0.95]. Con los mismos casos y remuestras pareadas, el IC de la diferencia (2 − 1) es [0.005; 0.070].

1. ¿Se solapan los dos IC? ¿Se puede concluir «no hay diferencia» por eso?
2. ¿Qué dice el IC de la diferencia pareada? ¿Y si fuera [−0.010; 0.080]?
3. Con un IC de la diferencia [0.001; 0.003] y una mejora relevante de 0.010, ¿qué se concluye?

Bloque 7 Probabilidad de quedar fuera de la remuestra ★★

Una muestra de prueba tiene n = 20 casos.

1. Calcula la probabilidad de que un caso concreto no aparezca en una remuestra de tamaño 20.
2. Calcula el número esperado de casos distintos en la remuestra.
3. Compara con el límite para n grande y con n = 171 (Wisconsin).

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Aciertos por ID: 1→1, 2→1, 3→0, 4→1, 5→1, 6→0, 7→1, 8→1. Exactitud = 6/8 = 0.750.
2	Remuestra A: aciertos 0, 0, 0, 1, 1, 1, 0, 1 → 4/8 = 0.500. IDs distintos: 6 (1, 2, 3, 5, 6, 8); no aparecen 4, 7.
3	Remuestra B: aciertos 1, 1, 1, 1, 1, 1, 1, 1 → 8/8 = 1.000. La misma muestra produce exactitudes de 0.500, 0.750 y 1.000: la métrica depende de qué casos entran, y el bootstrap mide esa variación.

Bloque 2

#	Solución
1	Se descartan los 2 menores (0.840, 0.849) y los 2 mayores (0.913, 0.914). IC del 90 % = [0.851; 0.911] (el 3.º menor y el 3.º mayor; *np.quantile* interpola y puede diferir en el tercer decimal).
2	0.884 sí está dentro. El 0.85 no está dentro: por tanto 0.85 queda fuera de los valores razonables según esta remuestra.
3	Correcto: el cálculo es estable (menos error Monte Carlo). Incorrecto: pensar que se sabe más sobre la población; la incertidumbre por tener solo n casos originales no baja con B.

Bloque 3

#	Solución
1	$\hat{a}$ = 54/60 = 0.90; SE = $\sqrt{(0.90 \times 0.10/60)}$ = 0.0387. El bootstrap (0.040) es casi igual: coincide porque el modelo es fijo y los casos independientes.
2	IC normal = 0.90 ± 1.96 × 0.0387 = [0.824; 0.976]. Con 60 casos y acierto cercano a 1 la aproximación normal es mala (la cota superior se acerca a 1); el IC exacto (Clopper-Pearson) es [0.795; 0.962].
3	El SE es proporcional a $1/\sqrt{n}$: para reducirlo a la mitad hay que cuadruplicar los casos: 240.

Bloque 4

#	Solución
1	Diferencias: 0.1, 0.2, 0.0, 0.2, 0.1, 0.1. Media = 0.1167; desviación (n − 1) = 0.0753.
2	SE pareado = $0.0753/\sqrt{6}$ = 0.0307. Sin emparejar: desviaciones 0.3061 y 0.2422 → SE = $\sqrt{(0.0937/6 + 0.0587/6)}$ = 0.1593.
3	El SE pareado es 5.2 veces menor: los casos difíciles suben la pérdida de ambos modelos; al restar, esa parte se cancela. Emparejar supone que los dos modelos se evalúan en los mismos casos.

Bloque 5

#	Solución
1	A: (80 + 15)/120 = 0.7917; B: (80 + 5)/120 = 0.7083.
2	b = 15 y c = 5: $\chi^2 = (\lvert 15 - 5 \rvert - 1)^2/20 = 81/20 = 4.05$. Es mayor que 3.84.
3	p ≈ 0.0442 (exacto 0.0414). Se rechaza «sin diferencia» al 5 %: A acierta más que B. La diferencia absoluta es 0.083.

Bloque 6

#	Solución
1	Sí: [0.88; 0.92] es común. No se puede concluir «no hay diferencia»: los IC marginales no usan el emparejamiento.
2	[0.005; 0.070] no contiene 0: el modelo 2 es mejor en esta evaluación. Con [−0.010; 0.080] contendría 0: no hay evidencia clara (no prueba equivalencia).
3	El IC excluye 0 (diferencia estadística), pero 0.003 es menor que la mejora relevante 0.010: es positiva y chica; en la práctica no justifica el cambio si la mejora relevante fijada es 0.010.

Bloque 7

#	Solución
1	$(1 - 1/20)^{20} = 0.95^{20} = 0.3585$.
2	$20 \times (1 - 0.3585) = 12.83$ casos distintos (≈ 64.2 %).
3	El límite es $1/e = 0.3679$ (36.8 % fuera, 63.2 % dentro); con n = 171, 0.3668. Con n = 20 ya es muy parecido: 0.0094 de diferencia.