Apuntes · Clase 44 · Aplicaciones de IA y panorama del Deep Learning

Para leer antes de los ejercicios · lectura de ~35 min · pensado para quien recién parte con deep learning

Lo más importante, en 7 ideas

1. **Primero la tarea.** Clasificar, pronosticar, recuperar o generar; luego datos, modelo y comprobación.
2. **Todo entra como números.** Una imagen 8 × 8 son 64 intensidades (0–16), escaladas a 0–1.
3. **El modelo entrega probabilidades.** Se predice la clase más probable; la probabilidad de la clase real da el log loss.
4. **Exactitud y log loss no dicen lo mismo.** Mismos aciertos, distinta calidad de probabilidades.
5. **Un resultado no es una garantía.** Bootstrap para la incertidumbre; desplazar la imagen para ver robustez.
6. **Embeddings: significado como cercanía.** Textos o imágenes como vectores; distancia y coseno.
7. **Costos, revisión y diseño de la prueba.** Errores con precio, capacidad limitada y separación por la unidad real.

Cada sección trae una explicación en palabras simples, un **ejemplo resuelto con números distintos** a los de los ejercicios y un resumen «para recordar». Ejercicios en `C44_Ejercicios_Cuaderno_AplicacionesIA_DeepLearning.pdf` y notebook `C44_AplicacionesIA_DeepLearning.ipynb`.

1 Antes de elegir un modelo: la tarea, los datos y la comprobación

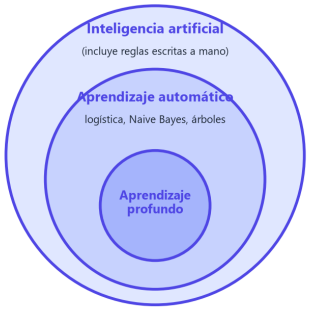
Imagina que te piden «automatizar algo». Lo primero no es escoger un algoritmo, sino responder tres preguntas: **¿qué entra?**, **¿qué debe salir?** y **¿cómo sabré que la salida sirve?** El profesor insistió en que el objetivo va **antes** que los datos: si se parte de «tengo estos datos, ¿qué hago?», se termina adaptando el método a lo que hay y no a lo que importa. Las tareas se agrupan en cuatro: **clasificar** (una categoría), **pronosticar** (una cantidad futura), **recuperar** (encontrar y ordenar fuentes) y **generar** (texto o imagen). Una aplicación real mezcla varias; a esa cadena de tareas se le llama **sistema**.

Ejemplo resuelto · «Me cobraron dos veces y necesito el comprobante»

Paso	Tarea	Salida posible	Cómo se comprueba
1	Clasificar	Categoría «cobros» y prioridad	Compararla con la categoría correcta
2	Consultar y recuperar	Registros del caso y procedimiento	Que sean pertinentes y estén vigentes
3	Redactar	Borrador de respuesta	Cada afirmación tiene respaldo; lo faltante se declara

Lectura: una sola consulta se descompone en tres tareas distintas, cada una con su evaluación. **Error común**: evaluar solo que «el texto se lea bien» (fluidez) y no que sea verdadero (fidelidad).

Dentro de este mapa aparecen tres términos que suelen confundirse: la **inteligencia artificial** (todo sistema que reconoce, predice o genera, incluso con reglas escritas a mano), el **aprendizaje automático** (aprende patrones de datos: logística, Naive Bayes) y el **aprendizaje profundo** (aprende varias transformaciones sucesivas). Cada uno está dentro del anterior.



Lo que debes recordar

- Tarea → datos → modelo → salida → comprobación → uso
- Cuatro tareas: clasificar, pronosticar, recuperar, generar
- Fluidez ≠ fidelidad: un texto bien escrito puede inventar una aprobación

2 Representar los datos: de una imagen a 64 números

Un modelo matemático no «ve» una foto: recibe números. Una imagen en blanco y negro es una cuadrícula de celdas (**píxeles**) y cada celda tiene una **intensidad**. En la colección de dígitos hay 1797 imágenes de 8 × 8 píxeles, con intensidades de 0 (blanco) a 16 (negro). La matriz se lee **fila por fila en un orden fijo** y se obtiene un vector de 64 números; se divide por 16 para que queden entre 0 y 1. La etiqueta (el dígito correcto) se guarda **aparte**: no es parte de la entrada.

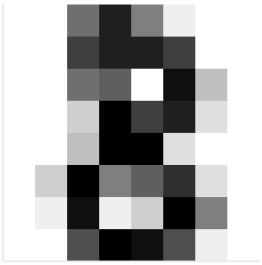
Ejemplo resuelto · la imagen del 8 de la diapositiva 11

Paso	Cálculo	Resultado
Primera fila de la matriz	leer de izquierda a derecha	[0, 0, 9, 14, 8, 1, 0, 0]
Tamaño de la entrada	8 filas × 8 columnas	64 números
Escalar 9, 14 y 8	dividir por 16	0.5625; 0.875; 0.5
Etiqueta	se guarda separada	8

Lectura: el modelo recibe 64 columnas entre 0 y 1; la etiqueta solo sirve para aprender y para evaluar. **Error común**: pensar que hay una única forma «correcta» de pasar objetos a números: hay infinitas, y hay que diseñarla según la tarea.

Lo mismo pasa con un texto. Si se cuentan las palabras «crédito, gratis, urgente», el correo «crédito gratis crédito» queda como [2, 1, 0]: se conservan las frecuencias pero se **pierde el orden** (por eso «el hombre mordió al perro» y «el perro mordió al hombre» darían los mismos números). La representación importa porque define qué diferencias puede usar el modelo.

Lo que vemos: etiqueta 8



Lo que ve el modelo: 8 × 8 = 64 números (0 a 16)

0	0	9	14	8	1	0	0
0	0	12	14	14	12	0	0
0	0	9	10	0	15	4	0
0	0	3	16	12	14	2	0
0	0	4	16	16	2	0	0
0	3	16	8	10	13	2	0
0	1	15	1	3	16	8	0
0	0	11	16	15	11	1	0

Primera fila → vector → escala 0 a 1

fila 1: [0, 0, 9, 14, 8, 1, 0, 0]

se lee por filas, siempre en el mismo orden:

[0, 0, 9, 14, 8, 1, ...] → 64 números

9 ÷ 16 = 0.5625

14 ÷ 16 = 0.875

8 ÷ 16 = 0.5

Entrada: 64 números entre 0 y 1.
La etiqueta se guarda aparte.

Lo que debes recordar

- Imagen 8 × 8 = 64 intensidades (0–16); ÷ 16 → 0–1
- La etiqueta va aparte de la entrada
- Contar palabras conserva frecuencias y pierde el orden

3 La salida: probabilidades, decisión y pérdida logarítmica

Para cada imagen el clasificador entrega **diez probabilidades** (una por dígito) que suman 1. La regla habitual es predecir la clase con la mayor. Pero **lo que se elige y la probabilidad de la clase real son dos cosas distintas**: si el real es 8 y el modelo da 0.25 al 8 y 0.60 al 3, predice 3 y se equivoca, aunque haya dado algo de probabilidad al 8. La **pérdida logarítmica** (log loss) mira justamente esa probabilidad de la clase real: la pérdida de una imagen es −ln(p), y el log loss es el promedio. Menor es mejor.

Ejemplo resuelto · cuatro imágenes con la probabilidad que el modelo dio al dígito real

Imagen	p del dígito real	Pérdida −ln(p)	Lectura
1	0.95	0.0513	muy buena
2	0.70	0.3567	buena
3	0.30	1.2040	mala (probablemente error)
4	0.02	3.9120	muy mala: error muy confiado
Promedio		1.3810	log loss de las 4 imágenes

Lectura: una sola imagen (la 4) aporta 71 % de la pérdida total. Por eso el log loss castiga los errores confiados. **Error común**: usar la probabilidad de la clase predicha en vez de la de la clase real (si el real es 8 y se predijo 3 con 0.90, se usa la probabilidad del 8, por ejemplo 0.01).



Un **umbral** es un valor de corte, por ejemplo «aceptar sin revisión si la probabilidad supera 0.90». Es una regla de decisión que se fija con validación, no algo que venga del modelo, y no garantiza el acierto: en los errores de la red hubo probabilidades de 0.76 a 0.94 (diapositiva 17).

Lo que debes recordar

- La clase elegida ≠ la probabilidad de la clase real
- log loss = promedio de −ln(p real); más bajo es mejor
- Una probabilidad alta no garantiza el acierto de esa imagen

4 Comparar dos modelos: exactitud, log loss y bootstrap

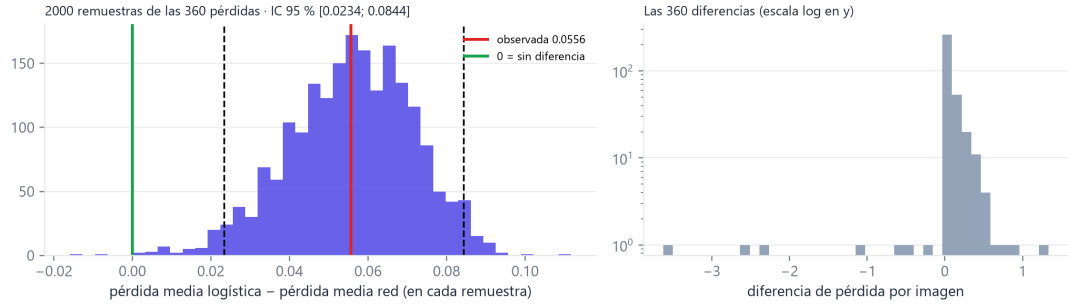
Se compara una regresión logística (referencia barata e interpretable) con una red neuronal. Cada una se ajusta con entrenamiento, se elige por validación y se evalúa **una vez** en las 360 imágenes de prueba. En la corrida del profesor, la logística acierta 353 y la red 354: **un acierto más equivale a 100/360 ≈ 0.28 puntos porcentuales**. El log loss, en cambio, difiere bastante (0.1353 vs 0.0657). En nuestra reproducción ambos aciertan 353 de 360 y el log loss es 0.1353 (logística) frente a 0.0797 (red).

Ejemplo resuelto · de aciertos a exactitud y por qué un acierto pesa tan poco

Concepto	Cálculo	Resultado
Exactitud de 353 aciertos	353 ÷ 360	98.06 %
Exactitud de 354 aciertos	354 ÷ 360	98.33 %
Diferencia	(354 − 353) ÷ 360	0.28 puntos
Log loss logística − red (diapositivas)	0.1353 − 0.0657	0.0696

Lectura: la exactitud casi no distingue; el log loss muestra que las probabilidades de la red son mejores. **Error común**: elegir un modelo solo por exactitud cuando los errores confiados importan.

¿Y si esa ventaja se debe a **cuáles** 360 imágenes se usaron? El **bootstrap** responde reutilizando las 360 pérdidas por imagen (con los modelos ya entrenados, sin volver a ajustarlos): se sortean 360 imágenes **con reposición**, se calcula la diferencia de pérdidas medias y se repite B = 2 000 veces. Los percentiles 2.5 y 97.5 forman un intervalo del 95 %. En las diapositivas el intervalo es [0.0478; 0.0901]; en nuestra reproducción, [0.0234; 0.0844]. En ambos **el 0 queda fuera**: hay evidencia de menor pérdida de la red, bajo independencia por imagen. No dice nada sobre la utilidad práctica de la mejora ni sobre un cambio de cámara.



Lo que debes recordar

- Un acierto más son 100/360 ≈ 0.28 puntos de exactitud
- Bootstrap: remuestrear las pérdidas por imagen, modelos fijos; el IC de la diferencia excluye 0 → evidencia de menor pérdida
- El IC no cubre la utilidad práctica ni el cambio de cámara

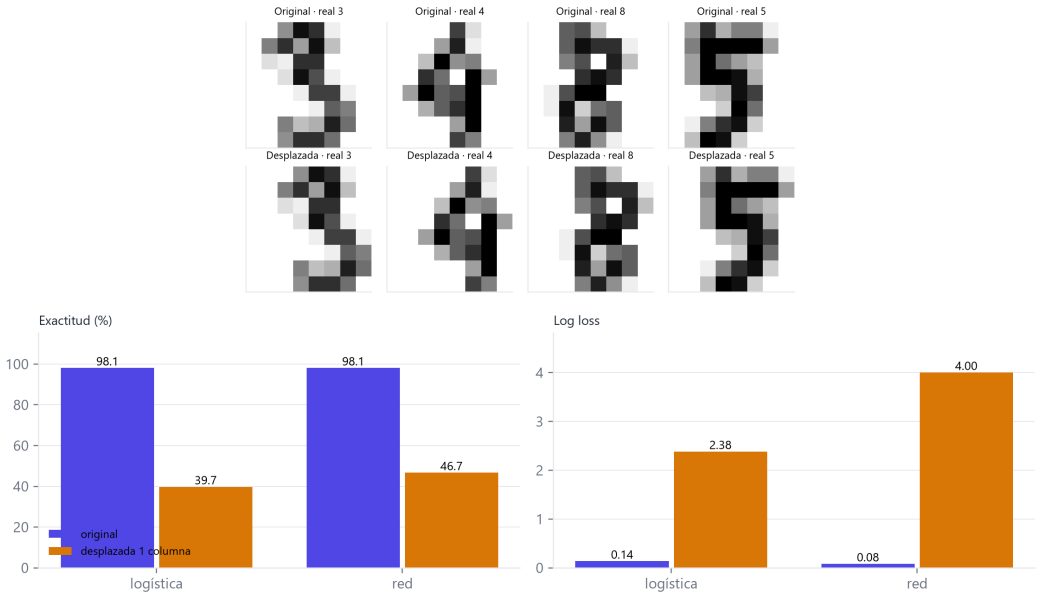
5 ¿Resiste otras condiciones? Robustez y límites de una prueba

Una prueba solo habla de las condiciones en que se midió: esta colección, esta cámara, estos trazos. Para ver si los modelos toleran un cambio, la clase hizo una **prueba de estrés**: desplazar cada imagen **una columna a la derecha** (la primera columna se rellena con 0 y la última original se descarta) y evaluar **los mismos modelos sin reajustarlos**. La exactitud de la logística cae de 98.06 % a 39.72 % y la de la red, de 98.06 % a 46.67 % (nuestra reproducción). Con 10 clases, adivinar daría 10 %. Para una persona es «la misma imagen»; para el modelo, los números cambiaron mucho. La red desplazada acierta algo más, pero su log loss es peor porque asigna probabilidades muy pequeñas al dígito real.

Ejemplo resuelto · desplazar una matriz de 4 × 4 una columna a la derecha

Fila	Original → desplazada	Qué pasó
1	[0, 5, 9, 2] → [0, 0, 5, 9]	entra un 0 a la izquierda y sale el último (2)
2	[1, 0, 7, 3] → [0, 1, 0, 7]	cada número se corre una posición

Lectura: todos los valores se movieron de posición; para un modelo que lee «posición 3 = tal intensidad», es una entrada completamente distinta. **Error común**: creer que un buen resultado original garantiza buenos resultados con cualquier cambio de entrada.



Lo que debes recordar

- Una prueba habla de sus condiciones: colección, cámara, escritores
- El desplazamiento es una prueba de estrés artificial, no una cámara real
- Un buen resultado original no garantiza robustez

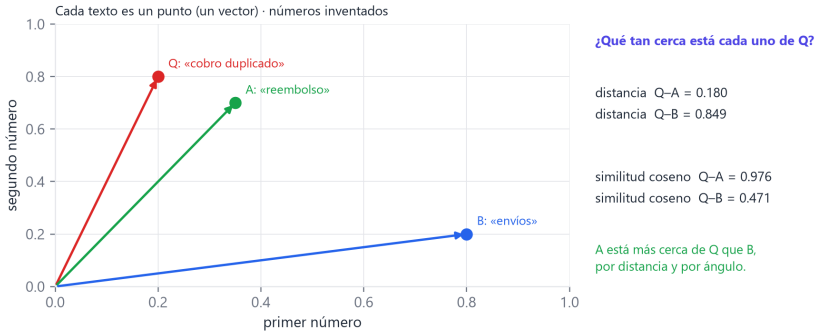
6 Embeddings: convertir significado en cercanía

Un **vector** es una lista ordenada de números. Un **embedding** usa un vector para representar un objeto (un texto, una imagen) de modo que objetos parecidos queden **cerca**. Las coordenadas las aprende un modelo con ejemplos; no son probabilidades ni etiquetas de temas. Con vectores se puede medir cercanía de dos maneras: la **distancia** (qué tan lejos están los puntos) y la **similitud coseno** (qué tan parecida es su dirección; 1 = misma dirección).

Ejemplo resuelto · tres vectores inventados (distintos de la diapositiva): U = (1, 2), V = (2, 3), W = (4, 0.5)

Paso	U–V	U–W
Diferencias	(2 − 1, 3 − 2) = (1, 1)	(4 − 1, 0.5 − 2) = (3, −1.5)
Distancia = raíz de la suma de cuadrados	√(1 + 1) = 1.414	√(9 + 2.25) = 3.354
Producto punto U · otro	1·2 + 2·3 = 8	1·4 + 2·0.5 = 5
Normas	2.236 y 3.606	2.236 y 4.031
Coseno = punto ÷ (norma × norma)	0.992	0.555

Lectura: V está más cerca de U (distancia menor y coseno mayor). **Error común**: creer que distancia y coseno siempre coinciden; un vector duplicado, como (2, 4) respecto de (1, 2), tiene coseno 1 pero está a distancia 2.236.



Esta idea sostiene la **búsqueda por significado**: se convierten la consulta y los documentos en vectores y se devuelven los más cercanos. Por palabras se busca coincidencia de términos (falla si la fuente dice «reembolso» y tú escribes «cobro duplicado»); por significado se compara cercanía, pero un texto cercano puede **no responder** la

pregunta, ser de otro servicio o estar desactualizado. Una **base de datos vectorial** guarda los puntos cercanos cerca unos de otros para encontrarlos rápido: es una forma de guardar, no un método de aprendizaje. CLIP aplica la idea a imagen y texto (da una similitud, no una probabilidad de daño) y la recomendación de contenidos parte de una tabla personas × cursos (1 = hay clic; 0 = no hay clic registrado, no rechazo).

Lo que debes recordar

- Embedding = vector que representa un objeto; lo parecido queda cerca
- Distancia: raíz de la suma de cuadrados; coseno: punto ÷ (norma × norma)
- Cercano no significa «responde la pregunta»: hay que verificar

7 Generar contenido, aprender sin etiquetas y reutilizar modelos

Generar texto. La instrucción dice qué resultado se quiere y el contexto es el texto disponible (antecedentes y lo ya escrito). Un modelo de lenguaje aprende regularidades en el orden de las palabras y, al generar, **añade unidades una tras otra** usando el contexto. Producir una continuación plausible no garantiza que sea verdadera. **Generar imágenes (difusión).** Un modelo parte de ruido visual y lo transforma de a poco en una imagen guiada por la descripción; se evalúan objetos, cantidades y relaciones, y el realismo no acredita un hecho.

De dónde viene la señal para aprender. En el aprendizaje **supervisado** la respuesta es externa (el dígito correcto). En el **autosupervisado** la respuesta sale de los propios datos: si se oculta la palabra «crédito» en «el banco aprobó el crédito», la palabra original sirve para comparar. **Modelos preentrenados.** Alguien ya entrenó un modelo con otros datos; se puede aprovechar con tres grados de cambio: **instrucciones y contexto** (no se reentrena), **reutilizar representaciones** (vectores + un clasificador propio) o **ajuste fino** (se modifica el modelo con datos locales). Hay que comprobar que lo aprendido sea pertinente (un modelo de fauna de otro continente no sirve igual en Chile) y que se pueda evaluar con datos locales. AlphaFold 3 es un ejemplo científico: propone cómo se disponen proteínas, ADN y otras moléculas y se verifica contra estructuras determinadas experimentalmente; una estructura predicha orienta la investigación pero no demuestra por sí sola que un compuesto sea un tratamiento eficaz.

Ejemplo resuelto · verificar un borrador contra su fuente

Fuente: «La revisión del cobro puede tardar hasta cinco días hábiles.» · Borrador: «Su devolución está aprobada y llegará mañana.»

Paso	Afirmación	Respaldo en la fuente	Decisión
1	Su devolución está aprobada	No: la fuente no informa el resultado del caso	quitarla o declarar que falta
2	Llegará mañana	No: la fuente habla de revisión, no de fecha de abono	quitarla o declarar que falta
3	Respuesta corregida	«hasta cinco días hábiles de revisión»	no confirmar aprobación ni fecha

Lectura: de un solo borrador salieron dos afirmaciones sin respaldo. **Error común**: dar por buena una redacción fluida sin verificar cada hecho.

Lo que debes recordar

- Generar = añadir unidades sucesivamente con el contexto; plausible ≠ verdadero
- Supervisado: respuesta externa; autosupervisado: la respuesta sale de los datos
- Preentrenado: punto de partida; su utilidad local se demuestra con datos locales

8 Costos, carga de revisión y una prueba que represente el uso

Dos errores distintos no cuestan lo mismo. En una inspección hay **defectos omitidos** (falsos negativos) y **falsas alarmas** (falsos positivos). Se les asigna un costo por caso y se suma. Además, cada alerta consume una **revisión**: aunque el sistema detecte muchos defectos, si genera más alertas de las que se pueden revisar, no sirve. Finalmente, la prueba debe parecerse al uso: si habrá **personas o envases nuevos**, todas las observaciones de una persona o envase van al mismo conjunto; si habrá **meses futuros**, se evalúa en fechas posteriores al desarrollo; si cambia la cámara, hay que observar datos de esa cámara.

Ejemplo resuelto · 500 piezas, 10 con defecto; se omiten 2, hay 15 falsas alarmas; costos 40 y 1; capacidad 12 revisiones

Concepto	Cálculo	Resultado
Costo de omitidos	2 × 40	80
Costo de falsas alarmas	15 × 1	15
Costo total	80 + 15	95 unidades
Defectos detectados	10 − 2	8
Revisiones si se revisan todas las alertas	8 + 15	23
¿Alcanza la capacidad de 12?	23 frente a 12	No: faltan 11
Exactitud del sistema	(500 − 2 − 15) ÷ 500	96.6 %
«Decir siempre sano»	(500 − 10) ÷ 500; costo 10 × 40	98.0 %; costo 400

Lectura: «decir siempre sano» tiene **mayor** exactitud (98.0 % frente a 96.6 %), pero omite todos los defectos y su costo es mucho más alto (10 × 40 = 400 frente a 2 × 40 + 15 × 1 = 95). **Error común**: juzgar por la exactitud sin mirar el costo y la capacidad de revisión.



Caso integrador. Hay 6 000 fotografías de 1 200 envases (cinco vistas cada uno). La decisión es por envase, así que la unidad de evaluación es el **envase**, no la foto: si se separara por foto, vistas del mismo envase quedarían en entrenamiento y prueba y la prueba «ya conocería» el objeto. Una separación por envase 70/15/15 daría 840, 180 y 180 envases (4 200, 900 y 900 fotos). Para el próximo mes (cámara y línea nuevas) hay que reunir datos de esas condiciones, reservar envases que no se usen para adaptar ni elegir, comparar una referencia simple con un candidato y medir defectos omitidos, falsas alarmas y revisiones por envase; el bootstrap remuestrea **envases completos**. Si después de mirar la prueba se cambia el procedimiento, hace falta otra evaluación independiente.

Restricciones y automatización. Además del error hay tiempo (latencia: si llega una pieza por segundo y se tardan cinco en procesar cada una, se acumula trabajo), costo, datos y mantenimiento. Conviene empezar por una **referencia simple** (regresión, árbol o una regla basada en historia reciente): si un modelo complejo no la supera, no vale la pena. Y se decide **qué parte automatizar**: proponer un borrador (alguien lo revisa), priorizar casos (se observan los que quedan atrás) o ejecutar una decisión (con evidencia, límites y seguimiento). La revisión humana también puede fallar o sobrecargarse.

Lo que debes recordar

- Costo = Σ cantidad × costo por caso; revisiones = detectados + falsas alarmas
- La unidad de separación es la unidad de decisión (envase, persona, fecha)
- Empieza con una referencia simple y define qué automatizar