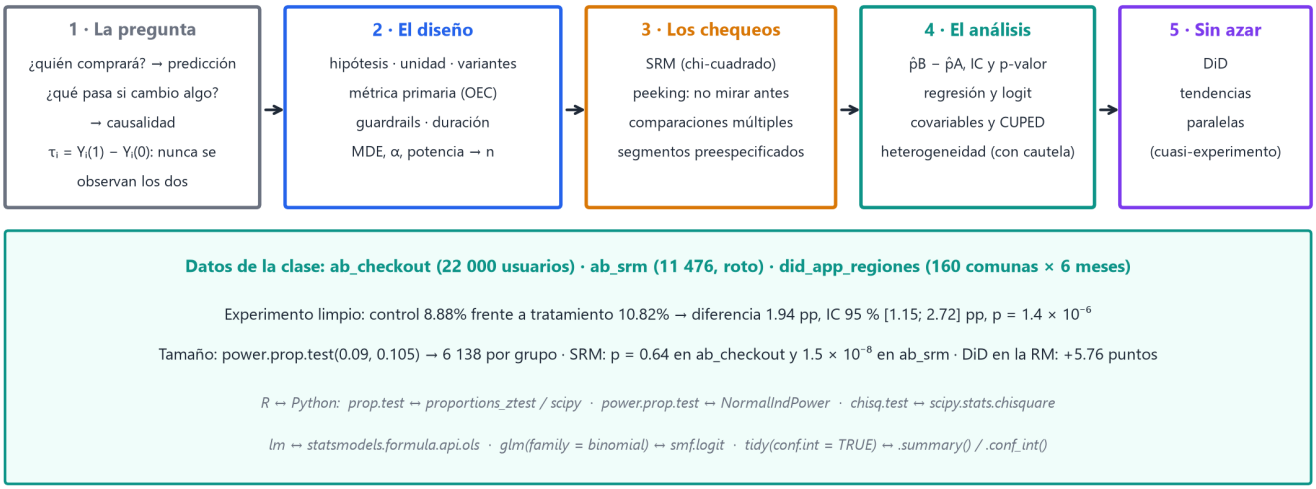
Clase 22 · Experimentación, A/B testing y causalidad aplicada

Profesora Maritza Márquez · de la predicción a la decisión · sigue a los GLM (Clases 20–21) y precede a la estadística bayesiana (Clases 23–24)

La gran idea de la clase

Un modelo predictivo responde «¿quién comprará?»; una decisión necesita otra pregunta: **«¿qué pasa si cambio algo?»**. Esa es una pregunta **causal** y no se contesta con una correlación. El **A/B testing** la contesta **asignando al azar** quién recibe el cambio: así los dos grupos son comparables en promedio y la diferencia de resultados se atribuye al cambio. Después hay que **diseñar** (hipótesis, métrica primaria, guardrails, tamaño de muestra), **vigilar** (SRM, peeking, comparaciones múltiples), **analizar** (diferencia de tasas, intervalo de confianza, p-valor, regresión, CUPED) y, cuando no se puede aleatorizar, recurrir a **diferencias en diferencias**.

La clase en una imagen



Lo que necesitas ANTES

- **Test de hipótesis, p-valor e intervalo de confianza** (Etapa 0 y Clases 17–19): aquí se usan de verdad y se explican con calma
- **Regresión lineal** y su lectura de coeficientes (Clases 17–19): el efecto del tratamiento es un coeficiente
- **Regresión logística y odds** (Clases 20–21): el modelo logit de la práctica
- Proporciones, desviación estándar y la normal: ver recuadro de abajo

Ruta de la clase y datos

- **Causalidad → anatomía del experimento → tamaño de muestra → chequeos (SRM, peeking) → efecto principal → covariables y CUPED → heterogeneidad → DiD**
- **ab_checkout**: 22 000 usuarios (control 10 965, tratamiento 11 035); **ab_srm**: 11 476 usuarios con la asignación rota; **did_app_regiones**: 160 comunas × 6 meses (64 en la RM, tratadas)
- Pregunta guía: ¿el nuevo checkout aumenta la conversión, y cómo sé que puedo creerle al experimento?

Puentes con las clases vecinas

C17–19 → C22: el modelo lineal con una variable binaria T es el test de dos grupos: β_1 es la diferencia de medias. **C20–21 → C22**: con Y = 1 si convierte, el modelo lineal es el «modelo lineal de probabilidad» y la logística da los odds. **C22 → C23–24**: la estadística bayesiana mira las mismas preguntas (¿cuánto mejora B?) con una probabilidad directa; el p-valor y el IC de hoy son la versión frecuentista.

Recuadro: p-valor e intervalo de confianza, sin fórmulas

p-valor = «si el cambio no hiciera nada (H_0), ¿qué tan raro sería ver una diferencia al menos así de grande solo por el azar del muestreo?». Un p-valor pequeño dice que *ese azar no alcanza* para explicar lo visto. **No** es la probabilidad de que H_0 sea cierta, ni dice qué tan grande o importante es el efecto. **Intervalo de confianza del 95 %** = rango de efectos que los datos «toleran»: si repitiéramos el experimento muchas veces, el 95 % de los intervalos así construidos contendría el efecto verdadero. Si no contiene el 0, el p-valor es menor que 0.05; pero el IC además dice **cuánto** (y permite compararlo con lo que al negocio le importa).

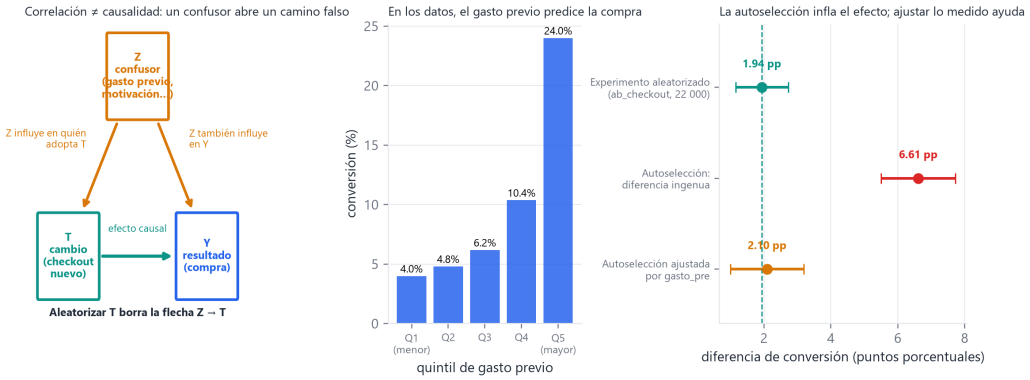
Clase 22 · Causalidad y aleatorización

Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

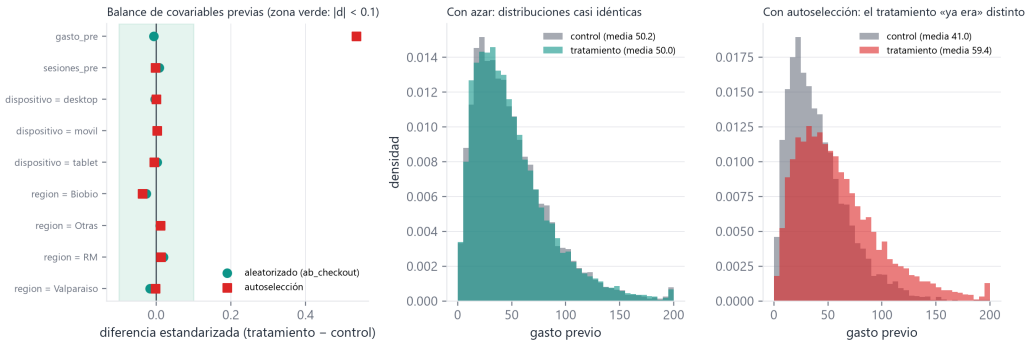
Una asociación entre «cambio» y «mejora» no prueba que el cambio la causó: los usuarios expuestos pueden ser distintos de los no expuestos. Asignar al azar rompe esa asociación sistemática y deja grupos comparables en promedio.

Conceptos clave

1. **Resultados potenciales.** Cada usuario tendría dos resultados: $Y_i(1)$ con el tratamiento y $Y_i(0)$ sin él. El efecto individual $\tau_i = Y_i(1) - Y_i(0)$ **nunca se observa**: del otro resultado (el contrafactual) no hay dato.
2. **Efecto promedio (ATE).** ATE = E[Y(1) − Y(0)]. Con aleatorización se estima con la diferencia de promedios $\bar{Y}_{T=1} - \bar{Y}_{T=0}$: no hace falta que los grupos sean idénticos persona a persona, sino comparables en promedio.
3. **Confusores.** Una variable Z (gasto previo, motivación) que influye en quién adopta el cambio y en el resultado crea una diferencia que **no** es causal. Aleatorizar elimina la flecha Z → T.



Izquierda: diagrama del confusor. Centro: en ab_checkout la conversión sube de 4.0 % a 24.0 % del quintil 1 al 5 de gasto previo. Derecha: con una submuestra de «autoselección» (más gasto → más probable adoptar), la diferencia ingenua es 6.61 pp frente a 1.94 pp del experimento; ajustar por gasto_pre la baja a 2.10 pp.



Con aleatorización las covariables previas quedan equilibradas (máxima diferencia estandarizada 0.026); en la submuestra con autoselección, el gasto previo difiere en 0.54 desviaciones.

Fórmulas y reglas

$\tau_i = Y_i(1) - Y_i(0)$ (no observable)

ATE = E[Y(1)] − E[Y(0)]

ATE estimado = $\bar{Y}_B - \bar{Y}_A$ (si hay azar)

balance: d = $(\text{media}_T - \text{media}_C)$ / sd

Con los datos de la clase

- Control 8.88 % frente a tratamiento 10.82 %: ATE estimado 1.94 pp (21.8 % más, en relativo)
- El gasto previo medio es 50.2 (control) y 50.0 (tratamiento); sesiones previas, 3.96 y 3.98: equilibrados
- La autoselección se construyó con los propios datos (submuestra de 11 098 usuarios): es una ilustración, no un hallazgo de la clase
- **Cuidado.** Balancear lo **observado** es una buena señal, no una prueba: el azar equilibra también lo **no observado**, y de eso se trata aleatorizar.

Clase 22 · Efecto principal: diferencia de tasas, IC y p-valor

Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

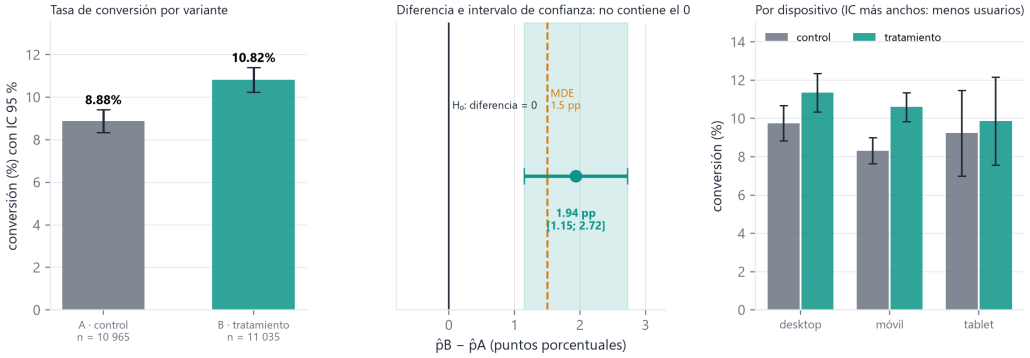
Con respuesta binaria (Y_i = 1 si convierte), el efecto es la diferencia de tasas $\hat{p}_B - \hat{p}_A$. El intervalo de confianza dice qué tan grande puede ser y el p-valor mide cuán compatible es lo visto con «sin efecto».

Conceptos clave

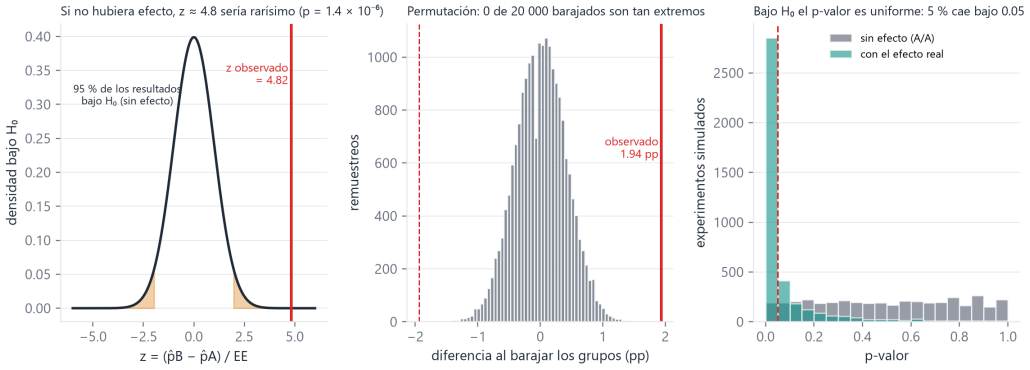
1. **Estimador y error estándar.** $\hat{p}$ = x/n en cada grupo; $EE(\hat{p}_B - \hat{p}_A) = \sqrt{[\hat{p}_A(1-\hat{p}_A)/n_A + \hat{p}_B(1-\hat{p}_B)/n_B]}$. Mide cuánto variaría la diferencia de un experimento a otro.

2. **Intervalo de confianza.** diferencia ± 1.96 · EE (95 %). Se lee como el rango de efectos plausibles; si no contiene el 0 y supera el MDE, el efecto es estadística y prácticamente interesante.

3. **Test z y p-valor.** z = diferencia / $EE_{agrupado}$ (bajo H_0 ambas tasas son iguales, así que se usa la tasa conjunta). El p-valor es la probabilidad, bajo H_0, de un |z| al menos tan grande.



Izquierda y derecha: tasas con IC 95 %. Centro: la diferencia de 1.94 pp con IC [1.15; 2.72] no contiene el 0 y supera el MDE de 1.5 pp.



Izquierda: bajo H_0, z observado = 4.82 cae muy lejos. Centro: al barajar 20 000 veces quién es tratamiento, ninguna diferencia llega a 1.94 pp. Derecha: simulación (n = 3 000 por grupo): sin efecto, 4.8 % de p-valores bajo 0.05; con el efecto real, 71 %.

Fórmulas y reglas

$$EE = \sqrt{[\,\hat{p}_A(1-\hat{p}_A)/n_A + \hat{p}_B(1-\hat{p}_B)/n_B\,]}$$

IC 95 %: $(\hat{p}_B - \hat{p}_A) \pm 1.96 \cdot EE$

$$z = (\hat{p}_B - \hat{p}_A) \,/\, \sqrt{[\,\hat{p}(1-\hat{p})(1/n_A + 1/n_B)\,]},\ \hat{p} = (x_A+x_B)/(n_A+n_B)$$

```
proportions_ztest([x_B, x_A], [n_B, n_A])
smf.ols('convierte ~ trat', ab).fit()
smf.logit('convierte ~ trat', ab).fit()
```

Con los datos de la clase

- Control 974/10 965 y tratamiento 1 194/11 035: diferencia 1.937 pp, EE 0.402 pp
- IC 95 % [1.15; 2.72] pp; z = 4.82, χ^2 = 23.24, p = 1.43 × 10^{-6}
- Modelo lineal: β_0 = 8.88 %, β_1 = 1.94 pp, p = 1.43 × 10^{-6}. Logit: β_1 = 0.2188, odds ratio 1.245 [1.139; 1.361], p = 1.48 × 10^{-6}
- **Cuidado.** Un p-valor pequeño **no** dice que el efecto sea «real y relevante»: dice que el azar no lo explica. La relevancia se juzga con el IC y el MDE. Y p = 0.03 **no** significa «3 % de que H_0 sea cierta».

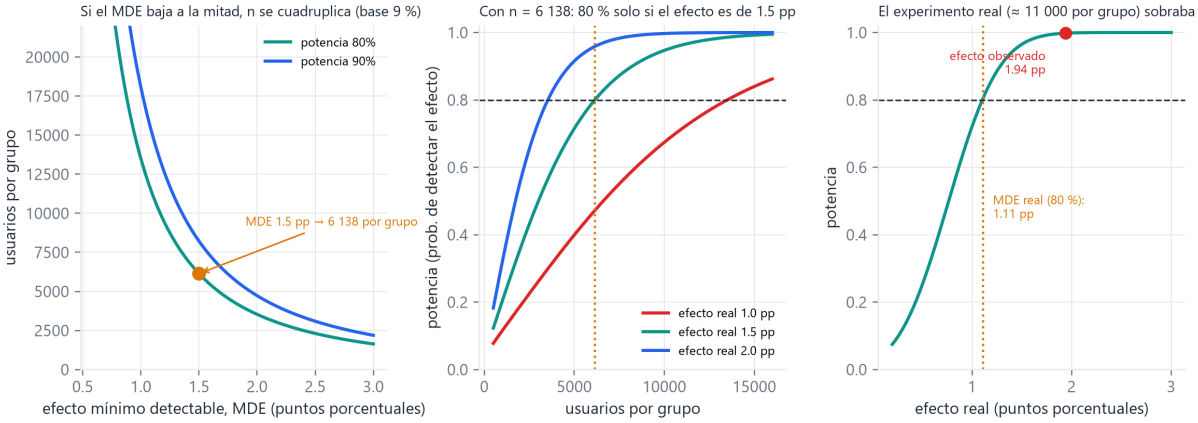
Clase 22 · Potencia, MDE y tamaño de muestra

Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

Antes de empezar se fija el efecto mínimo detectable (MDE), el nivel de significancia α y la potencia 1 − β. De ahí sale cuántos usuarios hay que reunir. Si el MDE se divide por 2, n se multiplica por ≈ 4.

Conceptos clave

1. **α y potencia.** α = probabilidad tolerada de falso positivo (decir «hay efecto» cuando no lo hay, error tipo I). Potencia = probabilidad de detectar un efecto real del tamaño del MDE (1 − β; β es el error tipo II).
2. **MDE.** Es el menor efecto que al negocio le importa detectar, no una predicción del efecto. Se acuerda **antes** de mirar resultados.
3. **Tamaño por grupo.** n crece con la variabilidad p(1 − p), con el nivel de confianza y con la potencia; baja con el cuadrado del MDE. Es el n **por grupo**: el total es el doble.
4. **Potencia ex post.** Con n fijo se puede calcular qué MDE alcanzaba el experimento: aquí, ≈ 11 000 por grupo detectan ≈ 1.1 pp con 80 % de potencia.



Izquierda: n por grupo según el MDE (línea base 9 %). Centro: potencia según n para tres efectos reales; con n = 6 138 y un efecto de 1.0 pp la potencia es solo 47 %. Derecha: el experimento real tenía potencia 99.8 % para el efecto observado.

Fórmulas y reglas

$$n = [\, z_{1-\alpha/2}\cdot\sqrt{(2\bar{p}(1-\bar{p}))} + z_{1-\beta}\cdot\sqrt{(p_1(1-p_1)+p_2(1-p_2))}\,]^2 \,/\, (p_2 - p_1)^2$$

$z_{0.975} = 1.960$, $z_{0.80} = 0.842$, $z_{0.90} = 1.282$

n total = 2 · n por grupo

En Python

```
from statsmodels.stats.power import
NormalIndPower
h = proportion_effectsize(0.105, 0.09)
NormalIndPower().solve_power(h, power=0.8,
alpha=0.05)
```

Con los datos de la clase

- $p_1 = 0.09$, $p_2 = 0.105$ (MDE 1.5 pp), α = 0.05, potencia 80 %: **6138.0 → 6 138 por grupo** (12 276 en total) con la fórmula de `power.prop.test`
- Otros MDE: 1.0 pp → 13 495; 2.0 pp → 3 531; 0.75 pp → 23 709. Con potencia 90 % y 1.5 pp: 8 217
- La diapositiva dice 6 131 (12 262 en total): es la aproximación del arcoseno (h de Cohen, 6130.6), no `power.prop.test`

Cuidado
Tomar el efecto **observado** como MDE después del experimento (potencia «post hoc») no aporta información: el MDE se acuerda antes.

Clase 22 · Errores frecuentes: SRM, peeking y comparaciones múltiples

Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

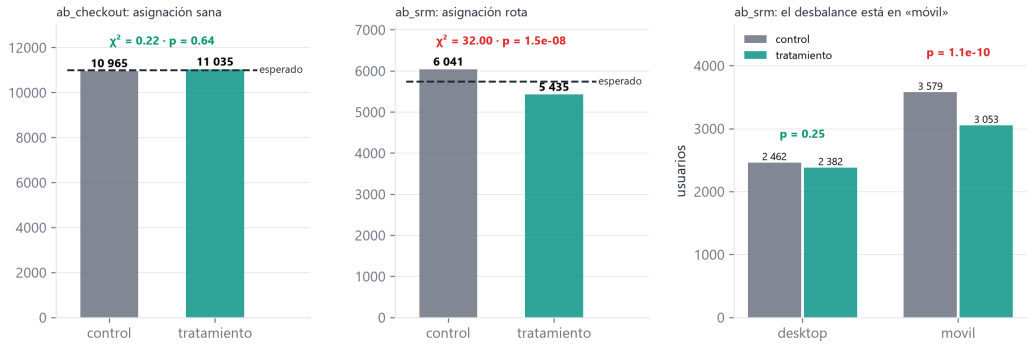
Un experimento bonito se puede destruir de tres formas: asignación rota (SRM), mirar el p-valor antes de tiempo (peeking) y probar muchas cosas y mostrar la que salió. Todo se define antes de lanzar.

Conceptos clave

1. **SRM (Sample Ratio Mismatch).** La proporción observada de usuarios por grupo no coincide con la planeada (p. ej. 50/50). Se prueba con chi-cuadrado sobre los conteos: $\chi^2 = \Sigma\ (obs - esp)^2/esp$. Regla práctica: $p < 0.001$ → no se reporta el efecto, se audita la instrumentación.

2. **Peeking.** Mirar el p-valor varias veces y parar cuando baja de 0.05. Cada mirada es otra oportunidad de falso positivo: el error real supera el 5 %.

3. **Comparaciones múltiples.** Con m pruebas independientes al 5 %, P(al menos un falso positivo) = $1 - 0.95^m$. Con 20 métricas, 64 %. Se corrige (Bonferroni: α/m) o se preespecifica la métrica primaria.



ab_checkout: 10 965 frente a 11 035 (esperado 11 000), $\chi^2 = 0.22$, $p = 0.64$. ab_srm: 6 041 frente a 5 435 (esperado 5 738), $\chi^2 = 32.0$, $p = 1.54 \times 10^{-8}$; el desbalance está en móvil.



Simulación de experimentos sin efecto (tasa 8.88 %, 12 000 por grupo, 4 000 repeticiones). Con 10 miradas el falso positivo llega a 19.1 %; mirando cada 100 usuarios, 39 %.

Fórmulas y reglas

$\chi^2 = \Sigma\ (observado - esperado)^2 / esperado$, $gl = k - 1$

$P(\geq 1\ falso\ positivo) = 1 - (1 - \alpha)^m$

Bonferroni: usar α/m en cada prueba

Con los datos de la clase

- ab_srm: $\chi^2 = 32.0$ con 1 gl, $p = 1.54 \times 10^{-8}$: se audita. Por dispositivo, desktop $p = 0.25$ y móvil $p = 1.05 \times 10^{-10}$
- 20 métricas sin corregir: 64 % de falso positivo; con Bonferroni, 4.9 %
- **Cuidado.** Un SRM no significativo ($p = 0.64$) **no demuestra** aleatorización perfecta. Con ab_srm no se reporta la conversión ingenua (12.5 % y 12.7 %).

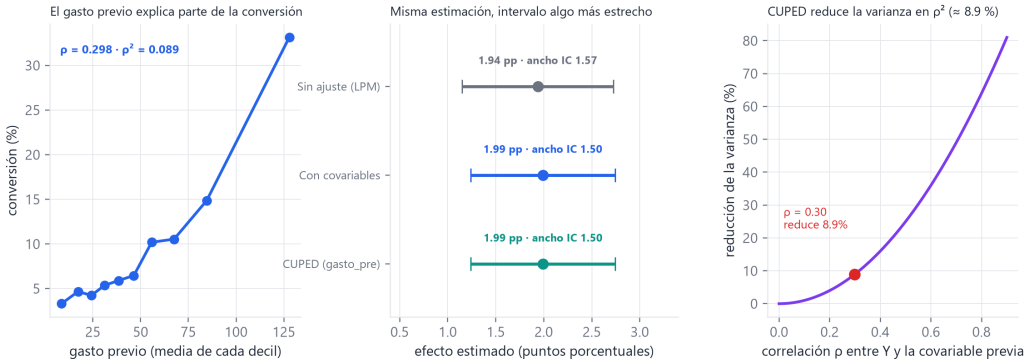
Clase 22 · Covariables, CUPED y heterogeneidad

Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

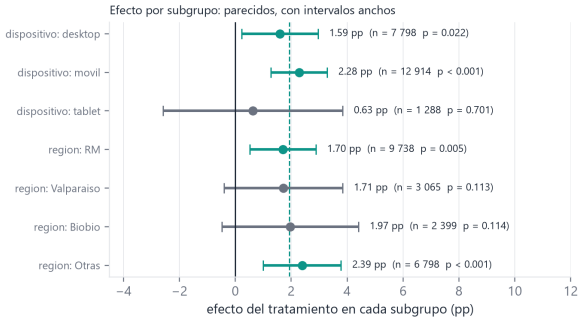
En un experimento bien aleatorizado, ajustar por covariables previas no corrige sesgo: gana precisión. CUPED hace lo mismo restando la parte de Y que predice el comportamiento previo. La heterogeneidad se mira con cautela.

Conceptos clave

1. **Covariables.** $Y_i = \beta_0 + \beta_1 T_i + \gamma X_i + \varepsilon_i$ con X_i medido **antes** del tratamiento. Nunca se ajusta por variables que el tratamiento afecta (estarían «después»). β_1 sigue siendo el efecto promedio.
2. **CUPED.** $Y^{cuped} = Y - \theta(X - \bar{X})$, con $\theta = Cov(Y, X)/Var(X)$. Misma media de efecto, menos varianza: la reducción es $\approx \rho^2$, con $\rho = Cor(Y, X)$. No arregla un SRM ni una mala aleatorización.
3. **Heterogeneidad.** $Y_i = \beta_0 + \beta_1 T_i + \beta_2 D_i + \beta_3 (T_i D_i) + \varepsilon_i$. β_3 es la **diferencia de efecto** entre segmentos. Si no estaba preespecificada, es exploratoria.



CUPED con gasto_pre (ρ = 0.298): reduce la varianza en 8.9 %, igual que ρ^2 = 8.9 %; el IC se estrecha un 4.5 %.




```
Modelo lm(convierte ~ trat * dispositivo)

efecto en desktop (referencia): 1.59 pp
interacción móvil: +0.68 pp (p = 0.42)
interacción tablet: -0.97 pp (p = 0.59)
prueba conjunta (F): p = 0.52

Conclusión: no hay evidencia suficiente de
que el efecto cambie con el dispositivo.
Pero «sin evidencia» ≠ «efecto igual»:
el IC de cada interacción es ancho.
```

Efecto por dispositivo y por región: todos parecidos al promedio; los intervalos de tablet, Valparaíso y Biobío incluyen el 0 por tener pocos usuarios, no porque el efecto desaparezca.

Fórmulas y reglas

$\theta = Cov(Y, X) / Var(X)$

$Y^{cuped} = Y - \theta(X - \bar{X})$

reducción de varianza $\approx \rho^2$

interacción: $\beta_3 = efecto_{móvil} - efecto_{desktop}$

```
smf.ols('convierte ~ trat + gasto_pre +
sesiones_pre + C(dispositivo)', ab)
theta = np.cov(y, x)[0, 1] / x.var()
smf.ols('convierte ~ trat * C(dispositivo)', ab)
```

Con los datos de la clase

- Sin ajuste 1.94 pp (EE 0.402); con covariables 1.99 pp (EE 0.383); CUPED 1.99 pp (EE 0.384), θ = 0.0025
- Efecto por dispositivo: desktop 1.59, móvil 2.28, tablet 0.63 pp
- Interacciones: móvil 0.68 pp (p = 0.42), tablet -0.97 pp (p = 0.59); prueba conjunta p = 0.52
- **Cuidado.** Mirando 7 subgrupos, cuatro salen «significativos» y tres no, aunque el efecto es casi el mismo: la significancia depende de n. Compara **efectos**, no solo p-valores.

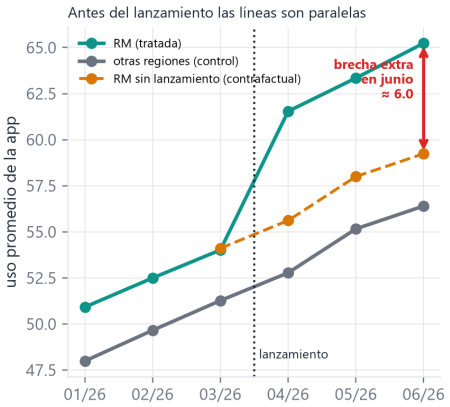
Clase 22 · Cuando no se puede aleatorizar: diferencias en diferencias

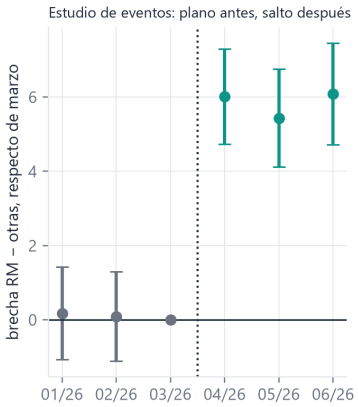
Fuente: transcripción + diapositivas + Clase22_ABtesting.R/.ipynb + datos de la profesora Maritza Márquez

Si el cambio no se puede asignar al azar (campañas regionales, políticas), se compara cuánto cambió el grupo tratado con cuánto cambió un grupo de control en el mismo período. Es creíble solo si, sin el cambio, ambos habrían evolucionado en paralelo.

Conceptos clave

1. **Idea.** DiD = $(\bar{Y}_{T,post} - \bar{Y}_{T,pre}) - (\bar{Y}_{C,post} - \bar{Y}_{C,pre})$. La resta del control quita lo que habría pasado de todos modos (la tendencia).
2. **Regresión.** $Y_{it} = \beta_0 + \beta_1 Trat_i + \beta_2 Post_t + \beta_3 (Trat_i \times Post_t) + u_{it}$. El efecto causal es β_3 y coincide con el DiD de las medias.
3. **Tendencias paralelas.** Es el supuesto clave y no se prueba, solo se respalda: gráfico antes del lanzamiento, estudio de eventos y coeficientes previos cercanos a cero.
4. **Errores estándar.** Cada comuna aparece 6 veces: los errores deben agruparse por comuna (cluster). Aquí el modelo simple del script es, si acaso, conservador.





2 × 2 de medias (antes = ene–mar)
DiD = 10.90 − 5.14

	Antes	Después	Δ
RM	52.48	63.37	10.90
Otras	49.64	54.78	5.14
DiD			**5.76**

Izquierda: uso medio de la app; la línea punteada es la RM «sin lanzamiento» (la brecha previa se mantiene). Centro: la brecha respecto de marzo es ≈ 0 antes y ≈ 6 después. Derecha: DiD = 5.76.

Fórmulas y reglas

DiD = (63.37 − 52.48) − (54.78 − 49.64) = 5.76

uso ~ trat * post: β_3 = coeficiente de trat:post

efectos fijos: uso ~ trat:post + C(comuna) + C(mes)

En Python

```
smf.ols('uso_app ~ trat * post',
did).fit(cov_type='cluster', cov_kwds={'groups':
comuna})
```

Con los datos de la clase

- Modelo simple: β_3 = 5.76, IC 95 % [4.58; 6.94], p = 8.36×10^{-21} (como la diapositiva 30)
- Con errores agrupados por comuna: EE 0.333 frente a 0.601; IC [5.10; 6.41]. Con efectos fijos de comuna y mes: 5.76, EE 0.339
- Pre-tendencia: brecha RM − otras de 2.93, 2.84 y 2.75 antes; 8.76, 8.18 y 8.83 después. Interacción con el tiempo: -0.09 (p = 0.76)

Cuidado
Un buen gráfico previo **respalda** pero no **prueba** las tendencias paralelas. Y la RM pudo recibir otras cosas al mismo tiempo (campañas, feriados): el DiD solo identifica el efecto si nada más cambió solo en la RM.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase

- **«El p-valor es bajito, entonces el efecto parece real y relevante»**: el p-valor solo mide compatibilidad con H_0; la relevancia se ve en el IC frente al MDE.
- **«Si el p-valor del SRM es grande, el experimento está completamente aleatorizado»**: un p grande no prueba aleatorización; solo no hay evidencia de desbalance en los conteos.
- **«La idea es que las proporciones sean distintas»**: el test es neutro; no se busca rechazar H_0. Buscarlo es la raíz del peeking y de las comparaciones múltiples.
- **«6131 usuarios por grupo» con** `power.prop.test`: esa función da 6 137.95 → 6 138 (12 276 en total). 6 131 es la aproximación del arcoseno.
- **«P2 = 0.15»** (dicho al explicar los parámetros): el código usa $p_2 = 0.105$ (MDE de 1.5 pp). Con 0.15 harían falta solo 459 por grupo.

Diapositivas y scripts

- **Diapositiva 21 (peeking)**: «con 10 miradas independientes al 5 %, el falso positivo se acerca a 40 %». $1 - 0.95^{10} = 40.1$ % solo vale si las miradas fueran independientes; con datos que se acumulan **no** lo son. Simulado: 19.1 % con 10 miradas; ≈ 40 % exige mirar de forma casi continua.
- **Diapositiva 30 y script (DiD)**: `lm(uso_app ~ trat * post)` ignora que cada comuna se repite 6 veces. El IC [4.58; 6.94] es más ancho que con errores agrupados [5.10; 6.41]; el punto estimado (5.76) no cambia.
- **Diapositiva 29**: «si antes ya corrían en direcciones distintas, el DiD queda a medio camino» es impreciso: el DiD queda **sesgado** en la magnitud de la diferencia de tendencias, sin un «medio camino» definido.
- **Diapositiva 15 (regresión = test)**: coinciden las conclusiones y el efecto del modelo lineal, pero no los números exactos (EE del test con tasa conjunta; la logística da odds ratio, no diferencia). El modelo lineal debería usar errores robustos (aquí son idénticos a 4 decimales).
- **Diapositivas 5 y 6**: «estima lo ocurrido si ¿cambiamos…?» y «27 %:,» son erratas de redacción. Las cifras históricas (1747, 1948, Obama 2008, Bing 12 %) no se verificaron aquí.

Transcripción con ruido

Whisper confundió Wardrails (guardrails), picking (peeking), Coupet / Cuper (CUPED), DIT (DiD), «Yesu-i» (Y sub i), «Tao Tzu Y» (τ_i), ATG (ATE), VIM (Bing), SAS (SaaS), «Valleciana» (Bayesiana), «cita» (srm_test). El recreo (≈ 1:21:15 del video) no está en el video; la corrección de este material dejó las frases dudosas como las dijo la profesora.

Checklist y criterio de dominio

- ☐ Distingo una pregunta predictiva de una causal y explico por qué aleatorizar
- ☐ Calculo a mano la diferencia de tasas, su IC y el z, y explico qué dice y qué no dice el p-valor
- ☐ Calculo n por grupo con la fórmula y explico cómo cambia con el MDE, α y la potencia
- ☐ Hago un chi-cuadrado de SRM y sé qué hacer si falla; explico por qué no se «mira» el p-valor antes de tiempo
- ☐ Estimo un DiD con una tabla 2 × 2 y discuto las tendencias paralelas
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos