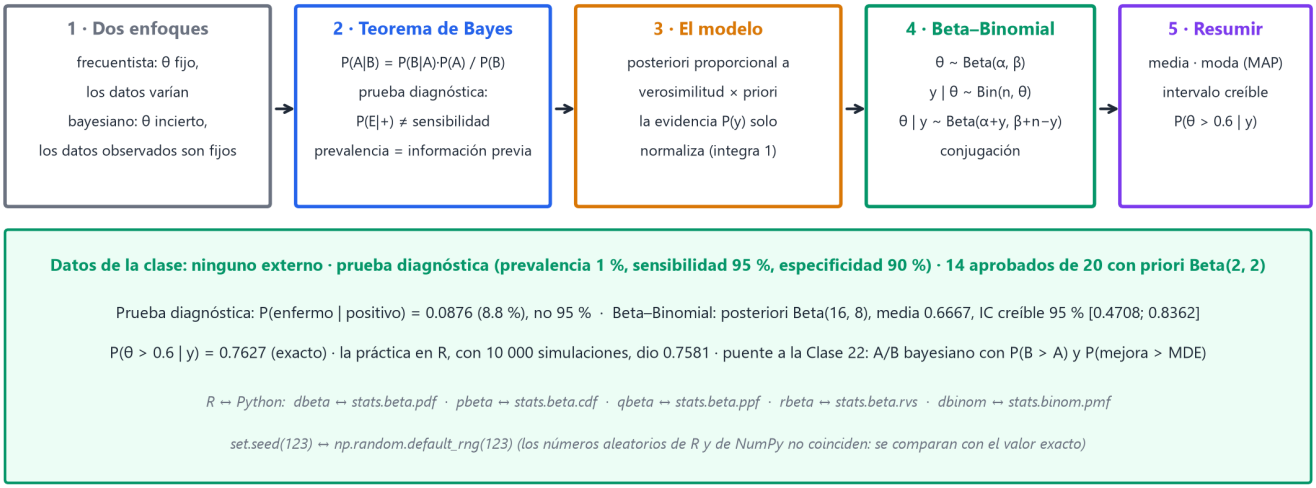
Clase 23 · Estadística bayesiana: fundamentos

Profesora Maritza Márquez · primera de dos sesiones · sigue al A/B testing (Clase 22) y precede a predicción, Monte Carlo y MCMC (Clase 24)

La gran idea de la clase

La estadística bayesiana trata el parámetro desconocido θ como una cantidad **incierta** y describe esa incertidumbre con una **distribución de probabilidad**. Se parte de una **priori** (lo que se sabía), se mide con la **verosimilitud** qué tan compatibles son los datos con cada valor de θ y el **teorema de Bayes** las combina en una **posteriori** (lo que se sabe ahora): **creencia inicial + evidencia nueva = creencia actualizada**. Con proporciones, el modelo **Beta–Binomial** lo resuelve con una suma: éxitos previos + éxitos observados, fracasos previos + fracasos observados. Y el **intervalo creíble** sí se lee como suena: «hay 95 % de probabilidad de que θ esté aquí, dados el modelo y los datos».

La clase en una imagen



Lo que necesitas ANTES

- **Probabilidad, eventos y proporciones** (Etapa 0): P(A), complemento, «A y B»
- **Distribución binomial** y **logística** (Clases 20–21): Y ~ Binomial(n, θ) es el modelo de datos de hoy
- **Intervalo de confianza y p-valor** (Clases 17–19 y 22): se comparan con el intervalo creíble
- Calcular con scipy: `stats.beta` y `stats.binom` (equivalentes de `dbeta, qbeta, dbinom` de R)

Ruta de la clase y datos

- **Dos enfoques → probabilidad condicional y Bayes → modelo: priori × verosimilitud → Beta–Binomial → resumir la posteriori → intervalo creíble vs de confianza**
- No hay archivos de datos: la clase usa una **prueba diagnóstica** (prevalencia 1 %, sensibilidad 95 %, especificidad 90 %) y **14 aprobados de 20** con priori Beta(2, 2)
- Pregunta guía: ¿cómo cambia lo que creo sobre θ cuando llegan datos, y cuánta incertidumbre queda?

Puentes con las clases vecinas

C17–21 → C23: en regresión y GLM los parámetros (β) eran fijos y se estimaban con máxima verosimilitud; ahora la **verosimilitud** es la misma pero se *multiplica* por una priori. **C22 → C23**: el p-valor y el IC del A/B test son la respuesta frecuentista; la bayesiana contesta «¿qué probabilidad hay de que B supere a A?» y «¿de que la mejora supere el MDE?» (se calcula en la página 7). **C23 → C24**: la posteriori completa permite predecir y simular (Monte Carlo); cuando no tiene fórmula cerrada se usa MCMC.

Recuadro: probabilidad condicional, sin fórmulas

P(A | B) se lee «probabilidad de A **sabiendo que** B ya ocurrió»: se mira solo el grupo de los casos con B. P(enfermo | positivo) mira a quienes dieron positivo; P(positivo | enfermo) mira a los enfermos. Son grupos distintos, así que **no tienen por qué ser iguales**: la sensibilidad es la segunda, y lo que quiere saber un paciente es la primera.

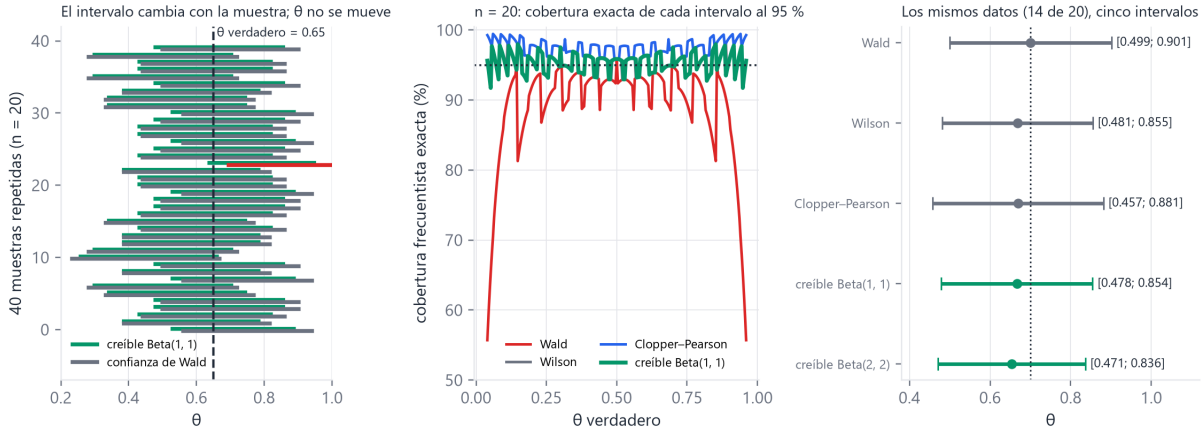
Clase 23 · Dos enfoques: frecuentista y bayesiano

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

Los dos enfoques modelan los mismos fenómenos; cambia qué es aleatorio. Frecuentista: el parámetro es fijo y los datos varían de muestra en muestra. Bayesiano: los datos observados son fijos y la incertidumbre está en el parámetro.

Conceptos clave

1. **Frecuentista.** θ fijo pero desconocido. La probabilidad describe la repetición de experimentos. Se estima y se reporta error estándar, p-valor e intervalo de confianza (todo depende de la muestra que salió).
2. **Bayesiano.** θ se describe con una distribución. La probabilidad cuantifica incertidumbre y se puede escribir P(θ > 0.6 | datos) = 0.82. La inferencia sale de la posteriori.
3. **Preguntas distintas.** Frecuentista: «¿qué pasaría si repitiéramos el experimento muchas veces?». Bayesiano: «dado lo que ya sabía y lo observado, ¿qué valores de θ son más plausibles?».
4. **¿Cuál es mejor?.** Ninguno: son enfoques distintos, con supuestos distintos. El bayesiano ayuda cuando hay pocos datos, hay información previa o los datos llegan en secuencia.



Izquierda: 40 muestras repetidas de n = 20 con θ = 0.65; los intervalos cambian, θ no (1 intervalo de Wald lo falla, en rojo). Centro: cobertura frecuentista exacta; el creíble con priori uniforme cubre en promedio 95.4 %, Wald solo 89.0 %. Derecha: con los mismos datos (14 de 20) los cinco intervalos se parecen, pero se interpretan distinto.

Fórmulas y reglas

P(θ ∈ [a, b] | y) = 0.95 → intervalo creíble

IC de confianza: el **procedimiento** contiene a θ el 95 % de las veces

posteriori ∝ verosimilitud × priori

En Python

```
from scipy import stats
stats.beta(16, 8).interval(0.95) # creíble
stats.beta(16, 8).sf(0.6) # P(θ > 0.6 | y)
```

Con los números de la clase

- Interpretación bayesiana: dado el modelo y los datos, hay 95 % de probabilidad de que θ esté en [0.47; 0.84]
- Interpretación frecuentista de un IC 95 %: si repitiéramos el muestreo muchas veces, el 95 % de los intervalos construidos así contendría el parámetro; este intervalo en particular lo contiene o no
- El error típico de estudiantes: leer un IC de confianza como «95 % de probabilidad de que θ esté dentro»

Cuidado
El intervalo creíble depende de la **priori**; el de confianza, no. Y «95 % de los datos dentro del intervalo» no es ninguna de las dos lecturas: ambos intervalos hablan del **parámetro**.

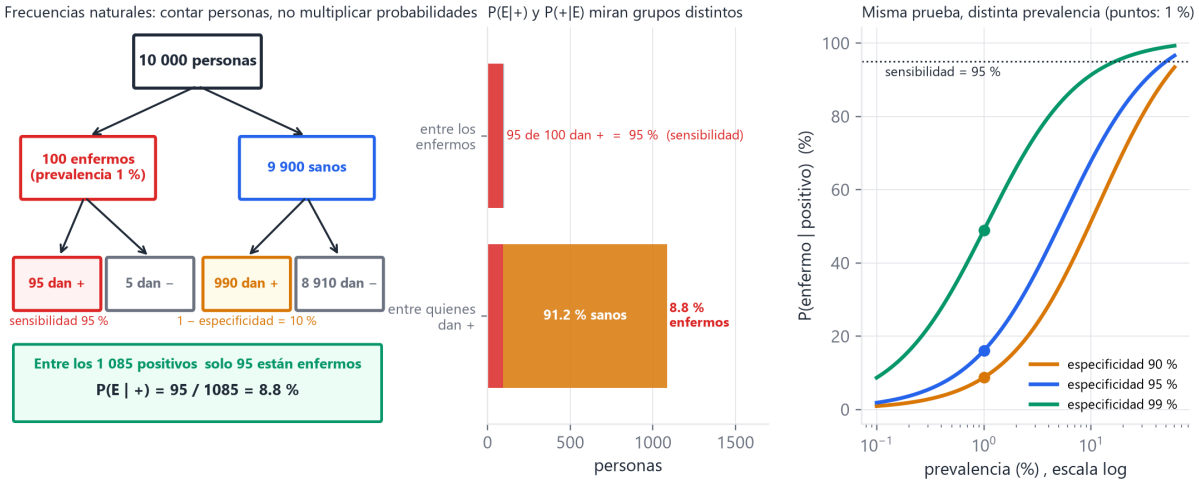
Clase 23 · Teorema de Bayes y frecuencias naturales

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

Bayes invierte una condicional: pasa de P(datos | hipótesis) a P(hipótesis | datos). La forma más fácil de entenderlo es contar personas: de cada 10 000, ¿cuántas dan positivo y cuántas de ellas están enfermas?

Conceptos clave

1. **Probabilidad condicional.** P(A | B) = P(A ∩ B) / P(B), con P(B) > 0. Como P(A ∩ B) = P(B | A)·P(A), se despeja Bayes: P(A | B) = P(B | A)·P(A) / P(B).
2. **Cuatro piezas.** P(A) = priori (prevalencia); P(B | A) = verosimilitud (sensibilidad); P(B) = evidencia (probabilidad total de dar positivo); P(A | B) = posteriori.
3. **Probabilidad total.** P(+) = P(+ | E)·P(E) + P(+ | E^c)·P(E^c). Suma las dos formas de dar positivo: siendo enfermo y siendo sano (falso positivo).
4. **Prevalencia manda.** Con una enfermedad rara, los falsos positivos (de un grupo enorme de sanos) superan a los verdaderos positivos. Nunca se interpreta un test sin la prevalencia.



Izquierda: de 10 000 personas, 95 de los 1085 positivos están enfermos → 8.8 %. Centro: P(E | +) y P(+ | E) miran grupos distintos. Derecha: la posteriori sube con la prevalencia y con la especificidad (a 1 %: 8.8 %, 16.1 % y 49.0 %).

Fórmulas y reglas

P(A | B) = P(B | A)·P(A) / P(B)

P(E | +) = 0.95·0.01 / (0.95·0.01 + 0.10·0.99)

= 0.0095 / 0.1085 = 0.0876

posteriori = verosimilitud × priori / evidencia

En Python

```
prev, sens, esp = 0.01, 0.95, 0.90
p_pos = sens*prev + (1 - esp)*(1 - prev)
sens*prev / p_pos # 0.0875576
```

Con los números de la clase

- 10 000 personas: 100 enfermos (95 dan + y 5 dan −) y 9 900 sanos (990 dan + y 8 910 dan −)
- Positivos: 95 + 990 = 1 085; P(E | +) = 95/1 085 = 0.0876 (la práctica en R da 0.0875576)
- Con un segundo test positivo independiente la posteriori sube a 47.7 %; con un tercero, a 89.6 %: la posteriori de hoy es la priori de mañana

Cuidado

Dos cosas se confunden: «el test es 95 % sensible» (P(+ | E)) y «si doy positivo, tengo 95 % de estar enfermo» (P(E | +)). Con prevalencia 1 % la segunda es 8.8 %.

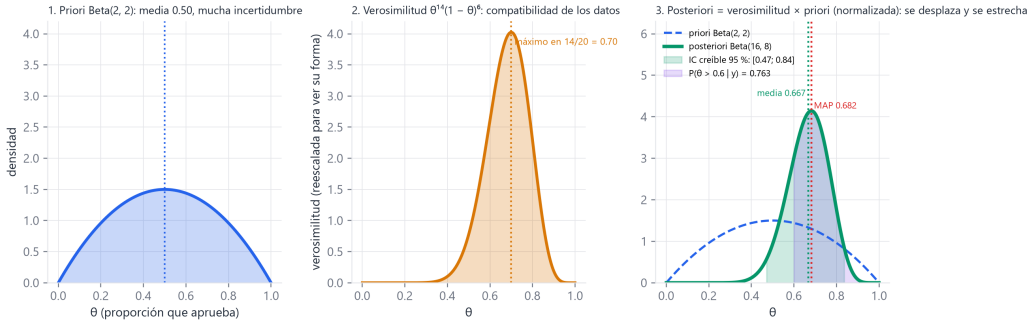
Clase 23 · Modelo bayesiano básico y Beta–Binomial

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

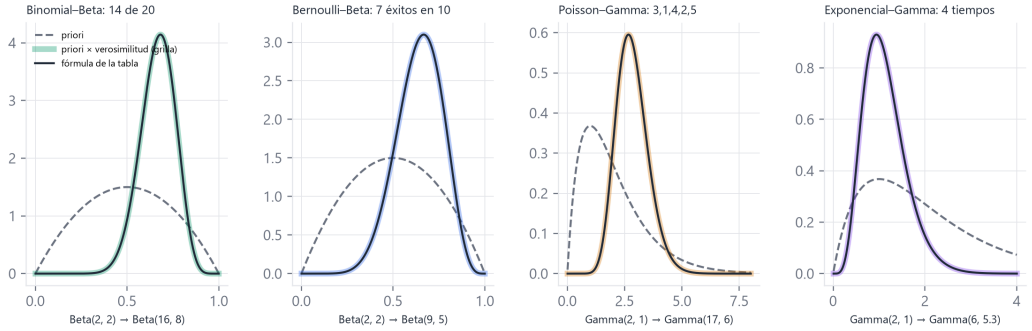
Un modelo bayesiano tiene tres ingredientes: priori p(θ), verosimilitud p(y | θ) y posteriori p(θ | y) ∝ p(y | θ)·p(θ). Con datos binomiales y priori Beta, la posteriori es otra Beta: conjugación.

Conceptos clave

1. **Beta como priori.** Una proporción vive en (0, 1): θ ~ Beta(α, β). Beta(1, 1) es uniforme; Beta(2, 2) es una campana suave centrada en 0.5. La media es α/(α + β) y α + β mide cuán informativa es.
2. **Verosimilitud.** Con y éxitos en n intentos, $L(\theta; y) = C(n, y)\cdot\theta^{y}(1-\theta)^{n-y}$. No es una distribución de θ: mide qué tan compatibles son los datos con cada θ.
3. **Actualización conjugada.** θ | y ~ Beta(α + y, β + n − y). «Éxitos previos + éxitos observados; fracasos previos + fracasos observados». La evidencia p(y) solo normaliza (la posteriori integra 1).



Priori Beta(2, 2) (media 0.50) × verosimilitud de 14 aprobados de 20 (máximo en 0.70) = posteriori Beta(16, 8): media 0.667, MAP 0.682, IC creíble 95 % [0.471; 0.836], P(θ > 0.6 | y) = 0.763.



Verificación numérica: la posteriori calculada multiplicando priori × verosimilitud y normalizando en una grilla (trazo ancho) coincide con la fórmula de la tabla (línea negra). Diferencia máxima entre 1.9×10^{-14} y 2.7e-05.

Fórmulas y reglas

θ ~ Beta(α, β), y | θ ~ Bin(n, θ)

θ | y ~ Beta(α + y, β + n − y)

Poisson–Gamma: λ | y ~ Gamma(a + S, b + m)

Exponencial–Gamma: λ | y ~ Gamma(a + m, b + S)

```
alpha_p, beta_p = 2 + 14, 2 + 20 - 14
post = stats.beta(alpha_p, beta_p) # Beta(16, 8)
post.mean() # 0.6667
```

Con los números de la clase

- Priori Beta(2, 2) y 14 aprobados de 20: α = 2 + 14 = 16, β = 2 + 20 − 14 = 8 → media 16/24 = 0.6667
- La media posteriori es un promedio ponderado: 16.7 % de peso a la priori (media 0.50) y 83.3 % a los datos (14/20 = 0.70)
- Evidencia p(y) = 0.05929 (fórmula cerrada y grilla coinciden)
- **Cuidado.** La profesora dijo que α = β = 2 «no significa dos aprobados y dos reprobados»; la diapositiva 23 sí los llama «éxitos y fracasos previos». Ambas lecturas son útiles: para actualizar, Beta(2, 2) se comporta **como si** se hubieran visto 2 éxitos y 2 fracasos más.

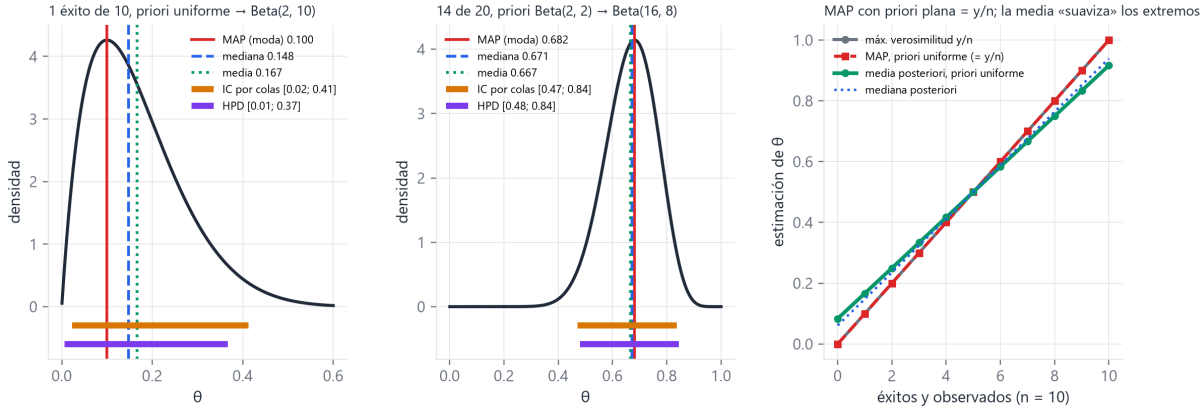
Clase 23 · Resumir la posteriori: media, MAP e intervalo creíble

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

La posteriori completa es el resultado; un solo número (media, mediana o MAP) la resume pero oculta la incertidumbre. El intervalo creíble añade lo que falta y se lee de forma directa.

Conceptos clave

1. **Resúmenes puntuales.** Media posteriori $\alpha/(\alpha + \beta)$; mediana; moda o MAP (máximo a posteriori) $(\alpha - 1)/(\alpha + \beta - 2)$ si $\alpha, \beta > 1$. Con posterioris simétricas casi coinciden; con asimetría se separan.
2. **Intervalo creíble 95 %.** $[a, b]$ con $P(a < \theta < b \mid y) = 0.95$. El «por colas» deja 2.5 % a cada lado (`qbeta`); el HPD es el más corto con 95 % de masa. Ambos son válidos y distintos.
3. **Probabilidades de decisión.** $P(\theta > 0.6 \mid y)$ se calcula directo con la cola de la Beta (o con rbeta y la media de un indicador, por simulación).
4. **MAP y máxima verosimilitud.** Con priori plana, el MAP es y/n, el estimador de máxima verosimilitud. La media posteriori suaviza los extremos: con 0 éxitos de 10 da 0.083, no 0.



Izquierda: posteriori asimétrica Beta(2, 10) (1 éxito de 10): MAP 0.100, mediana 0.148, media 0.167; el HPD 0.01–0.37 es más corto que el de colas iguales. Centro: Beta(16, 8), casi simétrica. Derecha: estimaciones de θ con n = 10 según y.

Fórmulas y reglas

media = $\alpha/(\alpha + \beta)$

MAP = $(\alpha - 1)/(\alpha + \beta - 2)$

IC creíble por colas = [qbeta(0.025, α, β); qbeta(0.975, α, β)]

$P(\theta > c \mid y) = 1 - \text{pbeta}(c, \alpha, \beta)$

En Python

```
post.ppf([0.025, 0.975]) # qbeta
post.sf(0.6) # 1 - pbeta
(16 - 1) / (16 + 8 - 2) # MAP
```

Con los números de la clase

- Beta(16, 8): media 0.6667, mediana 0.6714, MAP 0.6818, desviación 0.0943
- IC creíble 95 % por colas [0.4708; 0.8362] (R: 0.4708083 y 0.8362364); HPD [0.4811; 0.8446]
- $P(\theta > 0.6 \mid y) = 0.7627$ exacto; con 10 000 simulaciones la práctica obtuvo 0.7581 (error de simulación ≈ 0.0043); el ancho del IC baja de 0.81 (priori) a 0.37

Cuidado
En clase se dijo «0.47 y 0.83»; el valor exacto es 0.8362, que la práctica escribe 0.84. Y `qbeta(0.025, ·)` da **cuantiles** (percentiles 2.5 % y 97.5 %), no «cuartiles».

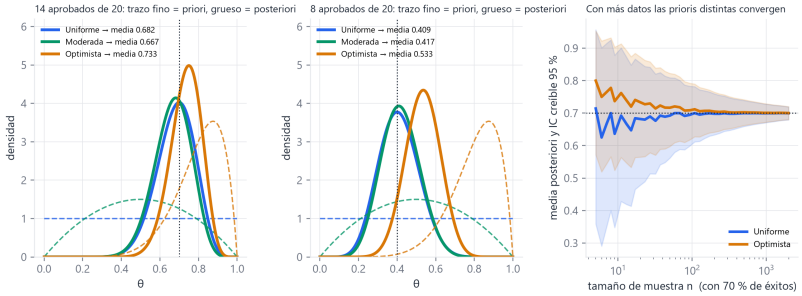
Clase 23 · Priori, tamaño de muestra y actualización secuencial

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

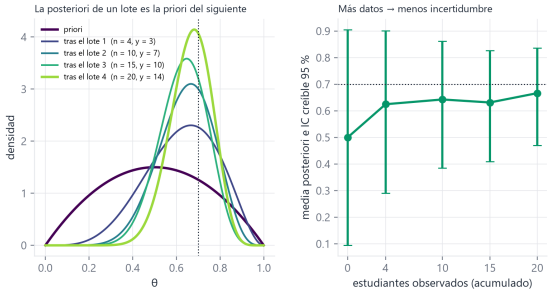
La priori pesa como una muestra previa de tamaño α + β: cuanto más datos, menos importa. Y como la posteriori de hoy es la priori de mañana, los datos pueden llegar de a poco y el resultado es el mismo que si llegaran juntos.

Conceptos clave

1. **Sensibilidad a la priori.** Con las mismas observaciones, prioris distintas dan posterioris distintas. Se reporta con varias prioris razonables y se ve si la conclusión cambia.
2. **Peso de la priori.** Peso = (α + β)/(α + β + n). Beta(2, 2) con n = 20: 4/24 = 17 %. Beta(8, 2): 10/30 = 33 %, no es «poco informativa».
3. **Más datos, convergencia.** Al crecer n, las posterioris de prioris distintas se parecen entre sí y se acercan a y/n; el intervalo se estrecha en ≈ 1/√n.



Tres prioris de la práctica con 14 de 20: medias 0.682, 0.667 y 0.733; con 8 de 20 (ejercicio de la profesora): 0.409, 0.417 y 0.533. Derecha: con 70 % de éxitos, las medias de Beta(1, 1) y Beta(8, 2) pasan de 0.67 y 0.75 (n = 10) a 0.700 y 0.701 (n = 1 000).



Por lotes o todo junto: la misma posteriori

Lote	n	y	(α, β)
priori			(2, 2)
1	4	3	(5, 3)
2	6	4	(9, 5)
3	5	3	(12, 7)
4	5	4	(16, 8)
todo junto	**20**	**14**	**(16, 8)**

Cuatro llegadas de estudiantes (4, 6, 5 y 5; con 3, 4, 3 y 4 aprobados): los parámetros pasan por (5, 3), (9, 5), (12, 7) y (16, 8), igual que con todos los datos de una vez.

Fórmulas y reglas

peso de la priori = (α + β)/(α + β + n)

media posteriori = w·media priori + (1 − w)·y/n

w = (α + β)/(α + β + n)

```
for a, b in [(1, 1), (2, 2), (8, 2)]:
    post = stats.beta(a + y, b + n - y)
    print(post.mean(), post.sf(0.6))
```

Con los números de la clase

- y = 14: posterioris Beta(15, 7), Beta(16, 8), Beta(22, 8); P(θ > 0.6) = 0.800, 0.763, 0.943
- y = 8: Beta(9, 13), Beta(10, 14), Beta(16, 14); P(θ > 0.6) = 0.035, 0.035, 0.234. La priori optimista pesa más cuando los datos la contradicen
- Ejercicio de la práctica: la media pasa de 0.67 a 0.42 con Beta(2, 2); influye más la más informativa, Beta(8, 2)
- **Cuidado.** Beta(8, 2) equivale a 10 observaciones previas: con 20 datos es un tercio de la información. Hay que **justificarla** (datos históricos, expertos), no elegirla por el resultado.

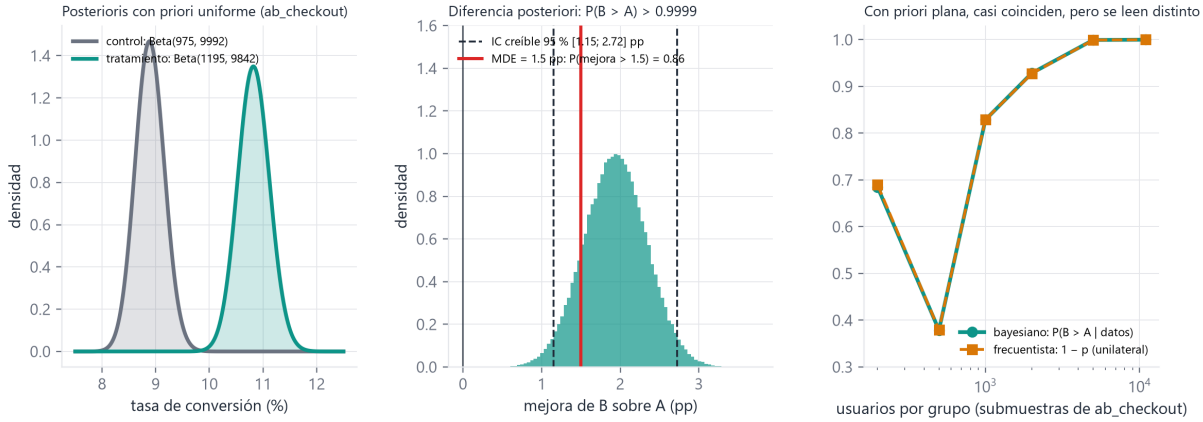
Clase 23 · Puente con la Clase 22: A/B testing bayesiano

Fuente: transcripción + diapositivas + Clase23.ipynb / práctica en R de la profesora Maritza Márquez

El experimento de checkout de la Clase 22 se puede analizar con Beta–Binomial en cada grupo. La respuesta ya no es un p-valor sino una probabilidad directa: P(B > A | datos) y P(mejora > MDE | datos). (La clase no lo hizo: es una extensión de este material.)

Conceptos clave

1. **Un modelo por grupo.** Cada grupo: conversiones ~ Binomial(n, θ) con priori uniforme Beta(1, 1). Posterioris: control Beta(975, 9 992), tratamiento Beta(1 195, 9 842).
2. **Diferencia por simulación.** Se simulan 200 000 pares (θ_A, θ_B) de las Betas y se mira θ_B − θ_A: la media, el intervalo creíble y la fracción > 0 o > MDE.
3. **Qué responde.** P(B > A) > 0.9999; IC creíble 95 % de la mejora [1.15; 2.72] pp; P(mejora > 1.5 pp) = 0.86. La Clase 22 solo podía decir que el extremo bajo del IC (1.15) no supera el MDE.
4. **Parentesco.** Con priori plana y mucho n, el IC creíble ≈ IC de Wald y P(B > A) ≈ 1 − p unilateral. Los números casi coinciden; cambia la lectura.



Izquierda: posterioris de las dos tasas. Centro: la diferencia simulada, con su IC creíble y el MDE de 1.5 pp. Derecha: con submuestras de ab_checkout, P(B > A) y 1 − p (unilateral) casi coinciden (por ejemplo, con 1 000 por grupo: 0.829 y 0.829).

Fórmulas y reglas

θ_A ~ Beta(1 + x_A, 1 + n_A − x_A)

θ_B ~ Beta(1 + x_B, 1 + n_B − x_B)

P(B > A) = promedio de (θ_B > θ_A) en las simulaciones

mejora = θ_B − θ_A

En Python

```
sa = stats.beta(975, 9992).rvs(200000,
random_state=rng)
sb = stats.beta(1195, 9842).rvs(200000,
random_state=rng)
(sb - sa > 0.015).mean() # P(mejora > 1.5 pp)
```

Con los números de la clase

- Control 974/10 965 = 8.88 %; tratamiento 1 194/11 035 = 10.82 %; diferencia 1.937 pp
- IC de Wald (Clase 22) [1.15; 2.72] frente a creíble [1.15; 2.72]
- P(mejora > 1.0 pp) = 0.991; P(mejora > 1.5 pp) = 0.862

Cuidado
«P(B > A) = 0.97» no dice que B sea **bueno**: dice cuán probable es que sea algo mejor. La decisión necesita el tamaño de la mejora, el costo y los guardrails. Y con una priori muy informativa, los resultados dejan de coincidir con el frecuentista.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase

- **«gamma de alfa más gamma de beta»** (densidad Beta): el denominador es el **producto** Γ(α)Γ(β); la diapositiva 23 lo escribe bien. Se verificó contra `stats.beta.pdf`.
- **«Los parámetros α y β no son dos aprobados y dos reprobados»** frente a la diapositiva 23 («éxitos y fracasos previos»): para *actualizar* funcionan como pseudo-conteos; la media posteriori usa (α + y)/(α + β + n).
- **«La posteriori es la sensibilidad por la priori sobre la posteriori»** (práctica en R): el denominador es la **evidencia** P(+) = 0.1085, no la posteriori.
- **«Los valores 0.025 y 0.975 son cuartiles»**: son **cuantiles** (percentiles 2.5 % y 97.5 %). Cuartiles son 25, 50 y 75 %.
- **«95 % de las veces ese parámetro queda dentro del intervalo»** (frecuentista): el parámetro es fijo; lo que se repite y varía es el **intervalo**. La profesora lo corrigió en el momento.
- **«Función de densidad de la binomial»**: es una función de **masa** de probabilidad; como función de θ se llama verosimilitud y no integra 1.

Diapositivas, práctica en R y cuaderno

- **P(θ > 0.6 | y)**: el cuaderno entrega 0.7581 con `rbeta` (10 000 simulaciones, `set.seed(123)`); el valor exacto es 0.7627 (`1 − pbeta`, 0.7627291 en la tabla de la práctica). La diferencia es ruido de Monte Carlo (error estándar ≈ 0.0043).
- **Intervalo**: la práctica reporta «entre 0.47 y 0.84» y en clase se leyó 0.83; el extremo exacto es 0.8362 (se redondea a 0.84). Es un intervalo **por colas**; el HPD [0.48; 0.84] también es un intervalo creíble.
- **Beta(8, 2) «optimista»**: es informativa (equivale a 10 observaciones, 33 % del peso con n = 20). No es una prueba de «prioridad suave».
- **Diapositiva 8**: «P(θ > 0.6 | datos) = 0.82» es un ejemplo ilustrativo; el valor de la práctica es 0.76.
- **Diapositiva 32**: anuncia una práctica «en R y Python» pero solo se entrega el archivo en R (`Clase23_Bayes_R.Rmd`); este material añade la versión en Python.

Transcripción con ruido

Whisper escribió «vallenciana», «valleciana», «vallesiana», «valleseano», «vayaciana» y «Valles» por *bayesiana* y *Bayes*, «cobi» por COVID, «cuartilas/cubeta» por cuantiles y qbeta, «Colap» por Colab. El recreo (≈ 1:24:30 del video) no está en el video; la corrección dejó marcado el punto.

Checklist, criterio de dominio y lo que viene

- ☐ Distingo P(A | B) de P(B | A) y calculo P(enfermo | positivo) con frecuencias naturales y con la fórmula
- ☐ Explico priori, verosimilitud, posteriori y para qué sirve la evidencia
- ☐ Actualizo una Beta con datos binomiales, y calculo media, MAP e intervalo creíble
- ☐ Leo un intervalo creíble y uno de confianza sin confundirlos, y explico cómo influyen la priori y n
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Clase 24** (próxima sesión): modelo Normal con varianza conocida, distribución predictiva, simulación de Monte Carlo e introducción a MCMC (Metropolis–Hastings).