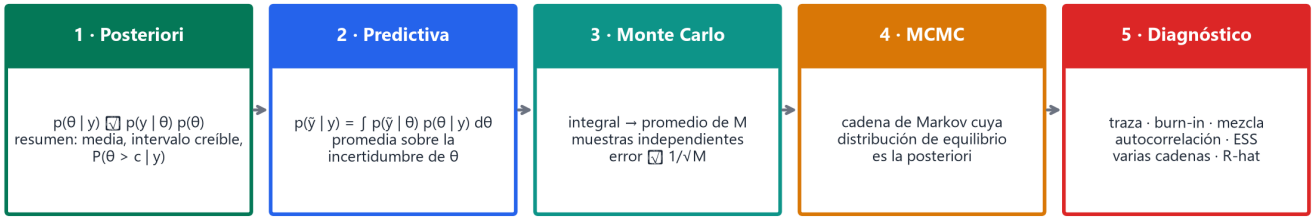
Clase 24 · Estadística bayesiana, parte 2: posteriori, predicción, Monte Carlo y MCMC

Profesora Maritza Márquez · continúa la Clase 23 (priori, verosimilitud, Beta–Binomial) y se conecta con GLM (C20–21), A/B testing (C22) y bootstrap (C43)

La gran idea de la clase

Cuando la posteriori **tiene fórmula** (Beta–Binomial, Normal–Normal) todo se calcula con álgebra: la media posteriori es un promedio ponderado por **precisiones**. La **predicción** no usa un solo valor de θ, sino todos, ponderados por la posteriori. Cuando una cantidad es una integral difícil se **simula** (Monte Carlo: integral = promedio de muestras). Y cuando ni siquiera se sabe simular de la posteriori, porque solo se conoce **proporcional** a priori × verosimilitud, se construye una **cadena de Markov** (MCMC, p. ej. Metropolis–Hastings) cuya distribución de equilibrio es la posteriori. Una cadena **no se acepta a ciegas**: se revisan la **traza**, el **burn-in**, la **autocorrelación**, el **tamaño efectivo** y el **R-hat** de varias cadenas.

La clase en una imagen



Aplicación: regresión logística bayesiana con los datos Pima (diabetes ~ glucosa + IMC + edad), muestreada con Metropolis

Lo que necesitas ANTES

- **Priori × verosimilitud ∝ posteriori**, Beta–Binomial e intervalo creíble (Clase 23)
- **Regresión logística y odds ratio** (Clases 20–21): hoy se ajusta con el enfoque bayesiano
- **IC, valor p y bootstrap** (Clases 22 y 43): se comparan con la posteriori
- **scipy y numpy**: `stats.norm`, `stats.beta`, `rng.normal`; el muestreador se escribe a mano

Ruta de la clase y datos

- **Normal–Normal → predictiva → Monte Carlo → por qué MCMC → Metropolis paso a paso → traza, burn-in, ESS, R-hat → regresión logística bayesiana**
- **Pima.tr** (paquete MASS de R): 200 mujeres, 68 con diabetes y 132 sin ella; predictores glucosa, IMC y edad (estandarizados). Está en `Guias/datos/pima_tr.csv`
- Pregunta guía: ¿qué dicen los datos sobre el riesgo de diabetes y cuánta incertidumbre queda en cada coeficiente?

Puentes con otras clases (sin repetirlas)

C22 → C24: en lugar de «¿p < 0.05?» se pregunta P(θ > c | y); aquí P(μ > 65 | y) = 0.674. **C17–21 → C24**: la regresión logística es la de GLM; con 200 datos y prioris suaves la posteriori casi coincide con la máxima verosimilitud (glu_z: clásico 0.977, bayesiano 0.972), pero se interpreta como probabilidad. **C23 → C24**: la Beta(16, 8) de la clase pasada sirve para predecir la próxima cohorte (P(menos de 5 aprueben) = 0.114). **C43 → C24**: el bootstrap mide la variación del estimador al remuestrear datos (sd 0.210 para glu_z); la posteriori mide la incertidumbre dado un modelo y una priori (sd 0.196).

Recuadro: «cadena de Markov» sin fórmulas

Una cadena de Markov es una secuencia de valores donde **el siguiente depende solo del actual** (no de todo el pasado). Metropolis–Hastings la diseña para que, a la larga, visite cada valor de θ con frecuencia proporcional a la posteriori. Los valores consecutivos **no son independientes**: por eso hay que medir cuánta información real aportan (tamaño efectivo).

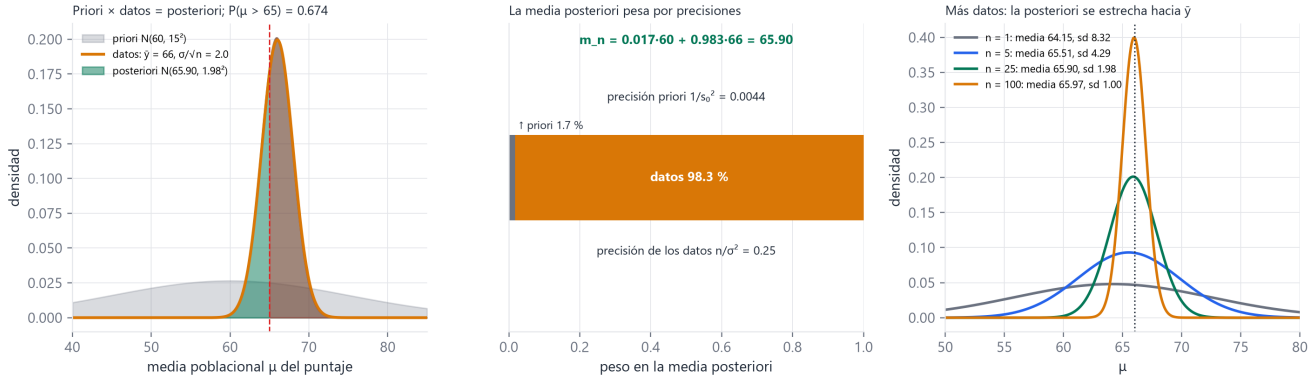
Clase 24 · Inferencia posteriori y el modelo Normal–Normal

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

Con datos normales de varianza conocida y priori normal, la posteriori es normal: su precisión es la suma de precisiones y su media, un promedio ponderado por precisiones. Con más datos, la priori pesa cada vez menos pero nunca desaparece.

Conceptos clave

1. **La posteriori, objeto central.** En vez de un estimador y un p-valor, el resultado es $p(\theta \mid y)$: de ahí salen estimaciones puntuales, intervalos creíbles, probabilidades posteriores $P(\theta > c \mid y)$, predicciones y decisiones.
2. **Normal–Normal.** $Y_i \mid \mu \sim N(\mu, \sigma^2)$ con σ^2 conocida y $\mu \sim N(m_0, s_0^2)$. Entonces $\mu \mid y \sim N(m_n, s_n^2)$: $1/s_n^2 = 1/s_0^2 + n/\sigma^2$ y $m_n = s_n^2 \cdot (m_0/s_0^2 + n\cdot\bar{y}/\sigma^2)$.
3. **Precisión = 1/varianza.** La priori aporta $1/s_0^2$; los datos, n/σ^2. Gana quien tiene más precisión. Si σ^2 fuera desconocida, el problema es otro (priori Normal–Gamma inversa; la marginal de μ es una t).



Ejemplo de la clase: priori $N(60, 15^2)$, $n = 25$, $\bar{y} = 66$, $\sigma = 10$. La priori vale 0.0044 de precisión y los datos 0.25: la posteriori $N(65.90, 1.98^2)$ queda casi sobre $\bar{y}$. Derecha: $n = 1, 5, 25$ y 100 con el mismo $\bar{y}$; la media pasa de 64.15 a 65.97 y la desviación baja de 8.32 a 1.00.

Fórmulas y reglas

$$1/s_n^2 = 1/s_0^2 + n/\sigma^2$$

$$m_n = s_n^2 \cdot (m_0/s_0^2 + n\cdot\bar{y}/\sigma^2)$$

$$m_n = w\cdot m_0 + (1 - w)\cdot\bar{y},\ w = (1/s_0^2)/(1/s_n^2)$$

$$P(\mu > c \mid y) = 1 - \Phi((c - m_n)/s_n)$$

```
from figuras_c24 import normal_normal
m, v = normal_normal(60, 15, 10, 25, 66)
stats.norm(m, v**0.5).sf(65) # P(μ > 65 | y)
```

Con los números de la clase

- $s_n^2 = 1/(1/225 + 25/100) = 3.9301$; $s_n = 1.9825$; $m_n = 65.8952$
- Peso de la priori $w = 0.0175$ (1.7 %); de los datos, 98.3 %
- $P(\mu > 65 \mid y) = 0.6742$; intervalo creíble 95 % [62.01; 69.78]
- Pregunta de la clase: al aumentar n, la priori **no desaparece**, pierde peso relativo frente a la verosimilitud
- **Cuidado.** En el notebook la función se llama `normal_normal(m0, s0, sigma, n, ybar)`; s_0 y σ son desviaciones (no varianzas).

Clase 24 · Distribución predictiva y simulación de Monte Carlo

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

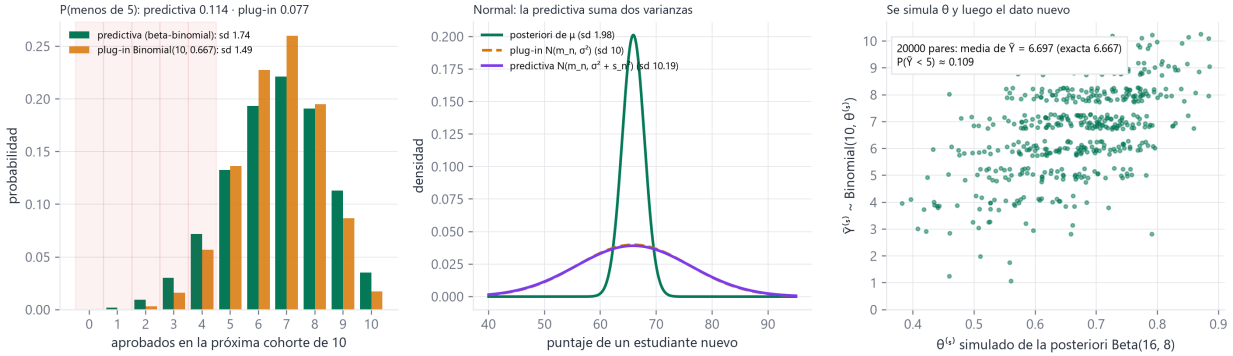
Para predecir un dato nuevo $\tilde{Y}$ se promedia sobre todos los valores de θ según la posteriori: la predictiva tiene más dispersión que usar un θ fijo. Y casi cualquier integral posterior se aproxima con un promedio de simulaciones.

Conceptos clave

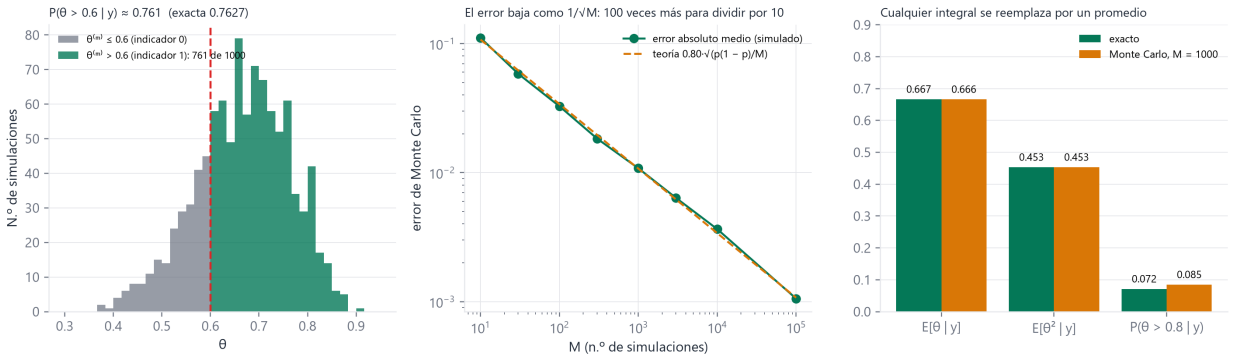
1. **Predictiva posterior.** $p(\tilde{y} \mid y) = \int p(\tilde{y} \mid \theta)\, p(\theta \mid y)\, d\theta$. Dos fuentes de variación: el azar del dato nuevo y la incertidumbre sobre θ. Se simula: $\theta^{(s)} \sim p(\theta \mid y)$ y luego $\tilde{Y}^{(s)} \mid \theta^{(s)}$.

2. **Monte Carlo.** $I = E[g(\theta) \mid y] \approx (1/M) \Sigma\, g(\theta^{(m)})$ con muestras independientes de la posteriori. Una probabilidad es un promedio de indicadores: $P(\theta > 0.6 \mid y) \approx$ fracción de $\theta^{(m)} > 0.6$.

3. **Error de simulación.** El error estándar baja como $1/\sqrt{M}$: para dividirlo por 10 hacen falta 100 veces más simulaciones. Es error de cálculo, no incertidumbre sobre θ (esa la da la posteriori).



Izquierda: con Beta(16, 8) y m = 10 la predictiva (beta-binomial, sd 1.74) es más ancha que la Binomial(10, 0.667) con θ fijo (sd 1.49): P(menos de 5) = 0.114 frente a 0.077. Centro: en el caso normal las varianzas se suman ($\sigma^2 + s_n^2$). Derecha: 20 000 pares simulados dan $P(\tilde{Y} < 5) \approx 0.109$.



Con M = 1000 simulaciones de la Beta(16, 8), 761 superan 0.6: P ≈ 0.761 (exacta 0.7627, error estándar ≈ 0.0135). Centro: el error baja como $1/\sqrt{M}$. Derecha: esperanzas y probabilidades, todas como promedios.

Fórmulas y reglas

$\tilde{Y} \mid \theta \sim \text{Binomial}(m, \theta)$, $\theta \mid y \sim \text{Beta}(\alpha, \beta)$

$\text{Var}(\tilde{Y}) = m \cdot \alpha\beta(\alpha + \beta + m) / ((\alpha + \beta)^2(\alpha + \beta + 1))$

$\text{Var}(\tilde{Y}_{\text{normal}}) = \sigma^2 + s_n^2$

$SE_{MC} \approx \sqrt{\hat{p}(1 - \hat{p})/M}$

```
th = stats.beta(16, 8).rvs(20000)
y_nuevo = rng.binomial(10, th)
(y_nuevo < 5).mean() # P(Ỹ < 5)
```

Con los números de la clase

- Beta(16, 8), m = 10: media 6.667; varianza 3.022 (con θ fijo: 2.222)
- $P(\tilde{Y} \geq 7) = 0.560$ (parecido al plug-in 0.559): en el centro coinciden, las colas difieren
- Normal: sd predictiva 10.195 frente a σ = 10; P(nuevo estudiante > 65) = 0.535
- La clase dijo «no basta decir que aprobarán 7; conviene decir qué tan probable es que aprueben menos de 5»
- **Cuidado.** Un promedio de Monte Carlo con M = 1 000 tiene error de ≈ 0.013 en una probabilidad cercana a 0.76: no reportes más de dos decimales.

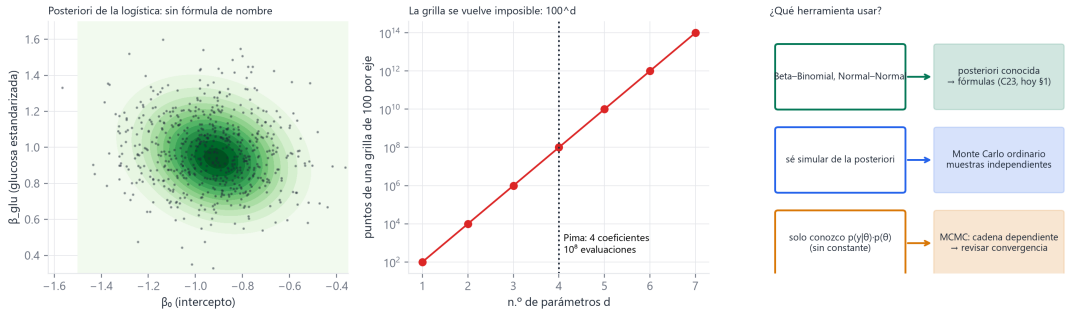
Clase 24 · Por qué MCMC y Metropolis paso a paso

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

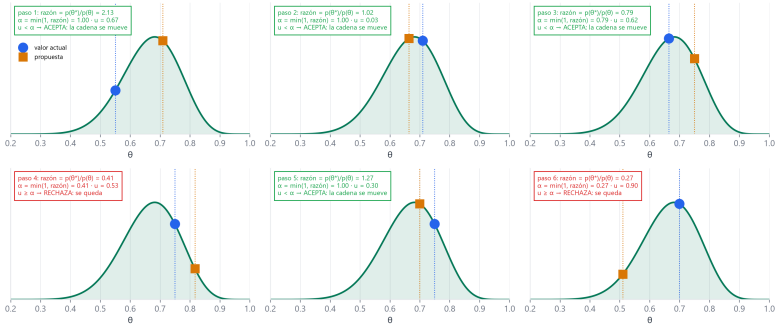
Si la posteriori solo se conoce salvo una constante, no se puede simular de ella directamente ni integrar con una grilla. Metropolis propone un valor cerca del actual, compara su plausibilidad según la posteriori y lo acepta o rechaza: la cadena resultante recorre la posteriori.

Conceptos clave

1. **El problema.** $p(\theta \mid y) = p(y \mid \theta)p(\theta)/p(y)$, y el denominador $p(y) = \int p(y \mid \theta)p(\theta)\, d\theta$ es una integral de d dimensiones. En la regresión logística no hay familia conocida y una grilla cuesta 100^d evaluaciones.
2. **Algoritmo de Metropolis.** Desde θ: propone $\theta^* \sim N(\theta, \tau^2)$; calcula $r = p(\theta^* \mid y)/p(\theta \mid y)$ (la constante se cancela); acepta con probabilidad $\alpha = \min(1, r)$. Si acepta, $\theta \leftarrow \theta^*$; si no, la cadena se repite en θ.
3. **Qué se obtiene.** Una cadena $\theta^{(1)}, \theta^{(2)}, \ldots$ cuya distribución de largo plazo es la posteriori; se usa como una muestra, pero con valores **dependientes**.



Izquierda: contorno de la posteriori de (β_0, β_glu) en la regresión de Pima con puntos de la cadena. Centro: una grilla de 100 valores por parámetro explota con d. Derecha: qué herramienta usar.



Seis pasos reales con la Beta(16, 8) como objetivo (núcleo $\theta^{15}(1-\theta)^7$), desde $\theta = 0.55$ y paso $\tau = 0.1$: sube la cadena cuando $r > 1$ (acepta siempre), y baja a veces ($r < 1$ acepta con probabilidad r); los pasos 4 y 6 se rechazan y la cadena **se repite**.

Fórmulas y reglas

$$r = p(\theta^* \mid y)/p(\theta \mid y) = [p(y \mid \theta^*)p(\theta^*)]/[p(y \mid \theta)p(\theta)]$$

$$\alpha = \min(1, r);\ \text{aceptar si } u < \alpha,\ \text{con } u \sim U(0, 1)$$

$$\text{propuesta asimétrica: } r = [p(\theta^*)q(\theta \mid \theta^*)]/[p(\theta)q(\theta^* \mid \theta)]$$

```
u = rng.uniform()
if np.log(u) < logp(prop) - logp(x):
    x = prop # acepta; si no, x queda igual
```

Con los números de la clase

- Paso 1: $r = 2.13$, $u = 0.67 \rightarrow$ acepta (θ: 0.55 → 0.71)
- Paso 3 (bajada): $r = 0.79 < 1$, $u = 0.62 < \alpha \rightarrow$ acepta igual: así la cadena explora las colas
- Paso 4: $r = 0.41$, $u = 0.53 \geq \alpha \rightarrow$ rechaza y se queda en 0.75
- Una propuesta fuera del soporte ($\theta \leq 0$ o ≥ 1) tiene densidad 0: $r = 0$ y siempre se rechaza
- **Cuidado.** Las diapositivas describen la propuesta «cercana»; con una propuesta **asimétrica** hay que incluir el cociente de las densidades de propuesta (corrección de Hastings), o la cadena converge a otra distribución (ver alerta).

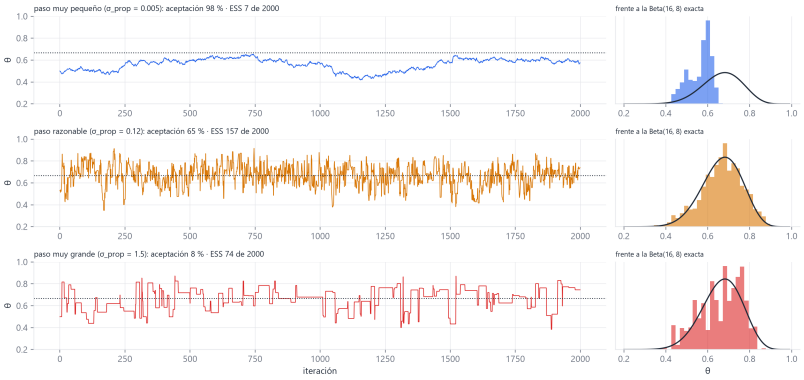
Clase 24 · Diagnóstico visual: traza, tamaño de paso y burn-in

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

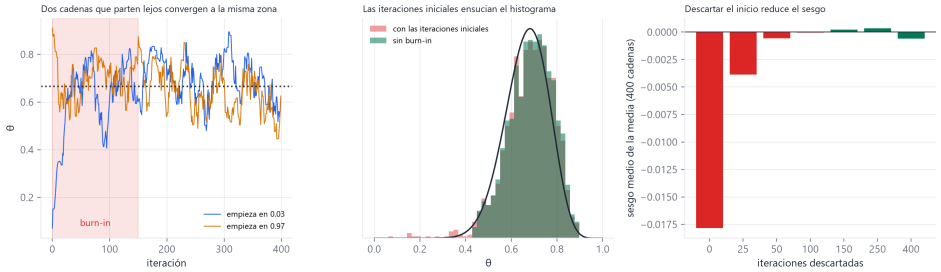
Una cadena no es un resultado hasta revisarla. La traza debe oscilar rápido alrededor de una zona estable, sin tendencias ni tramos pegados; el tamaño de paso decide si lo hace; y el comienzo (burn-in) se descarta.

Conceptos clave

1. **Traza.** Gráfico del valor simulado frente a la iteración. Buena: «oruga peluda» estable. Mala: tendencia, saltos largos, periodos inmóviles. Se acompaña del histograma o la densidad.
2. **Mezcla y tamaño de paso.** Paso muy pequeño: casi todo se acepta pero la cadena avanza a paso de tortuga. Paso muy grande: casi todo se rechaza y se queda pegada. El punto medio mezcla bien (aceptación ≈ 25–50 % en dimensiones moderadas).
3. **Burn-in (calentamiento).** Las primeras iteraciones dependen del punto de partida; se descartan. En el cuaderno: 4 cadenas, 2 000 iteraciones, las primeras 1 000 de «warmup». No arregla un modelo mal especificado ni una muestra pequeña.



Misma posteriori Beta(16, 8) y tres tamaños de paso (2 000 iteraciones desde 0.5). Con τ = 0.005 la cadena tarda cientos de iteraciones en recorrer lo que una buena cadena recorre en diez; con τ = 1.5 se queda pegada (92 % de rechazos).



Dos cadenas que parten de 0.03 y 0.97 se encuentran en la zona de la posteriori. Derecha: sesgo medio de la media de la cadena según las iteraciones descartadas (promedio de 400 cadenas de 700 iteraciones desde 0.03): -0.0178 sin descartar y ≈ 0 después de unas 50–100.

Fórmulas y reglas

aceptación = aceptadas/iteraciones

descarta las primeras b iteraciones: cadena[b:]

estimación = promedio de cadena[b:]

```
ch, acep = metropolis(logp, 0.5, 0.12, 2000,
rng)
ch = ch[150:] # sin burn-in
```

Con los números de la clase

- τ = 0.005: aceptación 98 %, ESS 7 de 2 000; media 0.561 (exacta 0.667)
- τ = 0.12: aceptación 65 %, ESS 157; media 0.667
- τ = 1.5: aceptación 8 %, ESS 74; media 0.661
- Aceptar mucho no es buena señal: aceptación 98 % con paso minúsculo da una cadena casi inmóvil
- **Cuidado.** Una traza «bonita» a ojo no basta; la misma cadena con paso minúsculo parece suave. Se cuantifican la autocorrelación, el ESS y el R-hat (página siguiente).

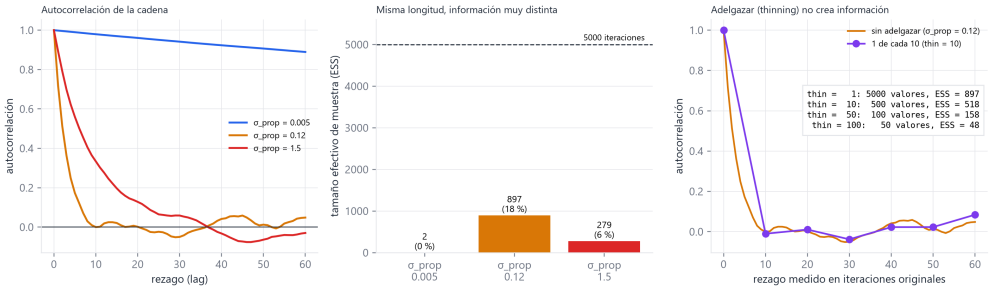
Clase 24 · Autocorrelación, tamaño efectivo y R-hat

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

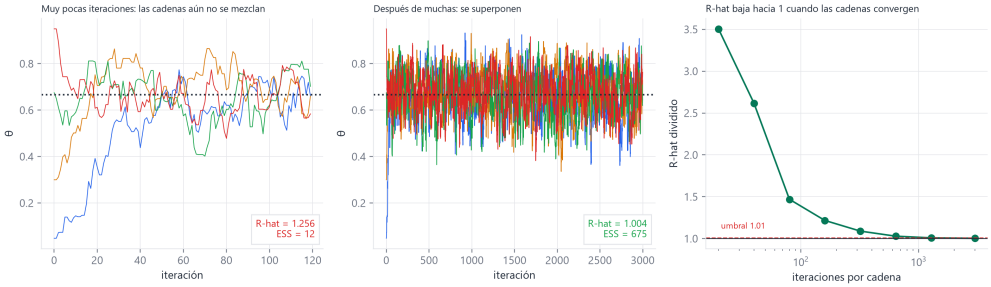
Los valores de una cadena están correlacionados: 5 000 iteraciones pueden valer solo unas decenas de muestras independientes. El tamaño efectivo (ESS) lo mide, y el R-hat compara varias cadenas con puntos de partida distintos para detectar falta de convergencia.

Conceptos clave

1. **Autocorrelación y ESS.** ρ_k = correlación entre $\theta^{(t)}$ y $\theta^{(t+k)}$. ESS ≈ M / (1 + 2 Σ ρ_k): cuántas muestras independientes «vale» la cadena. El error de Monte Carlo de la media es sd/√ESS, no sd/√M.
2. **Thinning (adelgazar).** Guardar 1 de cada k reduce la autocorrelación del resultado pero **no crea información**: el ESS no sube (baja si se tira información). Solo ahorra memoria; con ESS bajo hay que mejorar el muestreador o correr más.
3. **Varias cadenas y R-hat.** Se parten de valores dispersos. R-hat compara la varianza entre cadenas con la de dentro: ≈ 1 si todas exploran lo mismo; > 1.01 sugiere no convergencia. Es necesario, no suficiente.



5 000 iteraciones desde 0.68. La cadena con paso razonable pierde la memoria en ≈ 10 rezagos (ESS 897); la de paso minúsculo conserva autocorrelación 0.91 a 50 rezagos (ESS 2). Derecha: adelgazar la cadena razonable de 5000 a 500 valores baja el ESS de 897 a 518.



Cuatro cadenas desde 0.05, 0.3, 0.7 y 0.95. Con 120 iteraciones R-hat = 1.256 (no han convergido); con 3 000, 1.004 y ESS ≈ 675. A la derecha, R-hat decrece hacia 1 al alargar las cadenas.

Fórmulas y reglas

ESS ≈ M / (1 + 2 Σ_k ρ_k)

SE_MCMC ≈ sd / √ESS

R-hat = √[(varianza combinada)/(varianza dentro de cadenas)]

criterio habitual: R-hat < 1.01 y ESS ≳ 400 en total

```
ess, rhat = ess_rhat(cadenas) # (m, n)
autocorr(cadena, 50)[10] # ρ₁₀
```

Con los números de la clase

- Cuaderno de la profesora (Stan): R-hat 1.000, 1.000, 1.002 y 1.001; n_eff entre 3 668 y 4 139 de 4 000
- Mi Metropolis a mano con la misma configuración (4 × 1 000 válidas): ESS entre 254 y 331 y R-hat hasta 1.013
- Con 4 × 25 000 iteraciones: ESS 4625–7961 y R-hat 1.0012
- Un Metropolis de paseo aleatorio es mucho menos eficiente que el NUTS de Stan
- **Cuidado.** R-hat cercano a 1 no demuestra convergencia si todas las cadenas se quedan en la misma región equivocada, y un ESS alto no corrige un modelo mal planteado.

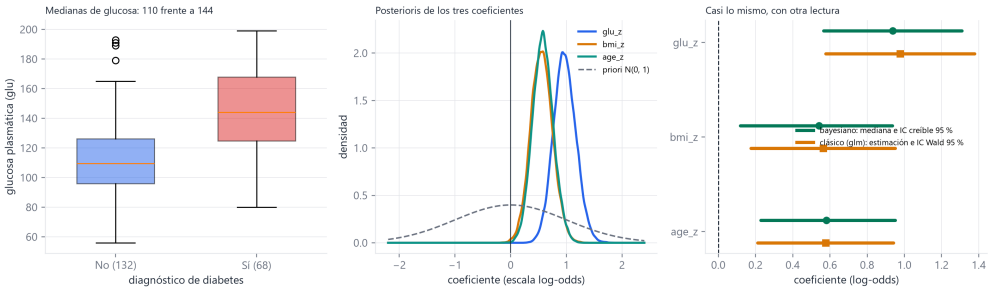
Clase 24 · Regresión logística bayesiana con los datos Pima

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

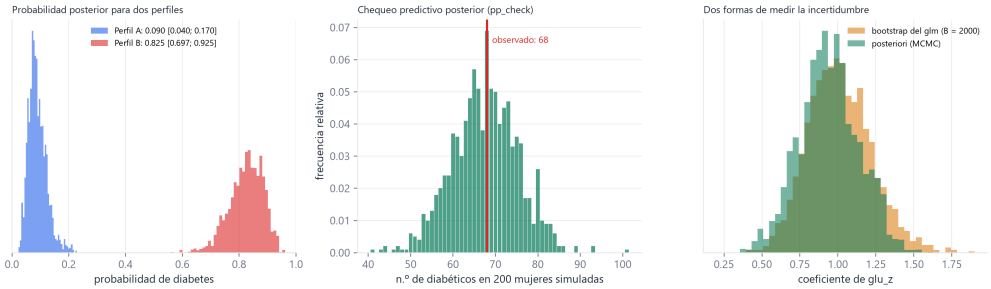
La regresión logística de GLM se ajusta con el enfoque bayesiano asignando prioris a los coeficientes; la posteriori no tiene fórmula, así que se muestrea con MCMC y todo (medianas, intervalos creíbles, odds ratios, predicciones) sale de las muestras.

Conceptos clave

1. **El modelo.** $\text{diabetes}_i \sim \text{Bernoulli}(p_i)$, $\text{logit}(p_i) = \beta_0 + \beta_1 \cdot \text{glu_z} + \beta_2 \cdot \text{bmi_z} + \beta_3 \cdot \text{age_z}$. Los predictores se **estandarizan** para que una misma priori (aquí N(0, 1) en los coeficientes y N(0, 2.5^2) en el intercepto) sea razonable para todos.
2. **Ajuste.** 4 cadenas, 2 000 iteraciones, 1 000 de calentamiento y semilla fija (rstanarm usa NUTS; aquí se reproduce con Metropolis). Antes de interpretar: trazas, R-hat y ESS.
3. **Resúmenes posteriores.** Media, mediana, intervalo creíble 95 % por cuantiles, $P(\beta > 0 \mid y)$ como promedio de indicadores y odds ratio = exp(β). Con glucosa estandarizada, OR compara a pacientes que difieren en **una desviación estándar**.



Izquierda: la glucosa mediana es 110 sin diabetes y 144 con ella. Centro: las tres posterioris frente a la priori N(0, 1). Derecha: mediana e IC creíble bayesianos y estimación e IC de Wald de glm: casi coinciden (n = 200 y priori suave).



Perfil A (glu 100, IMC 25, edad 30): 0.090 [0.040; 0.170]; Perfil B (160, 35, 55): 0.825 [0.697; 0.925]. Centro: la cantidad observada de diabéticos (68) cae en el centro de lo simulado. Derecha: bootstrap del glm y posteriori para glu_z.

Fórmulas y reglas

$$\text{logit}(p) = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3 z_3$$

OR = exp(β); IC creíble de OR = exp(IC creíble de β)

$P(\beta > 0 \mid y)$ = mean(muestras > 0)

```
m = cadenas.reshape(-1, 4) # 4 000 × 4
np.quantile(m[:, 1], [0.025, 0.975])
np.exp(np.median(m[:, 1])) # OR de glu_z
```

Con los números de la clase

- glu_z: mediana 0.966, IC creíble [0.587; 1.378], OR 2.63; rstanarm: 0.966 y [0.580; 1.386]
- bmi_z: 0.554 (rstanarm 0.548); age_z: 0.578 (rstanarm 0.573); intercepto -0.923 (rstanarm −0.921)
- $P(\beta > 0 \mid y)$: 1.000, 0.999 y 1.000: los tres intervalos quedan a la derecha de cero
- Exactitud aparente 0.76 (113, 19, 29 y 39 en la matriz): es dentro de la muestra y optimista
- **Cuidado.** «Intervalo de confianza para los odds ratios» (se dijo en clase y luego se corrigió): son intervalos **creíbles**. Y los resultados de rstanarm y de este muestreador difieren en el segundo decimal por error de Monte Carlo.

Clase 24 · Alertas, verificación y cierre

Fuente: transcripción + Clase 24.pdf + Clase24.ipynb (R, rstanarm) de la profesora Maritza Márquez

Lo dicho en clase y en las diapositivas (verificado)

- **El método del cuaderno no es Metropolis–Hastings**: `stan_glm` de rstanarm usa **HMC/NUTS**, no el algoritmo explicado en clase ni en la diapositiva 24. Además, «warmup» en Stan también **adapta** el paso (no es solo burn-in). La profesora lo dijo al final: MH «se utilizó para crear las cadenas»; en el cuaderno no es así.
- **La corrección de Hastings**: la diapositiva describe la propuesta como «cercana» y acepta según la razón de posterioris. Con propuesta **asimétrica** falta el cociente de propuestas: en el experimento de este material (Beta(16, 8), propuesta con deriva +0.08) la media sin corrección sale 0.778 y con corrección 0.665 (exacta 0.667).
- **«Más simulaciones o cadenas puede hacer que no converja»**: impreciso. En Monte Carlo ordinario el error baja siempre como $1/\sqrt{M}$; en MCMC más iteraciones no empeoran la estimación (solo el tiempo); lo que no mejora con más cadenas ni más iteraciones es un **modelo mal especificado** o una priori inadecuada (la diapositiva 26 lo dice bien).
- **«Monte Carlo es cuando no puedo calcular la integral; MCMC cuando ni siquiera normalizada puedo tener la expresión»**: más preciso: el Monte Carlo ordinario exige **saber simular** de la posteriori; MCMC solo exige evaluarla salvo una constante.
- **Diapositiva 20, «mientras mayor sea M, menor el error»**: vale con muestras independientes; con una cadena depende del ESS (5 000 iteraciones con ESS 2 no sirven de nada).
- **Diapositiva 28** anuncia una práctica `Clase24_Bayes_R.Rmd` con Normal–Normal, predictiva, A/B por Monte Carlo y Metropolis (y el título dice «R y Python»); el material entregado es el cuaderno `Clase24.ipynb` (solo R: regresión logística con rstanarm). Esta guía cubre ambas cosas en Python.
- **Cuaderno de la profesora**: `posterior_linpred(transform = TRUE)` está obsoleto (usar `posterior_epred`); la exactitud 0.76 es **aparente** (mismos datos); «ejemplo con datos real» es un error de tipeo. «R ajustado / reajustado» en la transcripción es el R-hat.
- **«Python es una caja negra y R está bien documentado»**: es una opinión; Stan, PyMC y brms están igual de documentados. Lo importante es saber cuántas cadenas, iteraciones y qué diagnósticos se usaron.

Verificación de este material

- Normal–Normal y predictiva por fórmula y por simulación (20 000 pares): $P(\tilde{Y} < 5)$ 0.1138 exacta frente a 0.1090 simulada.
- Cuaderno de la profesora reproducido con un Metropolis por bloques en numpy (sin Stan): con 4 × 25 000 iteraciones las medianas son -0.923, 0.966, 0.554 y 0.578 frente a −0.921, 0.966, 0.548 y 0.573 de rstanarm; glm clásico: -0.9243, 0.9769, 0.5632 y 0.5770 (los mismos de la profesora).
- Datos: Pima.tr, 200 filas, 68 «Yes» y 132 «No» (68 y 132 como en clase); media de aceptación del muestreador 0.33.
- **Transcripción con ruido** (ya corregido): «vallesiana/valleciana» = bayesiana, «Burkin/burin» = burn-in, «Geek Sample» = Gibbs sampler, «Nux» = NUTS, «SAEN» = SAEM, «math SD» = MAD_SD, «optradio» = odds ratio. Se marcó el recreo entre 1:26:49 y 1:48:15 (el video no tiene audio en ese tramo).

Checklist, criterio de dominio y lo que viene

- ☐ Calculo a mano la media y la varianza posteriores Normal–Normal y las leo como promedio ponderado por precisiones
- ☐ Distingo la posteriori de la predictiva y calculo la varianza predictiva (Normal y beta-binomial)
- ☐ Aproximo probabilidades y esperanzas por Monte Carlo y calculo su error estándar
- ☐ Explico por qué se necesita MCMC y hago un paso de Metropolis a mano (razón, α, u)
- ☐ Leo una traza, el burn-in, la autocorrelación, el ESS y el R-hat y decido si confiar en la cadena
- ☐ Resumo una posteriori con muestras: mediana, intervalo creíble, $P(\beta > 0)$, odds ratio
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Siguiente**: series de tiempo (Clases 25–27) y, más adelante, la evaluación de modelos con bootstrap (Clase 43).