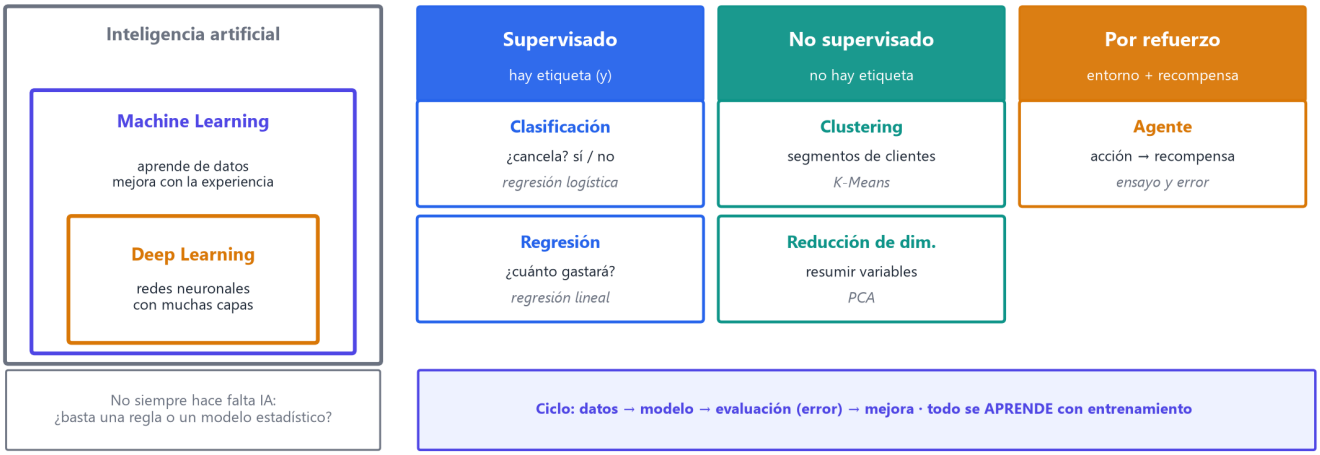
Clase 31 · Introducción al Machine Learning

Profesora Laura Sánchez · bloque de Machine Learning · sigue a Preparación para ML (C30) y precede a Reducción de dimensionalidad (C32)

La gran idea de la clase

En lugar de escribir a mano las reglas de decisión, se le entregan **ejemplos** a un modelo y él ajusta sus parámetros. Según lo que se tenga, el problema cae en una familia: con **etiqueta** (**supervisado**: clasificación o regresión), sin etiqueta (**no supervisado**: clustering o reducción de dimensionalidad) o con un entorno y recompensas (**refuerzo**). El ciclo es siempre el mismo: datos, modelo, **evaluación del error** y mejora. «No siempre se necesita inteligencia artificial: quieren un Ferrari para ir a comprar pan a la esquina.»

La clase en una imagen



Lo que necesitas ANTES

- Regresión lineal (Clases 17–19) y logística (Clases 20–21): aquí aparecen como «modelos de ML»
- Train / validación / prueba, Pipeline, Ridge y Lasso, accuracy / precision / recall / F1 (Clase 30)
- Imputar con media o mediana (Clase 30), ahora dentro de un Pipeline
- Distancia euclidiana y promedio (para K-Means); la idea de varianza (para PCA)

Ruta de la clase y datos

- **Reglas fijas → ciclo del ML → clasificación → regresión → K-Means y PCA → ajuste y regularización → trampa del accuracy → elegir el enfoque**
- Datos: **Club Activo**, 800 clientes simulados (el notebook usa `np.random.seed(42)`; 20.9 % cancela) y la **base real de 3.150 clientes** de la actividad de repaso (15.7 % de fuga), que sirve para el desafío «supervisado o no supervisado»
- Pregunta guía: ¿qué tipo de problema es, qué datos tengo y cómo sabré que el modelo sirve?

Puentes con las clases vecinas

C30 → C31: lo que allí se vio por piezas (división, regularización, métricas) aquí se aplica a un caso completo. **C31 → C32**: PCA aparece como «resumen visual» de 3 variables (58.2 % + 33.6 %); la Clase 32 explica cómo se calcula, cuántos componentes elegir y qué es t-SNE. Para no repetir: aquí solo se usa PCA para *mirar* segmentos, no para modelar.

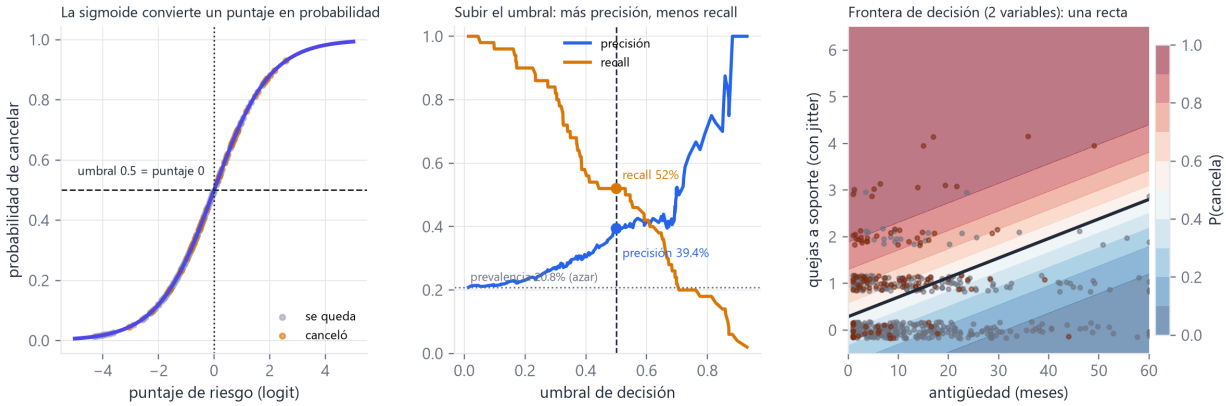
Clase 31 · Clasificación: la regresión logística

Fuente: transcripción de la clase + diapositivas + apunte + notebook y caso de la profesora Laura Sánchez

Si lo que se predice es una categoría (¿cancela, sí o no?), el problema es de clasificación. La regresión logística calcula un puntaje (logit) y lo convierte en probabilidad con la función sigmoide; el umbral decide la clase.

Conceptos clave

1. **Puntaje y probabilidad.** logit = $b_0 + b_1x_1 + \dots$; $p = 1 / (1 + e^{-\text{logit}})$. Puntaje 0 equivale a p = 0.5; cada unidad adicional de x_j multiplica las *odds* por e^{b_j}.
2. **Aprende con entrenamiento, se juzga con prueba.** Flujo de la Clase 30: dividir (estratificado), ajustar con `fit` solo en entrenamiento, evaluar en datos que el modelo nunca vio.
3. **class_weight='balanced'.** Pondera cada clase de forma inversa a su frecuencia (aquí 0.63 y 2.39): el modelo se vuelve «alarmista», gana recall y pierde precisión. Es una decisión de modelado, no un arreglo gratuito.
4. **El umbral es una decisión de negocio.** Con 0.5 se detecta el 52 %; subirlo da más precisión y menos recall. Se elige según el costo de cada error.



Izquierda: los 240 clientes de prueba sobre la sigmoide (el color real no se usó para ubicarlos). Centro: precisión y recall según el umbral. Derecha: frontera de decisión con solo antigüedad y quejas (una recta, porque el logit es lineal).

Fórmulas y reglas

$$p = 1 / (1 + e^{-z})$$

$$z = b_0 + b_1x_1 + b_2x_2 + \dots$$

$$\text{odds} = p / (1 - p) = e^{z}$$

En Python

```
Pipeline([('imp', ColumnTransformer(...)),
          ('esc', StandardScaler()),
          ('lr', LogisticRegression())])
```

Con los datos de la clase

- Prueba de 240 clientes (20.8 % cancela): accuracy 73.3 %, precisión 39.4 %, recall 52.0 %, F1 44.8 %, AUC 0.685
- Coeficientes (estandarizados): quejas +1.08, antigüedad −0.80, uso −0.22, edad +0.08; intercepto −0.39
- Sin class_weight: precisión 69.2 %, recall 18.0 %

Cuidado
El 73.3 % de accuracy es **menor** que el 79.2 % de «nadie cancela». Con un AUC de 0.685 el modelo es modesto, no «una moneda» ni «excelente».

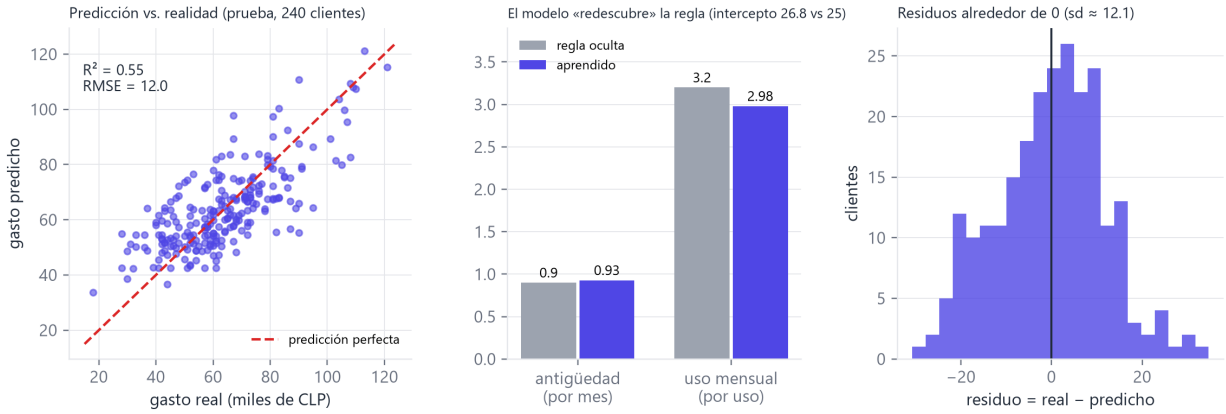
Clase 31 · Regresión: predecir un número

Fuente: transcripción de la clase + diapositivas + apunte + notebook y caso de la profesora Laura Sánchez

Si lo que se predice es un valor continuo (¿cuánto gastará?), el problema es de regresión. El modelo ajusta una función de las variables y se evalúa con el error entre lo predicho y lo real (MSE, RMSE, R^2).

Conceptos clave

1. **Métricas de error.** MSE = promedio de errores²; RMSE = su raíz, en las unidades del gasto (miles de CLP); R^2 = 1 − SSE/SST: la proporción de la variación explicada.
2. **Redescubrir una regla.** Los datos se generaron con gasto = 25 + 0.9·antigüedad + 3.2·uso + ruido. El modelo, sin conocer la fórmula, aprende 26.8, 0.93 y 2.98.
3. **R^2 moderado no es falla.** Con ruido (sd 12) sobre un gasto de sd 19, un R^2 de 0.55 es lo esperable: el techo lo pone el ruido, no el modelo.
4. **Mismo flujo, otra métrica.** En clasificación, matriz de confusión; en regresión, error cuadrático y R^2. Dividir y evaluar en datos no vistos no cambia.



Izquierda: predicción vs. gasto real en la prueba (R^2 0.55, RMSE 12.0). Centro: coeficientes ocultos y aprendidos. Derecha: los residuos se centran en 0 (sd ≈ 12).

Fórmulas y reglas

$$MSE = \frac{1}{n}\sum (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{MSE}$$

$$R^2 = 1 - SSE / SST$$

En Python

```
LinearRegression().fit(X_train, y_train)
mean_squared_error(y_test, pred)
r2_score(y_test, pred)
```

Con los datos de la clase

- MSE 144.9 · RMSE 12.0 · R^2 0.548 en la prueba (0.572 en entrenamiento)
- Coeficientes: antigüedad 0.929 (real 0.9), uso 2.981 (real 3.2), intercepto 26.76 (real 25)
- El gasto medio es 63.2 miles de CLP: un RMSE de 12 es ≈ 19 % del gasto medio

Cuidado
«Redescubrir» la fórmula es posible solo porque los datos se simularon con ella; en un caso real no existe una fórmula verdadera que comparar.

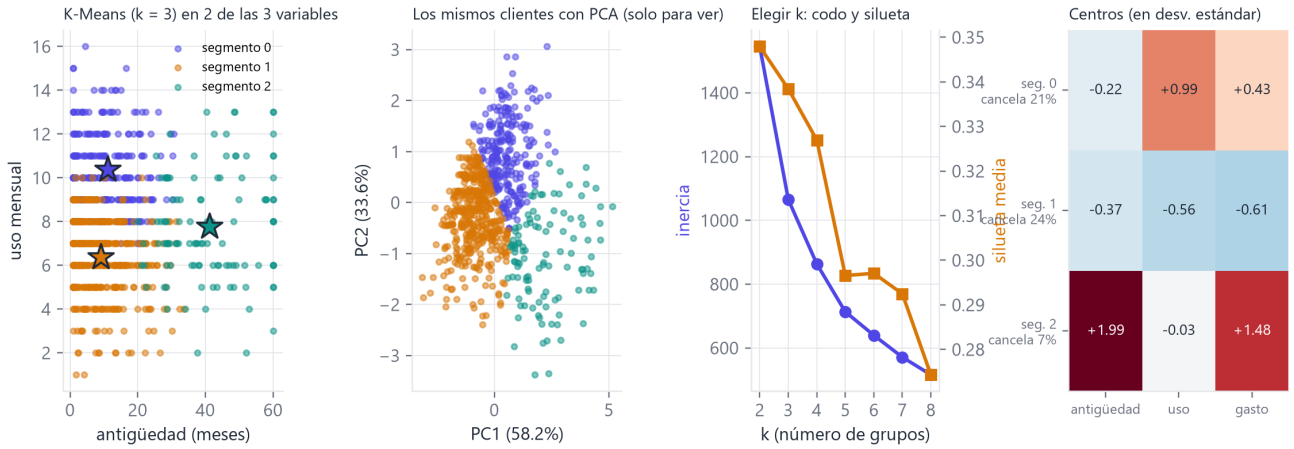
Clase 31 · Sin etiquetas: K-Means y PCA

Fuente: transcripción de la clase + diapositivas + apunte + notebook y caso de la profesora Laura Sánchez

En aprendizaje no supervisado no hay respuesta correcta; se busca estructura. K-Means forma grupos alrededor de centroides; PCA resume variables correlacionadas en pocos componentes. PCA no forma grupos: solo cambia el sistema de ejes.

Conceptos clave

1. **K-Means paso a paso.** Elegir k centroides → asignar cada punto al más cercano → recalcular cada centroide como la media de su grupo → repetir hasta que nada cambie. Minimiza la suma de distancias² a los centroides (inercia).
2. **Escalar antes de agrupar.** Se usan distancias: la variable de mayor escala domina. Sin estandarizar, los segmentos cambian (ARI 0.39 respecto de los estandarizados).
3. **Elegir k.** No hay un k verdadero: se mira el codo de la inercia, la silueta y, sobre todo, si los grupos tienen sentido para el negocio.
4. **Interpretar y validar.** Los grupos se leen mirando el perfil de cada uno. Aunque cancelo no se usó, un grupo (antiguos y de alto gasto) tiene 7 % de cancelación frente a 21–24 %.



K-Means con antigüedad, uso y gasto estandarizados (Club Activo). Izquierda: dos de las tres variables; segundo: los mismos clientes proyectados con PCA (58.2 % + 33.6 % = 91.8 % de la varianza); tercero: codo y silueta; derecha: perfil de cada segmento y su tasa de cancelación.

Fórmulas y reglas

$$\text{inercia} = \sum \|x_i - \mu_{c(i)}\|^2$$

μ_c = media de los puntos del grupo c

silueta ∈ [−1, 1]; más alta = grupos más separados

En Python

```
KMeans(n_clusters=3, n_init=10,
       random_state=42).fit_predict(Z)
silhouette_score(Z, etiquetas)
```

Con los datos de la clase

- Segmentos de 252, 439 y 109 clientes; silueta 0.348 (k = 2), 0.338 (k = 3), 0.327 (k = 4): sin un k claro
- Segmento 2: antigüedad +1.99 sd, gasto +1.48 sd, cancela 7 %; segmentos 0 y 1: 21 % y 24 %
- Base real, 6 variables de uso: k = 3, silueta 0.473; fuga de 24.7 %, 0.0 % y 2.3 % en la prueba

Cuidado
«Con dos de las tres variables llegamos a los mismos clústeres» no es exacto: los componentes mezclan las tres variables, y los clústeres los formó K-Means, no PCA.

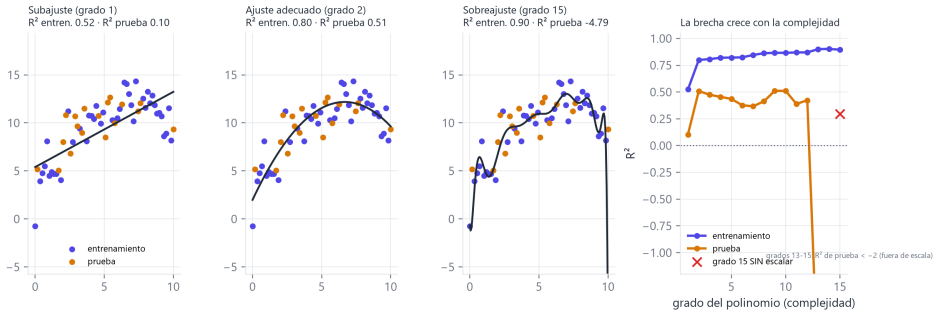
Clase 31 · Ajuste del modelo: subajuste, sobreajuste y regularización

Fuente: transcripción de la clase + diapositivas + apunte + notebook y caso de la profesora Laura Sánchez

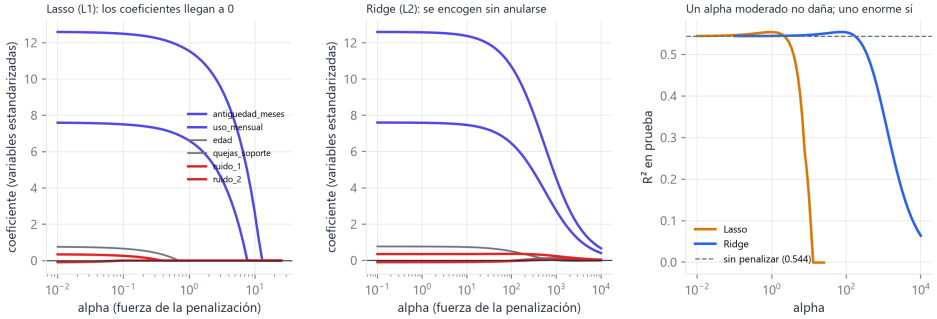
Un modelo demasiado simple no aprende el patrón (subajuste); uno demasiado complejo memoriza el ruido (sobreajuste). Se detecta comparando entrenamiento y prueba. La regularización penaliza coeficientes grandes: Ridge los encoge, Lasso puede llevarlos a cero.

Conceptos clave

1. **Subajuste y sobreajuste.** Subajuste: mal incluso en entrenamiento. Sobreajuste: muy bien en entrenamiento y mucho peor en prueba. La causa es la complejidad frente a los datos disponibles.
2. **Ridge (L2).** Penaliza $\Sigma\beta^2$: encoge todos los coeficientes, rara vez los anula.
3. **Lasso (L1).** Penaliza $\Sigma|\beta|$: lleva a cero los coeficientes poco útiles (selección automática).



Tres ajustes sobre la misma nube (60 puntos): grado 1, 2 y 15, y el R^2 de entrenamiento y prueba según el grado. La X roja es lo que ocurre sin escalar.



Caminos de coeficientes de Lasso y Ridge al subir alpha (antigüedad y uso en azul; ruido en rojo) y R^2 de prueba. Con alpha moderado el R^2 no cambia (0.544 → 0.552 con Lasso 0.5).

Fórmulas y reglas

Ridge: $\min \Sigma(y - \hat{y})^2 + \alpha \Sigma \beta^2$

Lasso: $\min \Sigma(y - \hat{y})^2 + \alpha \Sigma |\beta|$

si las columnas son ortonormales: Ridge = $\beta/(1+\alpha)$;

Lasso = $\text{signo}(\beta)\cdot\max(|\beta| - \alpha, 0)$

Con los datos de la clase

- Grado 1: R^2 0.52 / 0.10 · grado 2: 0.80 / 0.51 · grado 15 (escalado): 0.90 / −4.79 · (sin escalar: 0.30 / −0.56)
- Lasso (alpha 0.5) anula quejas, ruido 1 y ruido 2 y deja edad en 0.22; Ridge (alpha 5) apenas las encoge
- Con alpha enorme los dos tienden a predecir la media ($R^2 \approx 0$)

Cuidado
En el notebook de la clase el grado 15 sin escalar da R^2 de entrenamiento 0.30 (no «altísimo»): hay un problema numérico, no solo sobreajuste.

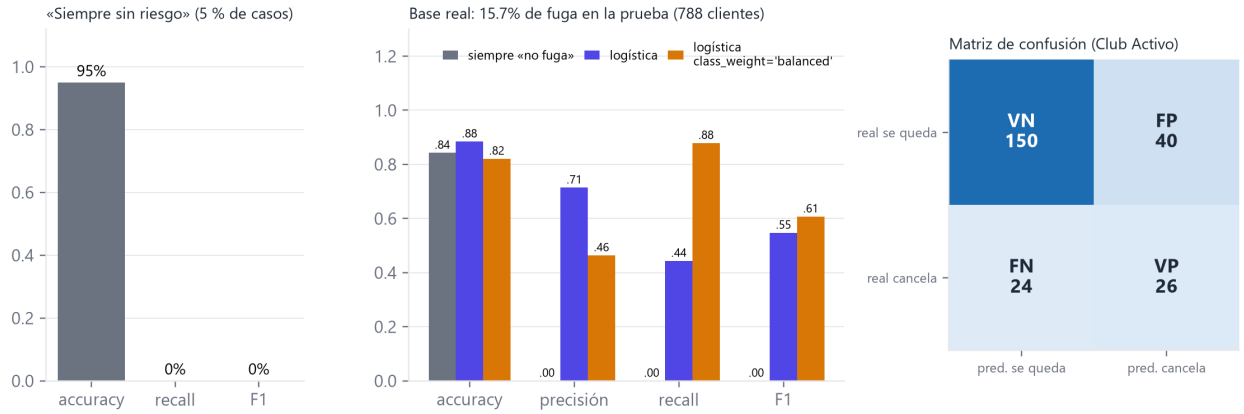
Clase 31 · Evaluar bien: la trampa del accuracy

Fuente: transcripción de la clase + diapositivas + apunte + notebook y caso de la profesora Laura Sánchez

Con clases desbalanceadas, un modelo que siempre responde «no pasa nada» obtiene un accuracy alto y un recall de 0. Hay que reportar la matriz de confusión y mirar precisión, recall y F1 junto con una línea base.

Conceptos clave

1. **Matriz de confusión.** Filas = real, columnas = predicho: VN y FP arriba, FN y VP abajo (convención de scikit-learn). Todas las métricas salen de estas cuatro cifras.
2. **Accuracy vs. recall.** Accuracy = (VP + VN)/total. Recall = VP/(VP + FN): de los que sí cancelan, cuántos se detectan. Precisión = VP/(VP + FP).
3. **Siempre comparar con la línea base.** En la base real, «nadie se fuga» ya logra 84.3 % de accuracy: un 88.5 % no es tan impresionante como parece.
4. **El costo manda.** Si dejar escapar un caso cuesta mucho más que una falsa alarma, se prioriza el recall (y se acepta menos precisión).



Izquierda: 1.000 casos con 5 % de riesgo y un modelo «perezoso». Centro: base real (prueba de 788 clientes) con la línea base, la logística y la logística balanceada. Derecha: matriz de confusión del modelo de Club Activo.

Fórmulas y reglas

precisión = VP / (VP + FP)

recall = VP / (VP + FN)

F1 = 2·precisión·recall / (precisión + recall)

En Python

```
confusion_matrix(y_test, pred)
DummyClassifier(strategy='most_frequent')
classification_report(y_test, pred)
```

Con los datos de la clase

- Club Activo: VN 150, FP 40, FN 24, VP 26 → precisión 26/66 = 39.4 %, recall 26/50 = 52.0 %
- Base real: logística 88.5 % acc, 71.4 % prec, 44.4 % recall, F1 0.547; balanceada 82.1 %, 46.4 %, 87.9 %, F1 0.607
- Mismo AUC (0.908 y 0.910): cambia el punto de operación, no la capacidad de ordenar

Cuidado
El F1 y el accuracy no se pueden leer como un ranking único: depende de qué error cuesta más.

Cómo elegir el enfoque, ML vs. Deep Learning y el flujo honesto

Primero el problema, luego el algoritmo

Pregunta	Si la respuesta es…	Enfoque a considerar
¿Tengo ejemplos con la respuesta correcta?	sí, y es una categoría	Clasificación (supervisado)
	sí, y es un número	Regresión (supervisado)
¿No tengo etiquetas?	quiero descubrir grupos	Clustering, p. ej. K-Means
	quiero simplificar muchas variables	Reducción de dimensionalidad, p. ej. PCA
¿Decisiones secuenciales con entorno?	ensayo y error con recompensa	Aprendizaje por refuerzo
¿Imágenes, audio, texto, gran volumen?	datos complejos	Deep Learning (redes neuronales)

Criterio	Machine Learning clásico	Deep Learning
Volumen de datos	suele bastar con miles de registros	suele necesitar muchísimos más
Hardware	CPU estándar	frecuentemente GPU
Extracción de atributos	manual, con conocimiento del negocio	automática, por capas ocultas
Interpretabilidad	en general mayor (la regresión lo es; otros modelos no)	en general menor
Casos de uso	datos tabulares, scoring	visión, audio, lenguaje, IA generativa

El Pipeline de la clase, honesto

`Pipeline([('imp', ColumnTransformer(...media / mediana...)), ('esc', StandardScaler()), ('lr', LogisticRegression(class_weight='balanced'))]).fit(X_train, y_train)`

El notebook de la clase imputa (media, mediana) y escala **antes** de dividir: es una fuga leve. Dentro de un Pipeline, cada paso aprende solo con entrenamiento y las métricas de la clase no cambian (73.3 / 39.4 / 52.0).

	Checklist del flujo	Cómo sé que lo hice bien
☐	Defino qué quiero predecir y qué decisión mejora	etiqueta o no, categoría o número
☐	Divido antes de imputar, escalar o ajustar	todo lo que aprende de los datos va en un Pipeline
☐	Comparo contra una línea base	«siempre la clase mayoritaria» o la regla fija actual
☐	Elijo la métrica según el costo del error	no solo accuracy; matriz de confusión completa
☐	Escalo antes de usar distancias o penalizaciones	K-Means, Ridge, Lasso
☐	Interpreto los segmentos con su perfil	los grupos de K-Means no traen nombre ni etiqueta

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene corregir (verificado con código)

Diapositivas, apunte y notebook

- **Nota del notebook sobre K-Means**: «el gasto mensual es la variable que más distingue al Segmento 2 y queda invisible». El que más lo distingue es la **antigüedad** (+1.99 sd; gasto +1.48) y sí se ve en el eje x. Los segmentos 0 y 1 se separan por uso (+0.99 frente a −0.56), también visible. Además se espera un segmento de **mayor** cancelación; ocurre lo contrario: el 2 cancela 7 % frente a 21 % y 24 %.
- **Sobreajuste con grado 15**: el texto habla de R^2 de entrenamiento «altísimo». Con `PolynomialFeatures(15)` sin escalar el R^2 de entrenamiento es 0.30 (menor que el 0.80 del grado 2) y el de prueba −0.56: la matriz está mal condicionada. Escalando, 0.90 y −4.79. El diagnóstico es correcto; las cifras de la celda no lo muestran.
- **K-Means (diapositiva 8)**: «encuentra centros (K) que minimizan la distancia entre los puntos de cada grupo». K es el número de grupos; se minimiza la suma de distancias² de cada punto a **su centroide**. Y PCA «elimina ruido visual»: descarta direcciones de poca varianza, que no es lo mismo que ruido.
- **Diapositiva 12**: «Modelos neuronales requieren conjuntos… divididos en entrenamiento, validación y prueba»: la división vale para **cualquier** modelo. **Diapositiva 13**: ML = «cajas blancas» y DL = «millones de registros» son tendencias, no reglas (un boosting no es caja blanca; hay redes con pocos datos).
- **Cierre del notebook**: «Próxima sesión (32): redes neuronales». La Clase 32 es reducción de dimensionalidad (PCA y t-SNE). Y `recomendar_enfoque` devuelve un solo enfoque como si fueran excluyentes.
- **Apunte**: dice que el modelo de clasificación usó «antigüedad, uso, edad, quejas y gasto» y que se predijo «un cliente nuevo»; usa cuatro variables (sin gasto) y predice el conjunto de prueba. En clase salió 22.8 % de cancelación; el notebook final da 20.9 %.

Lo dicho en clase

- «Precisión 51 % es como lanzar una moneda» y «recall 52 %… lo mismo que una moneda»: la comparación es con la **prevalencia** (20.8 %), no con 50 %. Un clasificador al azar tiene precisión igual a la prevalencia; este logra 39.4 % y AUC 0.685 (azar = 0.5): modesto, pero no es una moneda.
- «Esto es 149 verdaderos positivos»: la celda superior izquierda de scikit-learn son los **verdaderos negativos** (150 en el notebook final); los verdaderos positivos son 26.
- «Quitar quejas_soporte desbalanceó el modelo»: no cambia el balance de clases (20.8 %). Efecto real: accuracy 73.3 → 52.5 %, precisión 39.4 → 24.6 %, recall 52 → 62 %, F1 44.8 → 35.2 % y AUC 0.685 → 0.575. Subió solo el recall (lo dijo bien una participante).
- **90/10 «corre el riesgo de sobreajuste»**: un 10 % de prueba da una estimación ruidosa del error; el sobreajuste depende de la complejidad, no del porcentaje.
- **K-Means** «toma un punto, ve los más cercanos y mueve el centro»: no; asigna cada punto a su centroide más cercano y recalcula medias. **PCA «separa tres clústeres»**: los formó K-Means; PCA proyecta. «91.8 % de la *información*» es 91.8 % de la *varianza*.
- **Caso de repaso, pregunta 1.2**: predecir «cuántos meses le quedan antes de cancelar» no es sin más una regresión lineal; es un problema de tiempo hasta el evento con datos censurados (los que aún no cancelan), que se trata con análisis de supervivencia.

Transcripción con ruido

Whisper confundió KYC (KIC), K-Means (camins, Kamins, Cummings), accuracy (cura), recall (recol), PCA (PSA, IPCA), CAPTCHA (CAPCHAT), «redes neuronales» (jornales) y «Machine Learning» (Machilas, Machete). El volumen cayó a ≈ −65 dB desde ≈ 35:00 y a ≈ −78 dB desde ≈ 85:00 (se transcribió una copia amplificada); el recreo (≈ 0:59:00) no está en el video. Frases dudosas: «la gragasa» (omitida), «un platón de riesgo».

Criterio de dominio para pasar a la siguiente clase

- ☐ Clasifico un problema como clasificación, regresión, clustering, reducción de dimensionalidad o refuerzo
- ☐ Calculo a mano una probabilidad con la sigmoide y una iteración de K-Means
- ☐ Leo una curva de entrenamiento / prueba y explico qué hacen Ridge y Lasso
- ☐ Calculo accuracy, precisión, recall y F1 y comparo con la línea base
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos