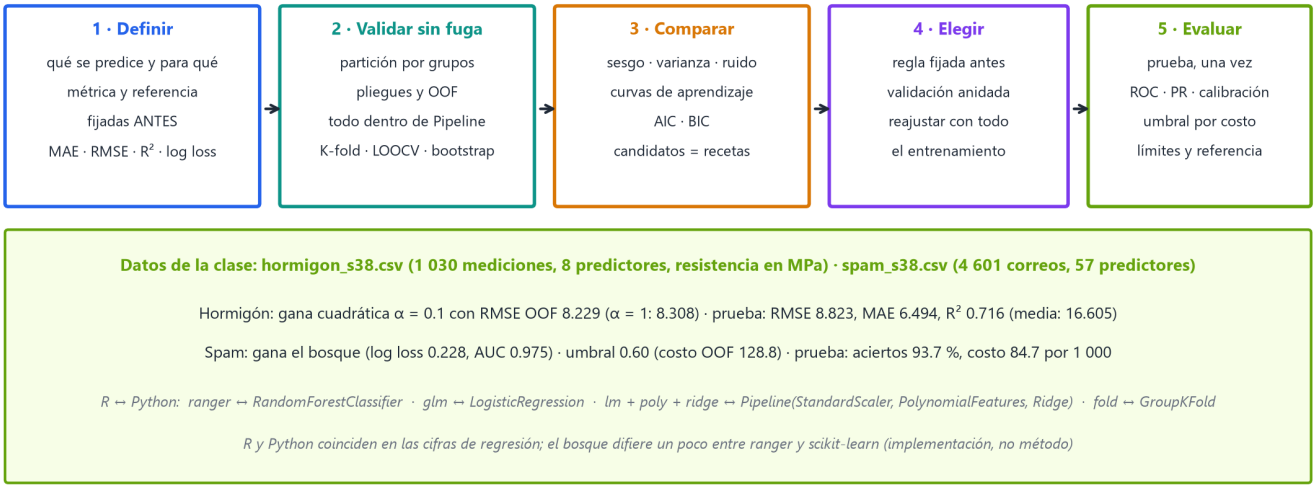
Clase 38 · Evaluación de modelos supervisados y selección de modelos

Profesor Eloy Alvarado · sigue a SVM y clasificadores clásicos (Clase 37) y precede a Naive Bayes (Clase 40) y al bootstrap (Clase 43)

La gran idea de la clase

«Mejor modelo» no significa nada hasta que se define **qué error importa** (la pérdida y la métrica), **en qué casos nuevos** (la partición) y **contra qué referencia**. El protocolo es siempre el mismo: fijar métrica y regla **antes** de ver resultados, comparar candidatos —cada uno una **receta completa**— con **validación cruzada** sin fuga de datos, **reajustar** lo elegido con todo el entrenamiento y evaluar **una sola vez** en la prueba reservada. En clasificación hay un paso más: una **probabilidad** no es una **decisión**; el umbral se elige según el costo de cada error.

La clase en una imagen



Lo que necesitas ANTES

- **Partición y validación** (Clase 30): entrenamiento, validación, prueba, K-fold y fuga de datos
- **Sobreajuste y regularización** (Clases 31 y 33): ridge y lasso; sesgo y varianza
- **Modelos** (Clases 34–37): regresión lineal y logística, bosques aleatorios y SVM como candidatos
- **Matriz de confusión, precision y recall** (Clase 37) e inferencia (Clase 22)

Ruta de la clase y datos

- **Qué es mejor → pérdida y métricas → pliegues y OOF → sesgo y varianza → elegir y reajustar → probabilidad, ROC/PR, calibración y umbral**
- **Hormigón** (regresión): 1 030 mediciones, 8 predictores, resistencia en MPa; **spam** (clasificación): 4 601 correos, 57 predictores
- Pregunta guía: ¿cuánto nos equivocaremos con datos que el modelo no vio, y cómo decidimos con honestidad?

Puentes con las clases vecinas (sin repetirlas)

C30 → C38: allí se aprendió a dividir y a validar; hoy se usa para *decidir* entre candidatos y se agrega la partición por grupos. **C31 → C38**: el sobreajuste de la Clase 31 se descompone en sesgo, varianza y ruido. **C34–C37 → C38**: árboles, bosques y SVM son solo candidatos; la evaluación es agnóstica al modelo. **C22 → C38**: la prueba reservada es un experimento: su cifra tiene incertidumbre (intervalo bootstrap). Lo nuevo de hoy: **validación anidada, bootstrap/.632, ROC y PR, calibración, umbral por costo y AIC/BIC**.

Recuadro: ¿qué es una receta?

Un candidato no es «una regresión»: es **todo** lo que se hace desde las columnas hasta la predicción (estandarizar, expandir términos, penalizar, umbral). Por eso se arma con un `Pipeline`: en cada pliegue se aprende con las filas de ajuste y se aplica a las de validación, y así no hay fuga.

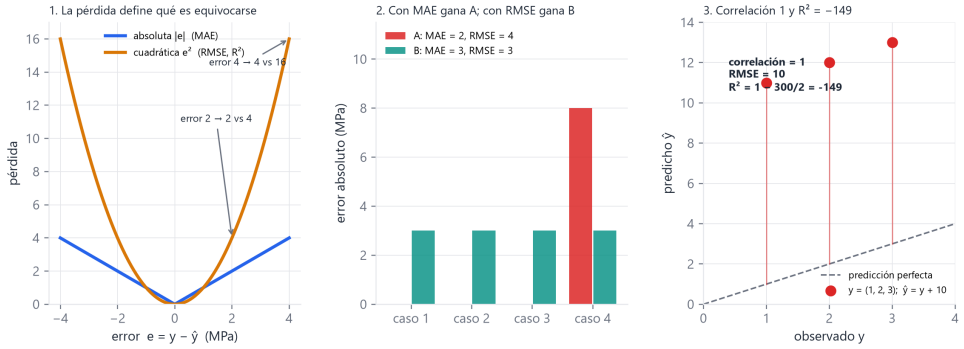
Clase 38 · Métricas y validación sin fuga

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

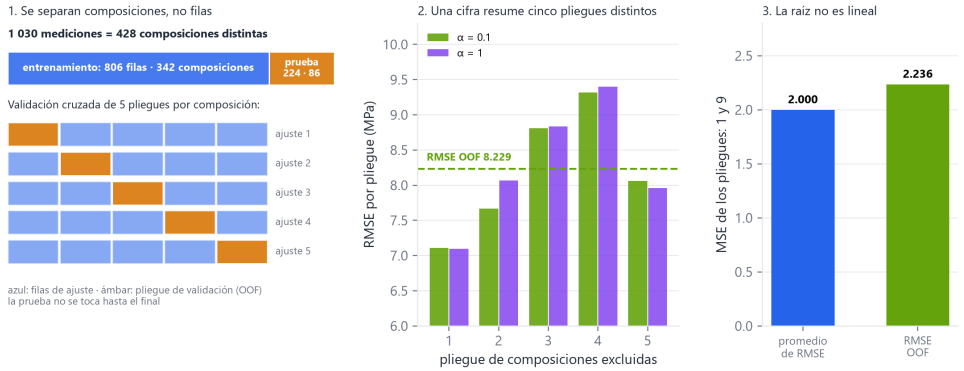
Una métrica resume el error con una pérdida; la partición representa los casos nuevos. En el hormigón se reservan composiciones completas (no filas), porque la misma mezcla aparece con varias edades.

Conceptos clave

1. **MAE, RMSE y R^2.** MAE promedia |error| (cada MPa pesa igual); RMSE promedia el cuadrado y luego saca raíz (castiga los errores grandes); $R^2 = 1 - SSE/SST$ compara con la media y **puede ser negativo**.
2. **Referencia primero.** El modelo constante (media de entrenamiento) obtiene RMSE OOF 16.75: es lo que aportan los predictores. Un candidato vale por cuánto mejora a su referencia.
3. **Pliegues por grupo y OOF.** 428 composiciones: 342 para ajustar (5 pliegues) y 86 para prueba. Cada fila recibe una predicción **fuera de pliegue**; con 7 candidatos son 35 ajustes.



Izquierda: un error de 4 pesa 4 con MAE y 16 con la pérdida cuadrática. Centro: el caso A (MAE 2, RMSE 4) gana con MAE y el B (MAE 3, RMSE 3) gana con RMSE. Derecha: correlación 1 y R^2 = -149.



Izquierda: la prueba (224 filas) se aparta y el entrenamiento se divide en 5 pliegues de composiciones. Centro: RMSE por pliegue de α = 0.1 y α = 1 (RMSE OOF 8.229). Derecha: con MSE de pliegues 1 y 9, promediar RMSE da 2 y el RMSE OOF da √5 = 2.236.

Fórmulas y reglas

$$MAE = (1/n)\ \Sigma\ |y_i - \hat{y}_i|$$

$$RMSE = \sqrt{[(1/n)\ \Sigma\ (y_i - \hat{y}_i)^2]}$$

$$R^2 = 1 - \Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2$$

$$RMSE\ OOF = \sqrt{[(1/806)\ \Sigma\ (y_i - \hat{y}_{i,OOF})^2]}$$

```
rmse = np.sqrt(np.mean((y - oof) ** 2))
mae = np.mean(np.abs(y - oof))
# oof[valida] = modelo.fit(X[~valida],
y[~valida]).predict(X[valida])
```

Con los números de la clase

- RMSE OOF: α = 0.1 → 8.229; α = 1 → 8.308; lineal → 10.560; media → 16.746 MPa
- Por pliegue, α = 0.1 gana en 3 de 5; promedio de RMSE 8.193 frente a RMSE OOF 8.229 (pliegues de 161–162 filas)
- Un $R^2 \approx 0.7$ no es «bueno» ni «malo» en abstracto: depende del campo (ciencias sociales frente a ingeniería)
- **Cuidado.** No se promedian los RMSE de los pliegues como si fueran datos independientes; y si se estandariza con todas las filas, la fuga ya ocurrió antes del primer pliegue.

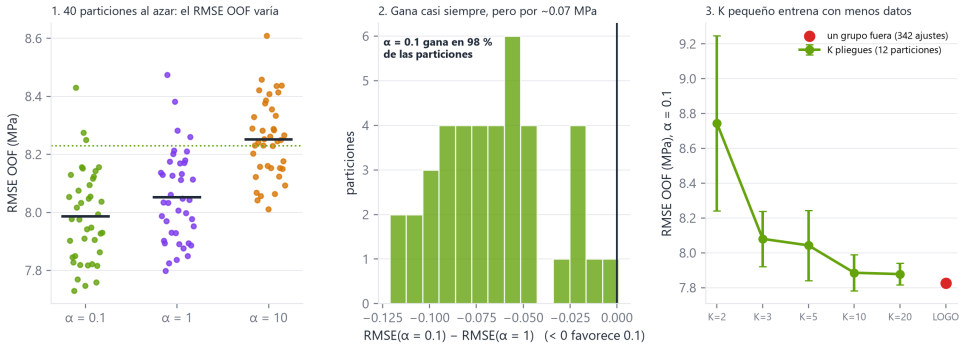
Clase 38 · La validación también varía: particiones repetidas, K y bootstrap

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

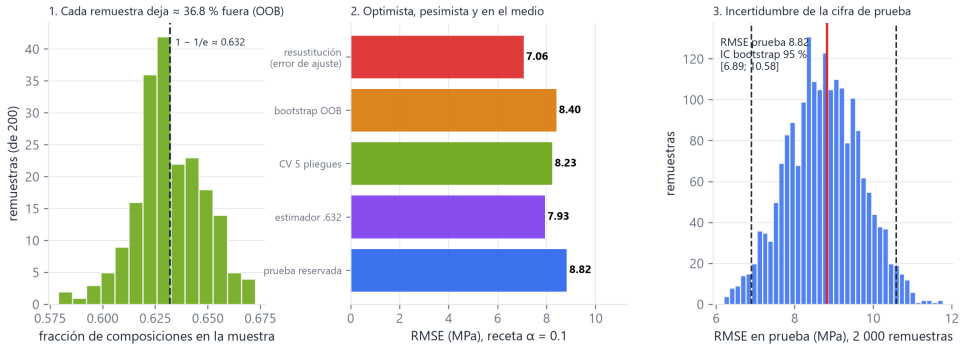
El RMSE OOF es una estimación: cambia si cambia la partición, y depende de cuántos datos se usan para ajustar. Repetir la partición y remuestrear (bootstrap) permite ver cuánto.

Conceptos clave

1. **Particiones repetidas.** Con 40 particiones al azar de las mismas composiciones, el RMSE OOF de α = 0.1 va de 7.73 a 8.43 (media 7.99, DE 0.16). Como los candidatos comparten pliegues, la *diferencia* es más estable que cada cifra.
2. **K, LOOCV y sesgo.** K = 2 entrena con la mitad y es pesimista (8.74); K = 5 da 8.04, K = 20 7.88 y dejar un grupo fuera (342 ajustes) 7.83. K grande: menos sesgo, más costo.
3. **Bootstrap y .632.** Cada remuestra de composiciones deja ≈ 36.8 % fuera (OOB). El error OOB es pesimista y el de ajuste, optimista; .632 los mezcla: 0.368·(ajuste) + 0.632·(OOB) en MSE → RMSE 7.93.



Izquierda: 40 particiones al azar para α = 0.1, 1 y 10 (rayas: medias). Centro: α = 0.1 gana en 98 % de las particiones, pero por solo ≈ 0.07 MPa. Derecha: RMSE OOF según K (barras: DE de 12 particiones) y dejando un grupo fuera.



Izquierda: fracción de composiciones que entran a la remuestra (≈ 0.632). Centro: cinco estimaciones del error de la misma receta (7.06 a 8.82 MPa). Derecha: bootstrap de las 86 composiciones de prueba: RMSE 8.82, IC 95 % [6.89; 10.58].

Fórmulas y reglas

fracción OOB = $(1 - 1/n)^n \to e^{-1} \approx 0.368$

MSE.632 = 0.368·MSE ajuste + 0.632·MSE OOB

error estándar de un promedio ≈ DE / √K (con cautela: no son independientes)

```
g = np.unique(grupos)
muestra = rng.choice(g, len(g), replace=True)
fuera = np.setdiff1d(g, muestra) # OOB
```

Con los números de la clase

- Prueba: RMSE 8.82; la media de entrenamiento obtiene 16.61; la reducción 46.9 % tiene IC 95 % de la diferencia de RMSE [3.98; 11.30] MPa
- CV 5 pliegues 8.229, bootstrap OOB 8.397, .632 7.931, prueba 8.823: ninguna es «la» verdad, todas son estimaciones
- **Cuidado.** Un intervalo de bootstrap con solo 86 composiciones es ancho; con casi-duplicados entre entrenamiento y prueba, además, la cifra es optimista (ver alertas).

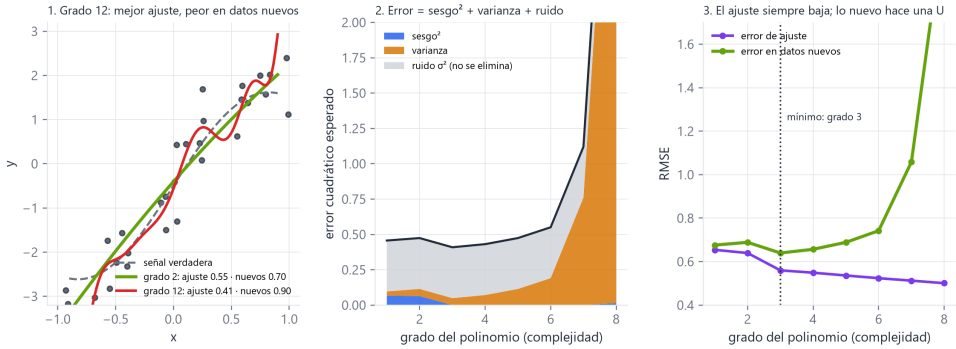
Clase 38 · Sesgo, varianza y complejidad

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

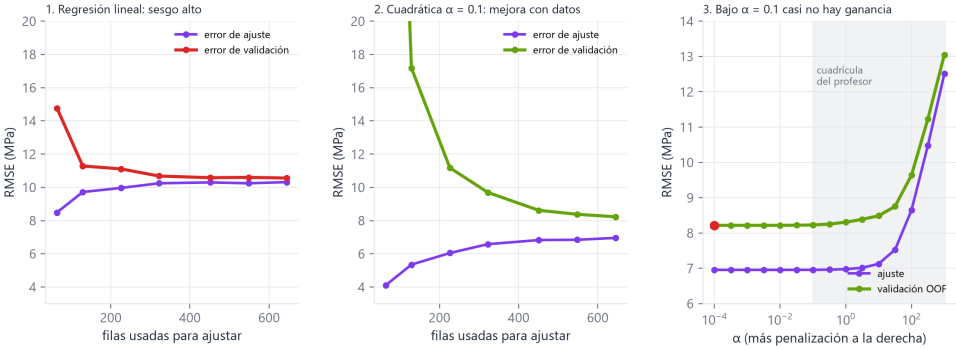
El error de predicción se descompone en sesgo² (qué tan lejos queda el ajuste promedio de la señal), varianza (cuánto cambia el ajuste con la muestra) y ruido (inevitable). Más flexibilidad baja el sesgo y sube la varianza.

Conceptos clave

1. **Error de ajuste ≠ error nuevo.** El error de ajuste siempre baja al añadir flexibilidad; el de datos nuevos hace una U. En la simulación el grado 12 ajusta mejor (0.41) y predice peor (0.90) que el grado 2 (0.55 y 0.70).
2. **Qué diagnostica cada curva.** Curva de aprendizaje: si ajuste y validación quedan altos y juntos → sesgo alto (añadir flexibilidad); si hay brecha grande → varianza alta (más datos o más penalización).
3. **Curva de validación.** En la cuadrícula del profesor (α ≥ 0.1) el mínimo está en el borde; bajar α hasta 10^{-4} solo mejora de 8.229 a 8.219 MPa: ganancia práctica nula.



Simulación (n = 30, σ = 0.6, 400 muestras por grado). Izquierda: un conjunto de datos con grado 2 y 12. Centro: la descomposición. Derecha: el mejor grado esperado es 3; el error de ajuste sigue bajando.



Izquierda y centro: curvas de aprendizaje del hormigón (error según filas de ajuste): la lineal se estanca alto (sesgo), la cuadrática sigue mejorando. Derecha: ajuste y validación según α; la zona gris es la cuadrícula del profesor.

Fórmulas y reglas

$$E[(Y - f(x))^2] = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$$

$$\text{Sesgo} = E[f(x)] - f(x)$$

$$\text{Varianza} = \text{Var}[f(x)]$$

ruido $\sigma^2 = \text{Var}(Y \mid X = x)$: no se reduce

```
from sklearn.model_selection import
learning_curve
# learning_curve(modelo, X, y, groups=g,
cv=GroupKFold(5), train_sizes=[.2, .5, 1.0])
```

Con los números de la clase

- Curva de aprendizaje de la cuadrícula: con 645 filas la cuadrática valida en 8.23 MPa y ajusta en 6.96; la lineal valida en 10.56 y ajusta en 10.32 (sesgo alto)
- Con α = 1000 sube el error de ajuste (13.05 RMSE OOF) porque la penalización restringe demasiado: sesgo alto otra vez
- **Cuidado.** La descomposición vale para un x fijo y ruido de media cero independiente del ajuste; con datos reales solo se estima su efecto conjunto con validación. Una U no está garantizada.

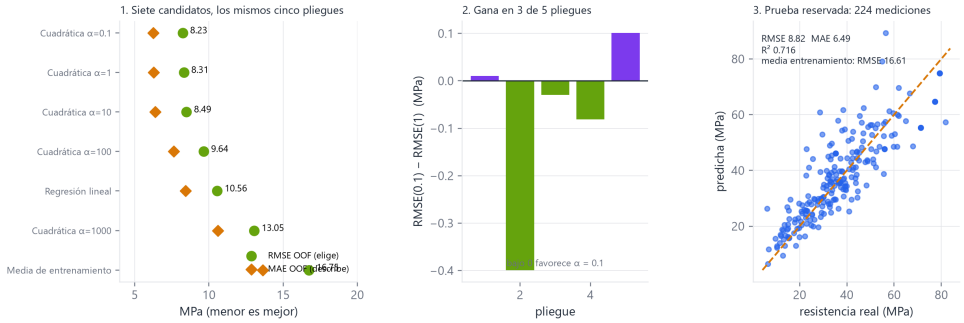
Clase 38 · Hormigón: elegir, reajustar y evaluar una vez

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

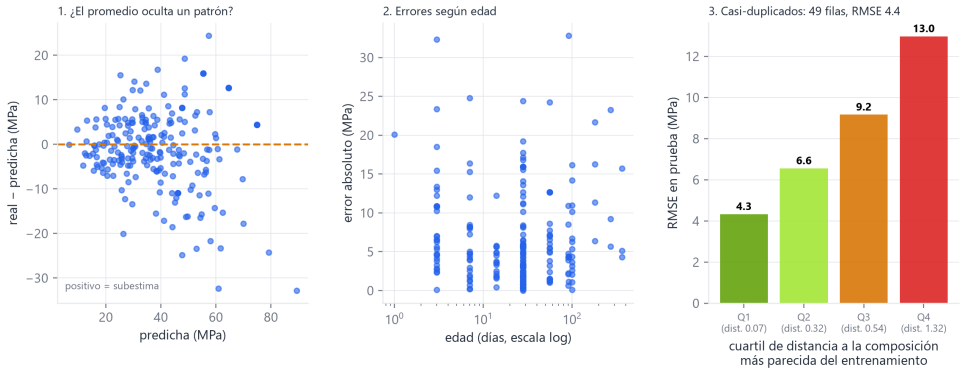
Siete recetas completas se comparan con los mismos cinco pliegues. Se elige con una regla fijada antes (menor RMSE OOF), se reajusta con las 806 filas y se evalúa una vez en las 224 reservadas.

Conceptos clave

1. **Elegir con OOF.** Gana la cuadrática con ridge α = 0.1 (8.229); α = 1 queda a 0.079 MPa. MAE y R^2 describen pero no cambian la regla.
2. **Reajustar, no promediar.** Se vuelven a estimar escalas y coeficientes con todo el entrenamiento. No se promedian los cinco modelos de la CV: sería otro procedimiento.
3. **Prueba y diagnóstico.** RMSE 8.823, MAE 6.494, R^2 0.716; la media da 16.605. Los residuos revelan dónde falla lo que el promedio esconde.



Izquierda: ranking OOF de los siete candidatos (RMSE elige; MAE describe). Centro: diferencia por pliegue entre α = 0.1 y 1. Derecha: predicción frente a resistencia real en prueba (224 mediciones).



Residuos y errores según la edad; a la derecha, el RMSE de prueba según qué tan cerca está cada composición de alguna del entrenamiento: 49 filas (22 %) son casi-duplicados y tienen RMSE 4.4.

Fórmulas y reglas

$\hat{m} = \text{argmin}_m \hat{R}_{CV}(m)$

reajustar: $\hat{m}$ con las 806 filas

evaluar: RMSE, MAE y R^2 en las 224 filas de prueba

mejora = 1 − RMSE_modelo / RMSE_media

```
ganador = ranking.modelo.iloc[0]
final = clone(modelos[ganador]).fit(X_tr, y_tr)
pred = final.predict(X_te)
```

Con los números de la clase

- Prueba: 8.823 MPa frente a 16.605 de la media: baja 46.9 %; R^2 de la media ≈ -0.007
- El RMSE de entrenamiento del ajuste final es 7.06: más bajo que en validación y prueba, como se espera
- Residuos: promedio -1.10 MPa y 43 % positivos (subestimación); error máximo 32.8 MPa
- **Cuidado.** Que gane por 0.079 MPa no prueba una superioridad estable; y si el resultado de prueba no gusta, no se vuelve a elegir con ella: se diseña una nueva selección con evaluación independiente.

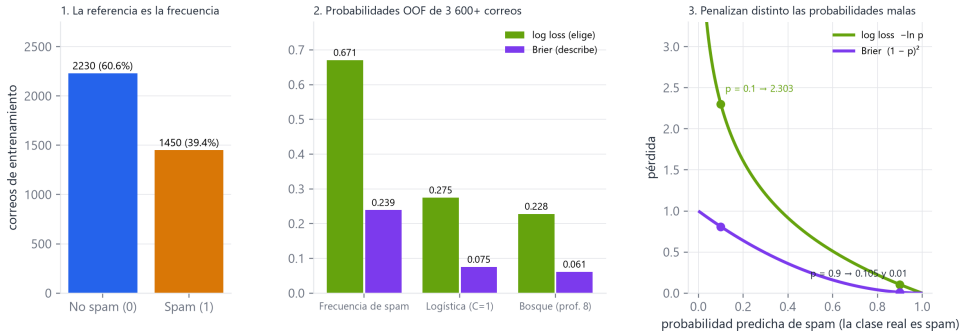
Clase 38 · Clasificación: probabilidades, costo y ranking

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

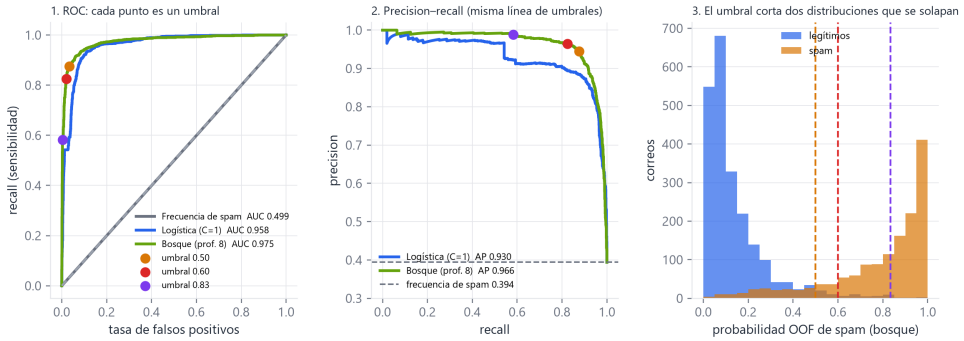
Un clasificador entrega una probabilidad; la decisión exige un umbral. Se evalúan tres cosas distintas: ¿ordena bien? (ROC, AP), ¿estima bien la probabilidad? (log loss, Brier, calibración) y ¿decide bien? (costo).

Conceptos clave

1. **Accuracy no basta.** «Siempre no spam» acierta 95 % de 100 correos con 5 % de spam y detecta 0. Dos matrices con el mismo 95 % tienen costos 90 y 210 por 1 000 con FP = 5 y FN = 1.
2. **Log loss y Brier.** Log loss = −ln p de la clase verdadera (p = 0.9 → 0.105; p = 0.1 → 2.303). Brier = $(y - p)^2$. Ambos premian probabilidades honestas; se elige por log loss OOF.
3. **ROC y precision–recall.** Cada punto de ambas curvas es un umbral. ROC: recall frente a tasa de FP; PR: precision frente a recall. AUC y AP resumen el ordenamiento; AP depende de la proporción de positivos.



Izquierda: la referencia es la frecuencia de spam (39.4 %). Centro: log loss y Brier OOF de los tres candidatos. Derecha: cómo castigan una probabilidad equivocada.



ROC con AUC 0.975 (bosque) y puntos para umbrales 0.50, 0.60 y 5/6; precision–recall con AP 0.966; a la derecha, las distribuciones OOF de legítimos y spam que el umbral corta.

Fórmulas y reglas

precision = VP / (VP + FP); recall = VP / (VP + FN)

F1 = 2·precision·recall / (precision + recall)

costo = (5·FP + 1·FN) / n (×1 000)

LogLoss = −(1/n) Σ [y ln p + (1 − y) ln(1 − p)]

```
log_loss(y, p); brier_score_loss(y, p)
roc_auc_score(y, p); average_precision_score(y, p)
confusion_matrix(y, p >= t, labels=[0, 1])
```

Con los números de la clase

- OOF (3 680 correos): log loss frecuencia 0.671, logística 0.275, bosque 0.228; Brier 0.239, 0.075, 0.061
- AUC bosque 0.975, AP 0.966; una AUC de 0.975 no es «97.5 % de aciertos»
- F1 prefiere B (0.783 frente a 0.706) pero el costo prefiere A: F1 no usa la razón 5:1
- **Cuidado.** La frecuencia de spam cambia la precision: misma sensibilidad 80 % y FP 10 %, con 50 % de spam es 88.9 % y con 5 % es 29.6 %. Una precision medida en un corpus no se traslada a otro.

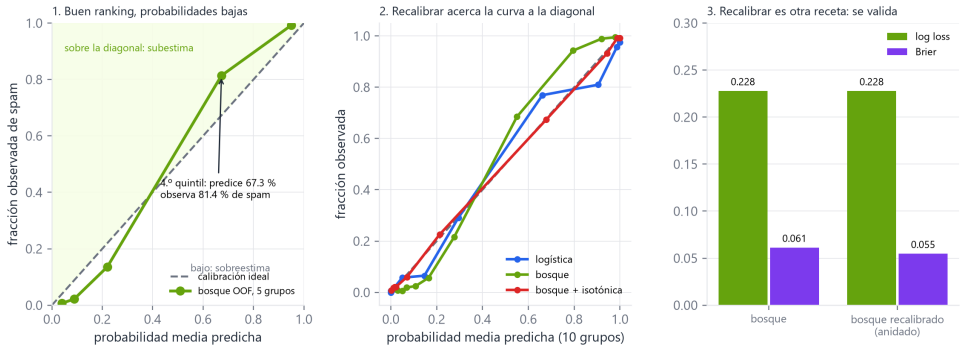
Clase 38 · Calibración y umbral por costo

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

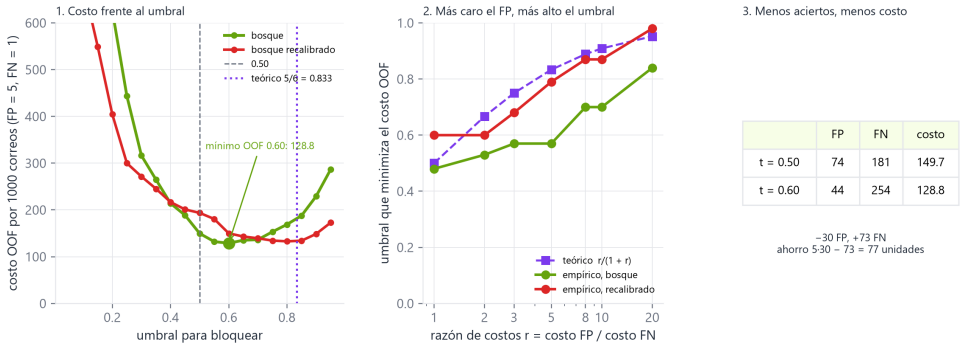
Un buen ranking no garantiza buenas probabilidades. La calibración compara lo que el modelo dice con lo que ocurre, y el umbral convierte probabilidades en acciones minimizando un costo declarado antes.

Conceptos clave

1. **Calibración.** Entre correos con probabilidad ≈ 0.8 esperamos ≈ 80 % de spam. El bosque, en su 4.º quintil, predice 67.3 % y observa 81.4 %: subestima.
2. **Umbral empírico y teórico.** Con costos conocidos y probabilidades correctas se bloquea si p > c_FP/(c_FP + c_FN) = 5/6 ≈ 0.833. El óptimo empírico del bosque es 0.60 (costo OOF 128.8), lejos de 0.833 por la mala calibración.
3. **Recalibrar es otra receta.** Con calibración isotónica anidada, el óptimo sube a 0.80 (cerca de la teoría), mejora el Brier (0.061 → 0.055), pero el costo OOF no baja (132.9).



Izquierda: curva de calibración del bosque en cinco grupos (sobre la diagonal, subestima). Centro: logística, bosque y bosque recalibrado en diez grupos. Derecha: log loss y Brier antes y después de recalibrar (todo anidado, sin mirar el pliegue de validación).



Izquierda: costo OOF por 1 000 correos según el umbral (mínimo del bosque en 0.60). Centro: umbral óptimo según la razón de costos, con la regla teórica r/(1 + r). Derecha: de 0.50 a 0.60 hay 30 FP menos y 73 FN más.

Fórmulas y reglas

bloquear si p > c_FP / (c_FP + c_FN)

costo esperado de bloquear = c_FP·(1 − p)

costo esperado de dejar pasar = c_FN·p

umbral teórico con 5:1 = 5/6 ≈ 0.833

```
CalibratedClassifierCV(modelo,
method='isotonic', cv=3)
costo = (5 * fp + fn) / n # por 1000: × 1000
```

Con los números de la clase

- Costos OOF por 1 000: t = 0.50 → 149.7; 0.55 → 132.3; 0.60 → 128.8; 0.65 → 135.3
- De 0.50 a 0.60: −30 FP, +73 FN; ahorro 5×30 − 73 = 77 unidades aunque los aciertos bajan de 93.1 % a 91.9 %
- Prueba (921 correos): t = 0.60 → aciertos 93.7 %, precision 98.4 %, recall 85.4 %, costo 84.7; «siempre no spam» cuesta 394.1
- **Cuidado.** La razón 5:1 es una prioridad hipotética elegida antes, no un costo medido; si cambia, cambia el umbral. Y no se reemplaza el umbral después de mirar la prueba.

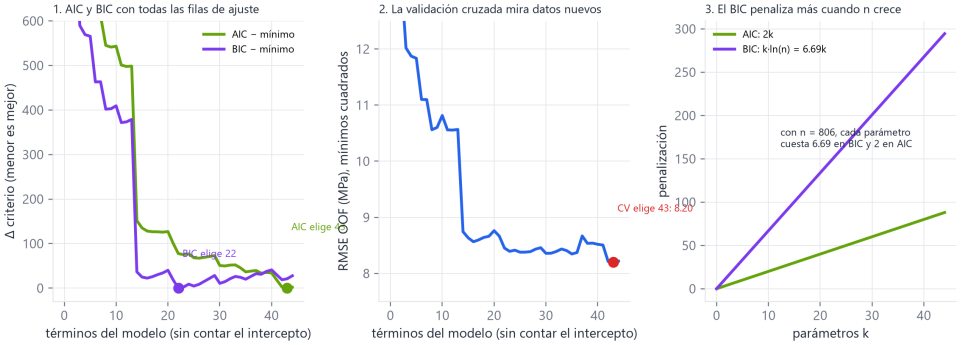
Clase 38 · AIC, BIC y validación anidada

Fuente: transcripción + diapositivas DipDS_2026_S38 + 38_evaluacion_seleccion.py / .R.txt del profesor Eloy Alvarado

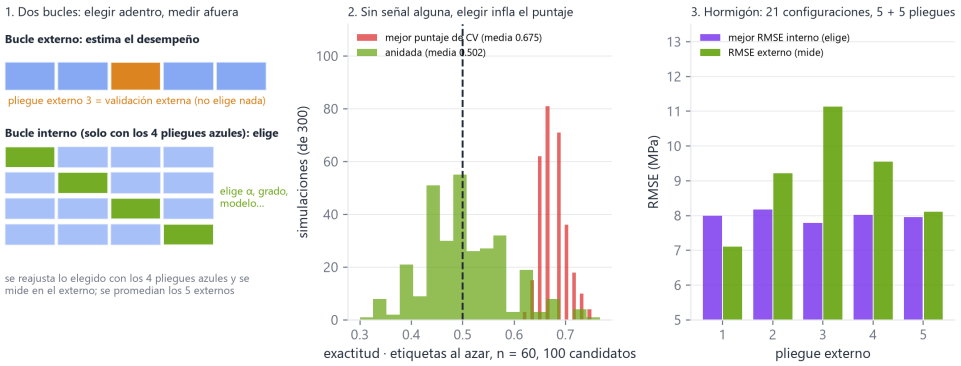
Hay dos maneras de penalizar la complejidad: con una fórmula (AIC, BIC) usando solo las filas de ajuste, o con validación (OOF). Y cuando además se elige con validación, el mejor puntaje obtenido es optimista: la validación anidada lo corrige.

Conceptos clave

1. **AIC y BIC.** AIC = −2 log L̂ + 2k; BIC = −2 log L̂ + k·ln n. Con n = 806 cada parámetro cuesta 2 en AIC y 6.69 en BIC. Menor es mejor y solo comparan modelos con los mismos datos.
2. **Cuándo coinciden con CV.** En el hormigón (OLS) el AIC elige 43 términos, la CV 43 y el BIC 22. No miran datos nuevos y suponen filas independientes.
3. **Validación anidada.** Bucle interno: elige hiperparámetros con las filas de ajuste; bucle externo: mide. Con etiquetas al azar, el mejor puntaje de CV entre 100 candidatos es 0.675; la anidada da 0.502 (la verdad: 0.5).



Izquierda: AIC y BIC (restados de su mínimo) según los términos del modelo OLS. Centro: RMSE OOF de los mismos modelos. Derecha: penalización de AIC (2k) y BIC (k·ln n).



Izquierda: los dos bucles. Centro: 300 simulaciones sin señal alguna. Derecha: hormigón con 21 configuraciones (grado × α): el mejor RMSE interno (7.99) es optimista frente al externo (9.12).

Fórmulas y reglas

AIC = n·ln(SSE/n) + 2k + const

BIC = n·ln(SSE/n) + k·ln(n) + const

ajustes: simple = pliegues × candidatos; anidada = externos × internos × candidatos + externos

```
GridSearchCV(pipe, rejilla, cv=GroupKFold(5))
cross_val_score(grid, X, y, groups=g,
cv=GroupKFold(5)) # anidada
```

Con los números de la clase

- AIC en los extremos: nulo 6830, lineal (8 términos) 6071, cuadrático (16) 5654, completo (44) 5528; BIC mínimo en 22 términos (5711)
- RMSE OOF: lineal 10.56, cuadrático sin penalizar 8.56, mínimo 8.20 con 43 términos
- Hormigón anidada: 530 ajustes (simple: 105); los hiperparámetros elegidos cambian entre pliegues externos
- **Cuidado.** AIC y BIC con un n ficticio (filas repetidas) parecen más seguros de lo que son. Y la anidada estima el desempeño de **todo el procedimiento** de selección; el modelo que se despliega se vuelve a elegir con todo el entrenamiento.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase

- **«El R^2 es un número entre 0 y 1»**: puede ser negativo, como el propio profesor mostró (correlación 1 y R^2 = -149); la media de entrenamiento da $R^2 \approx$ -0.007 en prueba.
- **«El ajuste … lo voy a realizar con el conjunto de prueba»** (sección del estandarizado): debe ser con el conjunto de **entrenamiento**; con prueba habría fuga.
- **«Voy a ocupar la pérdida cuadrática fuera de pliegue»** (clasificación): el script elige por **log loss** OOF; el Brier (error cuadrático de probabilidades) solo describe.
- **«Umbral 0.5 → costo 132; 0.6 → 128; 0.65 sube»**: los valores 132.3, 128.8 y 135.3 son de 0.55, 0.60 y 0.65; en 0.50 el costo es 149.7.
- **«α = 0.1 mejora en 2, 3 y 4; en el primero y el tercero gana α = 1»**: gana α = 1 en los pliegues **1 y 5**; α = 0.1 gana en 2, 3 y 4 (7.110 frente a 7.099, y 8.058 frente a 7.957).
- **«342 composiciones que representan 806 mediciones de las 1 030»**: son las de **entrenamiento**; el total es 428 y 86 están en prueba. Y «10 de los 1 000 datos … 9 990 restantes» mezcla 1 000 con 10 000.

Diapositivas, scripts y verificación

- **Grupos por igualdad exacta** no impiden casi-duplicados: 49 de 224 filas de prueba (22 %) tienen una composición del entrenamiento a menos de 0.1 desviaciones estándar y un RMSE de 4.4; las demás, 9.7. La cifra 8.82 es válida para esta partición, no para mezclas realmente nuevas.
- **«Elegir no prueba superioridad estable»** (diap. 26 y 29) se confirma y se matiza: con 40 particiones α = 0.1 gana en 98 %, pero por ≈ 0.07 MPa (< 1 %). El ranking es estable; la ventaja, trivial.
- **Umbral teórico (5/6) frente a empírico (0.60)** (diap. 55 y 53): lo explica la calibración (4.º quintil: predice 67 %, observa 81 %). Recalibrado, el óptimo empírico es 0.80, pero el costo OOF no mejora (132.9 frente a 128.8).
- **AIC y BIC** se nombran en clase pero no se calculan ni son OOF: aquí eligen 43 y 22 términos frente a 43 de la CV, con n = 806 filas no independientes.
- **R frente a Python** (diap. 50–57): el bosque difiere (log loss 0.228 y 0.223; costo a 0.60: 128.8 y 123.4) por implementación (`ranger` y scikit-learn), no por método; las cifras de este material son las de Python.
- **Detalles**: la diap. 24 nombra `38_evaluacion_seleccion.R` y se entrega `.R.txt`; el script de Python escribe sus resultados en una carpeta `resultados` junto al material.

Transcripción con ruido

Whisper escribió «Breyer / Bright / Ryre» por *Brier*, «lock-lock» por *log loss*, «ROP / ROCK» por *ROC*, «reach / rich / Bridge» por *ridge*, «lazo» por *lasso*, «OUF» por *OOF*, «ORMCE / RMC» por *RMSE*, «revisión» por *regresión*, «avaliación / ligación» por *validación* y «los pies» por *los pliegues*. El recreo (≈ 1:10:40 del video) quedó marcado en la transcripción.

Checklist, criterio de dominio y lo que viene

- ☐ Calculo MAE, RMSE y R^2 a mano y explico cuándo cada métrica cambia el ganador
- ☐ Separo por grupos, armo pliegues OOF y distingo el promedio de RMSE del RMSE OOF
- ☐ Diagnostico sesgo alto y varianza alta con curvas, y sé qué hacer en cada caso
- ☐ Construyo puntos de una ROC a mano, calculo la AUC por trapecios y elijo un umbral por costo
- ☐ Explico por qué la validación anidada y cuándo AIC/BIC y CV pueden discrepar
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Clase 40** (próxima del profesor): Naive Bayes y clasificación probabilística; **Clase 43**: evaluación estadística de modelos y bootstrap.