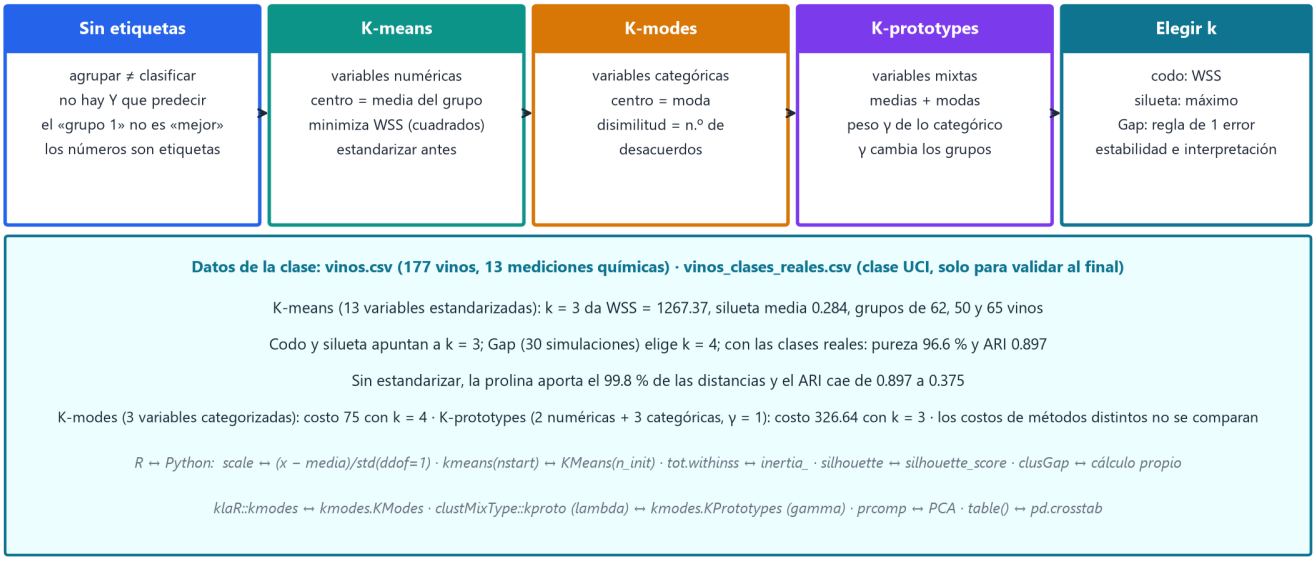
Clase 39 · Clustering: K-means, K-modes y K-prototypes

Profesor Pedro Luiz Ramos · retoma K-means y PCA (Clases 31 y 32); prepara el Taller 3 (pregunta 4) y se conecta con DBSCAN y Mahalanobis (Clase 41)

La gran idea de la clase

Agrupar no es clasificar: no hay una Y observada que predecir, así que no existe un «grupo correcto» y el «grupo 1» no significa «mejor» ni «positivo». **K-means** busca k centros (medias) que minimicen la suma de distancias al cuadrado de cada punto a su centro (WSS); **K-modes** hace lo mismo con categorías (modas y desacuerdos) y **K-prototypes** mezcla ambos con un peso γ. Hay que **estandarizar**, **repetir con varios inicios** (el algoritmo cae en mínimos locales), **elegir k** con varios criterios (codo, silueta, Gap) y **describir los grupos con perfiles**. Cuando existe una clase real, sirve solo para comprobar el método, nunca para ajustarlo.

La clase en una imagen



Lo que necesitas ANTES

- **K-means a mano** (Clase 31): asignar al centro más cercano y recalcular medias
- **Estandarización y PCA** (Clases 31 y 32): z = (x − media)/s; componentes para dibujar en dos ejes
- **Distancia euclidiana, media y moda**; matriz de contingencia (Clase 38)
- **R ↔ Python**: el profesor trae el mismo flujo en los dos lenguajes

Ruta de la clase y datos

- **Sin etiquetas → K-means y WSS/BSS → estandarizar e inicializar → elegir k → perfiles y validación → K-modes y K-prototypes**
- **vinos.csv**: 177 vinos y 13 mediciones químicas; **vinos_clases_reales.csv**: clase UCI (59, 71 y 47 vinos), solo para validar al final
- Pregunta guía: ¿qué grupos útiles hay y cuánta evidencia tengo de que no son un artefacto del método?

Puentes con otras clases (sin repetirlas)

C31/C32 → C39: allí se hizo una iteración de K-means y se vio el efecto de estandarizar; hoy se agregan el costo WSS/BSS, la elección de k y la validación. **C41 → C39**: K-means usa distancia euclidiana (ignora la correlación) y un solo extremo lo desvía; Mahalanobis y DBSCAN, de la Clase 41, son las salidas. **Taller 3, pregunta 4**: esta clase respalda ese ejercicio (K-means con k = 2 a 4, n_init ≥ 30, WSS y silueta media, perfiles de los grupos, y un grupo no es una clase predicha). Aquí no se resuelve nada con los datos del taller: la plantilla está en el notebook, con los vinos.

Recuadro: ¿un grupo es una clase?

No. Los grupos los fabrica el algoritmo con las variables elegidas; con otra escala, otro k u otro inicio salen otros. En los vinos, K-means con k = 3 coincide con la clase real en 171 de 177, pero eso se sabe solo porque existe una clase de comparación. Un grupo se justifica si es estable, tiene un perfil interpretable y sirve al propósito del análisis.

Clase 39 · K-means: asignar, promediar y el costo WSS

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

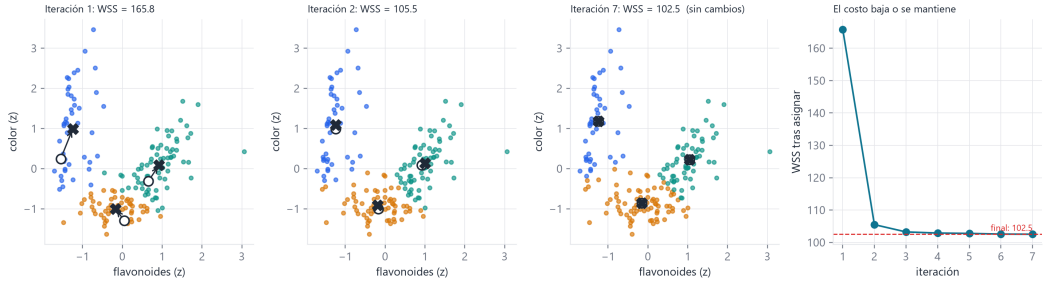
K-means repite dos pasos: asignar cada punto al centro más cercano y recalcular cada centro como la media de su grupo. Cada vuelta baja o mantiene el costo WSS; al no cambiar ninguna asignación, termina.

Conceptos clave

1. **El algoritmo.** Fijar k y centros iniciales → asignar → promediar → repetir. Con los vinos y k = 3 converge en 6 iteraciones; en el ejemplo de dos variables, en 7 (WSS 165.8 → 102.5).

2. **Qué minimiza.** WSS = Σ de $\|z - \mu_{grupo}\|^2$ (distancia euclidiana **al cuadrado**). Para un grupo fijo, el centro que minimiza ese costo es la media. Un WSS menor es más compacto, no «más verdadero».

3. **TSS = WSS + BSS.** Variabilidad total = dentro + entre grupos. Diapositiva 17: datos 1, 2, 3, 8, 9, 10 con centros 2 y 9: WSS = 4, BSS = 73.5, TSS = 77.5. En los vinos TSS = 2 288 y con k = 3: WSS = 1267.37, BSS = 1020.63.



Dos variables estandarizadas (flavonoides y color) con k = 3 y centros iniciales tomados de tres vinos. Los círculos blancos son los centros antes de actualizar y las cruces, después. El WSS final coincide con el de scikit-learn (102.54).



Izquierda: la iteración 1 de la diapositiva 13. Centro: TSS = WSS + BSS en el ejemplo pequeño. Derecha: en los vinos el TSS (2 288) es fijo; al subir k el WSS baja y el BSS sube.

Fórmulas y reglas

$$WSS = \sum_g \sum_{(i \text{ en } g)} \|z_i - \mu_g\|^2$$

μ_g = media de los z del grupo g

$$TSS = \sum \|z_i - \bar{z}\|^2 = WSS + BSS$$

$$BSS = \sum_g n_g \|\mu_g - \bar{z}\|^2$$

```
km = KMeans(3, n_init=50, random_state=2026,
            algorithm='lloyd').fit(z)
km.inertia_ # WSS
km.cluster_centers_; km.labels_ + 1
```

Con los números de la clase

- Diap. 13: con centros 1 y 8 los puntos 1, 2, 3 van al grupo 1 y 8, 9, 10 al grupo 2; nuevos centros 2 y 9
- Diap. 17: 1 + 0 + 1 + 1 + 0 + 1 = 4 (cuadrados); BSS = $3(2 - 5.5)^2 + 3(9 - 5.5)^2 = 73.5$
- R: `tot.withinss` = `inertia_`; `betweenss` = TSS − WSS
- **Cuidado.** El WSS usa distancias **al cuadrado** (en clase se dijo «sacamos la raíz»; con ceros y unos da igual, con otros números no). El centro es la media, no «una distancia».

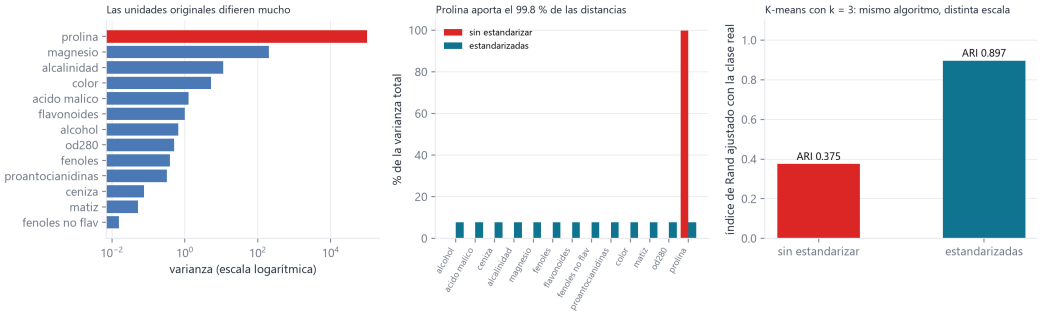
Clase 39 · Estandarizar e inicializar

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

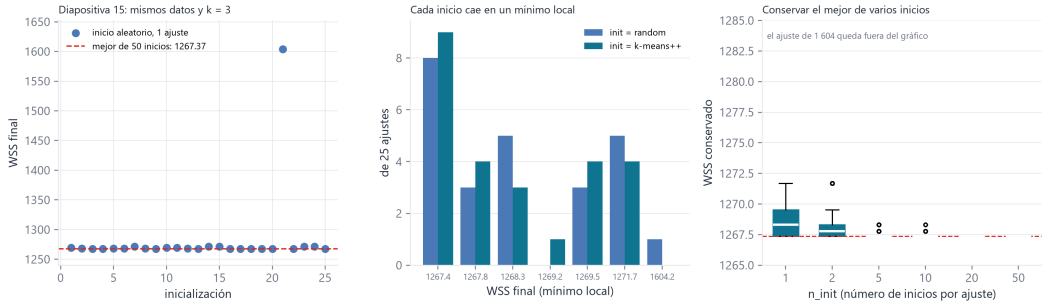
K-means usa distancias, así que una variable con unidades grandes domina el resultado. Y como el algoritmo cae en mínimos locales, hay que repetirlo desde varios inicios y quedarse con el de menor WSS.

Conceptos clave

1. **Estandarizar.** z = (x − media)/s con s muestral (`ddof=1`, igual que `scale()`). Ejemplo de la clase: alcohol 14, media 13, desviación 0.8 → z = 1.25. No elimina atípicos ni correlaciones.
2. **Qué pasa sin estandarizar.** La prolina (varianza 99 292) aporta el 99.8 % de las distancias; K-means casi solo ve prolina: ARI con la clase real 0.375 contra 0.897 estandarizando.
3. **Inicialización.** Con inicios aleatorios y un solo ajuste, 25 corridas dieron 6 valores de WSS entre 1267.37 y 1604.15. Conservar el mejor de n_init = 50 da 1267.37.



Izquierda: varianzas originales de las 13 variables (escala logarítmica). Centro: parte de la varianza total que aporta cada variable, con y sin estandarizar. Derecha: concordancia con la clase real (ARI) en ambos casos.



Izquierda: WSS final de 25 ajustes de un solo inicio (diapositiva 15). Centro: cada corrida termina en un mínimo local (aleatorio y k-means++). Derecha: el WSS que se conserva al aumentar n_init.

Fórmulas y reglas

z_ij = (x_ij − media_j)/s_j

ARI = 1: grupos iguales a las clases; ≈ 0: como al azar

n_init: nº de inicios; se conserva el menor WSS

StandardScaler usa ddof = 0 (divisor n)

```
z = (x - x.mean()) / x.std(ddof=1)
KMeans(3, init='random', n_init=1)
KMeans(3, n_init=50) # conserva el mejor
```

Con los números de la clase

- Con `StandardScaler` (divisor n) el WSS es 1274.57 en vez de 1267.37 (factor 177/176), con los mismos grupos (ARI 1.0)
- De 25 inicios aleatorios, 8 alcanzan el óptimo 1267.37; el peor llega a 1604.15 (26.6 % más)
- El profesor lo resumió así: conservar el ajuste de menor WSS entre varias inicializaciones; en R es `nstart`
- **Cuidado.** Se conserva el de **menor WSS**, no «el que más aparece». Y 50 inicios no garantizan el óptimo global; con k grande conviene aumentar n_init.

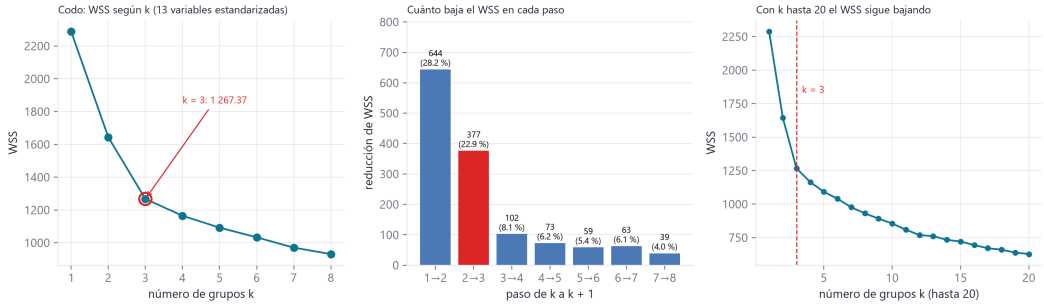
Clase 39 · Elegir k (1): codo y silueta

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

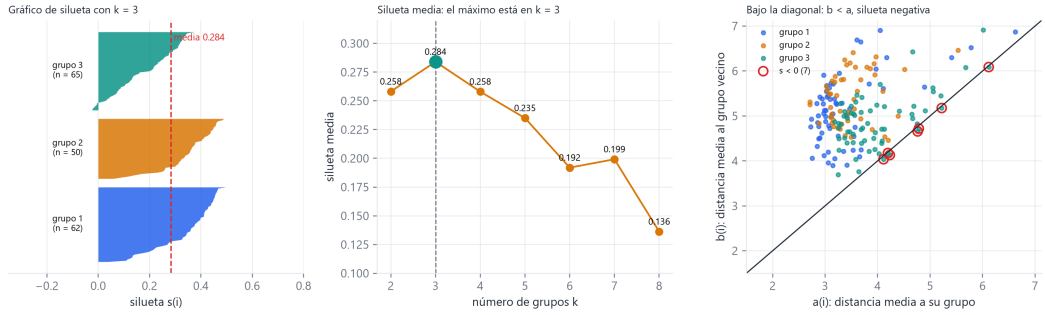
No existe un k «verdadero»: el WSS siempre baja al subir k (con k = n vale cero). Por eso se usan criterios adicionales: el codo mira dónde la ganancia se vuelve pequeña y la silueta mide qué tan separados quedan los grupos.

Conceptos clave

1. **Codo.** WSS para k = 1 a 8: 2 288, 1 644, 1 267, 1 165, 1 092, 1 033, 970, 931. La reducción cae de 377 (2 → 3) a 102 (3 → 4): el cambio de pendiente sugiere k = 3. No es una prueba formal.
2. **Silueta.** s(i) = (b − a)/máx(a, b), con a la distancia media a su grupo y b la menor distancia media a otro grupo. Cerca de 1: bien separado; cerca de 0: zona de superposición; negativo: más cerca de otro grupo. Ejemplo de la clase: a = 2, b = 6 → 0.667.
3. **Silueta media.** Máximo en k = 3 (0.284); k = 2 y k = 4 dan 0.258 y 0.258. El grupo 3 es el menos nítido: media 0.177 y 7 vinos con silueta negativa.



Izquierda: el codo en k = 3. Centro: cuánto baja el WSS en cada paso. Derecha: con k hasta 20 el WSS sigue bajando (no hay un k que lo minimice).



Izquierda: gráfico de silueta con k = 3. Centro: silueta media según k. Derecha: a(i) frente a b(i); los vinos bajo la diagonal tienen s < 0.

Fórmulas y reglas

s(i) = (b(i) − a(i)) / máx{a(i), b(i)}

a(i): distancia media a los demás de su grupo

b(i): menor distancia media a otro grupo

se usa la distancia euclidiana, no su cuadrado

```
silhouette_score(z, km.labels_) # media
silhouette_samples(z, km.labels_) # s(i)
# k = 1: no hay silueta (falta un grupo vecino)
```

Con los números de la clase

- Cálculo del script con 13 variables: silueta media 0.2582, 0.2840, 0.2580, 0.2350… para k = 2, 3, 4, 5…
- Calculada a mano con a(i) y b(i), la silueta coincide con scikit-learn (sí); el vino con silueta más baja es VIN79 (s = -0.024)
- Un grupo con una sola observación tiene silueta 0 por convención
- **Cuidado.** Un máximo de silueta de 0.28 es modesto: hay superposición. Y el codo y la silueta pueden discrepar; se decide con ambos y con la interpretación.

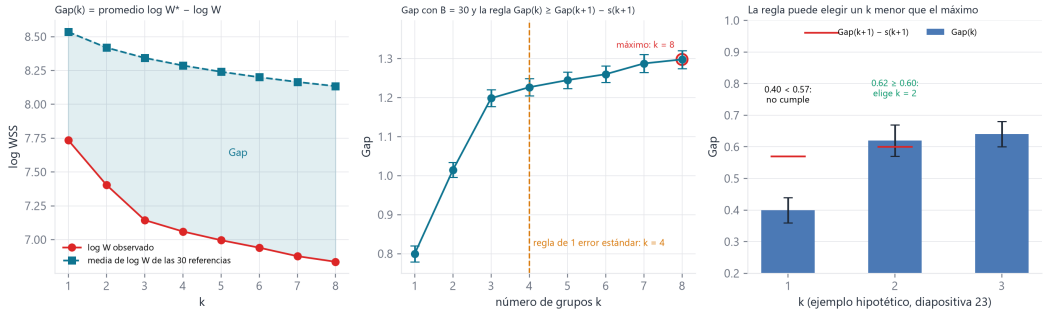
Clase 39 · Elegir k (2): Gap y perfiles de los grupos

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

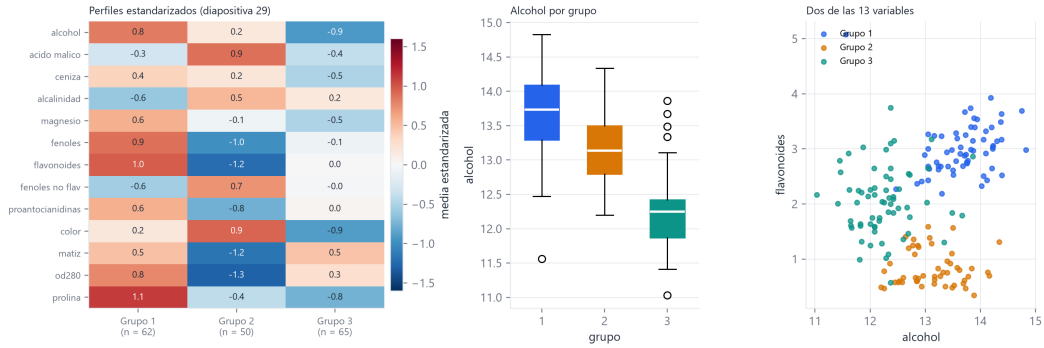
El Gap compara el WSS observado con el de datos simulados sin estructura de grupos. Una vez elegido k, se describen los grupos con sus perfiles (en la escala original y estandarizada), no con su número.

Conceptos clave

1. **Estadístico Gap.** Gap(k) = promedio de log W* − log W, con B = 30 bases uniformes en el rango de cada columna. Regla: el primer k con Gap(k) ≥ Gap(k+1) − s(k+1). Aquí da k = 4; el máximo de Gap está en k = 8 (la curva no tiene un máximo interior).
2. **Cuando discrepan.** Codo y silueta: k = 3; Gap: k = 4. La decisión de k = 3 salió de la mayoría de criterios. La regla es una cuasi-empate: Gap(3) = 1.199 no llega a 1.205, que es Gap(4) − s(4).
3. **Perfiles.** Grupos de 62, 50 y 65 vinos. Grupo 1: más prolina, flavonoides y alcohol; grupo 2: más color y ácido málico, menos matiz y flavonoides; grupo 3: menos alcohol, color y prolina.



Izquierda: log W observado frente al de las referencias simuladas. Centro: Gap con barras de error y la regla. Derecha: el ejemplo hipotético de la diapositiva 23 (elige k = 2 aunque Gap sigue subiendo).



Izquierda: medias estandarizadas por grupo (diapositiva 29). Centro: alcohol por grupo. Derecha: dos de las 13 variables, aunque el ajuste usó las 13.

Fórmulas y reglas

$$\text{Gap}(k) = (1/B)\ \Sigma_b \log W^*_{kb} - \log W_k$$

$$s_k = \text{sd}(\log W^*_k) \cdot \sqrt{(1 + 1/B)}$$

elegir el primer k con $\text{Gap}(k) \geq \text{Gap}(k+1) - s_{k+1}$

perfil = media del grupo (escala original o z)

```
ref = rng.uniform(z.min(), z.max(),
size=z.shape)
gap = log_wss_ref.mean(0) - np.log(wss)
x.groupby(grupo).mean() # perfiles
```

Con los números de la clase

- Perfiles originales (alcohol, flavonoides, color): grupo 1: 13.68, 3.00, 5.45; grupo 2: 13.14, 0.82, 7.18; grupo 3: 12.25, 2.05, 2.97
- Con 4 semillas distintas y con B = 60 la regla sigue dando k = 4
- Los números de grupo son etiquetas: el grupo 1 de R es el 3 de Python (diapositiva 27)
- **Cuidado.** Los perfiles son medias del grupo y no describen a cada vino. Y no permiten hablar de precio, calidad ni preferencia.

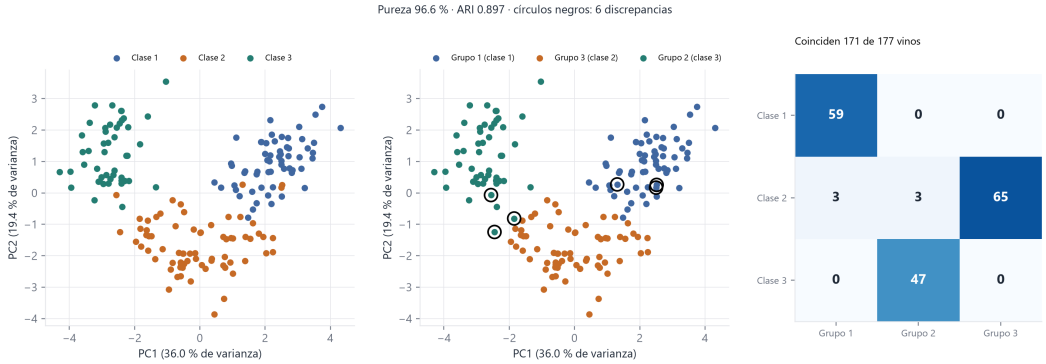
Clase 39 · Validar con las clases reales y con PCA

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

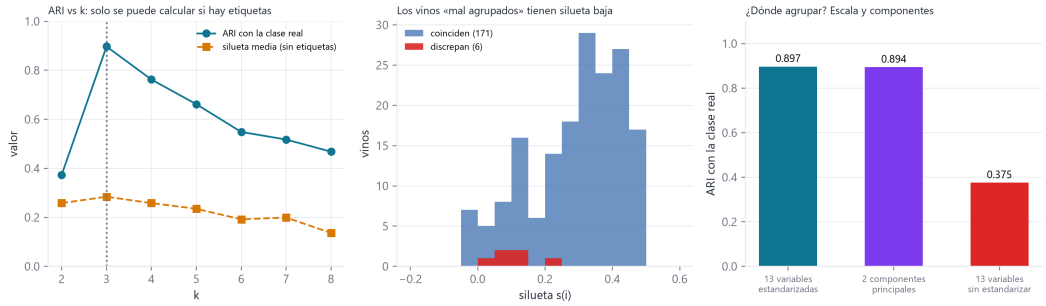
Los vinos traen una clase real que K-means no usó. Compararla con los grupos sirve para evaluar el método (pureza, ARI), no para elegir k en un problema real, donde esa clase no existe. El PCA solo ayuda a dibujar.

Conceptos clave

1. **Tabla de contingencia.** Con k = 3: coinciden 171 de 177 vinos (pureza 96.6 %, ARI 0.897). Las 6 discrepancias son vinos de la clase 2: 3 en el grupo 1 y 3 en el grupo 2; 65 de esa clase forman el grupo 3.
2. **PCA para dibujar.** Las dos primeras componentes explican 55.3 % de la varianza. K-means se ajustó con las 13 variables; ajustarlo sobre las 2 componentes da ARI 0.894, casi igual aquí, pero en general se pierde información.
3. **Qué no es.** La pureza es descriptiva de estos vinos, no la exactitud en vinos nuevos. Con k distinto de 3 el ARI cae (0.76 con k = 4), pero sin etiquetas ese dato no existe: la silueta no lo reemplaza.



Izquierda: clases reales en el plano de las dos primeras componentes. Centro: grupos de K-means coloreados por su clase mayoritaria; círculos negros, las 6 discrepancias. Derecha: tabla de contingencia.



Izquierda: ARI y silueta media según k. Centro: los vinos que discrepan tienen silueta baja. Derecha: ARI al agrupar con las 13 variables estandarizadas, con 2 componentes o sin estandarizar.

Fórmulas y reglas

pureza = Σ_grupos (máx. clase en el grupo) / n

ARI: 1 = igual, ≈ 0 = azar, puede ser negativo

el número de grupo es arbitrario: cambia al permutar

T = pd.crosstab(clase_real, grupo)

```
pd.crosstab(clase_real, grupo)
adjusted_rand_score(clase_real, grupo)
PCA(2).fit_transform(z) # solo para dibujar
```

Con los números de la clase

- Los 6 vinos que discrepan (VIN116, VIN104, VIN94, VIN82, VIN59, VIN56) tienen silueta media 0.112, contra 0.290 del resto
- Sin estandarizar el ARI baja a 0.375; con 2 componentes, 0.894; con las 13 estandarizadas, 0.897
- Recomendación del profesor: agrupar con la base original y usar el PCA solo para visualizar
- **Cuidado.** Comparar con una clase real valida el método en un caso de laboratorio. En la práctica no hay clase real: se valida con estabilidad, perfiles y propósito.

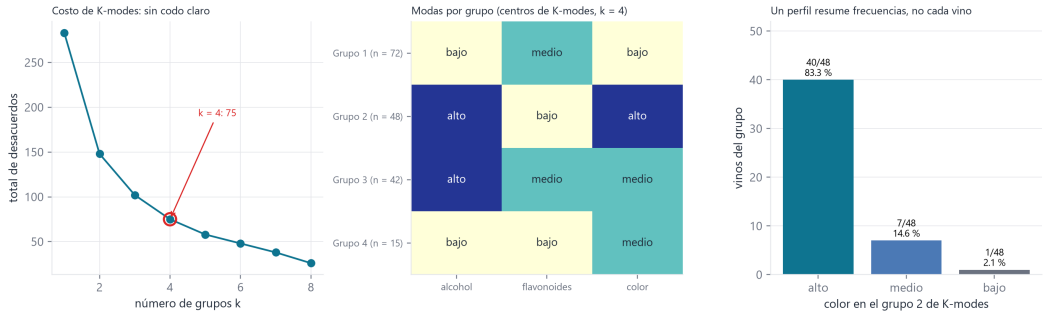
Clase 39 · K-modes y K-prototypes

Fuente: transcripción + diapositivas clase_39_clustering.pdf + kmeans_numero_clusters.py / .R del profesor Pedro Luiz Ramos

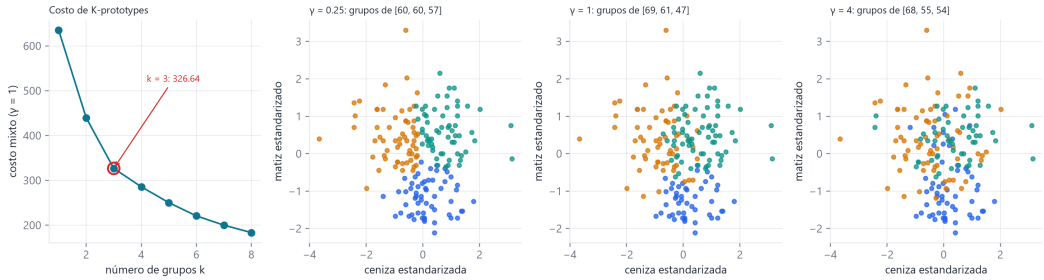
Si las variables son categóricas no se puede promediar: el centro es la moda y la distancia cuenta desacuerdos (K-modes). Con variables mixtas se suman un término de medias y otro de modas ponderado por γ (K-prototypes).

Conceptos clave

1. **K-modes.** Disimilitud d(x, m) = nº de variables con valor distinto. Diap. 33: cliente (Gold, App, Sur) frente a (Gold, App, Norte): 1; frente a (Silver, Web, Sur): 2. Con alcohol, flavonoides y color categorizados, el costo con k = 4 es 75.
2. **K-prototypes.** $d = \Sigma_{num} (x - \mu)^2 + \gamma \Sigma_{cat} 1(x \neq moda)$. Diap. 43: observación (1, 2) y (App, Sur): costo 1 + γ frente a 2; con γ = 0.5 gana A y con γ = 3 gana B. Con ceniza y matiz estandarizados más 3 categóricas, k = 3 y γ = 1: costo 326.64.
3. **El peso importa.** Con γ = 0.25, 1 y 4 los grupos son de [60, 60, 57], [69, 47, 61] y [55, 68, 54]; entre γ = 0.25 y 1 el ARI es 0.63. Sin variable respuesta no hay ROC ni validación cruzada para elegir γ.



Izquierda: costo de K-modes para k = 1 a 8 (sin codo claro). Centro: modas de cada grupo con k = 4. Derecha: el perfil del grupo 2: color alto en 40 de 48 vinos.



Izquierda: costo de K-prototypes (γ = 1). Derecha: tres particiones con k = 3 y γ = 0.25, 1 y 4, vistas en ceniza y matiz (colores alineados por el centro de matiz).

Fórmulas y reglas

K-modes: $d(x, m) = \Sigma_j 1(x_j \neq m_j)$

K-prototypes: $\Sigma_{num} (x_j - \mu_j)^2 + \gamma \Sigma_{cat} 1(x_j \neq m_j)$

centro: media (numérica) o moda (categórica)

costos de métodos distintos no son comparables

```
KModes(n_clusters=4, init='Huang', n_init=20)
KPrototypes(n_clusters=3, gamma=1, init='Huang')
kp.fit(X, categorical=[2, 3, 4])
```

Con los números de la clase

- Costos de la diap. 52: K-means 1267.37 (k = 3), K-modes 75 (k = 4), K-prototypes 326.64 (k = 3): **no se comparan** (unidades y funciones de costo distintas)
- Diap. 41: grupo de K-modes con n = 48: color alto 40 (83.3 %), medio 7 (14.6 %), bajo 1 (2.1 %)
- Elegir método: solo numéricas → K-means; solo categóricas → K-modes; mezcla → K-prototypes
- **Cuidado.** Categorizar una variable continua pierde información (cortes docentes, no umbrales enológicos). Y γ no es la penalización de Ridge: es un peso entre dos partes de la distancia.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase (transcripción)

- **«WSS: sacamos la raíz»** (ejemplo 1, 2, 3 | 8, 9, 10): el WSS suma distancias **al cuadrado**; el 4 sale igual porque los valores son 0 y 1.
- **«Los clústeres que más aparecieron»** (inicios): el criterio es el **menor WSS**. Y «50 mil iteraciones»: con los vinos convergen en 6 (el script usa un máximo de 100).
- **Silueta «casi 0.36»**: es 0.284 con k = 3 (y 0.258 con k = 2, como se dijo). Gap: la regla usa s(k+1), no el «valor anterior».
- **«Más de 90 %, 92 %; 8 o 9 mal clasificados»**: son 6 de 177 (pureza 96.6 %), todos de la clase 2. «Casi 56 %» de varianza en el PCA: 55.3 %.
- **«Vino blanco, Merlot, Cabernet»**: la base (UCI Wine) tiene tres cultivares de una misma región de Italia; el CSV no trae sus nombres. La diapositiva 6 aclara que son 177 filas (la fuente tiene 178).
- **Cifras de la transcripción**: «3.68» y «13.25» de alcohol son 13.68 y 12.25; «157 observaciones» son 177; «grupo 2: ceniza 0.5, matiz −0.22» es ceniza 0.225 y matiz −1.258 (diap. 49). Los números de grupo mezclan R y Python.
- **K-modes**: flavonoides «alto» es ≥ 3 (se dijo «menor que 3»). «Sabemos que son 3» usa la clase real, que no existe en la práctica.

Diapositivas, scripts y verificación

- **Estandarizar** (diap. 7 y 9): `ddof=1` reproduce `scale()`; `StandardScaler` usa ddof = 0 y da WSS 1274.57 (los mismos grupos).
- **Gap** (diap. 55 a 57): con B = 30, cuatro semillas más y B = 60 la regla da k = 4; es un resultado ajustado (Gap(3) = 1.199 frente a 1.205). El script de Python usa desviación con ddof = 1 y R, según su documentación, el divisor B; no se pudo ejecutar R aquí.
- **PCA y agrupar**: «agrupar con las 13 variables» es lo correcto en principio, pero aquí las 2 componentes dan ARI 0.894 frente a 0.897: sin diferencia relevante en estos datos.
- **Verificado**: WSS 1267.37, BSS 1020.63, TSS 2 288, grupos de 62/50/65, silueta 0.284, K-modes 75, K-prototypes 326.64 con grupos de 69/47/61: todo coincide con las diapositivas.
- **Jerárquico** (no se vio en clase): con enlace de Ward el ARI es 0.79; con single o average hay efecto cadena (grupos de 173, 3 y 1; ARI ≈ 0); K-means obtiene 0.90.
- **Transcripción con ruido**: «camins / camín» = K-means, «Camos / KAMMOD» = K-modes, «capot» = K-prototypes, «GEP» = Gap, «cilita / siluente» = silueta, «interacción» = iteración, «VWSS» = WSS. El recreo (hacia 1:08:40) quedó marcado y el audio termina a las 2:07:47 en la pregunta sobre γ.

Checklist, criterio de dominio y lo que viene

- ☐ Hago una iteración de K-means a mano y calculo WSS, BSS y TSS
- ☐ Explico por qué se estandariza y qué pasa si no (con un ejemplo numérico)
- ☐ Calculo la silueta de un punto y leo una tabla de WSS y silueta para elegir k
- ☐ Explico por qué se repite con varios inicios y qué conserva n_init
- ☐ Describo los grupos con perfiles y distingo grupo de clase (tabla de contingencia, ARI)
- ☐ Elijo entre K-means, K-modes y K-prototypes según el tipo de variables
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Siguiente**: Clase 41 (Mahalanobis y DBSCAN) y el Taller 3, pregunta 4 (K-means con k = 2 a 4).