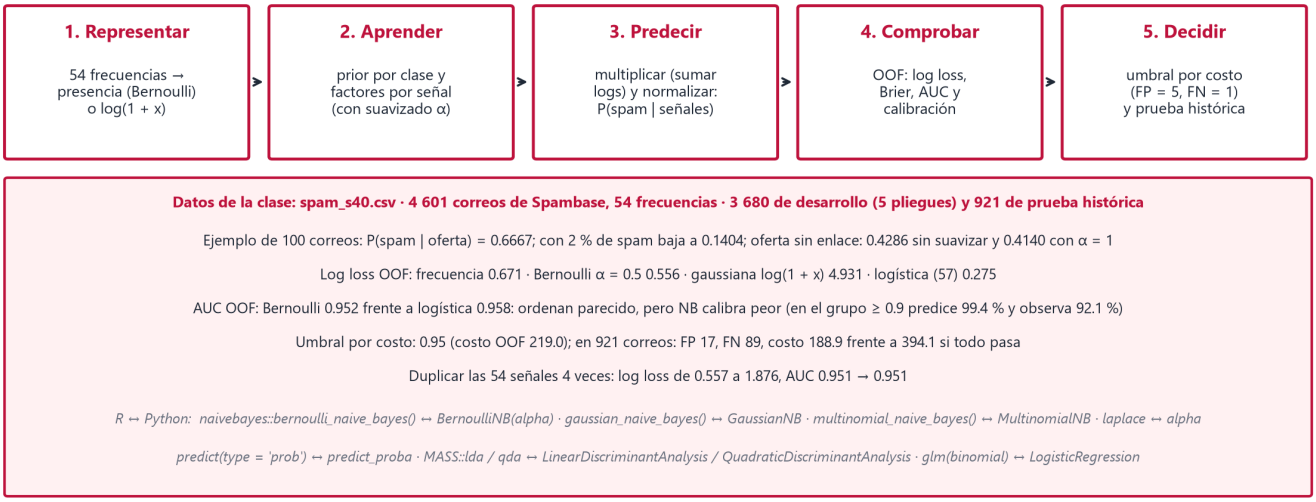
Clase 40 · Naive Bayes y clasificación probabilística

Profesor Eloy Alvarado · usa Bayes (Clase 23), retoma OOF, log loss, calibración y umbral por costo (Clase 38) y prepara el Taller 3 (pregunta 2)

La gran idea de la clase

Un clasificador probabilístico entrega una probabilidad, no solo una etiqueta, y **predecir no es decidir**: primero se construye P(clase | señales) y después un umbral, elegido con los costos de cada error, convierte esa probabilidad en una acción. **Naive Bayes** usa el teorema de Bayes y supone que, **dentro de cada clase, las señales son independientes**: así multiplica un factor por señal (o suma logaritmos) en vez de estimar toda la tabla conjunta. Hay que **suavizar** para evitar ceros, **comprobar con predicciones fuera de pliegue** y mirar la **calibración**: ordena bien, pero con señales dependientes sus probabilidades salen demasiado seguras.

La clase en una imagen



Lo que necesitas ANTES

- **Bayes y priors** (Clase 23): P(A | B) = P(B | A) P(A) / P(B)
- **Regresión logística y clasificadores** (Clases 31 y 37): probabilidad de la clase 1 y umbral
- **OOF, log loss, Brier, calibración y umbral por costo** (Clase 38), con los mismos correos de spam
- **R ↔ Python**: el profesor trae el mismo flujo en los dos lenguajes

Ruta de la clase y datos

- **Ejemplo de 100 correos → independencia y suavizado → 54 señales reales → variantes** (Bernoulli, gaussiana, multinomial) **→ OOF y calibración → umbral por costo**
- **spam_s40.csv**: 4 601 correos de Spambase y 54 frecuencias (48 palabras y 6 caracteres); 3 680 de desarrollo en 5 pliegues y 921 de prueba histórica. Es el mismo spam de la Clase 38
- Pregunta guía: ¿qué probabilidad de spam tiene este correo y conviene bloquearlo?

Puentes con otras clases (sin repetirlas)

C23 → C40: allí el prior y la verosimilitud actualizaban un parámetro; hoy actualizan la **clase** de un correo. **C37 → C40**: la regresión logística es el clasificador de referencia; con los mismos 57 predictores de la Clase 38 da log loss 0.275, frente a 0.556 de Naive Bayes Bernoulli, con AUC parecido (0.958 y 0.952). **C38 → C40**: OOF, log loss, Brier, curva de calibración y umbral con costo FP = 5 y FN = 1 se aplican igual; aquí se agrega la lectura de por qué las probabilidades salen extremas. **Taller 3, pregunta 2**: esta clase respalda el Naive Bayes del taller y su análisis (independencia condicional, variables 0/1, AUC frente a log loss); aquí solo hay ejemplos con spam, no con los datos del taller.

Recuadro: ¿una probabilidad alta es certeza?

No. En el correo ID 1 el modelo da 99.64 % de spam, pero entre los 1 157 correos con probabilidad ≥ 0.9 la predicción media es 99.4 % y la fracción real de spam es 92.1 %. Una probabilidad alta expresa una preferencia del modelo; su fiabilidad se comprueba con la calibración (diapositiva 58).

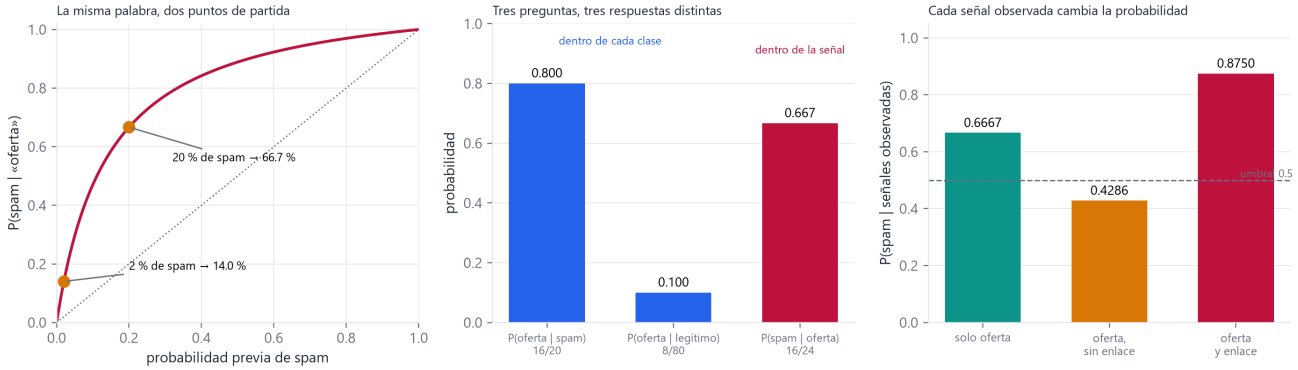
Clase 40 · Bayes para clasificar: previa, condicional y posterior

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

Hay tres preguntas distintas: la previa (¿qué fracción de los correos es spam?), la condicional (entre los spam, ¿qué fracción trae «oferta»?) y la posterior (entre los correos con «oferta», ¿qué fracción es spam?). Bayes pasa de la segunda a la tercera.

Conceptos clave

1. **La tabla de 100 correos.** 80 legítimos y 20 spam; «oferta» aparece en 8 legítimos y en 16 spam. P(oferta | spam) = 16/20 = 0.80 (se mira la fila), pero P(spam | oferta) = 16/24 = 0.667 (se mira la columna).
2. **Normalizar.** Producto de cada clase: legítimo 0.80 × 0.10 = 0.08; spam 0.20 × 0.80 = 0.16. Se divide por la suma (0.24): 0.6667. Los dos resultados suman 1.
3. **La prevalencia importa.** Con las mismas condicionales, si el spam fuera 2 % en vez de 20 %, P(spam | oferta) baja a 0.1404. La palabra ayuda, pero no decide por sí sola.



Izquierda: la posterior de «oferta» según la previa (diapositiva 10). Centro: las tres preguntas. Derecha: con «enlace» se agrega información: solo oferta 0.6667, oferta sin enlace 0.4286 y oferta con enlace 0.8750.

Fórmulas y reglas

$P(\text{spam} \mid x) = \pi_1 f_1(x) / [\pi_0 f_0(x) + \pi_1 f_1(x)]$

π_k: frecuencia de la clase k (previa)

$f_k(x)$: probabilidad de las señales en la clase k

con K clases: se suman K productos abajo

```
s1 = 0.20 * 0.80
s0 = 0.80 * 0.10
p = s1 / (s0 + s1) # 0.6667
```

Con los números de la clase

- Con oferta presente y enlace ausente: s0 = 0.80 × 0.10 × 0.80 = 0.064 y s1 = 0.20 × 0.80 × 0.30 = 0.048 → 0.4286 (diap. 17)
- Con oferta y enlace presentes: 0.112 y 0.016 → 0.8750 (diap. 18)
- Con umbral 0.5, solo «oferta» y «oferta con enlace» se clasificarían como spam
- **Cuidado.** Confundir P(oferta | spam) con P(spam | oferta) es el error clásico: el 80 % de los spam trae «oferta», pero solo dos tercios de los correos con «oferta» son spam.

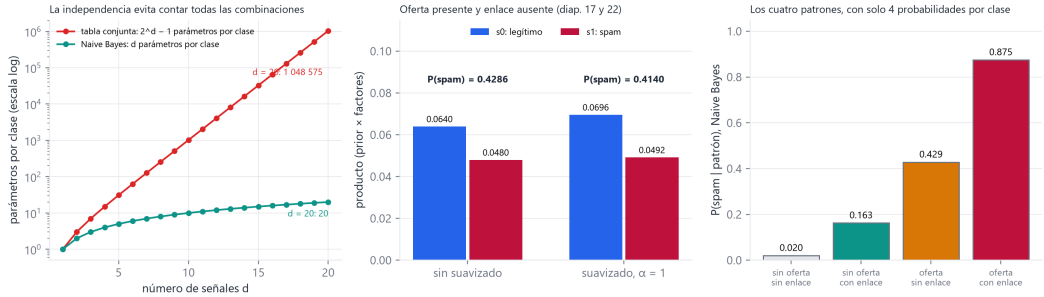
Clase 40 · Independencia condicional y el costo de ignorarla

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

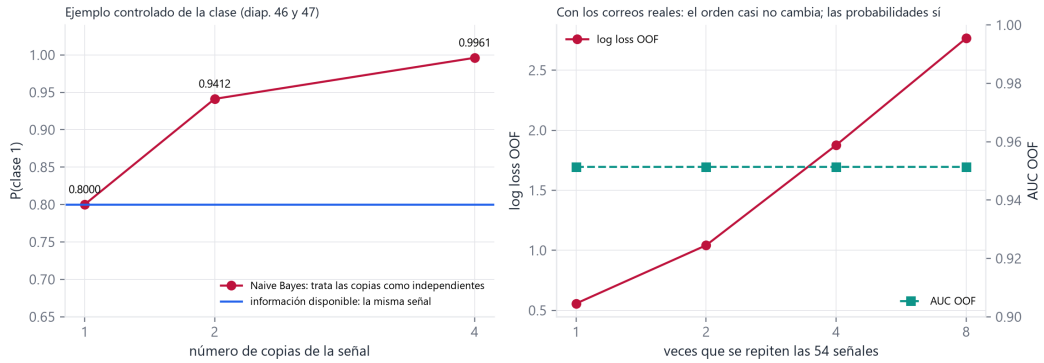
No se puede contar todas las combinaciones de señales: con d señales hay 2^d patrones por clase. Naive Bayes supone independencia dentro de cada clase y multiplica un factor por señal. Es un supuesto, no un hecho: si falla, el modelo cuenta dos veces la misma evidencia.

Conceptos clave

1. **Por qué «naive».** Con 10 señales hay 1 024 patrones por clase y con 54 hay 2^54: muchos no aparecerían nunca en los datos. Con independencia bastan d probabilidades por clase.
2. **El supuesto.** P(oferta, sin enlace | spam) = P(oferta | spam) × P(sin enlace | spam) = 0.80 × 0.30 = 0.24. Nada garantiza que se cumpla: se asume y se comprueba con los resultados.
3. **Duplicar una señal.** Si una señal (80 % en spam y 20 % en legítimos) se copia, la probabilidad sube de 0.80 a 0.9412 con 2 copias y a 0.9961 con 4, sin información nueva.



Izquierda: parámetros por clase con y sin independencia. Centro: los productos s0 y s1 de la diapositiva 17 y los de la 22 con suavizado. Derecha: las cuatro combinaciones de oferta y enlace.



Izquierda: el experimento controlado (diapositivas 46 y 47). Derecha: con los correos reales, repetir las 54 señales 1, 2, 4 y 8 veces lleva el log loss OOF de 0.557 a 2.766 mientras el AUC se mantiene en 0.951.

Fórmulas y reglas

f_k(x) = Π_j f_jk(x_j)

P(C_k | x) = π_k Π_j f_jk(x_j) / (suma sobre las clases)

d factores en lugar de 2^d patrones

copias: el factor se repite y la certeza sube

```
# duplicar columnas
Xdup = np.hstack([Xb, Xb])
BernoulliNB(alpha=1).fit(Xdup, y)
```

Con los números de la clase

- Con las 54 señales el 81 % de las probabilidades OOF queda fuera de (0.01, 0.99); con 4 repeticiones, el 96 %
- El orden no cambia (AUC 0.951 → 0.951) pero el log loss se multiplica por 3.4
- En la regresión, dos predictores idénticos no «suman» información; en Naive Bayes sí aumentan la certeza
- **Cuidado.** Duplicar una señal no mejora el modelo: lo hace más seguro de sí mismo. No es lo mismo que el sobreajuste (ajustar el ruido); es **sobreconfianza por dependencia**.

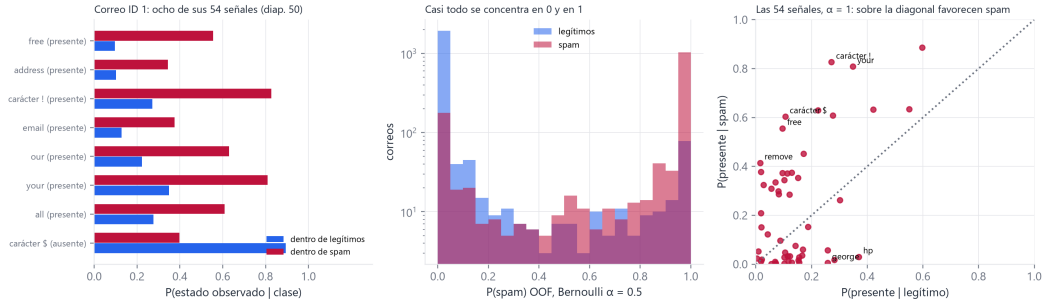
Clase 40 · Bernoulli sobre correos reales y suavizado de Laplace

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

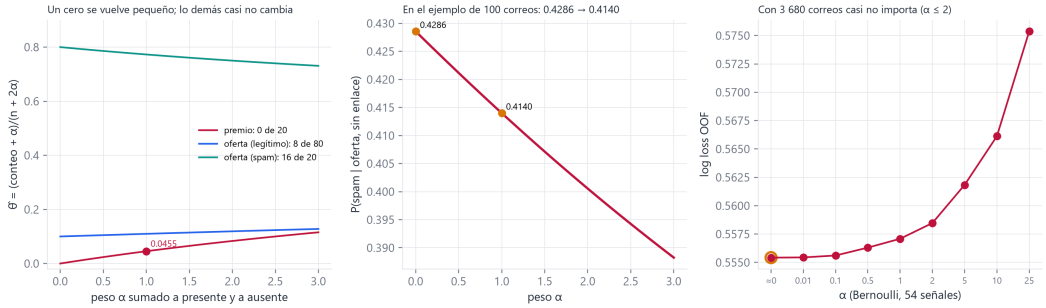
En la variante Bernoulli cada una de las 54 frecuencias se convierte en presente (1) o ausente (0); se aprende, por clase, la probabilidad de presencia, y se combinan presencias y ausencias. El suavizado de Laplace suma α a presente y a ausente para que ningún conteo cero anule el producto.

Conceptos clave

1. **Aprender y predecir.** Se cuentan correos por clase (legítimos 2 230, spam 1 450) y presencias por señal. Para «address» presente: legítimo 226/2 230 ≈ 0.1017, spam 498/1 450 ≈ 0.3437 (con α = 1, diap. 49).
2. **Suavizado.** $\hat{\theta}$ = (conteo + α)/(n + 2α). Una palabra («premio») con 0 de 20 pasa de 0 a 1/22 = 0.0455. En el ejemplo de 100 correos, 0.4286 → 0.4140 (diap. 22).
3. **Con datos reales.** El log loss OOF es casi igual para α entre 0 y 2 (0.5554 con α ≈ 0; 0.5563 con 0.5; 0.5585 con 2): con 3 680 correos ninguna señal queda con cero casos. El profesor eligió α = 0.5.



Izquierda: ocho de las 54 señales del correo ID 1 (diap. 50). Centro: las probabilidades OOF se concentran en 0 y 1 (81 % fuera de (0.01, 0.99)). Derecha: probabilidad de presencia por clase de las 54 señales.



Izquierda: cómo cambia $\hat{\theta}$ con α. Centro: la posterior del ejemplo de 100 correos. Derecha: el log loss OOF con 3 680 correos según α.

Fórmulas y reglas

$\hat{\theta}_{jk} = (c_{jk} + \alpha)/(n_k + 2\alpha)$

presente: $\hat{\theta}$; ausente: $1 - \hat{\theta}$

α = 1 es el suavizado clásico; puede ser 0.5

el suavizado no corrige la dependencia

```
m = BernoulliNB(alpha=0.5, binarize=0.0)
m.fit(X, y)
m.predict_proba(X_nuevo)[:, 1]
```

Con los números de la clase

- Correo ID 1: previa de spam 0.3940; suma de aportes 6.065 en log-odds; P(spam) = 0.9964
- Entre las 54 señales, 34 empujan hacia spam y 20 hacia legítimo para ese correo
- En el ejemplo de la diapositiva 25: oferta entre spam 17/22 = 0.7727 y enlace 15/22 = 0.6818
- **Cuidado.** Suavizar y decidir son pasos distintos: α cambia el cálculo de la probabilidad; el umbral cambia la acción. Y el suavizado importa sobre todo con pocos datos o señales muy raras.

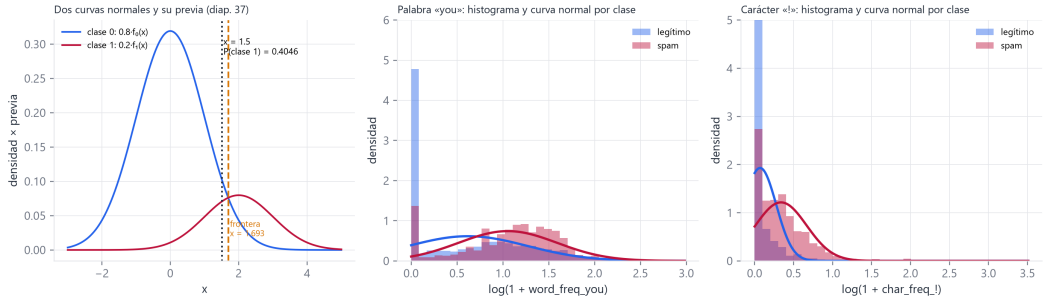
Clase 40 · Gaussiana, log-probabilidades y variantes

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

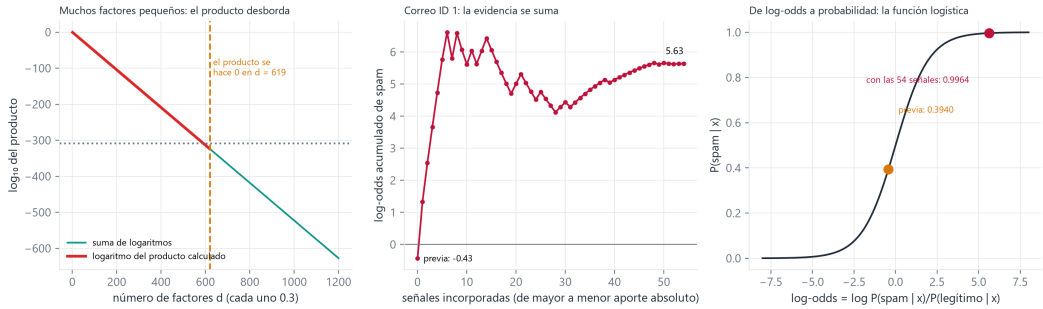
Cuando la señal es una medición, Naive Bayes gaussiano aprende una media y una desviación por clase y variable y multiplica alturas de curvas normales (densidades). En la práctica los productos se calculan como sumas de logaritmos: así no se pierde precisión y el resultado es una función logística de la evidencia.

Conceptos clave

1. **Densidad, no probabilidad.** Ejemplo de la clase: x = 1.5, medias 0 y 2, desviaciones 1 y previas 0.8 y 0.2: densidades 0.1295 y 0.3521; productos 0.1036 y 0.0704; P(clase 1) = 0.4046. La altura no es una probabilidad.
2. **Transformar.** El profesor usa z = log(1 + x) para comprimir valores grandes y conservar los ceros. No garantiza normalidad: en «you» hay 40 % de ceros en legítimos y en «!» 73 %; la curva normal no calza.
3. **Sumar logaritmos.** Con 54 factores el producto no es problema, pero con 619 factores de 0.3 ya vale 0 en doble precisión. Los log-odds se suman: previa -0.43 + aportes = 5.63 → 0.9964.



Izquierda: dos curvas normales ponderadas por su previa (diapositiva 37 y script 04). Centro y derecha: histogramas de log(1 + x) por clase con la normal ajustada.



Izquierda: el producto de muchos factores pequeños desborda; la suma de logaritmos no. Centro: la evidencia del correo ID 1 se acumula. Derecha: log-odds → probabilidad.

Fórmulas y reglas

$$f(x) = \exp(-(x-\mu)^2/2\sigma^2)/(\sigma\sqrt{2\pi})$$

$$\log P(C_k \mid x) = \log \pi_k + \Sigma_j \log f_{jk}(x_j) + \text{cte}$$

$$\text{log-odds} = \log(\pi_1/\pi_0) + \Sigma_j \log(f_{j1}/f_{j0})$$

$$P(\text{spam} \mid x) = 1/(1 + e^{-\text{log-odds}})$$

```
GaussianNB(var_smoothing=1e-9)
.fit(np.log1p(X), y)
.predict_log_proba(...) # sumas de logs
```

Con los números de la clase

- Gaussiana log(1 + x): log loss OOF 4.931 y exactitud 80.8 % (con umbral 0.5); Bernoulli α = 0.5: 0.556
- El AUC de la gaussiana es 0.940: ordena bien pero muchas probabilidades quedan en 0 o 1
- Multinomial: necesita conteos de términos (cuántas veces aparece cada palabra); un porcentaje no basta sin la longitud del mensaje
- **Cuidado.** La exactitud no ve la sobreconfianza: la gaussiana acierta 80.8 % y su log loss es nueve veces el del Bernoulli. Con evidencia extrema la probabilidad se redondea a 0 o a 1: conviene mirar también los log-odds.

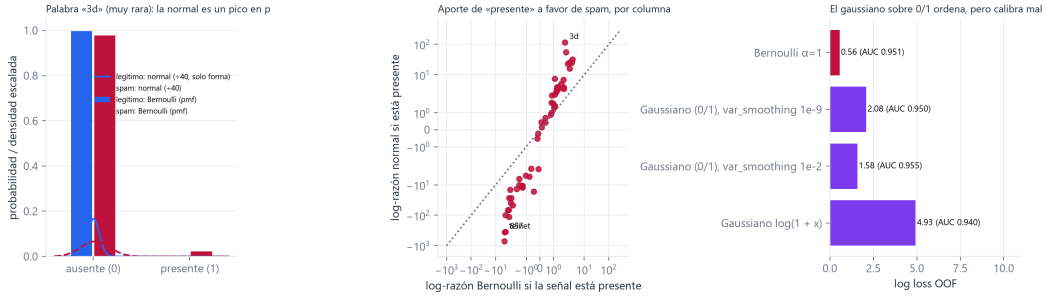
Clase 40 · Gaussiano sobre columnas 0/1 y fronteras de decisión

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

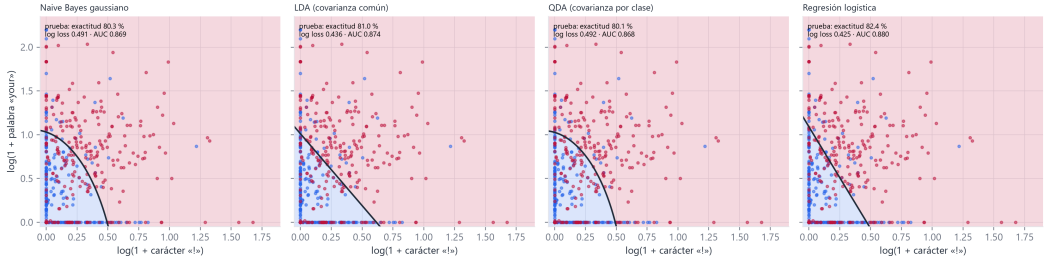
Aplicar un Naive Bayes gaussiano a una columna 0/1 la trata como una medición normal con media p y varianza p(1 − p). Es una aproximación torpe: la densidad no es una probabilidad, la varianza puede ser casi cero y el aporte de «presente» se exagera. Con las fronteras se compara Naive Bayes con LDA, QDA y regresión logística.

Conceptos clave

1. **Qué se aprende.** Para «3d» (presente en 8 de 2 230 legítimos y 33 de 1 450 spam): media 0.0036 y 0.0228, varianzas 0.0036 y 0.0222. La normal es un pico muy angosto en p.
2. **Qué se distorsiona.** Cuando la señal está presente, el aporte en log-razón es 1.85 con Bernoulli y 116 con la normal; para señales casi siempre ausentes llega a -714. Una sola columna domina el producto.
3. **Cómo se lee.** Log loss OOF: Bernoulli 0.56; gaussiano sobre 0/1 2.08 (con var_smoothing = 1e-2: 1.58); AUC casi igual. Ordena bien y calibra mal; la causa es el modelo de la columna, no el algoritmo.



Izquierda: una columna 0/1 rara; la pmf de Bernoulli frente a la normal (reescalada). Centro: aporte de «presente» por columna (escala simétrica logarítmica). Derecha: log loss OOF de las cuatro versiones.



Dos señales (log(1 + «!») y log(1 + «your»)) con regiones P = 0.5 de cuatro modelos. Naive Bayes y QDA dan fronteras curvas; LDA y logística, rectas. El resultado en los 921 correos de prueba está en cada panel.

Fórmulas y reglas

Normal en 0/1: $\mu = p$, $\sigma^2 = p(1 - p)$

NB gaussiano = QDA con covarianza diagonal

LDA: covarianza común → frontera lineal

logística: modela P(clase | x) directamente

```
GaussianNB().fit((X > 0).astype(float), y)
LinearDiscriminantAnalysis().fit(Z, y)
QuadraticDiscriminantAnalysis().fit(Z, y)
```

Con los números de la clase

- En la prueba con dos señales: NB 80.3 % y log loss 0.491; LDA 81.0 %; QDA 80.1 %; logística 82.4 % y 0.425
- Variables dummy 0/1 no son normales: con una sola dummy la «campana» no existe
- Una variable con media 0 en una clase (siempre ausente) deja varianza casi nula: la densidad explota
- **Cuidado.** Bernoulli es la variante natural para 0/1; un gaussiano sobre dummies **funciona como aproximación**, pero con probabilidades poco confiables. Aquí se explica solo con los correos de spam.

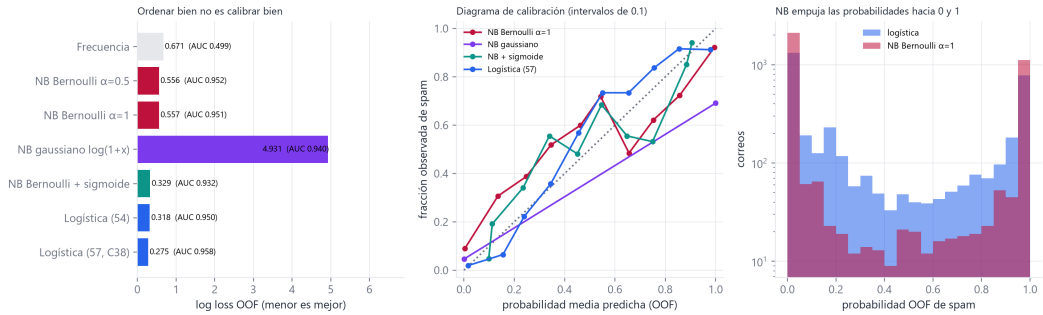
Clase 40 · Calibración y decisión por costo

Fuente: transcripción + diapositivas DipDS_2026_S40.pdf + 40_naive_bayes.py / .R del profesor Eloy Alvarado + spam_s40.csv

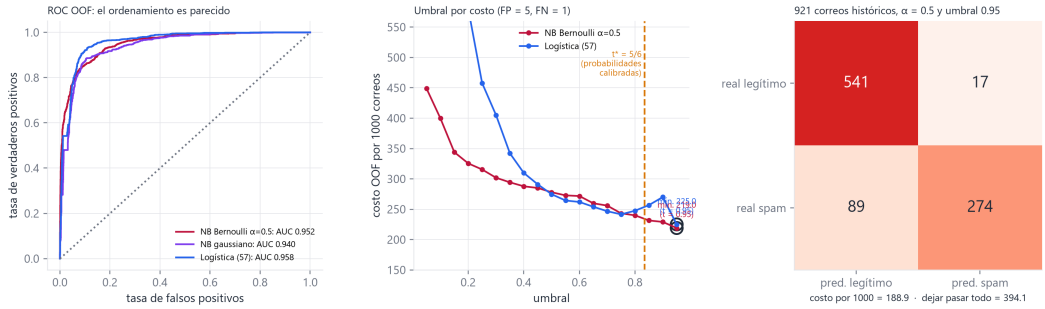
Ordenar bien no es calibrar bien. Naive Bayes y la regresión logística tienen un AUC parecido, pero las probabilidades de Naive Bayes son más extremas y el log loss es el doble. Una vez que se tiene una probabilidad, el umbral se elige con los costos de cada error (FP = 5, FN = 1), con predicciones OOF.

Conceptos clave

1. **Comparar con la logística.** Log loss OOF: frecuencia 0.671, Bernoulli α = 0.5 0.556, logística (54 señales) 0.318 y logística (57, Clase 38) 0.275; Brier 0.099 frente a 0.075; AUC 0.952 y 0.958.
2. **Recalibrar.** Una sigmoide ajustada dentro de cada pliegue lleva el log loss del Naive Bayes Bernoulli de 0.557 a 0.329: el orden casi no cambia, las probabilidades sí.
3. **Umbral por costo.** Con probabilidades calibradas, bloquear conviene si 5(1 − p) < p, es decir p > 5/6 ≈ 0.833. Con OOF el menor costo está en 0.95 (219.0 por 1000); en los 921 correos: FP 17, FN 89 y costo 188.9, frente a 394.1 si todo pasa.



Izquierda: log loss OOF y AUC de cada receta. Centro: diagrama de calibración. Derecha: distribución de las probabilidades OOF de Naive Bayes y de la logística.



Izquierda: ROC OOF. Centro: costo por 1000 correos según el umbral para Naive Bayes y la logística; el umbral teórico es 5/6. Derecha: matriz de confusión en los 921 correos históricos con α = 0.5 y umbral 0.95.

Fórmulas y reglas

costo bloquear: 5 (1 − p)

costo dejar pasar: 1 · p

bloquear si p ≥ 5/(5 + 1) = 0.833

costo por 1000 = 1000 (5 FP + FN)/n

```
costo = 1000 * (5 * fp + fn) / n
umbrales = np.arange(1, 20) / 20
# elegir en OOF; probar una vez en prueba
```

Con los números de la clase

- p = 0.90: bloquear cuesta 0.50 y dejar pasar 0.90 → bloquear; p = 0.70: 1.50 frente a 0.70 → dejar pasar (diap. 51)
- Con la logística (57), la prueba de 921 correos da FP 6, FN 158 y costo 204.1 con umbral 0.95; con Naive Bayes, 188.9
- El 0.95 está en el borde de la rejilla: con otra rejilla podría haber un umbral mejor
- **Cuidado.** Los 921 correos ya se usaron al comparar clasificadores: es una **comprobación retrospectiva**, no una prueba independiente. Elegir modelo y umbral en desarrollo, y probar una sola vez.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase (transcripción)

- **Enlace en la tabla**: se dijo «16 correos legítimos tienen enlace y 14 spam no tienen enlace». La diapositiva 11 dice: 16 legítimos con enlace y **14 spam con enlace** (6 sin enlace). Después se usa bien.
- **«6 correos sin enlace dentro de los 20 legítimos»**: son los 20 **spam** (los legítimos son 80, con 64 sin enlace). Y «20 de los spam observados son 80 de los 100» debe leerse 20 de 100 (denominador 20 + 2).
- **Costo de umbral**: la transcripción habló de un costo «216»; las diapositivas y el código dan **219.0** por 1000 (78 FP y 416 FN) con umbral 0.95. El log loss de la frecuencia es 0.671 (no 0.61) y el total son 4 601 correos (no 6 000).
- **«Es sobre ajuste»** (duplicar una columna): es **sobreconfianza por dependencia**; en regresión, columnas idénticas no suman información, en Naive Bayes sí aumentan la certeza.
- **Umbral y calibración**: con probabilidades calibradas el umbral teórico sería 5/6; el óptimo empírico (0.95) está en el borde de la rejilla de 19 valores. No demuestra que 0.95 sea el mejor umbral posible.
- **Suavizar no arregla la dependencia** (se dijo, y es correcto). Lo que sí corrige un desbalance fuerte es remuestrear y luego «reponer» la prevalencia real: las probabilidades quedan sobreestimadas si no se compensa.

Diapositivas, scripts y verificación

- **Reproducido con el script**: ejemplo de 100 correos (0.6667, 0.1404, 0.4286, 0.4140), suavizado, duplicación (0.80, 0.9412, 0.9961), gaussiana (0.4046), multinomial (0.8333 y 0.9615) y OOF: log loss 0.671, 0.556, 0.557, 0.558 y 4.931; AUC 0.952 y 0.940.
- **Prueba histórica**: 541 / 17 / 89 / 274, costo 188.9, log loss 0.533 y Brier 0.094; el correo ID 1 da 0.9964.
- **Qué no hace el script**: no compara con la regresión logística ni usa LDA o QDA; esas comparaciones son de esta guía (la logística con la receta de la Clase 38, 57 entradas, StandardScaler, C = 1).
- **Multinomial**: solo se vio un ejemplo construido; con frecuencias en % no se puede aplicar sin conocer la longitud del mensaje.
- **Transcripción con ruido**: «Nahid Valles / naivayes / NUGI» = Naive Bayes y Bernoulli, «suavizamiento de la plaza» = de Laplace, «el láser / el lazo» = el enlace, «cátera» = cátedra. El recreo (hacia 1:26:33) quedó marcado y el video continúa sin hueco.

Checklist, criterio de dominio y lo que viene

- ☐ Calculo P(spam | señales) a mano desde una tabla de frecuencias y distingo previa, condicional y posterior
- ☐ Explico qué supone Naive Bayes y qué pasa si dos señales repiten la misma información
- ☐ Aplico el suavizado de Laplace a un conteo cero y digo cuándo importa
- ☐ Calculo la verosimilitud gaussiana con medias y desviaciones dadas y explico por qué se usan logaritmos
- ☐ Explico por qué un gaussiano sobre columnas 0/1 es una aproximación débil
- ☐ Comparo Naive Bayes con la logística: mismo orden, distinta calibración (AUC frente a log loss)
- ☐ Elijo el umbral con costos y lo pruebo una sola vez
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Siguiente**: Clase 41 (anomalías) y el Taller 3, pregunta 2 (Naive Bayes).