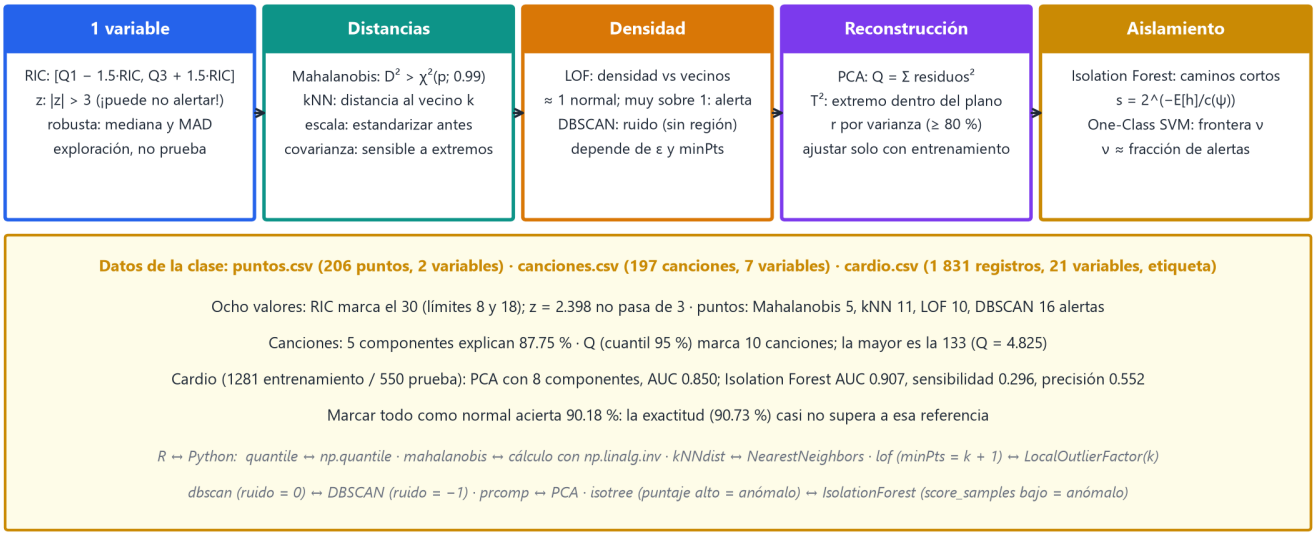
Clase 41 · Detección de anomalías

Profesor Pedro Luiz Ramos · aplica ideas de Clases 30–32 (calidad de datos, K-means, PCA), 35 (árboles) y 37 (SVM); la evaluación usa la Clase 38

La gran idea de la clase

Una **anomalía** es un caso que se aparta de lo esperado **bajo una referencia**; una alerta dice **qué revisar**, no que el dato esté mal. Cada método define «inusual» de otra manera: un valor extremo (RIC, z), una combinación que contradice la correlación (Mahalanobis), un vecindario vacío (kNN, LOF, DBSCAN), un patrón que el PCA no reconstruye o un punto que se **aísla** con pocos cortes al azar (Isolation Forest). Ninguna regla es universal: se usan varias, se compara dónde coinciden y se **investiga antes de eliminar**. Con etiquetas (cardio) se evalúa como cualquier clasificador, pero con una clase muy escasa: la exactitud engaña y importan sensibilidad, precisión y el corte.

La clase en una imagen



Lo que necesitas ANTES

- **Calidad de datos y atípicos** (Clase 30): cuartiles, boxplot, fuga de datos
- **K-means y PCA** (Clases 31 y 32): centroides sensibles a extremos; componentes y reconstrucción
- **Árboles y bosques** (Clases 34–35): particiones recursivas, submuestras; **SVM** (Clase 37)
- **Matriz de confusión, precisión, sensibilidad, ROC y PR** (Clases 37 y 38)

Ruta de la clase y datos

- **Qué es una anomalía → una variable → Mahalanobis → kNN, LOF, DBSCAN → PCA → Isolation Forest → evaluar con etiquetas**
- **puntos.csv** (206 puntos: 200 simulados + 6 añadidos), **canciones.csv** (197 canciones, 7 variables), **cardio.csv** (1 831 registros, 21 variables, 176 anomalías)
- Pregunta guía: ¿qué quiero revisar y cuántas alertas puedo atender?

Puentes con las clases vecinas (sin repetirlas)

C30 → C41: allí se detectaron atípicos con boxplot; hoy se formalizan (RIC, z, Mahalanobis) y se agregan métodos multivariados. **C31/C32 → C41**: K-means se distorsiona con un extremo (el profesor lo mostró con 1, 2, 3 y 30); el PCA sirve al revés: lo que no se reconstruye es anómalo. **C35 → C41**: el Isolation Forest usa árboles de cortes aleatorios, sin variable de respuesta. **C37 → C41**: la One-Class SVM (mencionada al cierre) es una SVM sin clases. **C38 → C41**: con una clase del 9.8 % la exactitud, la ROC y la PR cuentan historias distintas; el corte se fija con entrenamiento o validación, nunca con la prueba.

Recuadro: ¿atípico, error o evento real?

Antes de eliminar: verificar unidades, duplicados y faltantes; consultar el contexto; distinguir un error corregible (una edad de 99 que era 29) de un evento real poco frecuente (Black Friday); comparar resultados con y sin el caso. En fraude o fallas, el caso poco frecuente **es** el objeto de estudio. No se reemplaza cada valor marcado por la media.

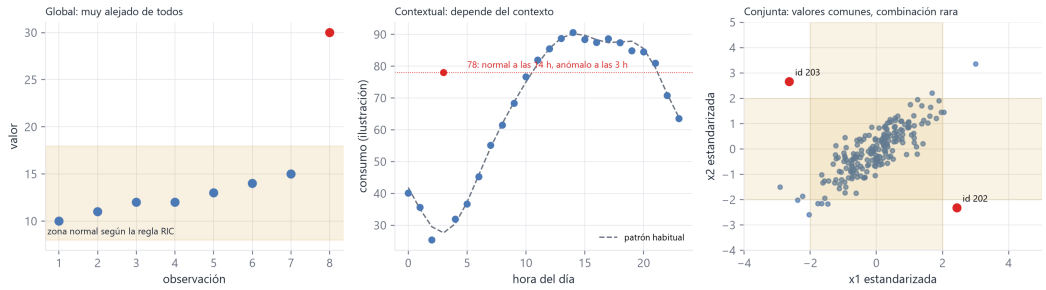
Clase 41 · Qué es una anomalía y reglas de una variable

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

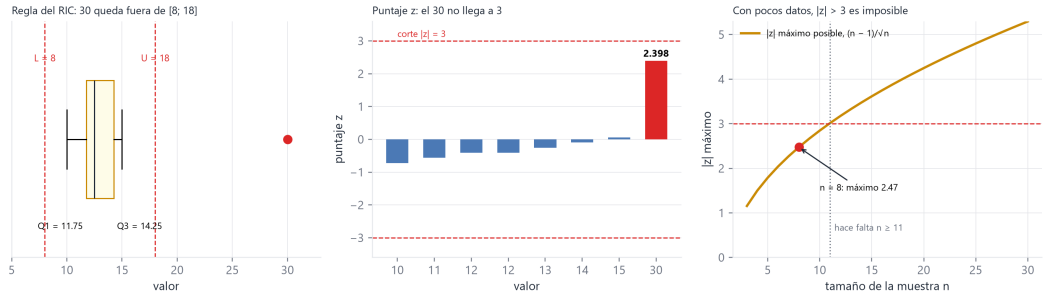
Hay anomalías globales, contextuales y conjuntas. Para una sola variable hay dos reglas: el RIC (cuartiles, no supone normalidad) y el puntaje z (media y desviación, que el propio extremo distorsiona).

Conceptos clave

1. **Tres tipos.** Global: un 30 entre valores de 10 a 15. Contextual: un consumo normal a las 14 h es anómalo a las 3 h. Conjunta: los casos 202 y 203 tienen valores marginales comunes ($|z| \le 2.67$) pero contradicen la correlación.
2. **RIC.** Q1 = 11.75, Q3 = 14.25, RIC = 2.5; límites 8 y 18. El 30 queda fuera: alerta. La regla es de exploración, no una prueba de error.
3. **Puntaje z.** Media 14.625 y desviación 6.413: z(30) = 2.398 < 3, sin alerta. No es mala suerte: con n = 8 el máximo posible es $(n-1)/\sqrt{n} = 2.47$; hace falta $n \ge 11$ para poder superar 3.



Izquierda: los ocho valores del profesor, con la zona del RIC. Centro: ilustración de una anomalía contextual (el mismo 78 es normal a las 14 h). Derecha: puntos.csv; dos casos añadidos con valores marginales comunes.



Izquierda: boxplot con límites 8 y 18. Centro: puntajes z de los ocho valores (el 30 llega a 2.398). Derecha: el |z| máximo posible crece como $(n-1)/\sqrt{n}$; con 8 datos nunca llega a 3.

Fórmulas y reglas

$RIC = Q3 - Q1$; $L = Q1 - 1.5 \cdot RIC$; $U = Q3 + 1.5 \cdot RIC$

alerta si $x < L$ o $x > U$

$z = (x - \text{media})/s$; alerta si $|z| > 3$

$|z| \le (n-1)/\sqrt{n}$ (con s muestral)

```
q1, q3 = np.quantile(v, [.25, .75])
ric = q3 - q1
z = (v - v.mean()) / v.std(ddof=1)
```

Con los números de la clase

- Fuera de ±2σ queda ≈ 4.55 % y fuera de ±3σ ≈ 0.27 % bajo una normal
- Sin el 30 la media es 12.429; con él, 14.625: el extremo arrastra media y desviación (enmascaramiento)
- Alternativa robusta: mediana 12.5 y MAD 1.5; z modificado = 0.6745·(x − mediana)/MAD = 7.87 > 3.5
- **Cuidado.** Una alerta no demuestra error. Y si los datos son muy asimétricos, el RIC marcará valores válidos de la cola.

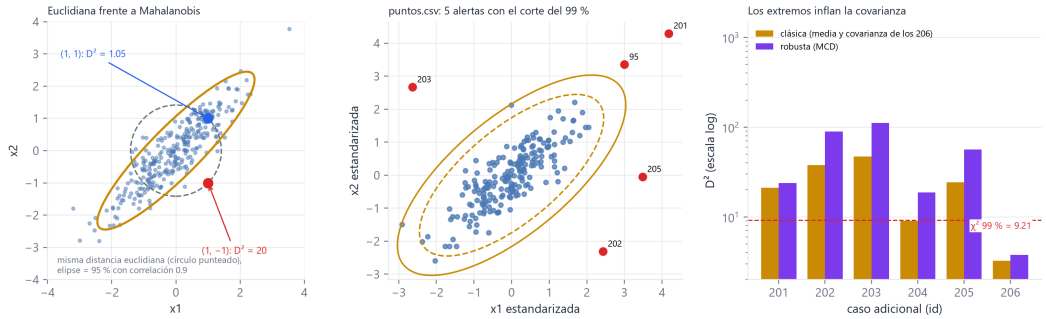
Clase 41 · Distancia de Mahalanobis

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

La distancia euclidiana ignora que las variables se mueven juntas. Mahalanobis mide cuántas «desviaciones» está un punto del centro en la dirección en que se mueve la nube: un punto contrario a la correlación queda lejos aunque sus valores sean moderados.

Conceptos clave

1. **Idea de la elipse.** Con correlación 0.9, (1, 1) y (1, −1) están a la misma distancia euclidiana (√2) pero D^2 = 1.053 y 20. Las elipses de 95 % y 99 % son los contornos de $D^2 = \chi^2$.
2. **Corte con χ^2.** Con p = 2 variables, $\chi^2(2; 0.99) = 9.210$. En puntos.csv marca 5 casos (ids 95, 201, 202, 203, 205); con 95 % son 8 y con 90 %, 14. Es una referencia aproximada bajo normalidad.
3. **Covarianza frágil.** Los seis casos añadidos reducen la correlación de 0.83 (200 puntos) a 0.70; así el caso 204 queda en D^2 = 8.99 < 9.21 y «se salva». Con una covarianza robusta (MCD) su D^2 sube a 18.7.



Izquierda: dos puntos a igual distancia euclidiana (círculo) con D^2 muy distinto (elipse del 95 %). Centro: puntos.csv con elipses de 95 % (punteada) y 99 % y las 5 alertas. Derecha: D^2 de los casos 201 a 206 con covarianza clásica y robusta.

Fórmulas y reglas

$D^2 = (x - m)^T S^{-1} (x - m)$

alerta si $D^2 > \chi^2(p; 0.99)$

$\chi^2(2; 0.99) = 9.210$; $\chi^2(2; 0.95) = 5.991$

mahalanobis() de R devuelve D^2, no D

```
S = np.cov(z, rowvar=False)
d2 = np.sum((c @ np.linalg.inv(S)) * c, axis=1)
umbral = chi2.ppf(0.99, df=z.shape[1])
```

Con los números de la clase

- Cuenta de la diapositiva 14: S = [[1, 0.9], [0.9, 1]], S^{-1} = (1/0.19)·[[1, −0.9], [−0.9, 1]]; $D^2(1, 1) = (1 + 1 - 1.8)/0.19 = 1.053$; $D^2(1, -1) = (1 + 1 + 1.8)/0.19 = 20$
- Con 200 puntos normales se esperan ≈ 2 alertas al 99 %: el caso 95 es una de ellas, no un error del método
- Estandarizar antes no cambia Mahalanobis (diferencia máxima 7e-15); sí importa para kNN, LOF, DBSCAN y One-Class SVM
- **Cuidado.** S debe ser invertible (cuidado con variables redundantes) y el corte χ^2 es una aproximación: con parámetros estimados no garantiza un 1 % de falsas alertas.

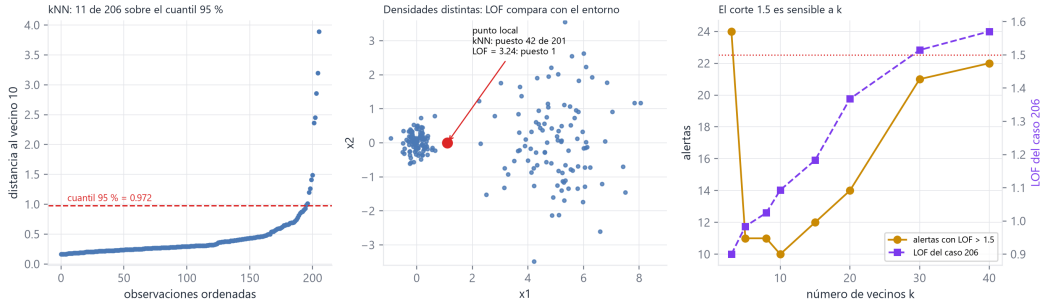
Clase 41 · Vecinos y densidad: kNN, LOF y DBSCAN

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

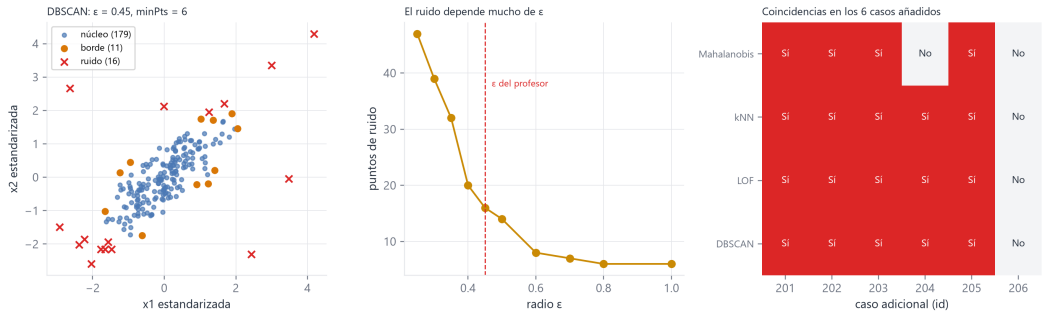
Tres maneras de mirar el vecindario: kNN usa la distancia al vecino k, LOF compara la densidad de un punto con la de sus vecinos (sirve cuando hay zonas más y menos densas) y DBSCAN deja como ruido lo que no pertenece a ninguna región densa.

Conceptos clave

1. **kNN.** Distancia al vecino k = 10 (sin el propio punto); corte en el cuantil 95 % (0.972): 11 de 206. Un cuantil 95 % siempre marca ≈ 5 %.
2. **LOF.** LOF = prom. lrd de vecinos / lrd(i): ≈ 1 normal, mucho mayor que 1 = menos denso que su entorno. Con k = 10 y corte 1.5: 10. Ejemplo del profesor: lrd(A) = 2, vecinos 6, 5, 7 → LOF = 3.
3. **DBSCAN.** ε = 0.45, minPts = 6: 179 núcleos, 11 bordes y 16 de ruido. Agrupa (no clasifica); solo el ruido se marca.



Izquierda: puntajes kNN ordenados y corte. Centro: dos densidades (simuladas): el punto rojo es apenas el puesto 42 por kNN pero el primero por LOF (3.24). Derecha: alertas con LOF > 1.5 según k.



Izquierda: núcleos, bordes y ruido. Centro: el ruido cae de 47 a 6 al subir ε. Derecha: de los seis casos añadidos, 201, 202, 203 y 205 los marcan los cuatro métodos; el 204 no lo marca Mahalanobis; el 206 (1.9, 1.9) no lo marca ninguno.

Fórmulas y reglas

kNN: score(i) = d(i, vecino k)

reach(i, j) = max{d(i, j), k-dist(j)}

lrd(i) = 1/promedio de reach(i, j); LOF = prom. lrd(vecinos)/lrd(i)

núcleo: ≥ minPts en el radio ε (incluye al punto)

```
LocalOutlierFactor(n_neighbors=10)
DBSCAN(eps=0.45, min_samples=6) # ruido = -1
```

Con los números de la clase

- Alertas: Mahalanobis 5, kNN 11, LOF 10, DBSCAN 16; 5 puntos los marcan los cuatro y 19 al menos uno
- Sugerencia del profesor: usar varios métodos y mirar dónde coinciden
- **Cuidado.** El corte 1.5 no es universal: el caso 206 llega a LOF 1.51 con k = 30 y las alertas pasan de 10 (k = 10) a 21. Y el ruido de DBSCAN depende de ε.

Clase 41 · PCA: el error de reconstrucción

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

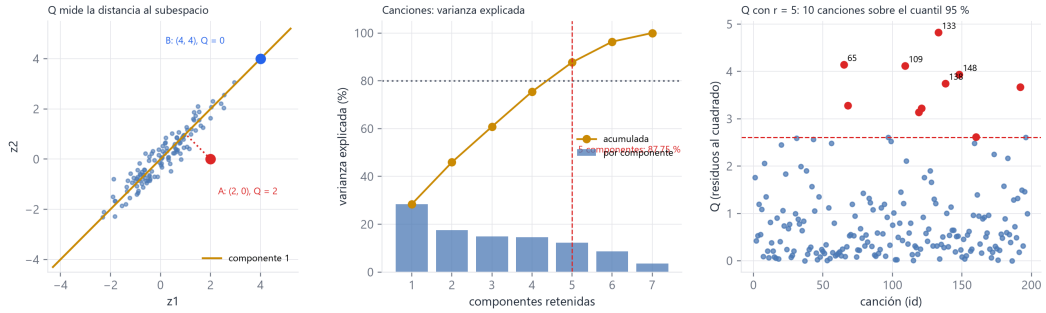
El PCA resume las variables en pocas componentes; si un caso no se reconstruye bien desde ellas, su combinación de variables es inusual. El error se mide con Q, la suma de residuos al cuadrado en escala estandarizada.

Conceptos clave

1. **Proyectar y volver.** $T = Z \cdot P$ (coordenadas en las r componentes), $\hat{Z} = T \cdot P^T$ (reconstrucción) y $Q = \Sigma(z - \hat{z})^2$. Con una componente $(1, 1)/\sqrt{2}$: A = (2, 0) tiene Q = 2 y B = (4, 4) tiene Q = 0.

2. **Canciones.** Siete variables, 197 canciones. Con 5 componentes se explica 87.75 % de la varianza; Q en el cuantil 95 % (2.611) marca 10 canciones. Las mayores: 133, 65, 109, 148, 138 (Q = 4.825 la primera).

3. **Lo que Q no ve.** B está lejos del centro y tiene Q = 0: un extremo *dentro* del subespacio. Lo cubre $T^2 = \Sigma\, t^2/\lambda$. En canciones Q y T^2 casi no se parecen (correlación 0.14): detectan cosas distintas.



Izquierda: A se aparta de la recta (Q = 2) y B no (Q = 0). Centro: varianza explicada; con 5 componentes 87.75 %. Derecha: Q de las 197 canciones con el corte del cuantil 95 %.

Fórmulas y reglas

$Z = (X - \text{media})/s$; $T = Z \cdot P_r$; $\hat{Z} = T \cdot P_r^T$

$Q_i = \Sigma_j\, (z_{ij} - \hat{z}_{ij})^2$

$T^2_i = \Sigma_l\, t_{il}^2/\lambda_l$

con r = p componentes, Q ≈ 0 para todos

```
pca = PCA().fit(z)
rec = (z @ P.T) @ P # P = pca.components_[:r]
q = ((z - rec) ** 2).sum(axis=1)
```

Con los números de la clase

- Cardio: con el 80 % de varianza se retienen 8 componentes y el corte Q (cuantil 95 % de entrenamiento) vale 11.990; AUC en prueba 0.850
- Q depende de r: con 2 componentes el AUC es 0.883, con 8, 0.850, con 12, 0.725; T^2 (r = 8) alcanza 0.918
- Para datos nuevos: misma media, escala y componentes de referencia; sin reajustar con los datos que dieron alarma
- **Cuidado.** Explicar mucha varianza no garantiza detectar todas las anomalías, y la elección de r (aquí 80 %) es una decisión que se fija antes de mirar la prueba.

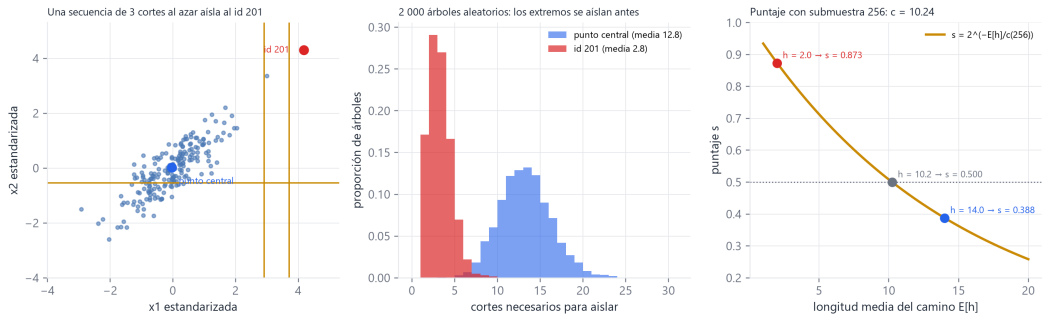
Clase 41 · Isolation Forest y One-Class SVM

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

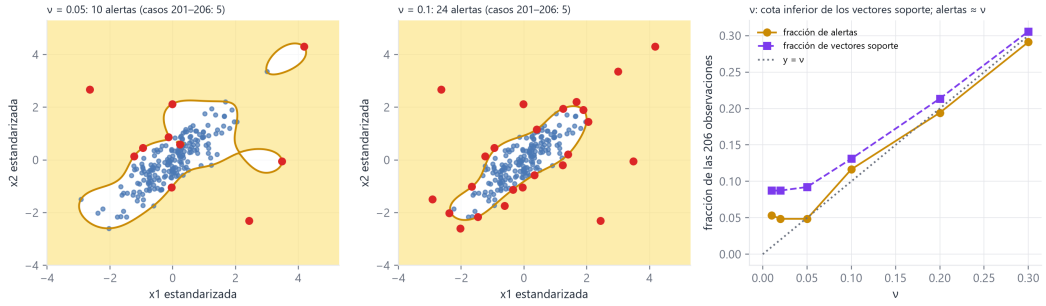
El Isolation Forest no mide distancias ni densidades: corta al azar y cuenta cuántos cortes hacen falta para dejar un punto solo. Los extremos se aíslan rápido; los del centro, tarde. Promediando muchos árboles se obtiene un puntaje.

Conceptos clave

1. **Árboles de aislamiento.** Cada árbol usa una submuestra; en cada nodo elige una variable y un corte al azar y se detiene al aislar. No usa etiquetas.
2. **Puntaje.** s = 2^(−E[h]/c(ψ)); c(256) = 10.24. E[h] = c(ψ) da 0.5; caminos más cortos dan s mayor. No es una probabilidad (la diapositiva usa c = 8 como ejemplo).
3. **One-Class SVM.** SVM sin clases: encierra la región normal con un núcleo y un parámetro ν (≈ fracción de alertas). En puntos.csv: ν = 0.05 marca 10; ν = 0.10, 24.



Izquierda: una secuencia de cortes al azar que aísla al caso 201. Centro: en 2 000 árboles el 201 se aísla con 2.8 cortes en promedio y un punto central con 12.8. Derecha: puntaje en función de E[h] con c(256).



One-Class SVM (núcleo gaussiano, γ = «scale») sobre puntos.csv: la frontera amarilla encierra lo normal. A mayor ν, más alertas.

Fórmulas y reglas

s(x) = 2^(−E[h(x)]/c(ψ))

c(ψ) = 2(ln(ψ − 1) + 0.5772) − 2(ψ − 1)/ψ

sklearn: score_samples = −s (más bajo = más anómalo)

contamination solo fija el corte de predict()

```
m = IsolationForest(n_estimators=300,
max_samples=256).fit(z_tr)
score = -m.score_samples(z_te) # alto = anómalo
```

Con los números de la clase

- Diap. 38: h = 2 y c = 8 → s = 0.841; con c(256) el mismo h = 2 da 0.873
- 300 árboles = caminos promediados; 256 = registros por árbol (no variables). Con «auto», predict() corta en s > 0.5: 59 alertas en prueba, no 29
- No necesita estandarizar: puntajes idénticos con las variables sin escalar
- **Cuidado.** Con 10 semillas el AUC va de 0.907 a 0.926; un puntaje 0.84 no es «84 % de probabilidad».

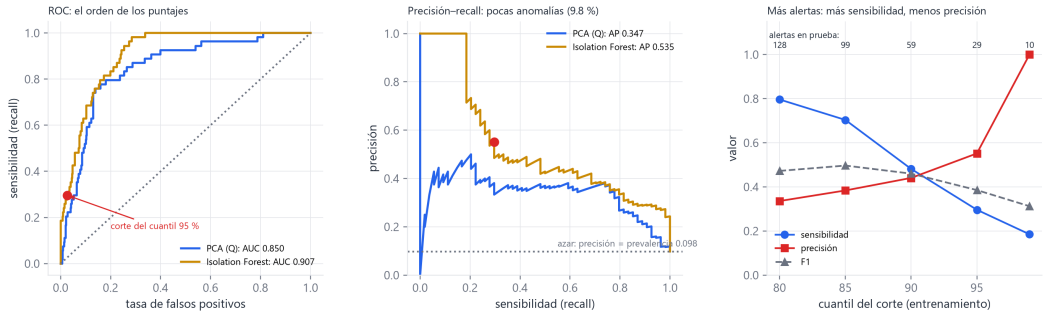
Clase 41 · Cardio: evaluar con etiquetas disponibles

Fuente: transcripción + diapositivas deteccion_anomalias.pdf + anomalias.py / .R del profesor Pedro Luiz Ramos

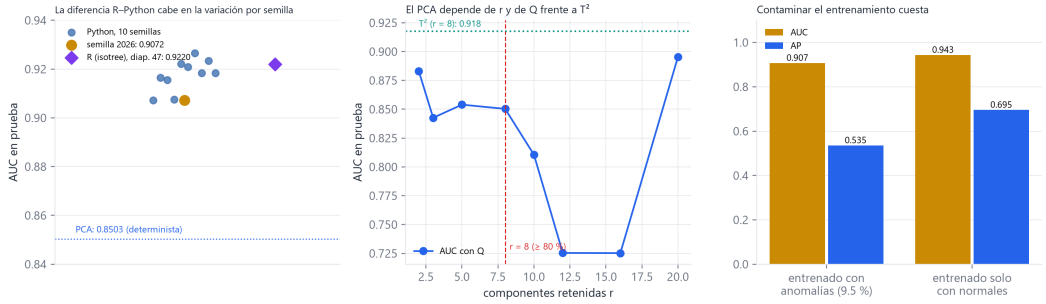
Con etiquetas se puede evaluar un detector, pero las anomalías son solo el 9.8 %. Todo se ajusta con entrenamiento (escala, componentes, bosque y corte) y la prueba se usa una vez. La exactitud casi no supera a «todo normal»; importan sensibilidad, precisión y el corte.

Conceptos clave

1. **Partición.** 1 831 registros, 176 anomalías: entrenamiento 1 281 (122), prueba 550 (54). El entrenamiento no se filtra por etiqueta.
2. **Corte del cuantil 95 %.** IF: matriz 483/13/38/16, exactitud 0.9073 (todo normal: 0.9018), sensibilidad 0.2963, precisión 0.5517, AUC 0.9072. PCA: 0.8800, 0.2963, 0.3636, 0.8503.
3. **El corte cambia todo.** Cuantil 90 %: 59 alertas, sensibilidad 0.481; 95 %: 29 y 0.296; 99 %: 10 y 0.185. El AUC no cambia.



Izquierda: ROC (AUC 0.850 y 0.907); el punto rojo es el corte del 95 %. Centro: precisión–recall con la línea de azar en 0.098 (AP 0.347 y 0.535). Derecha: sensibilidad, precisión y F1 según el cuantil del corte.



Izquierda: AUC del bosque con 10 semillas (0.907 a 0.926); el valor de R (0.9220) cae dentro. Centro: el AUC del PCA según r. Derecha: entrenar solo con casos normales sube el AUC de 0.907 a 0.943.

Fórmulas y reglas

sensibilidad = VP/(VP + FN); precisión = VP/(VP + FP)

exactitud = (VN + VP)/n

alertas ≈ (1 − cuantil)·n

referencia PR: precisión = prevalencia

```
u = np.quantile(score_train, 0.95)
clase = (score_test > u).astype(int)
```

Con los números de la clase

- Con ≈ 5 % de alertas la sensibilidad no puede pasar de 0.51 (hay 9.8 % de anomalías)
- Cuantil elegido con CV en entrenamiento (F1): 0.80; en prueba, sensibilidad 0.796, precisión 0.336, 128 alertas
- Es un benchmark, no una herramienta clínica
- **Cuidado.** Un AUC alto no implica que el cuantil 95 % detecte la mayoría; el corte no se elige con la prueba.

Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

Lo dicho en clase (transcripción)

- **«El z no marca el 30 porque el extremo elevó la media y la desviación»** (cierto, pero incompleto): con n = 8 marcarlo es imposible; $|z| \le (n-1)/\sqrt{n} = 2.47$ (y 2.65 con desviación poblacional). Hace falta n ≥ 11.
- **«Cuartil 11.65 por los empates» y «la media pasa de 12.5 a 14.62»**: con la interpolación del código Q1 = 11.75 (no 11.65) y la media sin el 30 es 12.43; con él, 14.625.
- **«Seis sigmas = uno en un millón»**: fuera de ±6σ queda ≈ 2 por mil millones; la cifra de 3.4 por millón viene de la convención con un desplazamiento de 1.5σ.
- **Mahalanobis «95 %: 4 bien y 1 mal»**: con 95 % hay 8 alertas (5 añadidos y 3 naturales: 25, 83, 95); con 99 %, 5 (4 añadidos y el 95).
- **kNN «umbral ≈ 0.98»**: es 0.972. Y se dice que la media sería «más razonable», pero el script usa la distancia al vecino k (el máximo de las k).
- **«DBSCAN … método de clasificación»**: es agrupamiento (no supervisado); «Bayescan», «debes» y «B-scan» son DBSCAN.
- **Varianza de las canciones «30, 40, 60, 70, 80, 81 %»**: las acumuladas reales son 28.4, 45.9, 60.8, 75.5, 87.8 %. Y «38» es la canción 138.
- **Cardio «166 anomalías», «sensibilidad de 16 %», «acuracia del PCA 0.9» y «sensibilidad 0.815 con 0.4994»**: son 176 anomalías; la sensibilidad es 16 de 54 = 0.296 (16 es el conteo); la exactitud del PCA es 0.88; y con 0.4994 la sensibilidad es 0.4815 (26/54), no 0.815.

Diapositivas, scripts y verificación

- **Estandarizar y Mahalanobis** (diap. 11 y 13): es invariante a escalas (diferencia 7e-15); la estandarización importa para kNN, LOF, DBSCAN y One-Class SVM, y no es necesaria para el Isolation Forest (puntajes idénticos).
- **Covarianza clásica y enmascaramiento** (diap. 15): con los 6 casos añadidos la correlación baja de 0.83 a 0.70; con MCD el caso 204 también alerta (7 alertas).
- **LOF 1.5 «ilustrativo»** (diap. 21): la diapositiva ya lo dice; verificado: 10 alertas con k = 10 y 21 con k = 30. En R, `minPts = k + 1` equivale a `n_neighbors = k`.
- **Q y T^2** (diap. 29): confirmado; en canciones los diez mayores Q y los diez mayores T^2 no comparten ninguno (0). Con r = 7, Q ≈ 0 (2e-28).
- **Isolation Forest R frente a Python** (diap. 47): 0.9220 frente a 0.9072 cabe en la variación por semilla de scikit-learn (0.9072 a 0.9265); no es evidencia de que un programa sea mejor.
- **contamination** (diap. 39): solo fija el corte de `predict()`; con 0.1 el corte es 0.4994, el cuantil 90 % de entrenamiento. El «auto» (−0.5) marca 59 casos en prueba (sensibilidad 0.481).
- **Entrenamiento contaminado** (diap. 41): se ajusta con 9.5 % de anomalías; con solo normales el AUC sube a 0.943 y el AP a 0.535 → 0.695.
- **Transcripción con ruido**: «HIC / RIC / ÚRIC» = RIC (IQR), «KNN / KNL» = kNN, «loft» = LOF, «Isosation / Presolation Forest» = Isolation Forest, «ESF» = IF, «camins» = K-means, «VWSS» = WSS, «ROCK» = ROC. El recreo (1:05:53–1:26:21) quedó marcado.

Checklist, criterio de dominio y lo que viene

- ☐ Calculo cuartiles, límites del RIC y z a mano, y sé por qué |z| > 3 puede ser imposible
- ☐ Calculo D^2 con una matriz de covarianza 2×2 y lo comparo con χ^2
- ☐ Calculo k-distancia, lrd y LOF en un conjunto pequeño y explico qué corrige LOF frente a kNN
- ☐ Reconstruyo un punto con una componente (Q) y explico qué ve T^2 que Q no ve
- ☐ Razono la longitud esperada de aislamiento y calculo s = 2^(−E[h]/c)
- ☐ Elijo un corte según las alertas que puedo revisar y evalúo precisión y sensibilidad frente a la prevalencia
- ☐ Resuelvo los bloques 1 a 6 del cuaderno con al menos 80 % de aciertos
- ☐ **Siguiente**: el taller del curso; sin etiquetas se revisan casos con especialistas y se prueba estabilidad (vecinos, escala, semilla).