Clase 42 · Taller #3: respuesta a una campaña bancaria

Prof. Eloy Alvarado · 60 puntos · entrega miércoles 21-oct-2026, 23:59 · grupos de 3 a 5 · R o Python

Cómo usar esta guía

Dice **qué se pide** en cada pregunta, **qué concepto evalúa**, **en qué archivo tuyo ya lo estudiaste**, qué trampas hacen perder puntos y qué revisar antes de entregar. **No contiene respuestas ni cifras de la base del banco**: el taller es una evaluación calificada del grupo. Para ver cada técnica resuelta de punta a punta hay un notebook espejo con **otra base** (churn de telefonía, Clase 33): `Guias/notebooks/C42_Practica_TallerEspejo.ipynb`, con la misma estructura 1(a)–5(b) y, en cada paso, una nota «En el Taller 3 esto corresponde a…».

El caso

- Banco portugués que ofrece **depósitos a plazo** por teléfono; contactar a toda la cartera tiene costo.
- Hay que **anticipar qué registros contratarán** (`contrata = 1`, clase positiva) y recomendar a quién llamar.
- La predicción es **antes de la llamada registrada**. Cierra con perfiles (PCA, K-means) y registros inusuales (Mahalanobis).
- Muestra pública *Bank Marketing* (UCI), 4 521 registros: **3 617** de entrenamiento y **904** de prueba.
- Cubre el módulo de aprendizaje automático: **Clases 30 a 41** (el profesor dijo «desde la 30 en adelante, incluyendo los repasos»).

Nota y reparto de puntos

Sección	Pts	%
1 · Problema, preparación y representación	12	20 %
2 · Selección de variables y modelos	24	40 %
3 · Evaluación y decisión	10	17 %
4 · Componentes principales y agrupamiento	8	13 %
5 · Detección de anomalías	6	10 %
Total (Nota = 1 + P/10)	60	100 %

Se evalúan **procedimiento, resultados e interpretación**. Crédito parcial y **sin descontar dos veces un mismo error arrastrado**; se aceptan diferencias numéricas y ganadores distintos si la implementación y la regla de selección están justificadas.

Reglas de entrega

- Un solo archivo `Grupo_XX_Taller3.zip` por grupo (sube **una** persona) con el **notebook ejecutado** y los **dos .csv**.
- **Todo en el mismo lenguaje** (R o Python). Identifica a todos los integrantes. Rutas **relativas**; indica las **versiones de los paquetes**.
- Cada respuesta con **código, resultado e interpretación**. Si entregan HTML/PDF, adjunten también la **fuente** (.ipynb, .Rmd o .qmd).
- Plantillas del profesor: `Taller03_Python.ipynb / .qmd` y las equivalentes en R.
- Semilla **2026**; **conservar las filas**; **5 pliegues entregados** (columna `pliegue`); la prueba solo se usa en **3(b)**.

Plan para los días que quedan (hoy es domingo 18)

Día	Meta del grupo
Dom 18	Leer enunciado y esta guía; repartir roles; correr el notebook espejo; **Sección 1** y la carga de datos
Lun 19	**Sección 2** completa (OOF de los 9 modelos) y 3(a); redactar 2(c) con la tabla en mano
Mar 20	3(b), **Secciones 4 y 5**; ejecutar el notebook **de cero** y corregir
Mié 21	Revisión cruzada con el checklist, zip, subir **antes de las 18:00** (margen de 6 h)

Orden de estudio sugerido (≈ 3 h): Guía C30 → C33 (selección dentro del pliegue) → C38 (OOF, log loss, umbral por costo) → resto de las clases según la tabla de las páginas 2–3 → notebook espejo (un ejercicio por pregunta) → recién entonces abrir la plantilla del taller.

Dudas para el foro (el enunciado no las precisa): ¿cómo tratar *dia* y *mes* (numéricas o categorías)? · ¿qué valores toma *pliegue* (0–4 o 1–5)? · ¿las columnas *mora/hipoteca/prestamo* entran como 0/1? · ¿se acepta Boosting de *HistGradientBoosting* o *XGBoost*? · ¿pueden repetirse los grupos de los talleres anteriores? (la pregunta del chat quedó cortada en el video y no se alcanza a oír la respuesta).

Pregunta por pregunta: qué piden y dónde lo estudiaste

Los archivos son de tu carpeta Guias/ (notebooks y guías PDF). «Partes» = secciones del notebook. Cada clase tiene su guía C3x_Guia_*.pdf y apuntes en Guias/apuntes/.

Sección 1 · Problema, preparación y representación (12 pts)

Pregunta	En palabras simples	Qué evalúa	Dónde lo estudiaste
1(a) 3 pts	Decir qué tipo de problema es, qué es una fila y qué se predice. Explicar por qué **duracion** no puede usarse antes de la llamada y sacarla de los predictores (junto con *id_cliente, pliegue, contrata*).	Clasificación supervisada, unidad de observación, respuesta. Fuga por **momento de medición**: ¿existe la variable cuando hay que decidir?	`C31_IntroML.ipynb` **A1** (del problema a la tarea) `C30_PreparacionML.ipynb` **B3** (fuga de datos)
1(b) 4 pts	Revisar tipos, faltantes, categorías *unknown*, duplicados y balance. Interpretar los **saldo negativos** y el código **−1** de dias_previos. ¿Bastaría la exactitud de predecir siempre la clase mayoritaria?	Calidad de datos: valor *imposible* vs. *posible* vs. *código*; exactitud vs. sensibilidad; línea base.	`C30_PreparacionML.ipynb` **A1–A3, D2** `C33_FeatureEngineering.ipynb` **A1–A4** (imposibles, duplicados, no borrar filas) `C31_IntroML.ipynb` **B3**
1(c) 5 pts	Crear *contactado_antes* y *log_contactos_previos* y explicar su sentido; cambiar −1 por 0 conservando el indicador; mantener *unknown* como categoría; one-hot; **describir y aplicar el escalamiento que necesita cada método**.	Variables derivadas, códigos especiales, codificación, qué métodos requieren escala (logística y SVM sí; árboles y NB no), todo dentro del *Pipeline*.	`C30_PreparacionML.ipynb` **A1, B4, C1** `C32_ReduccionDimensionalidad.ipynb` **B1–B4** `C33_FeatureEngineering.ipynb` **B2**; `C34_ArbolesDecision.ipynb` **D2**; `C37_SVM.ipynb` **B4**

Sección 2 · Selección de variables y modelos supervisados (24 pts)

Pregunta	En palabras simples	Qué evalúa	Dónde lo estudiaste
2(a) 5 pts	Logística **sin penalización**: todas las columnas preparadas vs. las **10 de mayor F de ANOVA** (elegidas en cada pliegue). Informar las columnas por pliegue y comparar métricas OOF. ¿Diferencia con PCA? ¿Limitación del filtro univariado?	Selección **dentro** del pliegue; filtro supervisado vs. extracción no supervisada; redundancia e interacciones.	`C33_FeatureEngineering.ipynb` **C2–C5, E1–E4** (ANOVA F, irrelevante sola, XOR, redundancia, pipeline honesto) `C32_ReduccionDimensionalidad.ipynb` **Parte C** (PCA) `C37_SVM.ipynb` **A2** (penalty=None)
2(b) 11 pts	Comparar **9 filas** con predicciones OOF: referencia, logística (2), árbol prof. 3 y 6 (mín. 20 por hoja), Random Forest (200, √p, mín. 10), Boosting (≤ 200, prof. 3; informar variante y tasa), SVM radial (C = 1, γ = 1/p) y Naive Bayes gaussiano. Log loss, Brier, AUC; **SVM solo AUC**; árboles: log loss medio de entrenamiento. Elegir el probabilístico de **menor log loss OOF**.	Validación cruzada con pliegues dados, OOF, métricas probabilísticas, configuración exacta de hiperparámetros, puntaje de decisión vs. probabilidad.	`C38_EvaluacionModelos.ipynb` **A3, B2, B3** (OOF, log loss/Brier, AUC) `C34_ArbolesDecision.ipynb` **C1–C2**; `C35_RandomForest.ipynb` **B1, B3** `C36_Boosting.ipynb` **C3, D1**; `C37_SVM.ipynb` **B3, C3** **Naive Bayes:** `C40_NaiveBayes.ipynb` **B3–B4, C3–C4, D2**
2(c) 8 pts	Interpretar con los números de la tabla: profundidad y sobreajuste; bagging vs. RF vs. boosting; independencia condicional y límite de la gaussiana con columnas binarias; efecto de C, γ y escala en SVM; **¿mejor orden implica mejores probabilidades?**	Sesgo–varianza, brecha entrenamiento–validación, supuestos de Naive Bayes, hiperparámetros del kernel, ranking (AUC) vs. calibración (log loss).	`C34_ArbolesDecision.ipynb` **C2**; `C35_RandomForest.ipynb` **A3, B2–B3**; `C36_Boosting.ipynb` **A3** `C37_SVM.ipynb` **B2–B4, C3**; `C38_EvaluacionModelos.ipynb` **B2–B4** (calibración)

Sección 3 · Evaluación y decisión (10 pts)

Pregunta	En palabras simples	Qué evalúa	Dónde lo estudiaste
3(a) 4 pts	Con las probabilidades OOF del modelo elegido, evaluar umbrales **0.05, 0.10, …, 0.95**, predecir contratación si **p ≥ t** y elegir el que minimiza **C(t) = FP + 5·FN**. Tabla o curva e interpretación de ambos errores.	Matriz de confusión por umbral, costos asimétricos, qué significan FP y FN para el banco.	`C38_EvaluacionModelos.ipynb` **B5, C7** (costo y umbral; umbral teórico) `C30_PreparacionML.ipynb` **D2–D3**; `C37_SVM.ipynb` **A3–A4**
3(b) 6 pts	**Reajustar con todo el entrenamiento** y evaluar en la prueba: log loss, Brier, AUC y curva ROC; umbral elegido vs. 0.50 con matriz de confusión, sensibilidad, especificidad y **C/n**; incluir la referencia. Recomendar, concluir y decir qué falta verificar.	Evaluación final honesta (prueba una vez), ROC, comparación de reglas por costo, lectura crítica y límites.	`C38_EvaluacionModelos.ipynb` **A5, B3, B6** `C37_SVM.ipynb` **A4**; `C31_IntroML.ipynb` **B3**

Secciones 4 y 5 · Componentes principales, agrupamiento y anomalías (14 pts)

Se usan solo **edad, saldo, contactos_campana y contactos_previos** del entrenamiento, **estandarizadas con media y desviación muestral**.

Pregunta	En palabras simples	Qué evalúa	Dónde lo estudiaste
4(a) 3 pts	PCA: varianza explicada por PC1 y PC2, su suma, las cargas y el gráfico de las observaciones en ese plano. ¿Qué resume la proyección y qué omite?	Autovalores/varianza explicada, interpretación de cargas, límites de una proyección (no usa la respuesta).	`C32_ReduccionDimensionalidad.ipynb` **C2, C4** `C31_IntroML.ipynb` **C3**
4(b) 5 pts	K-means con **k = 2, 3, 4** y **≥ 30 inicializaciones**: comparar WSS y silueta media, elegir el k de mayor silueta, informar tamaños, perfiles, grupos en el plano PCA y la proporción de contratación por grupo. ¿Por qué los grupos no son clases predichas?	Aprendizaje no supervisado, WSS vs. silueta, perfilamiento, diferencia entre segmentar y predecir.	`C31_IntroML.ipynb` **C1–C2** Clase 39 (profesor): `clase_39_clustering.pdf`, `kmeans_numero_clusters.py`
5(a) 3 pts	Calcular la distancia de **Mahalanobis al cuadrado**; corte = cuantil 0.99 de una **χ^2 con 4 g. l.**; informar corte, cantidad y % marcados; presentar los **dos registros** de mayor distancia con sus valores originales.	Distancia que usa la covarianza, χ^2 como referencia bajo normalidad, lectura de registros.	`C41_Anomalias.ipynb` **A3** Guía `C41_Guia_Anomalias.pdf` (página de Mahalanobis)
5(b) 3 pts	¿Por qué son inusuales esos dos? ¿Demuestra que son errores? ¿El corte **garantiza** marcar el 1 %? Fundamentar y decir qué se revisaría antes de eliminar un registro.	Atípico ≠ error; supuestos de la χ^2; criterio de revisión (unidades, duplicados, contexto, con/sin el caso).	`C41_Anomalias.ipynb` **A3, A7, D1** Guía C41: recuadro «¿atípico, error o evento real?»

Naive Bayes (Clase 40). Para 2(b) y 2(c) estudia `C40_NaiveBayes.ipynb` y `C40_Guia_NaiveBayes.pdf` (independencia condicional, copias de una variable tratadas como independientes, *GaussianNB* vs. *BernoulliNB*); material del profesor, como apoyo secundario: `Clase 40 Naive Bayes…/DipDS_2026_S40.pdf` y `40_naive_bayes.py`. La base conceptual (teorema de Bayes, P(y|x) proporcional a P(x|y)·P(y)) está en `C23_Bayesiana.ipynb`, pero esa clase trata inferencia bayesiana, **no** Naive Bayes. El notebook espejo muestra cómo se ve un Naive Bayes gaussiano con muchas columnas redundantes.

Trampas que hacen perder puntos

Cada fila es un error frecuente; la columna derecha dice cómo evitarlo

#	Trampa	Cómo evitarla
1	Usar **duracion**, *id_cliente* o *pliegue* como predictores.	Excluir *duracion, id_cliente, pliegue, contrata* de X desde el comienzo y dejar la lista escrita.
2	Ajustar escalador, one-hot, imputación o selección con **todo** el entrenamiento y recién después validar (fuga).	Un *Pipeline/ColumnTransformer* que se ajusta **solo con las filas de ajuste** de cada pliegue (R: *recipes* dentro del bucle).
3	No usar la columna **pliegue** dada (*cross_val_score*, *KFold* propio).	Bucle sobre *sorted(pliegue.unique())*; ajuste = pliegue ≠ k, validación = pliegue = k. Mira primero los valores de la columna.
4	F de ANOVA calculado fuera del pliegue; no informar las columnas seleccionadas **por pliegue**.	*SelectKBest* dentro del Pipeline; guardar *get_support()* de cada ajuste y mostrar una tabla pliegue × columnas.
5	SVM: pedir probabilidades, calcular log loss/Brier o promediar puntajes entre pliegues como si fueran probabilidades.	*decision_function* OOF y **solo AUC**; C = 1; **γ = 1/p** con p = columnas **ya preparadas** (después del one-hot).
6	Referencia mal definida (0.5, o la tasa de todo el entrenamiento dentro de la CV).	En cada pliegue: tasa positiva de las **filas de ajuste**; en la evaluación final: tasa de **todo** el entrenamiento.
7	Elegir el modelo por AUC, o dejar competir a la SVM o a la referencia.	Regla escrita: **menor log loss OOF entre los probabilísticos**. Un ganador distinto al de otros grupos es válido si está justificado.
8	Árboles: olvidar el **log loss medio de entrenamiento de los cinco ajustes**; confundir mínimo por hoja con mínimo para dividir.	Calcular log loss sobre las filas de ajuste en cada pliegue y promediar; *min_samples_leaf* = 20 (árboles) y 10 (RF).
9	Umbral con **p > t**, o costo 5·FP + FN; tocar la prueba antes de 3(b) o elegir el umbral con ella.	Regla **p ≥ t** con t = 0.05, 0.10, …, 0.95; C(t) = FP + 5·FN; el umbral sale de los **OOF**; la prueba se usa una sola vez.
10	Confundir **ordenar** con **dar buenas probabilidades** (AUC alto ≠ log loss bajo).	En 2(c) contrasta ambas métricas con la propia tabla; el AUC no cambia con transformaciones monótonas de p.
11	Naive Bayes gaussiano sobre columnas 0/1 «porque lo pide el enunciado»: se interpreta mal el resultado.	Hacerlo como se pide y **comentar** el límite (una dummy no es normal; independencia condicional falsa; probabilidades extremas).
12	Perder el indicador al reemplazar −1 por 0, o tratar −1 como un número de días.	Crear *contactado_antes* **antes** de reemplazar; explicar que −1 es un código y que **saldo** negativo es un valor posible.
13	PCA/K-means con desviación poblacional (*StandardScaler* divide por n) o sobre variables sin estandarizar; K-means con una sola inicialización.	Z = (x − media)/sd con **ddof = 1**; *n_init* ≥ *30*, semilla 2026; elegir k por **silueta** y reportar WSS.
14	Mahalanobis: decir que el corte «marca el 1 %» o que lo marcado «son errores».	El 1 % vale solo con normalidad multivariada y parámetros conocidos; una alerta es una **pista de revisión** (C41).
15	Mezclar lenguajes, rutas absolutas, no declarar versiones, no ejecutar de cero, entregar solo código sin interpretación.	Reiniciar kernel y ejecutar todo; rutas relativas; imprimir versiones; **una interpretación bajo cada resultado**.

Para grupos que elijan R. Mismas decisiones, otras funciones: *glm(family = binomial)*, *rpart* (*minbucket* = 20, *cp* = 0), *ranger* (*num.trees* = 200, *mtry* = floor(√p), *min.node.size* = 10), *e1071::svm* (*decision.values* = TRUE; ojo con el signo), *naiveBayes*, *prcomp*, *kmeans(nstart = 30)*, *mahalanobis* y *qchisq(0.99, 4)*. La tabla completa R ↔ Python está al final del notebook espejo. El profesor aceptó **diferencias numéricas** entre lenguajes.

Checklist de entrega y lo que dijo el profesor en la clase

Transcripción corregida de «Clase 42 taller 3» (≈ 19 min); los tiempos son mm:ss del video

- ☐ Notebook ejecutado **de punta a punta** en un kernel limpio, sin errores
- ☐ Nombres de los **integrantes** en el encabezado
- ☐ Un solo lenguaje; **rutas relativas**; versiones de paquetes impresas
- ☐ Semilla **2026** en todo lo aleatorio; clase positiva = 1
- ☐ *duracion, id_cliente, pliegue, contrata* fuera de los predictores
- ☐ Transformaciones y selección **solo con filas de ajuste** de cada pliegue
- ☐ Se usó la columna **pliegue** entregada (5 pliegues)
- ☐ 1(b): faltantes, *unknown*, duplicados, balance, saldo negativo y −1 interpretados
- ☐ 1(c): variables nuevas explicadas y escalamiento descrito por método
- ☐ 2(a): columnas elegidas **por pliegue** + métricas OOF + diferencia con PCA + limitación
- ☐ 2(b): 9 filas; SVM solo AUC; árboles con log loss de entrenamiento; modelo elegido con regla escrita
- ☐ 2(c): las cinco preguntas respondidas con los números de la tabla
- ☐ 3(a): umbrales 0.05–0.95, $p \geq t$, $C = FP + 5 \cdot FN$, tabla o curva
- ☐ 3(b): reajuste con todo el entrenamiento; prueba **una vez**; ROC; matrices en t* y 0.50; C/n; referencia; recomendación
- ☐ 4–5: cuatro variables estandarizadas (sd muestral); PCA, k-means (n_init ≥ 30), Mahalanobis con $\chi^2(0.99; 4)$
- ☐ Interpretación bajo **cada** resultado; gráficos con ejes y título
- ☐ Si hay HTML/PDF: **fuente** adjunta. Zip `Grupo_XX_Taller3.zip` con notebook + 2 .csv
- ☐ Subido **antes de las 18:00 del miércoles** (límite 23:59); una sola persona sube

Qué aclaró el profesor al leer el enunciado (con tiempos)

Tiempo	Lo que dijo	Qué cambia para ti
01:07–01:17	Grupos de tres a cinco; admite uno algo menor, pero recomienda al menos tres.	Define el grupo hoy; solo uno sube el archivo.
02:07–02:21	El taller abarca el módulo de aprendizaje automático, **desde la sesión 30 en adelante, incluidos los repasos**.	Las Clases 30–41 son la base; la Clase 43 (bootstrap) no se menciona en el enunciado.
04:37–05:30	El zip se llama **Grupo_XX_Taller3**; si compilan a PDF/HTML, deben **incorporar los archivos fuente** (el .qmd o el notebook).	No basta el HTML: adjunta la fuente.
06:03–06:25	Entrenar solo con *clientes_entrenamiento*; la prueba está **reservada para 3(b)**; conservar las filas; semilla 2026; contrata = 1 es la clase positiva.	Sin eliminar filas; sin tocar la prueba antes.
06:31–07:10	**5 pliegues**; aprender transformaciones y selección **solo con las filas de ajuste**; reunir predicciones fuera de pliegue: probabilidades y, para SVM, puntajes de decisión. La referencia es la proporción positiva de las filas de ajuste; en la evaluación final, la de **todo** el entrenamiento.	Es la trampa 2, 3, 5 y 6.
08:16–08:30	Las particiones las hizo el profesor por **reproducibilidad y para tener un recurso común entre lenguajes**.	No rehacer la separación ni los pliegues.
10:47–11:18	Para SVM, **solo AUC**; incluir la referencia y, para ambos árboles, el log loss medio de entrenamiento de los cinco ajustes.	Tabla de 2(b) con esos detalles.
11:39–11:48	«¿Un mejor ordenamiento implica mejores probabilidades? Tienen que fundamentarlo.»	Pregunta explícita de 2(c); no se responde con un sí/no.
12:44–13:13	3(b): informar log loss, Brier, AUC y ROC; comparar el umbral elegido con 0.5; **«traten de explayarse lo suficiente»** en las repercusiones.	La recomendación al banco merece extensión y matices.
14:36–15:12	5(b): ¿demuestra errores? ¿el corte garantiza el 1 %? ¿qué revisarían antes de eliminar? **Un error no arrastra descuento sustancial** al resto; **pueden existir diferencias numéricas** entre lenguajes.	No te bloquees por un número distinto; justifica.
16:07–16:37	Entrega el **miércoles 21**; la idea es empezar hoy y resolver dudas; habrá un **foro** en el módulo como en el Taller 2.	Usa el foro para dudas de interpretación.