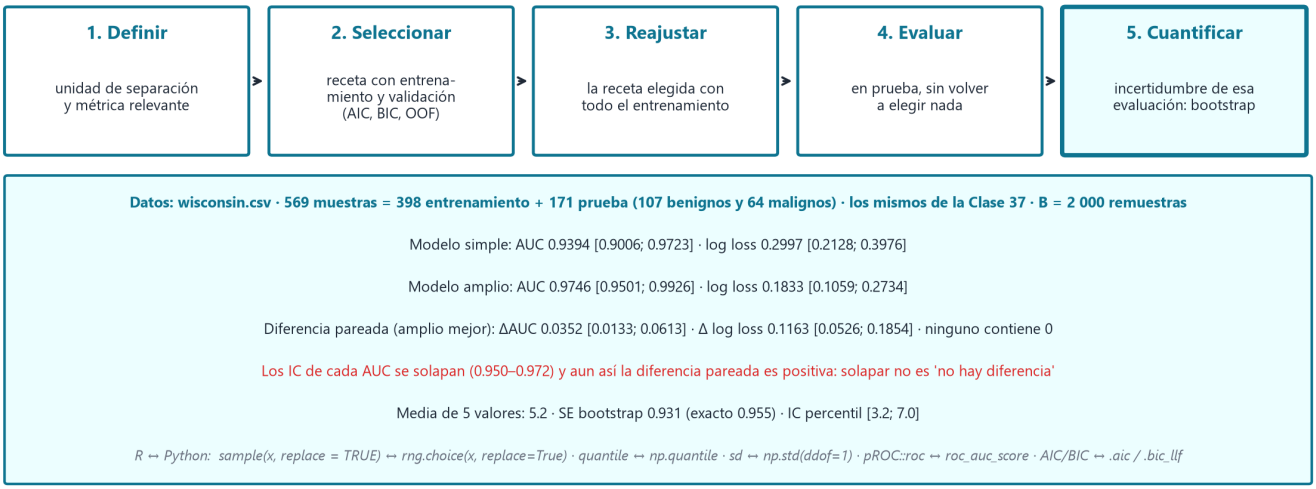
# Clase 43 · Evaluación estadística de modelos predictivos y bootstrap

Profesor Pedro Luiz Ramos · retoma IC y valores p (Clase 22), la credibilidad bayesiana (Clase 23), SVM y Wisconsin (Clase 37) y OOF, CV y bootstrap/.632 (Clase 38)

**La gran idea de la clase**

**Una métrica de prueba es una estimación, no una constante**: con otros casos de evaluación saldría otro valor. Por eso, después de **seleccionar** la receta con entrenamiento y validación y **evaluarla** una sola vez en prueba, hay que **cuantificar la incertidumbre**. El **bootstrap** remuestrea con reposición los casos de prueba (con los modelos y sus predicciones fijos), recalcula la métrica miles de veces y usa los percentiles como intervalo. Para **comparar dos modelos** se remuestrean los **mismos casos** para ambos y se mira la **distribución de la diferencia**: si el intervalo de la diferencia contiene 0 no hay evidencia clara; si no lo contiene, la hay. Comparar dos intervalos separados no es lo mismo.

## La clase en una imagen




### Lo que necesitas ANTES

- **IC y valor p** (Clase 22) e **intervalo creíble** (Clase 23): qué significa «95 %»
- **Regresión logística, AUC y Wisconsin** (Clases 31 y 37): las mismas 569 muestras y la misma partición
- **OOF, validación cruzada y bootstrap/.632** (Clase 38): aquí se usa el bootstrap sobre los casos de **prueba**
- **R ↔ Python**: el profesor trae los dos scripts, con generadores aleatorios distintos

### Ruta de la clase y datos

- **Una diferencia no basta → AIC, BIC y OOF** (seleccionar) **→ bootstrap de la media → IC de AUC y log loss → diferencia pareada → alcance y límites**
- **wisconsin.csv**: 569 muestras, 398 de entrenamiento (5 pliegues) y 171 de prueba (107 benignos y 64 malignos). Es la misma partición de la Clase 37 (con las columnas id y fold)
- Pregunta guía: ¿el modelo amplio es mejor que el simple, o fue la suerte de esta prueba?

**Puentes con otras clases (sin repetirlas)**

**C22 → C43**: allí se construía un IC y se leía el valor p de un contraste; hoy el IC es para una **métrica de predicción** y no tiene fórmula cerrada simple (se obtiene remuestreando). **C23 → C43**: con Beta(1 + k, 1 + n − k) el intervalo creíble de la exactitud del modelo amplio (161 de 171) es [0.896; 0.968], casi igual al bootstrap [0.901; 0.971]. **C37 → C43**: el modelo amplio es la logística de la Clase 37 (AUC 0.9746, exactitud 0.9415); ahora se le pone un intervalo. **C38 → C43**: el bootstrap OOB y el .632 estimaban el **error** de una receta; aquí el bootstrap mide la **incertidumbre de la evaluación** de modelos ya ajustados.

**Recuadro: ¿0.9746 es «la» AUC del modelo?**

No: es la AUC en **estos** 171 casos. Con el bootstrap, el intervalo del 95 % es [0.9501; 0.9926]; el simple, [0.9006; 0.9723]. Una sola cifra de prueba sin intervalo oculta cuánto podría cambiar con otra muestra de casos.

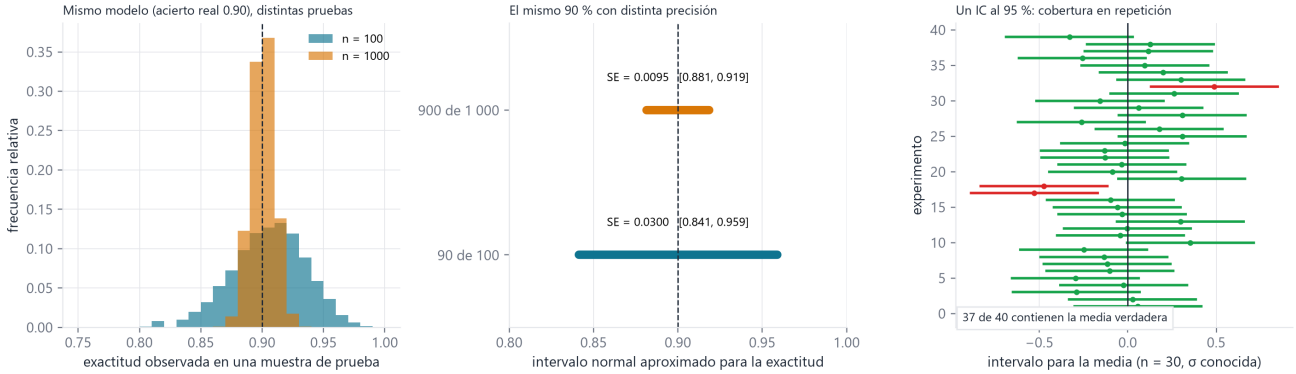
# Clase 43 · Una diferencia observada no basta

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

**Dos modelos con log loss 0.30 y 0.28 difieren en 0.02, pero otra muestra de evaluación podría dar otra diferencia. Evaluar también es cuantificar la incertidumbre: el error estándar describe cuánto varía una estimación, no cuánto difieren los casos entre sí.**

## Conceptos clave

1. **El mismo modelo, otras pruebas.** Con acierto real 0.90, la exactitud observada tiene desviación 0.0299 con n = 100 y 0.0095 con n = 1 000: el modelo no cambió, cambiaron los casos.
2. **SE de una exactitud.** SE ≈ √(â(1 − â)/n): 0.0300 con 90 de 100 y 0.0095 con 900 de 1 000. Intervalos normales aproximados [0.841; 0.959] y [0.881; 0.919] (diapositiva 12).
3. **Qué significa un IC.** «95 %» describe el **procedimiento**: en 40 muestras simuladas, 37 intervalos contienen la media verdadera (la diapositiva muestra 38); no todos deben hacerlo.




Izquierda: distribución de la exactitud observada para n = 100 y n = 1 000 (diapositiva 11). Centro: SE e intervalo normal del mismo 90 %. Derecha: 40 intervalos al 95 % para una media (σ = 1 conocida).

## Fórmulas y reglas

SE(â) ≈ √(â(1 − â)/n)

IC aprox. = â ± 1.96 · SE

desviación estándar de los datos ≠ error estándar de una estimación

dependencia entre casos → otro análisis

## Con los números de la clase

- Wisconsin, modelo amplio: 161 de 171 → â = 0.9415, SE = 0.0179; sensibilidad 58 de 64: SE = 0.0364 (solo 64 malignos)
- Una mejora pequeña puede ser relevante o no según el objetivo: hace falta el intervalo y un criterio previo
- Con la fórmula normal, para reducir el SE a la mitad se necesitan 4 veces más casos
- **Cuidado.** La fórmula del SE supone casos independientes y un clasificador fijo; cerca de 0 o 1 el intervalo normal puede salirse de [0, 1] (use Wilson o exacto). El IC de una media no es un IC para los datos.

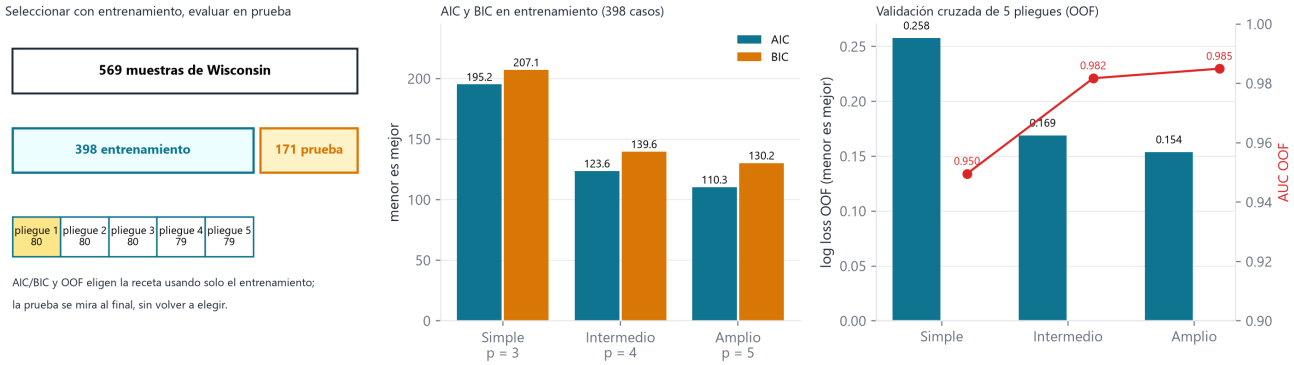
# Clase 43 · Seleccionar y evaluar son tareas distintas: AIC, BIC y OOF

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

**Primero se define la unidad de separación y la métrica; se selecciona la receta con entrenamiento y validación; se reajusta con todo el entrenamiento; se evalúa en prueba sin volver a elegir; y recién entonces se cuantifica la incertidumbre. Cambiar la receta mirando la prueba la deja de hacer independiente.**

## Conceptos clave

1. **Receta dentro del pliegue.** Estandarizar, elegir variables y fijar el umbral se hace **solo con las filas de ajuste** (en un Pipeline). Estandarizar antes de separar filtra información; el bootstrap no corrige una fuga anterior.
2. **AIC y BIC.** AIC = $-2\ell + 2p$; BIC = $-2\ell + p \log(n)$. Menor es mejor y solo se comparan **dentro de la columna**. En Wisconsin ambos eligen el modelo amplio: AIC 110.29 y BIC 130.22, frente a 195.16 y 207.12 del simple.
3. **Condiciones de uso.** Misma respuesta y mismas observaciones, verosimilitudes comparables y ajuste por máxima verosimilitud: no se aplican a SVM, Isolation Forest ni logísticas penalizadas como si nada cambiara.




Izquierda: la partición de Wisconsin (398 + 171; pliegues de 80, 80, 80, 79 y 79). Centro: AIC y BIC en entrenamiento. Derecha: log loss y AUC fuera de pliegue (OOF) con los cinco pliegues del profesor.

## Fórmulas y reglas

AIC = $-2\ell(\hat{\theta}) + 2p$

BIC = $-2\ell(\hat{\theta}) + p \log(n)$

p cuenta el intercepto y cada coeficiente

$\Delta$AIC = AIC − AIC mínimo

```
modelo.aic
modelo.bic_llf # = -2ℓ + p·ln(n), como BIC() de R
```

## Con los números de la clase

- Ejemplo de la clase (n = 100): AIC 166, 162 y 167; BIC 173.82, 175.03 y 187.84 → AIC elige B y BIC elige A
- OOF en entrenamiento: log loss 0.258, 0.169 y 0.154; AUC 0.950, 0.982 y 0.985
- Un AIC menor no cuantifica una mejora práctica ni garantiza buenas predicciones
- **Cuidado.** Seleccionar con OOF no vuelve independiente la cifra del ganador. Y los 171 casos de prueba ya se revisaron en clases anteriores: aquí son una **demostración**, no una validación nueva.

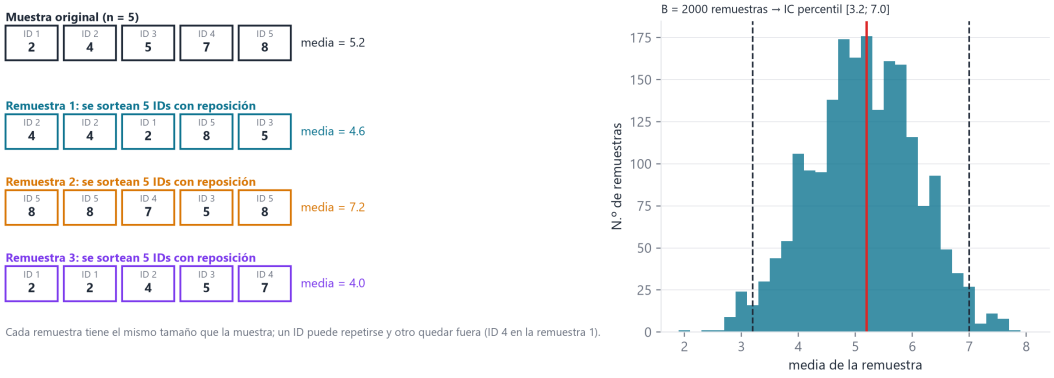
# Clase 43 · Bootstrap: remuestrear con reposición

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

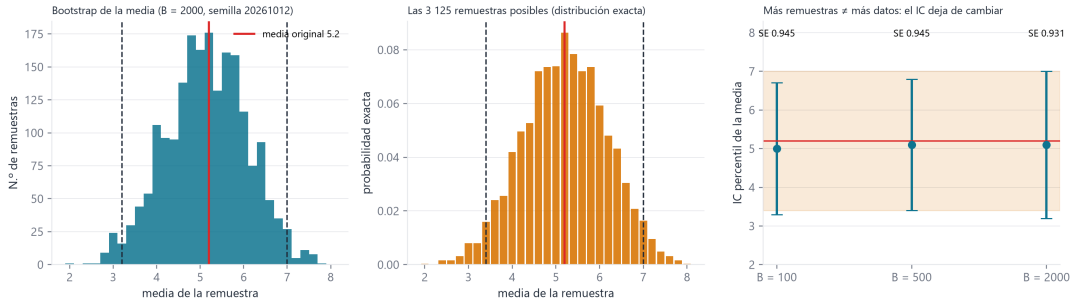
**El bootstrap parte de la muestra observada, no de la población: se sortean n IDs con reposición para formar una remuestra del mismo tamaño, se calcula la estadística y se repite B veces. Las B estadísticas forman una distribución bootstrap; sus percentiles 2.5 y 97.5 dan el IC percentil.**

## Conceptos clave

1. **Una remuestra.** Con los valores 2, 4, 5, 7 y 8 (media 5.2), la remuestra 1 de la diapositiva sortea los IDs 2, 2, 1, 5 y 3 → media 4.6; la 2, media 7.2; la 3, media 4.0.
2. **Error estándar e IC.** Con B = 2 000 (semilla 20261012) en Python: SE = 0.9306 e IC [3.2; 7.0]; en R: 0.966 y [3.4; 7.0]. La distribución **exacta** (3 125 remuestras) da SE 0.9550 e IC [3.4; 7.0].
3. **Más remuestras ≠ más datos.** Subir B reduce el error Monte Carlo del cálculo (SE 0.945, 0.945 y 0.931 con 100, 500 y 2 000), pero no la incertidumbre de tener solo 5 casos.




Izquierda: la muestra original y las tres remuestras de la diapositiva 31; el ID 4 queda fuera de la primera. Derecha: distribución bootstrap de la media con B = 2 000 y límites percentiles.




Izquierda: el resultado de Python. Centro: las 3 125 remuestras posibles. Derecha: el IC apenas cambia al aumentar B.

## Fórmulas y reglas

$\theta^*_b$ = estadística de la remuestra b

$SE_{boot} = \sqrt{\Sigma(\theta^*_b - \theta^*)^2/(B-1)}$

IC percentil = $[Q_{0.025}(\theta^*), Q_{0.975}(\theta^*)]$

$P(\text{un caso queda fuera}) = (1 - 1/n)^n \approx 0.368$

```
rng = np.random.default_rng(20261012)
m[b] = rng.choice(v, size=5,
replace=True).mean()
np.quantile(m, [0.025, 0.975])
```

## Con los números de la clase

- Un caso queda fuera de una remuestra con probabilidad 0.328 si n = 5 y 0.367 si n = 171 (límite 1/e = 0.368)
- R y Python usan generadores distintos: las diferencias pequeñas entre límites son variación Monte Carlo
- Con cinco datos, el intervalo no está bien calibrado: sirve para entender la cuenta
- **Cuidado.** Sortear filas como si fueran independientes subestima la incertidumbre si hay varias mediciones por paciente (remuestrear pacientes) o dependencia temporal (bloques).

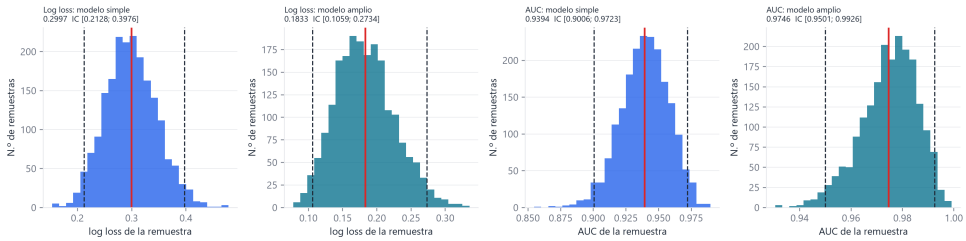
# Clase 43 · IC bootstrap de las métricas de un modelo fijo

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

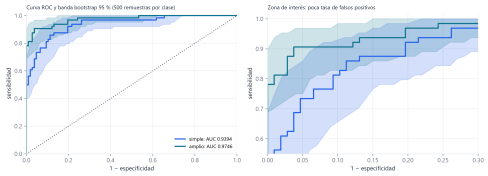
**En la prueba no se entrena de nuevo: se conservan las probabilidades de cada caso y se remuestrean los casos. El log loss y la exactitud se remuestrean por filas; la AUC, por clase (107 benignos y 64 malignos), y los dos modelos usan los mismos IDs. El intervalo estudia la evaluación del modelo ya ajustado.**

## Conceptos clave

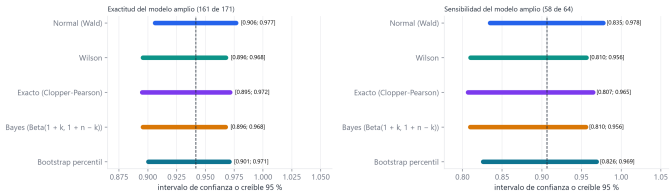
1. **Resultados puntuales.** Simple: AUC 0.9394, log loss 0.2997, exactitud 0.8596, sensibilidad 0.7812. Amplio: 0.9746, 0.1833, 0.9415 y 0.9062 (umbral 0.5 para las dos últimas).
2. **Intervalos percentiles.** AUC simple [0.9006; 0.9723] y amplio [0.9501; 0.9926]; log loss simple [0.2128; 0.3976] y amplio [0.1059; 0.2734] (en R el profesor obtuvo [0.9004; 0.9708], [0.9503; 0.9915], [0.2124; 0.4005] y [0.1066; 0.2798]).
3. **Otras métricas.** Exactitud del amplio: Wilson [0.896; 0.968], exacto [0.895; 0.972], bootstrap [0.901; 0.971]. Sensibilidad (64 casos): bootstrap [0.826; 0.969].




Distribuciones bootstrap (B = 2 000) de log loss y AUC de los modelos simple y amplio; línea roja: estimación original; discontinuas: límites percentiles (diapositivas 42 y 43).




Curva ROC con banda bootstrap del 95 % (500 remuestras por clase): la del modelo simple es más ancha.




Cinco formas de intervalo para la exactitud y la sensibilidad del modelo amplio (puente con las Clases 22 y 23).

## Fórmulas y reglas

log loss = −media[y ln p + (1 − y) ln(1 − p)]

AUC: se remuestrea dentro de cada clase

mismos IDs para los dos modelos

no se repite fit() ni predict() en el ciclo

## Con los números de la clase

- Los errores seguros pueden inflar el log loss de una remuestra; el IC del simple (0.185 de ancho) es más ancho que el del amplio (0.167)
- La banda ROC media mide 0.103 (simple) y 0.057 (amplio) de ancho
- No aplicar log loss a puntajes de SVM o de anomalía que no sean probabilidades
- **Cuidado.** El intervalo no incluye la variación por volver a entrenar ni cambios futuros de población o prevalencia.

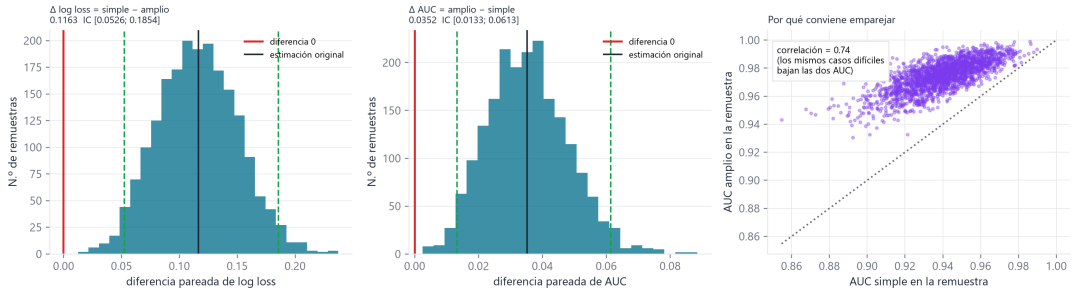
# Clase 43 · Comparar dos modelos: la diferencia pareada

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

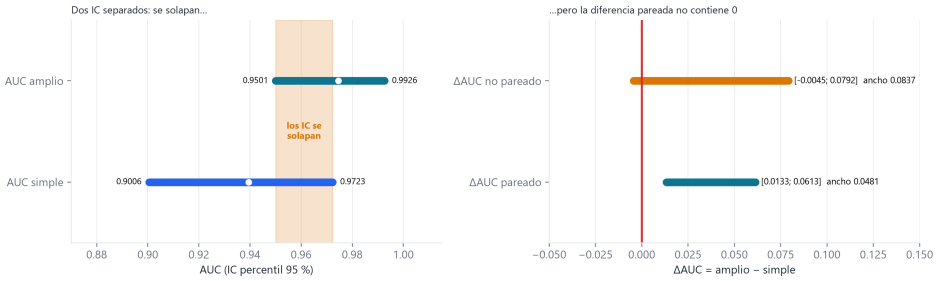
**Los dos modelos ven los mismos casos: un caso difícil los perjudica a ambos. Por eso se remuestrean los mismos IDs, se calcula la diferencia en cada remuestra y se toman los percentiles de esas diferencias. Restar los extremos de dos intervalos separados no es lo mismo.**

## Conceptos clave

1. **La diferencia.** Positivo favorece al amplio: Δ log loss = simple − amplio = 0.1163, IC [0.0526; 0.1854]; ΔAUC = amplio − simple = 0.0352, IC [0.0133; 0.0613]. Ninguno contiene 0.
2. **Emparejar angosta el intervalo.** La AUC del simple y del amplio en cada remuestra tiene correlación 0.74. Con remuestras independientes el ΔAUC daría [-0.0045; 0.0792] (ancho 0.084, contiene 0) frente a [0.0133; 0.0613] (ancho 0.048).
3. **Estadístico y utilidad.** Que el IC excluya 0 muestra una diferencia **estadística**; que sea **útil** depende de una mejora relevante fijada antes (0.010 no es regla universal). Si el IC contiene 0 hay «no hay evidencia clara», no «equivalencia».




Izquierda y centro: diferencias pareadas de log loss y de AUC en 2 000 remuestras (rojo: 0; verde: límites). Derecha: las AUC de las dos remuestras están correlacionadas (diapositivas 47 a 50).




Izquierda: los IC de cada AUC se solapan. Derecha: la diferencia pareada no contiene 0 y es más precisa que la no pareada.

## Fórmulas y reglas

Δ*_b = LL*_simple,b − LL*_amplio,b

IC de la diferencia = percentiles de Δ*

log loss: simple − amplio; AUC: amplio − simple

positivo favorece al amplio en ambos

```
d = ll_boot[:, 0] - ll_boot[:, 1]
d_auc = auc_boot[:, 1] - auc_boot[:, 0]
np.quantile(d, [0.025, 0.975])
```

## Con los números de la clase

- Las dos primeras remuestras de log loss del script dan Δ = 0.1566 y 0.0741; la diferencia original es 0.1163
- En ninguna de las 2 000 remuestras el amplio fue peor (0 % con ΔAUC ≤ 0)
- Este es un IC de diferencia, no un valor p; pero «el IC excluye 0» es equivalente a rechazar «sin diferencia» al 5 %
- **Cuidado.** Dos IC que se solapan no implican «sin diferencia significativa»: la diferencia pareada puede excluir 0 aunque los IC individuales se toquen.

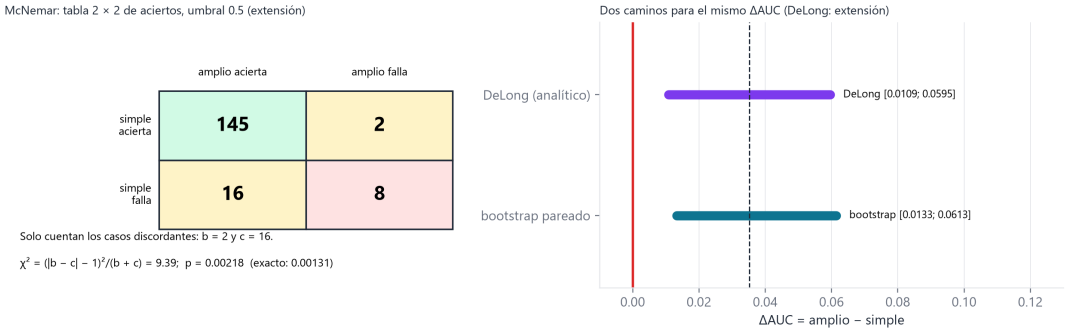
# Clase 43 · Alcance del intervalo: qué cubre y qué no

Fuente: transcripción + diapositivas clase.pdf + evaluacion_bootstrap.py / .R del profesor Pedro Luiz Ramos + wisconsin.csv

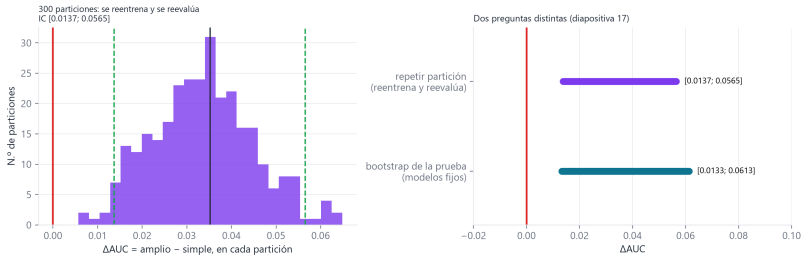
**El intervalo calculado cubre la variación al remuestrear los casos de evaluación de modelos fijos. No cubre la variación por volver a entrenar y seleccionar toda la receta, ni cambios de población, mediciones o prevalencia, ni corrige sesgos de diseño o fuga de datos.**

## Conceptos clave

1. **Dos preguntas distintas.** Repitiendo 300 particiones de las 569 muestras (reentrenando y reevaluando) el ΔAUC tiene media 0.0337, desviación 0.0113 e IC [0.0137; 0.0565]; el amplio ganó en 100 % de las particiones.
2. **McNemar y DeLong (extensión).** McNemar compara exactitudes con casos discordantes: b = 2 y c = 16, $\chi^2$ = 9.39, p = 0.0022 (exacto 0.0013). DeLong da ΔAUC 0.0352, z = 2.84, p = 0.0046. No se vieron en clase.
3. **El tamaño de la prueba.** El ancho del IC baja como 1/√n: con acierto 0.90, 0.118 con 100 casos y 0.037 con 1 000. En regresión (MAE/RMSE) con 5 casos: MAE 3.0 [1.8; 4.2], RMSE 3.317 [1.949; 4.359] (ilustrativo).




Izquierda: tabla 2 × 2 de aciertos de los dos modelos con umbral 0.5. Derecha: el mismo ΔAUC con bootstrap pareado y con DeLong.




Izquierda: ΔAUC al repetir la partición y reentrenar. Derecha: comparación con el intervalo del bootstrap de la prueba (modelos fijos).

## Fórmulas y reglas

McNemar: $\chi^2 = (|b - c| - 1)^2/(b + c)$

gl = 1; exacto: binomial(b + c, 0.5)

se_AUC = f(estructura de los pares)

ancho IC □ 1/√n

```
from scipy.stats import binomtest
binomtest(min(b, c), b + c, 0.5).pvalue
```

## Con los números de la clase

- McNemar usa solo 18 de 171 casos (los discordantes): el amplio acierta 16 que el simple falla; el simple, 2 que el amplio falla
- Repetir particiones da un IC de ancho 0.043; el bootstrap de la prueba, 0.048: parecidos aquí, pero responden preguntas distintas
- Con más casos de prueba el intervalo se angosta; con más remuestras solo se estabiliza el cálculo
- **Cuidado.** La prueba reutilizada es una demostración docente, no una validación externa nueva. Repetir el cálculo 2 000 veces no corrige sesgos de diseño, selección ni fuga de datos.

# Alertas del material, repaso y criterio de dominio

Diferencias entre materiales y qué conviene precisar (verificado con código)

**Lo dicho en clase (transcripción)**

- **«Si los intervalos se cruzan, no hay diferencia entre los modelos»** (y el ejemplo de las encuestas): es **incorrecto en general**. Aquí los IC de la AUC se solapan (0.950–0.972) y la diferencia pareada [0.0133; 0.0613] excluye 0; con remuestras independientes sí contendría 0. El mismo profesor muestra después que ΔAUC es significativa.
- **«Con log loss gana el modelo simple»**: el signo está al revés. Δ = simple − amplio = 0.1163 > 0 y el IC [0.0526; 0.1854] favorecen al **amplio** (como dice la diapositiva 49); con AUC también gana el amplio.
- **«No se pueden usar bootstrap y validación cruzada»**: es imprecisión. Se pueden combinar (bootstrap de las predicciones OOF, .632, validación anidada), con cuidado; lo que no se debe es reajustar o elegir con la prueba.
- **«Nivel de confianza de 2 puntos»** (encuestas): son 2 puntos de **margen de error**; el nivel de confianza es 95 %.
- **Cifras mal transcritas** (ya corregidas): RMSE 3.31 (no 3.81), log loss del ejemplo 0.4723 (no 0.46), B = 100 (no 1 000) para el SE 1.029, prueba de 171 (no 161 ni 179) y 569 muestras (no 659).
- **Fold de «80 casos»**: los pliegues del entrenamiento miden 80, 80, 80, 79 y 79; se ajusta con 318 o 319 casos (la diapositiva 4 dice 318).

**Diapositivas, scripts y verificación**

- **Reproducido con el script de Python** (semillas 20261012, 20261013, 20261017, 20261014): AIC 110.2908 y BIC 130.2230 del amplio; AUC 0.9394 y 0.9746; log loss 0.2997 y 0.1833; SE de la media 0.9306; ΔAUC 0.0352 [0.0133; 0.0613].
- **R frente a Python**: las diapositivas muestran los resultados de R (SE 0.966; IC [3.4; 7.0]; [0.1066; 0.2798]…); Python con la misma semilla da otras remuestras y límites algo distintos (por ejemplo [3.2; 7.0]). Son variación Monte Carlo; el SE exacto de la media es 0.955.
- **Slide 13**: «compras muy distintas entre sí» es un error de tipeo (deben ser **muestras**). **Script en R**: la ruta de lectura es absoluta (D:/Aulas_Diplomado/…): hay que cambiarla.
- **Qué no hace el material**: no incluye McNemar ni DeLong, no usa pruebas con varios umbrales ni estudia la variación por reentrenar; esas piezas son extensiones de esta guía.
- **Transcripción con ruido**: «Bustrap / Boostrepp» = bootstrap, «IC / ICIe / A y C» = AIC, «curva rock» = ROC, «relm» = glm, «error coláctico» = error cuadrático. Se marcó el recreo hacia 0:47:31 (el video sigue sin hueco).

**Checklist, criterio de dominio y lo que viene**

- ☐ Explico por qué una métrica de prueba tiene incertidumbre y calculo el SE de una exactitud
- ☐ Hago una remuestra bootstrap a mano y calculo la estadística; construyo un IC percentil desde valores ordenados
- ☐ Distingo seleccionar (AIC, BIC, OOF) de evaluar, y sé qué queda dentro del pliegue
- ☐ Hago bootstrap de la prueba con modelos fijos: log loss por filas, AUC por clase
- ☐ Comparo dos modelos con la diferencia pareada y explico por qué solapar IC no basta
- ☐ Calculo el estadístico de McNemar a mano y lo interpreto
- ☐ Digo qué incertidumbre cubre el intervalo y cuál no
- ☐ Resuelvo los bloques 1 a 7 del cuaderno con al menos 80 % de aciertos
- ☐ **Siguiente**: repaso final con el profesor y el Taller.