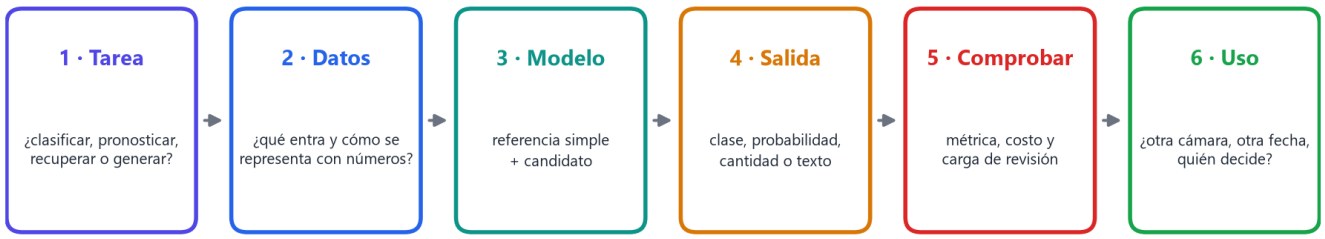
Clase 44 · Aplicaciones de IA y panorama actual del Deep Learning

Profesor Eloy Alvarado · conecta clasificación (Clases 20–21 y 31), evaluación (Clases 38 y 43), distancia y clustering (Clase 39) con imágenes, texto y modelos preentrenados

La gran idea de la clase

Antes de elegir un modelo hay que definir la tarea, los datos y cómo se comprobará el resultado. Un mismo dato (una foto, un texto) sirve para tareas distintas: **clasificar, pronosticar, recuperar o generar**. Todo modelo recibe **números**, así que hay que decidir cómo **representar** la entrada (una imagen son 64 intensidades; un texto, un vector). Después se evalúa con criterios que reflejen el **uso real**: la exactitud no basta (hay que mirar las probabilidades con el log loss), un buen resultado no garantiza resistir un cambio de cámara, y los errores tienen **costos** y **carga de revisión**. Una red neuronal es solo una herramienta más; la elección depende de la tarea, de los datos y de la evaluación.

La clase en una imagen



El objetivo (paso 1) va antes que los datos; el paso 6 vuelve a preguntar por la tarea cuando cambian las condiciones.

Lo que necesitas ANTES

- **Regresión logística y probabilidades** (Clases 20–21 y 31): cada clase recibe una probabilidad
- **Exactitud y matriz de confusión** (Clase 38): aciertos, falsos positivos y falsos negativos
- **Bootstrap** (Clase 43): remuestrear casos de prueba con los modelos fijos
- **Distancia entre datos** (Clase 39): la idea de «cercano» en un espacio de números

Ruta de la clase

- **Definir la tarea → representar con números → probabilidades y log loss → bootstrap y prueba de estrés**
- Pausa (~15 min) y luego: **texto, embeddings, búsqueda, generación → modelos preentrenados → costos, revisión y diseño de la prueba**
- Bloque práctico: **dígitos escritos a mano** (1797 imágenes de 8 × 8; 1077 entrenamiento, 360 validación, 360 prueba)
- La red neuronal se construye recién el 20 de octubre (Clase 45): hoy se estudian sus entradas y salidas

Cómo leer los números de este material

Las **diapositivas** muestran la corrida del profesor. Aquí se **reprodujo** el bloque de dígitos con la misma partición (digitos.csv) y scikit-learn. La regresión logística coincide con las diapositivas: 353 de 360 aciertos, log loss 0.1353, y con el desplazamiento 39.72 % y 2.3826. La red neuronal sale distinta (otra inicialización, o quizá otro programa): 353 de 360 y log loss 0.0797 (diapositivas: 354 y 0.0657). La conclusión cualitativa es la misma; cuando una cifra es de la corrida del profesor, se dice «diapositivas».

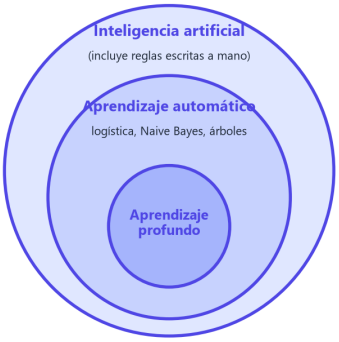
Clase 44 · Primero la tarea: IA, aprendizaje automático y profundo

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

Se parte del objetivo, no de los datos. Hay que poder completar la frase: «entra X, el sistema entrega Y, y lo considero útil si Z». Si no se puede, falta precisar la tarea.

Conceptos clave

1. **Los tres círculos.** IA es el campo más amplio (incluye reglas escritas a mano). El aprendizaje automático aprende patrones de los datos (logística, Naive Bayes). El aprendizaje profundo aprende **varias transformaciones sucesivas**. Todo deep learning es ML y es IA; no al revés.
2. **Cuatro tareas, cuatro salidas. Clasificar** (una categoría), **pronosticar** (una cantidad futura), **recuperar** (fuentes relevantes) y **generar** (texto o imagen). Cada una se comprueba distinto.
3. **Un sistema es una cadena de tareas.** Atender «me cobraron dos veces» es **clasificar** (categoría y prioridad), **consultar** (registros y procedimiento) y **redactar** (borrador). Se evalúa cada paso y el resultado completo.
4. **Fluidez no es fidelidad.** Un texto puede leerse muy bien y afirmar algo sin respaldo. La fluidez dice si suena natural; la fidelidad, si conserva los hechos de las fuentes.



Relación entre los campos (diapositiva 4): cada círculo está dentro del anterior.



Las cuatro preguntas para estudiar una aplicación (diapositiva 3).

En palabras simples

Piensa en un taller. **Primero decides qué quieres construir** (la tarea), **luego buscas los materiales** (datos) y **al final defines cómo revisarás la obra** (evaluación). Comprar un martillo gigante sin saber qué construir es empezar por el modelo.

Aprendizaje profundo, dentro de aprendizaje automático, dentro de IA

Tarea → datos → modelo → salida → comprobación → uso

Con los números de la clase

- Ejemplo de clasificación de la clase: ¿este envase presenta daño? (se compara con la etiqueta correcta)
- Ejemplo de pronóstico: se venderán 120 unidades mañana; se vendieron 100 → error absoluto $|120 - 100| = 20$
- Pregunta de alumna: ¿red neuronal = deep learning? No siempre; una red con una neurona y una capa se parece a una regresión. «Profundo» pide muchas capas (se verá el 20 de octubre)

Cuidado. Tener datos disponibles no es un objetivo. Empezar por «tengo estos datos, ¿qué hago?» lleva a resolver problemas que no importan.

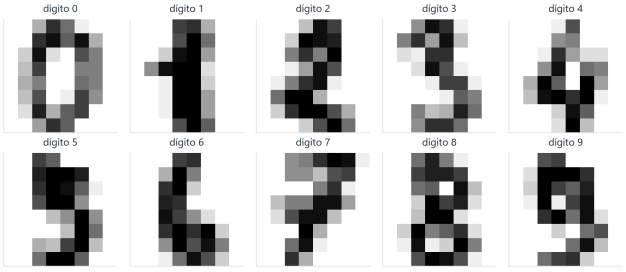
Clase 44 · Representar los datos: una imagen son números

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

Un modelo solo recibe números. Una imagen de 8 × 8 píxeles se convierte en 64 intensidades (0 a 16); se leen por filas y se dividen por 16 para quedar entre 0 y 1. La etiqueta se guarda aparte.

Conceptos clave

1. **Píxeles e intensidad.** Cada celda (píxel) tiene un número que describe su tono: 0 es blanco y 16 es negro. Con color habría tres números por celda (rojo, verde y azul).
2. **De matriz a vector.** La matriz de 8 × 8 se «estira» fila por fila: primera fila, luego la segunda… en total 64 números en un orden fijo. Otra lectura (por columnas) también sería válida si se usa siempre la misma.
3. **Hay muchas representaciones.** Un correo «crédito gratis crédito» puede contarse por palabras (crédito, gratis, urgente → [2, 1, 0]) o solo por su largo (3). Contar conserva frecuencias pero pierde el orden: «el hombre mordió al perro» y «el perro mordió al hombre» tendrían los mismos conteos.
4. **La etiqueta.** En entrenamiento se conoce el dígito correcto de cada imagen; en prueba se oculta para ver si el modelo acierta con imágenes que no usó para ajustarse.



Un ejemplo de cada dígito de la colección (1797 imágenes de 8 × 8; diapositiva 10).



La imagen de la diapositiva 11 (un 8): se lee por filas y se escala. Cuanto más cerca de 16, más oscuro.

En palabras simples

Es como describir un cuadro por teléfono: **cuadrícula de 8 por 8, y te dicto el tono de cada cuadradito de izquierda a derecha y de arriba hacia abajo**. Quien escucha puede reconstruir el cuadro porque ambos usan el mismo orden.

intensidad ÷ 16 = valor entre 0 y 1

8 × 8 = 64 píxeles = 64 columnas de entrada

Con los números de la clase

- La imagen de ejemplo tiene 26 celdas en 0 y 6 en 16; su primera fila es [0, 0, 9, 14, 8, 1, 0, 0]
- 9 ÷ 16 = 0.5625 · 14 ÷ 16 = 0.875 · 8 ÷ 16 = 0.5
- Todas las imágenes tienen el mismo tamaño; con más píxeles o tamaños distintos, la representación ya no es trivial

Cuidado. Que los números sirvan no está garantizado: una buena representación depende de la tarea. Cambiar la representación puede cambiar el resultado del modelo.

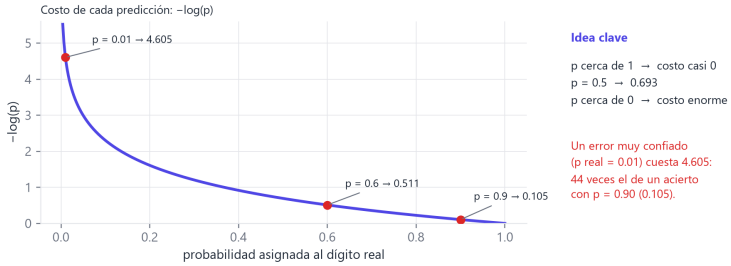
Clase 44 · La salida: probabilidades y pérdida logarítmica (log loss)

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

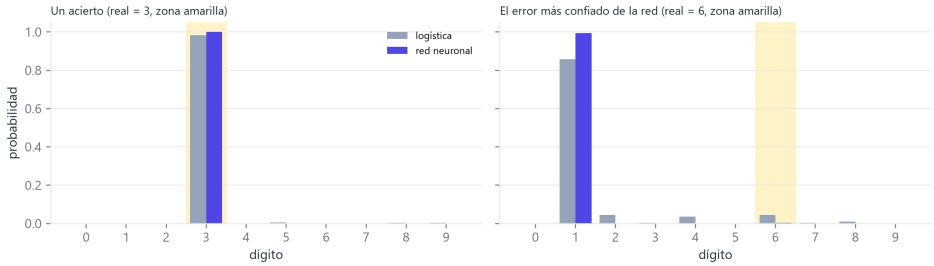
El clasificador entrega 10 probabilidades (una por dígito) que suman 1; se predice la clase con más probabilidad. La clase elegida y la probabilidad de la clase real dan información distinta: el log loss mira esta última.

Conceptos clave

1. **Probabilidad ≠ acierto.** Si el real es 8 y el modelo da 0.60 al 3 y 0.25 al 8, predice 3 y se equivoca, aunque haya dado algo de probabilidad al 8.
2. **Pérdida = −log(p real).** Se toma la probabilidad del dígito **real**, se calcula −ln(p) y se promedia sobre todas las imágenes. Menor es mejor. Una predicción confiada y equivocada cuesta muchísimo.
3. **Dos métricas, dos preguntas.** La **exactitud** cuenta aciertos (más alto es mejor). El **log loss** castiga probabilidades mal puestas (más bajo es mejor). Dos modelos pueden acertar casi lo mismo y tener log loss muy distinto.
4. **Umbral y regla de decisión.** «Aceptar sin revisión si p ≥ 0.90» es una regla humana, no del modelo. Una probabilidad alta no garantiza el acierto de esa imagen.



Izquierda: costo −log(p) para tres valores de la diapositiva 15. Derecha: lectura rápida.



Probabilidades de ambos modelos en nuestra reproducción para un acierto y para el error más confiado de la red (la zona amarilla marca la clase real).

En palabras simples

Imagina que un **pronosticador apuesta fichas** al dígito correcto. Si apostó casi todo a la respuesta verdadera, pierde poco; si apostó casi todo a una respuesta equivocada, **pierde muchísimo**. El log loss mide cuántas fichas pierde en promedio.

log loss = promedio de −ln(p del dígito real)

exactitud = aciertos ÷ imágenes

Con los números de la clase

- −ln(0.90) = 0.105 · −ln(0.60) = 0.511 · −ln(0.01) = 4.605 (diapositiva 15)
- Imagen de la diapositiva 19 (real = 3): logística asigna 0.983575 y pérdida 0.0166; nuestra red, 0.999975 y 0.000025 (diapositivas: 0.999775 y 0.000225)
- Hipótesis de la diapositiva 12: 0.60 al 3, 0.25 al 8 y 0.15 repartido entre las otras 8 clases

Cuidado. −ln se calcula con el logaritmo **natural**. Si usas log base 10 los valores cambian (pero el orden entre modelos no).

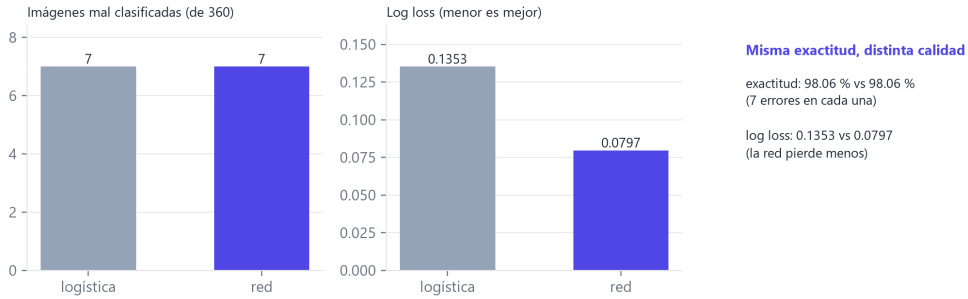
Clase 44 · Dos recetas para los dígitos: regresión logística y red neuronal

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

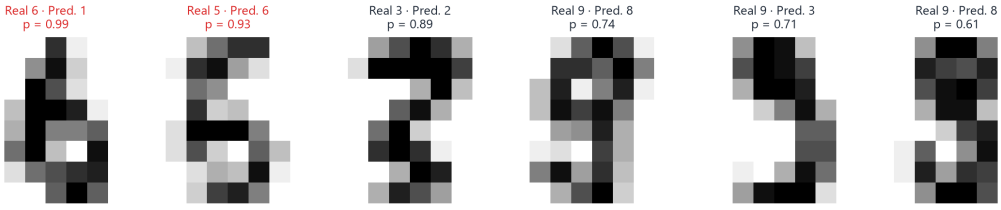
Los datos se separan en entrenamiento (1077), validación (360) y prueba (360). Con entrenamiento se ajustan los candidatos, con validación se elige, se reajusta con las 1437 imágenes de desarrollo, y la prueba se mira al final, una sola vez.

Conceptos clave

1. **Referencia: regresión logística.** Usa los 64 píxeles para calcular 10 probabilidades. Es barata, fácil de implementar e interpretable: es el modelo a vencer. Tiene 650 parámetros.
2. **Candidato: red neuronal.** Aprende transformaciones de los mismos 64 píxeles. Aquí se eligió por validación entre dos tamaños (16 o 32 unidades ocultas): ganó 32 (log loss de validación 0.0676); tiene 2 410 parámetros.
3. **Mismas imágenes, mismos casos.** Ambos modelos se evalúan sobre las mismas 360 imágenes, así se pueden comparar. El experimento compara **estas dos recetas**: no dice qué familia gana en todos los problemas.
4. **Lo que sí y no se puede concluir.** La separación fue por imagen y no hay identificador de escritor: no se demuestra desempeño en personas nuevas.



Nuestra reproducción en las 360 imágenes de prueba: misma cantidad de errores, distinto log loss.



Los errores de la red, ordenados por confianza (etiqueta real, predicha y probabilidad de la clase predicha). En rojo, los que la red declara con p ≥ 0.90.

En palabras simples

Es como dos alumnos con la **misma nota** en una prueba de 360 preguntas. Uno responde con dudas y el otro con seguridad: cuando se equivoca el seguro, el error es más grave. La nota (exactitud) no los distingue; **la confianza (log loss) sí**.

Con los números de la clase

- Nuestra reproducción: logística 353 de 360 (98.06 %), log loss 0.1353 · red 353 de 360 (98.06 %), log loss 0.0797
- Diapositivas: logística 353 (98.06 %, 0.1353) · red 354 (98.33 %, 0.0657): un acierto más = 100/360 ≈ 0.28 puntos
- De nuestra red, 2 de 7 errores tienen p ≥ 0.90 (diapositiva 17: la red del profesor erró 6, con p entre 0.76 y 0.94)
- En la red, los 7 errores concentran 24.0 de 28.7 de pérdida total (84 %)

Cuidado. Un valor distinto en la red es normal: depende de la inicialización y de las épocas. La lección de la clase no cambia: con exactitud casi igual, el log loss puede diferir bastante.

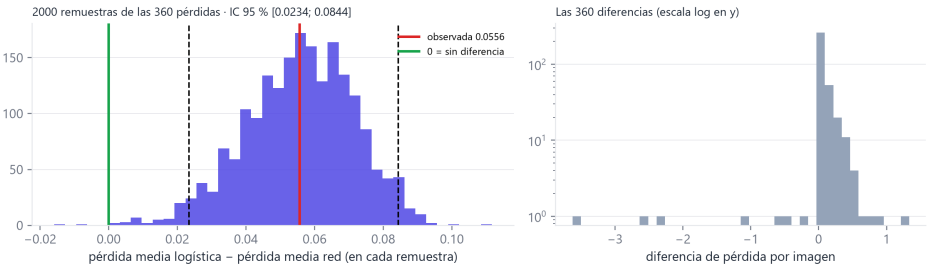
Clase 44 · ¿La ventaja es real? Bootstrap y prueba de estrés

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

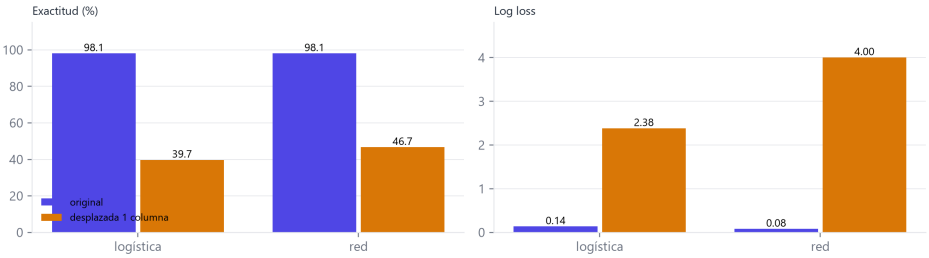
Una diferencia entre dos modelos medida en 360 imágenes podría cambiar con otras 360. El bootstrap reutiliza las pérdidas de esas imágenes (modelos fijos) para estimar cuánto varía la diferencia. Después, la prueba de estrés pregunta si el resultado resiste un cambio en la entrada.

Conceptos clave

1. **Diferencia de pérdidas.** Se resta pérdida de la logística menos pérdida de la red, imagen por imagen. Si el promedio es positivo, la red pierde menos.
2. **Intervalo bootstrap.** Se remuestrean las 360 pérdidas con reposición B = 2 000 veces; el intervalo del 95 % usa los percentiles 2.5 y 97.5. Si **0 queda fuera**, hay evidencia de menor pérdida de la red (bajo independencia por imagen).
3. **Desplazar una columna.** Se corre cada imagen una columna a la derecha (la primera se rellena con 0 y la última original se descarta). Los mismos modelos, sin reajustar.
4. **Un buen resultado no garantiza robustez.** Para una persona la imagen es «la misma»; para el modelo, los números cambiaron mucho. Otra cámara, otro trazo o otra posición pueden alterar la entrada.



Izquierda: distribución bootstrap de la diferencia de pérdidas medias (nuestra reproducción). Derecha: las 360 diferencias por imagen; hay 7 imágenes donde la logística pierde menos.



Exactitud y log loss con las imágenes originales y desplazadas una columna a la derecha (nuestra reproducción; diapositivas 21 y 22).

En palabras simples

El bootstrap es como **preguntarte qué habría pasado si el examen hubiera tenido otras preguntas parecidas**: vuelves a sacar «preguntas» de las mismas 360 (con reposición) muchas veces y miras cuánto cambia la ventaja.

diferencia = pérdida media (logística) − pérdida media (red)

IC 95 % = percentiles 2.5 y 97.5 de las B diferencias

Con los números de la clase

- Nuestra reproducción: diferencia 0.0556, IC [0.0234; 0.0844] (excluye 0). Diapositivas: 0.0696, IC [0.0478; 0.0901]
- Desplazadas, logística: 39.72 % y log loss 2.3826 (diapositivas: 39.72 % y 2.3826, igual)
- Desplazadas, red: 46.67 % y 4.0037 (diapositivas: 45.00 % y 3.1314). La red acierta más que la logística pero su log loss es peor
- El azar entre 10 clases sería 10 % de exactitud

Cuidado. El intervalo no mide la utilidad práctica de la mejora ni cubre un cambio de cámara. El desplazamiento es una prueba de estrés artificial, no una cámara real.

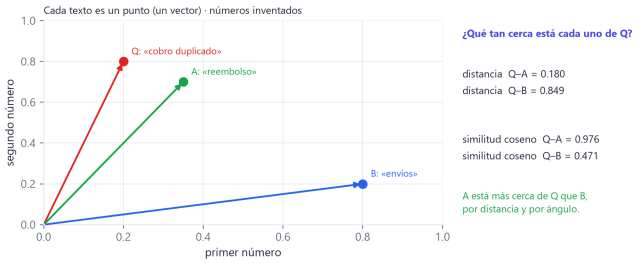
Clase 44 · Después de la pausa: texto, embeddings y búsqueda por significado

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

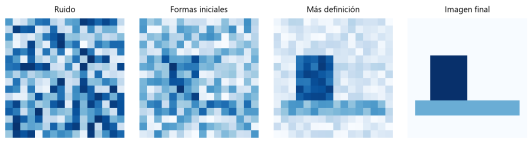
Un embedding representa un objeto (un texto, una imagen) con un vector para poder compararlo con otros. Si dos textos se parecen, sus vectores quedan cerca. Así se busca «por significado» y no solo por palabras exactas.

Conceptos clave

1. **Vector y embedding.** Un vector es una lista ordenada de números. Las coordenadas las aprende un modelo con ejemplos; no son probabilidades ni etiquetas de temas.
2. **Cercanía.** Con números inventados: Q «cobro duplicado» = [0.2, 0.8], A «reembolso» = [0.35, 0.7], B «envíos» = [0.8, 0.2]. A está a 0.180 de Q y B a 0.849: A es más cercano.
3. **Búsqueda por palabras vs por significado.** Por palabras compara términos (falla si la fuente dice «reembolso» y tú escribes «cobro duplicado»). Por significado compara vectores, pero la cercanía puede traer un texto relacionado que no responde. Hay que comprobar que respondan, correspondan al servicio y estén vigentes.
4. **CLIP y recomendación.** CLIP aprende con pares imagen–texto a producir vectores comparables (da una similitud, no una probabilidad de daño). En recomendación, un 1 es «hay clic» y un 0 es «no hay clic registrado», no rechazo.



Los tres textos de la diapositiva 27 como puntos y vectores; distancia y similitud coseno calculadas aquí.



Idea de difusión (diapositiva 32, ilustración propia): del ruido a una imagen guiada por el texto, en muchos pasos.

En palabras simples

Un embedding es como **ubicar ciudades en un mapa**: Santiago y Valparaíso quedan cerca; Santiago y Punta Arenas, lejos. Con textos, el «mapa» se aprende para que los de significado parecido queden juntos. Una **base de datos vectorial** solo guarda los puntos cercanos cerca unos de otros para encontrarlos rápido.

$$\text{distancia}(Q, A) = \sqrt{(q_1 - a_1)^2 + (q_2 - a_2)^2}$$

$$\text{coseno}(Q, A) = (Q \cdot A) / (\|Q\| \, \|A\|)$$

Con los números de la clase

- Q–A: distancia 0.180, coseno 0.976 · Q–B: distancia 0.849, coseno 0.471
- Generar texto: un modelo de lenguaje aprende regularidades en el orden de las palabras y añade unidades sucesivamente usando el contexto
- Generar imágenes (difusión): parte de ruido visual y lo transforma gradualmente guiado por la descripción; el realismo no acredita un hecho
- Autosupervisado: ocultar «crédito» en «el banco aprobó el crédito» y compararlo con la palabra original; la respuesta sale de los datos

Cuidado. Producir una continuación plausible no garantiza que sea verdadera. Y la diapositiva dice A = [0.35, 0.70]; en la clase se mencionó 0.3 y 0.7, una aproximación oral.

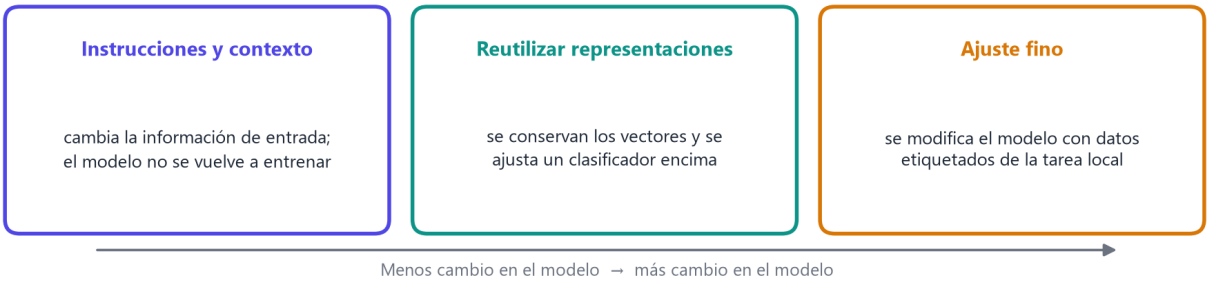
Clase 44 · Modelos preentrenados, panorama actual y verificación de lo generado

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

Un modelo preentrenado ya aprendió con otros datos; su utilidad local se demuestra con datos de la aplicación. Y una respuesta generada se verifica afirmación por afirmación contra la fuente.

Conceptos clave

1. **Reutilizar un aprendizaje previo.** Permite aprovechar otros datos y ajustar menos desde cero. Hay que comprobar que sea pertinente (un modelo de fauna de otro continente no sirve igual en Chile) y que haya datos locales para adaptar y evaluar.
2. **Tres formas de adaptar. Instrucciones y contexto** (cambia la entrada, sin reentrenar), **reutilizar representaciones** (vectores + un clasificador propio) y **ajuste fino** (se modifica el modelo con datos de la tarea).
3. **Panorama y benchmarks.** Un **benchmark** es una evaluación con tareas, datos y reglas definidos; su resultado no se traslada solo a otra población. Hay que preguntar qué tarea se evaluó y si nuestros datos son comparables.
4. **Una aplicación es más que el modelo.** Datos y contexto, modelo, verificación, decisión y seguimiento: puede fallar cualquiera. Ej.: 12 cajas de 24 unidades son 12 × 24 = 288 unidades, no 12.



Tres formas de adaptar (diapositiva 35), de menos a más cambio en el modelo.

En palabras simples

Un preentrenado es como **contratar a alguien con experiencia en otro rubro**: ya sabe mucho, pero hay que comprobar que lo que aprendió sirva en tu trabajo, y darle algo de práctica local. Partir desde cero tiene sentido solo si nadie ha tenido un problema parecido.

Con los números de la clase

- Fuente: «hasta cinco días hábiles de revisión». Borrador: «aprobada y llegará mañana»: ambas afirmaciones **sin respaldo** (la fuente no informa el resultado ni una fecha de abono)
- AlphaFold 3: recibe información de los componentes del complejo y propone su estructura; se comprueba contra estructuras determinadas experimentalmente. Orienta la investigación, pero no demuestra que un compuesto sea un tratamiento eficaz
- Respuesta corregida de la diapositiva 40: «El procedimiento indica hasta cinco días hábiles de revisión. Con esta información no puedo confirmar una aprobación ni una fecha de abono.»

Cuidado. Si una afirmación no tiene respaldo en la fuente, se corrige o se declara información faltante. Basta que un paso falle para que las decisiones automatizadas salgan mal.

Clase 44 · Costos, carga de revisión y una prueba que represente el uso

Fuente: transcripción + diapositivas DipDS_2026_S44.pdf del profesor Eloy Alvarado + reproducción propia con scikit-learn (digitos.csv)

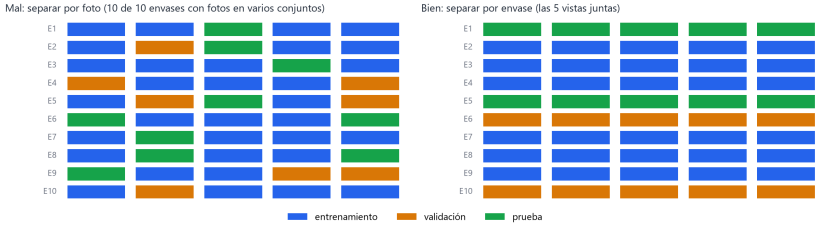
Los errores no cuestan lo mismo y la revisión humana tiene capacidad limitada. Además, la prueba debe imitar el uso previsto: las 5 fotos de un envase no son 5 envases independientes.

Conceptos clave

1. **Costo de los errores.** De 1000 piezas, 20 tienen defectos. El sistema deja pasar 4 y manda 30 sanas a revisión. Con costos de 50 y 1 unidades: 4 × 50 + 30 × 1 = 230 unidades.
2. **Carga de revisión.** Se detectaron 16 defectos. Si se revisan todas las alertas son 16 + 30 = 46 revisiones; con capacidad de 20 no alcanza (faltan 26).
3. **Separar por la unidad real.** 6 000 fotos de 1 200 envases (5 vistas cada uno). Todas las vistas de un envase van al mismo conjunto, y el bootstrap remuestrea envases completos.
4. **Qué falta para el próximo mes.** Una cámara nueva en otra línea: hay que reunir datos de esas condiciones, reservar envases que no se usen para adaptar ni elegir, comparar una referencia simple con un candidato y medir defectos omitidos, falsas alarmas y revisiones.



Diapositiva 41: costo total de los errores y carga de revisión frente a la capacidad.



Caso integrador (diapositivas 46 y 47): separar por foto filtra información; separar por envase mantiene juntas las vistas (ilustración con 10 envases).

En palabras simples

Es como **corregir pruebas de varias hojas**: si pones la hoja 1 de un alumno en el grupo de estudio y la hoja 2 en el examen, el examen ya vio al alumno. Hay que mantener todas las hojas de la misma persona (o del mismo envase) en el mismo grupo.

costo = Σ (cantidad de error × costo unitario)

revisiones = defectos detectados + falsas alarmas

Con los números de la clase

- Omitir un defecto cuesta 50 y una falsa alarma 1: omitir cuesta más
- Exactitud del sistema: 96.6 %; «decir siempre sano» lograría 98.0 % pero omitiría los 20 defectos (costo 1000)
- Otras restricciones: tiempo (latencia), costo, datos, mantenimiento; si llega 1 pieza por segundo y se tardan 5 s en procesar cada una, se acumula trabajo
- Primera comparación: una referencia simple (regresión, árbol, regla de historia reciente). Una alternativa simple puede resolver mejor el problema

Cuidado. Cambiar el procedimiento después de mirar la prueba exige otra evaluación independiente. La conclusión se limita a las condiciones observadas.

Repaso, alertas del material y criterio de dominio

Preguntas para responder sin apuntes y lo que debes poder hacer antes de la Clase 45 (redes neuronales)

Alertas del material

Qué conviene saber al leer las diapositivas y la transcripción

- **Las cifras de la red son de la corrida del profesor.** La logística se reproduce exacta (353 de 360, log loss 0.1353, desplazada 39.72 % y 2.3826); la red no (ver la página inicial).
- **La transcripción tenía errores de reconocimiento de voz** (red neuronal escrita como «renda oral», log loss como «LOC-LOS», 0.1353 como «0.3353»…). Se corrigieron en la versión limpia; en el original sigue el audio literal.
- **«Deep learning» y «red neuronal» no son sinónimos:** una red muy pequeña se parece a una regresión. Profundo = muchas capas (Clase 45).
- **Las diapositivas piden no sobreinterpretar:** los valores 0.20/0.80, 0.35/0.70 y 0.80/0.20 son inventados para ilustrar; las similitudes de CLIP (0.82, 0.39, 0.06) también.
- **Ejemplos hipotéticos:** inspección de envases, demanda, cursos, cobros y 1 000 piezas son escenarios ilustrativos, no datos reales.

Preguntas de repaso (intenta responder antes de leer)

#	Pregunta	Respuesta corta
1	¿Cuál es el orden correcto: datos, tarea o evaluación?	Primero la tarea (qué se quiere hacer), luego los datos y cómo se evaluará.
2	Un clasificador da 0.60 al 3 y 0.25 al 8; el real es 8. ¿Acierta? ¿Cuánto vale la pérdida de esa imagen?	No (predice 3). Pérdida = −ln(0.25) = 1.386.
3	Dos modelos aciertan casi lo mismo, pero uno tiene la mitad de log loss. ¿Qué significa?	Que sus probabilidades están mejor puestas (más seguras cuando aciertan, menos extremas al errar).
4	El IC bootstrap de la diferencia de pérdidas excluye 0. ¿Qué concluyes? ¿Qué no concluyes?	Evidencia de menor pérdida de un modelo en estos casos; no que sea mejor en otra cámara ni que la mejora sea útil.
5	¿Qué muestra desplazar las imágenes una columna?	Que un buen resultado original no garantiza resistir cambios de entrada: ambos modelos caen mucho.
6	¿Por qué «cobro duplicado» y «reembolso» pueden estar cerca en un embedding?	Porque el modelo aprendió a acercar textos de significado relacionado, aunque no compartan palabras.
7	¿Qué mide «4 × 50 + 30 × 1»?	El costo de los errores: 4 defectos omitidos a 50 y 30 falsas alarmas a 1 = 230 unidades.
8	6 000 fotos de 1 200 envases: ¿cómo separas entrenamiento, validación y prueba?	Por envase: las 5 vistas de cada envase en un solo conjunto.

Criterio de dominio para pasar a la Clase 45

- ☐ Defino una aplicación con tarea, entrada, salida y forma de comprobar
- ☐ Explico cómo una imagen 8 × 8 se convierte en 64 números entre 0 y 1
- ☐ Calculo −log(p) y el log loss promedio a mano, y explico por qué complementa la exactitud
- ☐ Interpreto un IC bootstrap de la diferencia de pérdidas y los límites de la conclusión
- ☐ Calculo el costo de errores y la carga de revisión, y diseño una separación que no filtre información