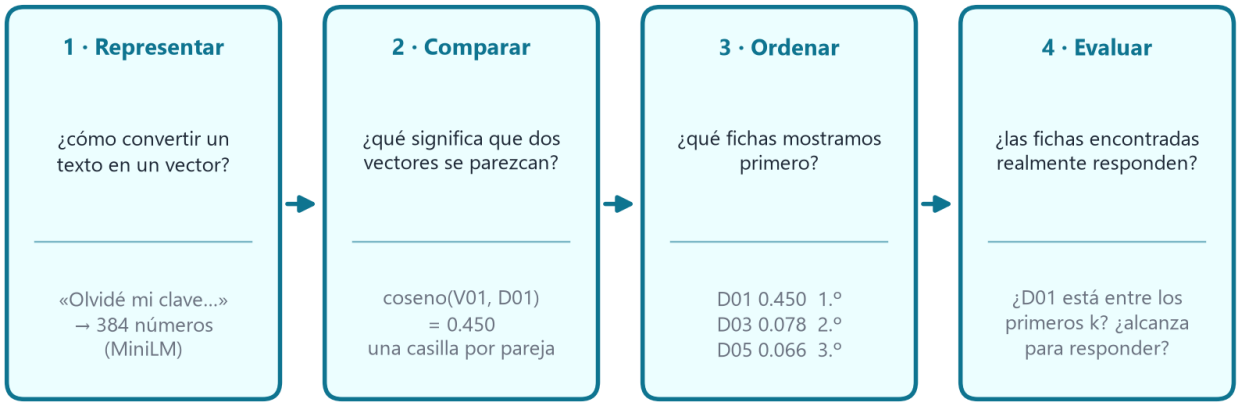
Clase 47 · Embeddings y representaciones vectoriales

Profesor Eloy Alvarado · cómo convertir un texto en números para que un computador encuentre la ficha de ayuda que responde una pregunta

La gran idea de la clase

Para que un computador compare textos hay que convertirlos en vectores. Contar palabras es lo más simple, pero «clave» y «contraseña» quedan como vectores perpendiculares: para un conteo no se parecen en nada. Un **embedding** es un vector de 384 números producido por una red ya entrenada (MiniLM), que deja cerca los textos con significado parecido. Con esos vectores se **compara** cada pregunta con cada una de las 12 fichas de ayuda mediante el **coseno**, se **ordenan** las fichas por puntaje y se **evalúa** (rango, Hit@k, MRR, preguntas sin respuesta). Un buen puntaje no garantiza una buena respuesta: hay que revisar los errores.

Las cuatro etapas del buscador de Aula Abierta



Cada etapa tiene su propio criterio: un buen puntaje (etapa 2) no garantiza una buena respuesta (etapa 4)

Lo que necesitas ANTES

- **Red neuronal** (Clase 45): pesos que se ajustan para reducir un error
- **Autoencoder y representación** (Clase 46): un vector que resume la entrada; aquí la entrada es texto
- **Conteo de palabras** (Clase 40, spam): palabras como variables
- **PCA** (Clase 32): resumir muchas coordenadas en pocas
- **Validación y prueba** (Clases 30 y 38): elegir con una, evaluar al final con otra

Ruta de esta guía

- Texto → vector: contar palabras y TF-IDF
- Embedding (MiniLM) y cómo se aprendió
- Geometría: norma, producto interno, coseno
- Una consulta contra 12 fichas: matriz y ranking
- Evaluar: rango, Hit@k, MRR y elegir k
- Errores y límites: A17/A71, información insuficiente, cortes
- Mirar el espacio con PCA y reutilizar embeddings

Cómo leer los números de este material

La grabación **empieza unos 5 minutos tarde** (la primera frase está a medias) y tiene un **recreo** entre 1:10:26 y 1:28:13; con las diapositivas se cubre todo. Las cifras de las diapositivas son la corrida del profesor: se ejecutó **su mismo programa** (`embeddings.py`, solo numpy, con los vectores de MiniLM ya calculados, sin internet) y **las 27 cifras comparadas coinciden exactamente** (tabla en la última página). Se trabaja con las 16 consultas de **validación**; las 16 de prueba el profesor las reserva y aquí **no se evalúan**. Lo que se rotula «nuestro cálculo» o «ejemplo propio» no es de la clase.

1 Texto → vector: contar palabras, y por qué los sinónimos no se parecen

Un computador solo compara números. La forma más simple de convertir un texto en vector es contar cuántas veces aparece cada palabra de un vocabulario. Sirve para palabras exactas, pero no entiende sinónimos.

1. **Vector.** Una lista ordenada de números donde cada posición tiene un significado fijo. Aquí cada posición es una palabra del vocabulario, así que todos los textos tienen la misma cantidad de coordenadas.
2. **Conteo de palabras.** El texto «video clave» se convierte en (1, 0, 1) si las columnas son clave, contraseña y video (diapositiva 7). Se ignora el orden: solo importa cuántas veces sale cada palabra.
3. **Sinónimos perpendiculares.** «clave» = (1, 0, 0) y «contraseña» = (0, 1, 0) forman 90°: su coseno es 0. Para el conteo no tienen nada en común, aunque en la ficha D01 significan lo mismo.
4. **El problema inverso.** «Me senté en el banco de la plaza» y «Pedí un crédito en el banco» tienen la misma palabra y el mismo conteo, pero sentidos distintos (diapositiva 10). El significado depende del contexto.

En palabras simples

Es como buscar ropa en una tienda que ordena por la etiqueta exacta: si buscas «polera» y la tienda escribió «camiseta», el buscador por etiqueta no encuentra nada, aunque cualquier persona sabe que es lo mismo. Necesitamos un método que «sepa» que clave y contraseña significan lo mismo.

«clave» = (1, 0, 0)

«contraseña» = (0, 1, 0)

ángulo 90°, coseno 0

Con los números de la clase

- V01 «Olvidé mi clave, ¿cómo vuelvo a entrar?» y D01 (recuperar la contraseña) comparten 0 palabras
- El vocabulario de las 12 fichas tiene 146 palabras y «clave» no está entre ellas: se ignora. De las siete palabras de V01 solo «a» está en el vocabulario
- TF-IDF sitúa D01 en el lugar 6 con puntaje 0 (diapositiva 34)
- Las 5 fichas con puntaje distinto de 0 (D03, D09, D04, D12, D11) se activan solo por la palabra de relleno «a» (nuestro cálculo)

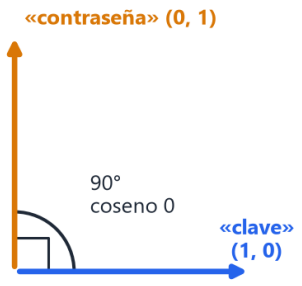
Cuidado. Contar no es «malo»: conserva las coincidencias exactas (códigos, nombres, fechas), que serán útiles en la sección 7.

Contar palabras: un vector por texto

texto	clave	contraseña	video
«clave»	1	0	0
«contraseña»	0	1	0
«video clave»	1	0	1

Cada columna es una palabra del vocabulario.

Sinónimos = flechas perpendiculares



Diapositiva 7: tres textos como vectores de conteo (izquierda) y por qué los sinónimos quedan perpendiculares (derecha).

V01 y D01 no comparten ninguna palabra: para un conteo no se parecen en nada

palabras en común: 0

Palabras de la consulta V01

olvide | mi | clave | como | vuelvo | a | entrar

Palabras de la ficha D01 (Acceso)

para | recuperar | la | contrasena | de | aula | abierta | use | acceso | en | pantalla | ingreso | recibira | un | enlace | su | correo | registrado

Nuestro cálculo con la tokenización del programa del profesor (minúsculas, sin tildes ni signos): V01 y D01 no comparten ninguna palabra.

2 TF-IDF: contar, pero dándole más peso a las palabras raras

TF-IDF multiplica cuántas veces aparece una palabra en el texto (TF) por un peso que crece cuando la palabra aparece en pocas fichas (IDF). Después se normaliza para comparar con el coseno.

1. **TF.** Term Frequency: cuántas veces aparece la palabra en el texto (diapositiva 30).
2. **DF e IDF.** DF (Document Frequency) es en cuántas de las N = 12 fichas aparece la palabra. IDF = ln((1 + N)/(1 + DF)) + 1: una palabra en una sola ficha pesa 2.87; una en 11 fichas, 1.08.
3. **Peso y normalización.** Peso = TF × IDF para cada palabra del vocabulario; luego se divide el vector por su norma para que mida 1 (ver sección 4). Vocabulario e IDF se calculan con las 12 fichas; las palabras que no están ahí se ignoran (diapositiva 28).
4. **Qué hace y qué no.** Premia las coincidencias de palabras raras, como un código de proyecto. No entiende sinónimos. En la clase es la **receta de referencia** contra la que se compara MiniLM.

En palabras simples

Si todas las fichas dicen «de», esa palabra no ayuda a distinguir una ficha de otra: es como gritar en una sala llena de gente. «A17», en cambio, aparece en una sola ficha: es una pista fuerte. El IDF le sube el volumen a lo raro y se lo baja a lo común.

TF-IDF = TF × IDF

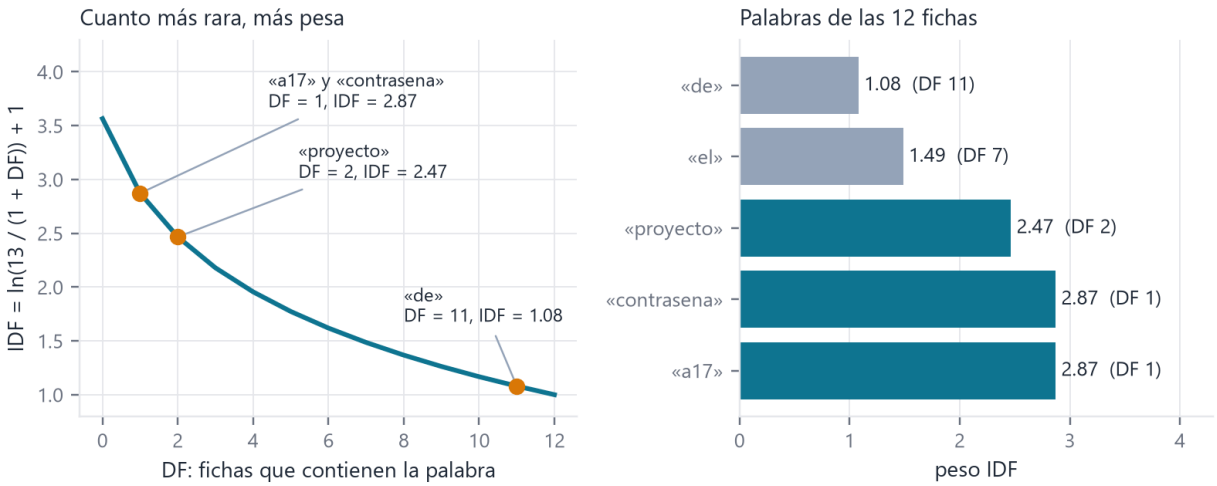
IDF = ln((1 + N) / (1 + DF)) + 1

N = 12 fichas; ln es el logaritmo natural

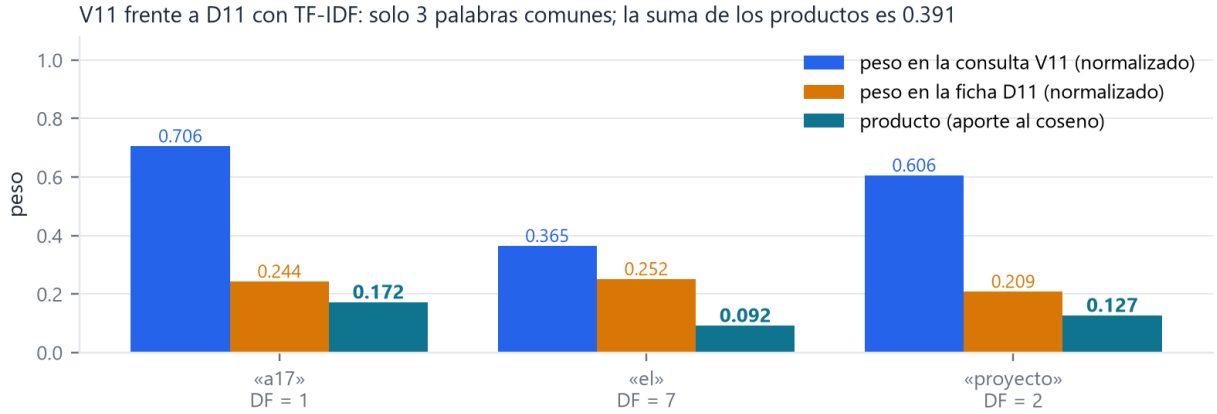
Con los números de la clase

- «de»: DF = 11, IDF = 1.08; «el»: DF = 7, IDF = 1.49; «proyecto»: DF = 2, IDF = 2.47; «a17»: DF = 1, IDF = 2.87
- De las 146 palabras del vocabulario, 106 están en una sola ficha
- V11 con D11: «a17» aporta 0.172, «el» 0.092 y «proyecto» 0.127; suma 0.391 (el puntaje de TF-IDF de V11 con D11, nuestro cálculo)

Cuidado. En la transcripción aparece «TF y DF»: es TF-IDF (corregido). Y TF-IDF no es otro embedding aprendido: sus pesos se calculan contando palabras en las 12 fichas.



Nuestro cálculo con las 12 fichas: la curva del IDF según el DF (izquierda) y cinco palabras de ejemplo (derecha).



Nuestro cálculo: V11 «¿Cuándo vence el proyecto A17?» frente a D11. Solo tres palabras son comunes y la suma de sus productos es el coseno que el programa asigna.

3 Embedding: un vector aprendido (MiniLM) en vez de un conteo

Un embedding es un vector que una red ya entrenada produce para cada texto, de modo que textos con significado parecido queden con vectores parecidos. Aquí son 384 números por texto.

1. **Embedding.** z = f_θ(x): entra el texto x, un codificador con pesos aprendidos θ lo procesa y sale un vector de d = 384 coordenadas (diapositiva 6). Es la misma idea del encoder de la Clase 46, pero con texto.
2. **Señal de relación.** Para aprender, las parejas de entrenamiento llevan una marca: «paráfrasis», «relevante» (1) o «no relevante» (0) (diapositiva 8). Esa marca es la referencia de la pérdida, no el coseno que calcula el modelo.
3. **El aprendizaje ocurrió antes.** Los autores entrenaron MiniLM con textos externos. Hoy solo se hace **inferencia**: los pesos no cambian. Agregar una ficha significa calcular un vector nuevo, no reentrenar la red (diapositiva 9).
4. **Del texto al vector.** Texto → tokens → vectores con contexto → vector de oración (MiniLM: media de las posiciones válidas, 384 valores). MPNet y LaBSE entregan 768. Los espacios no son intercambiables: consulta y fichas deben usar el mismo codificador (diapositivas 12 a 14).

En palabras simples

Piensa en un **mapa gigante** con 384 direcciones. Un cartógrafo ya entrenado (MiniLM) puso cerca los puntos de frases parecidas y lejos las distintas. Tú no dibujas el mapa: solo lo usas. Y no puedes mezclar las coordenadas de un mapa con las de otro, aunque tengan el mismo número de ejes.

$z = f_\theta(x) = (z_1, z_2, \ldots, z_{384})$

destilación: error = $((0.4 - 0.2)^2 + (0.6 - 0.8)^2) / 2 =$ 0.04

Con los números de la clase

- Modelo de la clase: paraphrase-multilingual-MiniLM-L12-v2; 384 coordenadas normalizadas, ya guardadas en `vectores.csv` (12 fichas + 32 consultas)
- Destilación (diapositiva 11): el maestro entrega la referencia (0.2, 0.8) y el estudiante parte en (0.4, 0.6); error medio cuadrático = 0.04. El maestro permanece fijo
- Hoy no se entrena nada: «hay datos locales para buscar y evaluar, no para entrenar MiniLM» (diapositiva 9)

Cuidado. MiniLM aquí produce vectores, no respuestas escritas (diapositiva 12). Y «ninguno tiene garantizado ser el mejor para nuestras consultas»: se valida con datos (diapositiva 13).

4 Geometría: distancia, producto interno, norma y coseno

Con vectores se puede medir «parecido» de tres maneras. El coseno compara la dirección y descarta el tamaño; por eso es la medida que usa el buscador.

1. **Vector en el plano.** Una flecha desde el origen. Su dirección es el perfil entre las coordenadas; su longitud es la escala. Ejemplo (diapositiva 15): q = (1, 1), A = (2, 0), B = (4, 4), que son conteos de «clave» y «recuperar».
2. **Distancia.** $\|q - a\| = \sqrt{2} \approx 1.414$; $\|q - b\| = \sqrt{18} \approx 4.243$. Como punto, A está más cerca de q (diapositiva 17).
3. **Producto interno.** Multiplicar las coordenadas correspondientes y sumar: $q^T a = 2$; $q^T b = 8$. Si se duplica el documento (8, 8), el producto se duplica a 16 aunque la dirección no cambió (diapositivas 18 y 19).
4. **Norma y normalización.** $\|z\| = \sqrt{(z_1^2 + \ldots + z_d^2)}$ mide la longitud: $\|q\| = \sqrt{2}$, $\|a\| = 2$, $\|b\| = \sqrt{32}$. Dividir por la norma da un vector de largo 1 con la misma dirección; q y B quedan iguales, (0.7071, 0.7071) (diapositivas 20 y 21).
5. **Coseno.** $\cos(q, z) = q^T z / (\|q\| \, \|z\|)$ es el producto de los vectores normalizados: 0.7071 para A (45°) y 1 para B (0°). 1 significa misma dirección, 0 perpendicular, −1 opuestos (diapositivas 22 y 23).

En palabras simples

Imagina a dos personas apuntando con el dedo. La **distancia** mide cuán separados están sus pies; el **coseno** mide si apuntan hacia el mismo lado, sin importar cuán largo sea el brazo. Un texto repetido cuatro veces tiene la misma dirección (de qué habla) pero una longitud mayor: el coseno no se deja engañar por la longitud.

$q^T z = \Sigma_j \, q_j \, z_j$

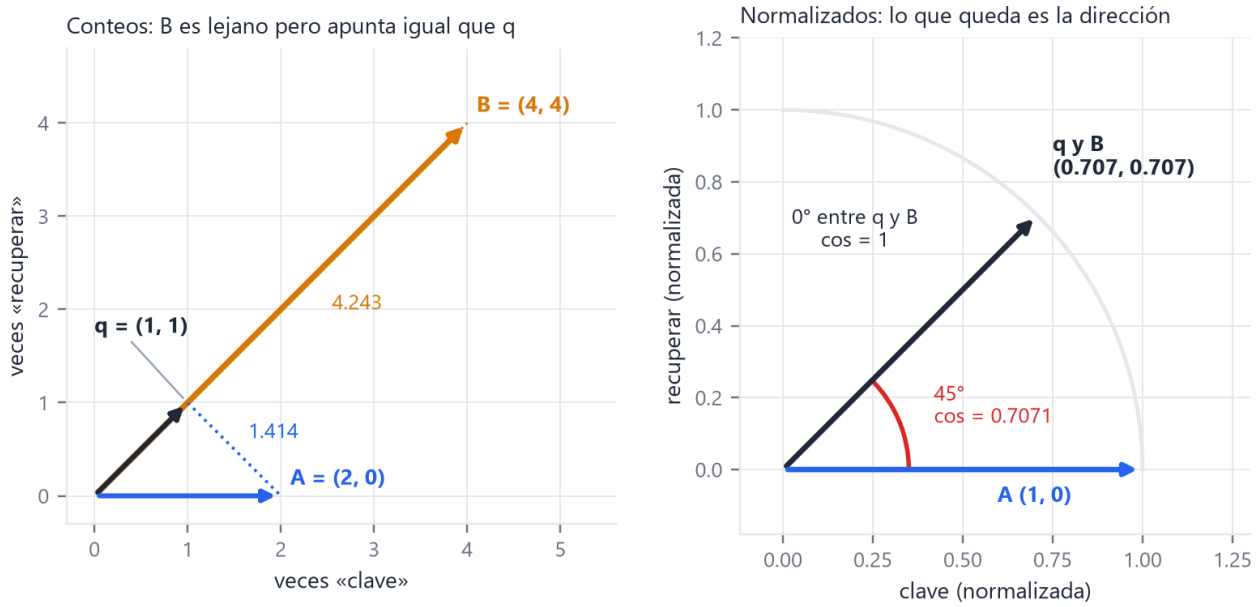
$\|z\| = \sqrt{(z_1^2 + z_2^2 + \ldots + z_d^2)}$

$\cos(q, z) = q^T z / (\|q\| \, \|z\|)$

Con los números de la clase

- Distancia: A 1.414, B 4.243 (favorece a A). Producto interno: A 2, B 8. Coseno: A 0.7071, B 1 (favorece a B) — diapositiva 24
- El coseno 0.8 es un puntaje geométrico, **no un 80 % de probabilidad** de acierto (diapositiva 23)
- Una fila nula (norma 0) no se puede normalizar: el programa la deja en 0 en lugar de dividir

Cuidado. El coseno no es una solución universal: la medida se elige según el modelo y la tarea (diapositiva 24).



Diapositivas 15 a 23: a la izquierda, los conteos y las distancias; a la derecha, los mismos vectores normalizados y el ángulo entre ellos.

Medida	A	B	Qué compara
Distancia	1.414	4.243	Separación entre los puntos finales
Producto interno	2	8	Coordenadas, con el efecto de la escala
Coseno	0.7071	1	Dirección, retirando la escala

5 Una consulta contra 12 fichas: del coseno en 384 dimensiones a un ranking

Con MiniLM los vectores vienen normalizados, así que el coseno es la suma de 384 productos. Hacerlo con cada pareja consulta-ficha da una matriz de 16 × 12; ordenar cada fila da el ranking.

1. **Una pareja.** V01 con D01: se multiplican las 384 coordenadas y se suman. Los tres primeros productos son −0.00114, 0.00082 y −0.00218; las otras 381 coordenadas suman 0.45262; el total es 0.45013 ≈ 0.450 (diapositiva 32).
2. **La matriz.** Q (16 × 384) por D^T (384 × 12) da S (16 × 12): una fila por consulta, una columna por ficha (diapositiva 33). Trasponer D pone las fichas en columnas.
3. **Ordenar.** En cada fila se ordena de mayor a menor puntaje; los empates se resuelven por identificador de ficha. Siempre hay un primer lugar, aunque ninguna ficha responda.
4. **Rango r.** Posición de la ficha relevante en el ranking. Para V01: r = 6 con TF-IDF y r = 1 con MiniLM (diapositiva 34). Para V02 con MiniLM: D06 (0.236), D02 (0.147) y D01 (0.131): r = 2 (diapositiva 35).
5. **Identificador.** D05 es solo el nombre de la ficha de pagos: el 05 no es un puntaje, una posición ni una coordenada (diapositiva 4).

En palabras simples

Es como un concurso con **384 jueces**: cada uno da un poquito de puntos a la pareja (algunos positivos, otros negativos) y el total es el coseno. Se hace lo mismo con las 12 fichas, se ordenan y la de mayor puntaje queda primera. Que gane no significa que responda la pregunta.

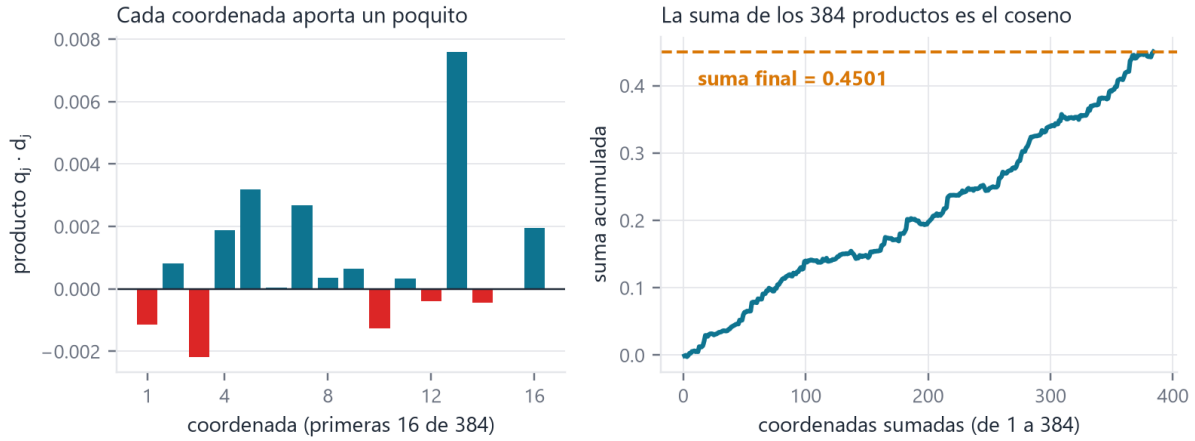
$S = Q\,D^{\intercal} \rightarrow (16 \times 384)(384 \times 12) = (16 \times 12)$

$\cos(V01, D01) = \Sigma_{j=1}^{384}\, q_j\, d_j$

Con los números de la clase

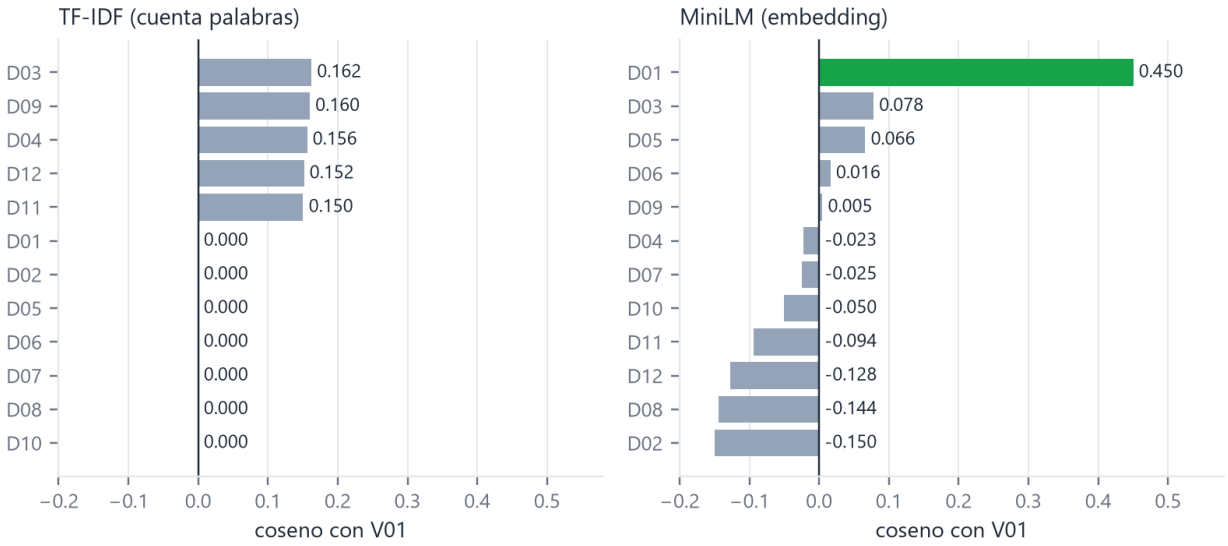
- De los 384 productos de V01 con D01, 244 son positivos (suman 0.590) y 140 negativos (suman −0.140); total 0.450 (nuestro cálculo)
- V01 con las fichas: D01 0.450, D02 −0.150, D03 0.078, D12 −0.128 (diapositiva 33)
- TF-IDF para V01: D03 0.162, D09 0.160, D04 0.156; MiniLM: D01 0.450, D03 0.078, D05 0.066

Cuidado. Los cosenos de MiniLM de consultas distintas no son comparables como «seguridad»: V01 acierta con 0.450 y V06 acierta con 0.262 (ver los mapas).

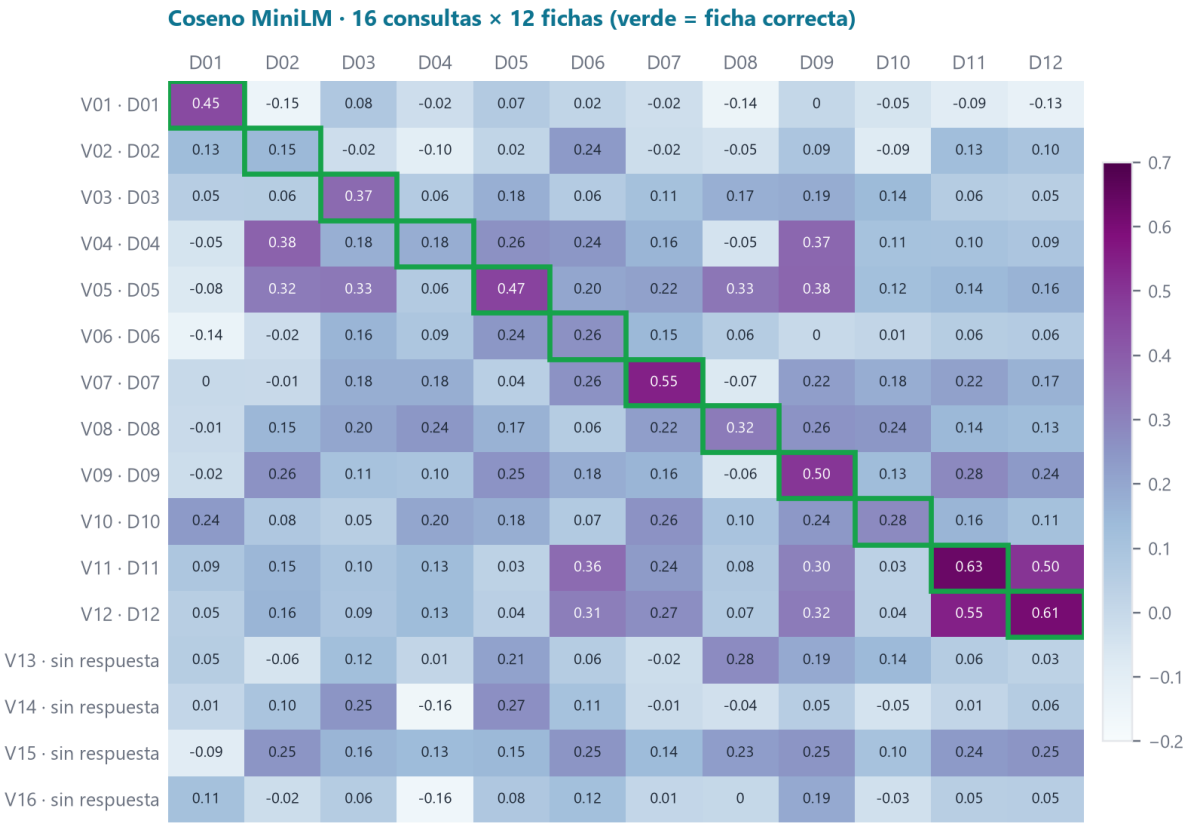


Nuestro cálculo para V01 con D01: los productos de las primeras 16 coordenadas (izquierda) y la suma acumulada de las 384 (derecha).

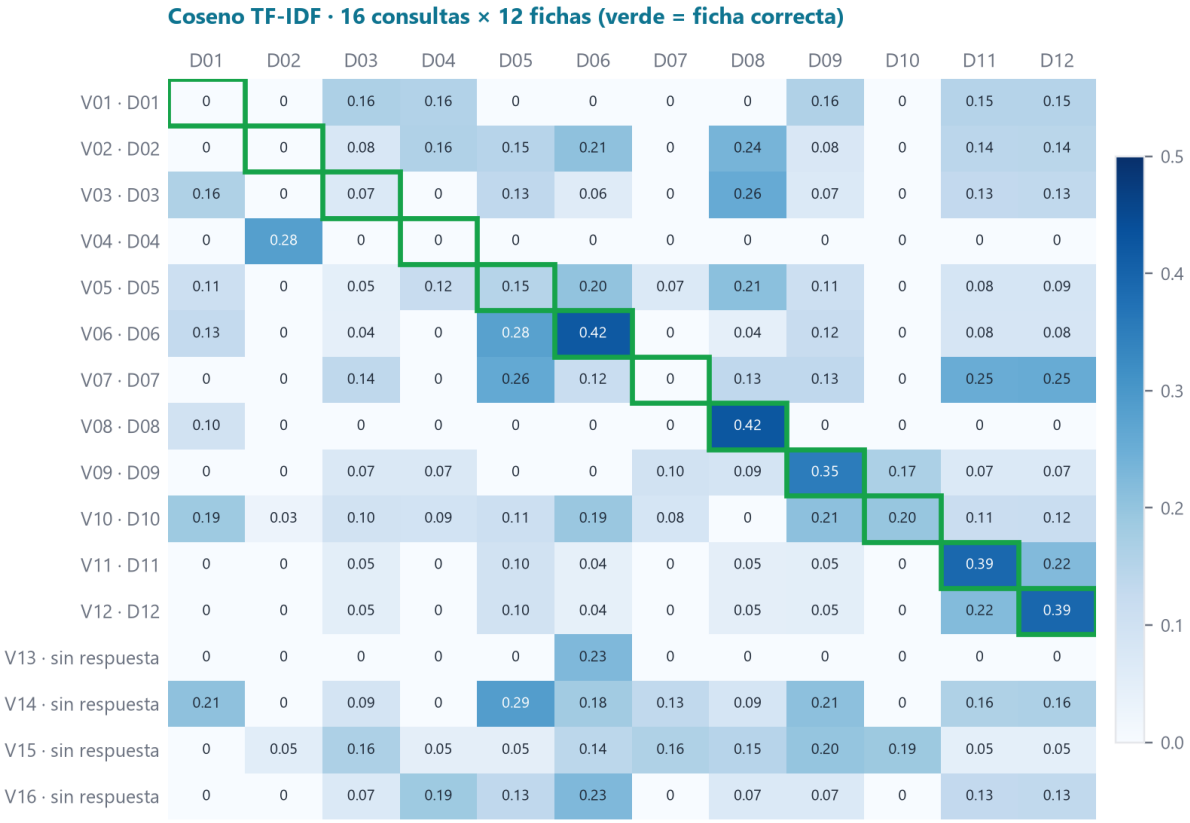
V01 «Olvidé mi clave…»: la ficha correcta (D01, verde) queda 6.ª con TF-IDF y 1.ª con MiniLM



Diapositiva 34, completa: los 12 puntajes de V01 con TF-IDF y con MiniLM. Verde: la ficha correcta.



Nuestro cálculo (coincide con el programa del profesor): la matriz S de MiniLM, 16 consultas × 12 fichas. Cuadro verde: la ficha correcta de cada consulta con respuesta; V13 a V16 no tienen ficha correcta.



Nuestro cálculo: la misma matriz con TF-IDF. Muchos ceros: una pareja sin palabras en común no suma nada, aunque hablen de lo mismo.

6 Evaluar: rango, Hit@k, MRR y elegir cuántas fichas mostrar

Para saber si el buscador funciona hay que medirlo con consultas cuya ficha correcta conocemos. Hit@k cuenta en qué proporción de consultas la ficha correcta está entre las k primeras; MRR premia que esté más arriba.

1. **Rango r.** La posición de la ficha relevante en el ranking de una consulta: 1 es la mejor. Es la base de las dos métricas.
2. **Hit@k.** Hit@k = (1/n) Σ 1[$r_i \le k$]. Con V01, V02 y V04 (rangos 1, 2 y 5) y k = 3, los aportes son 1, 1 y 0: Hit@3 = 2/3 ≈ 0.667 (diapositiva 36). Cada fila es una consulta distinta.
3. **MRR.** MRR = (1/n) Σ $1/r_i$ (Mean Reciprocal Rank). Con los mismos tres rangos: (1 + 1/2 + 1/5)/3 ≈ 0.567 (diapositiva 37). Distingue el primer lugar del segundo y **no depende de k**.
4. **Elegir k.** Mostrar más fichas aumenta los aciertos, pero también lo que hay que leer. Cuando el ranking no cambia, subir k solo cambia el Hit@k; el MRR queda igual (diapositiva 44). Con 100 fichas, mostrar 3 a 5 sería mucho más útil que con 12.
5. **Solo las respondibles.** Hit@k y MRR se calculan con las 12 consultas que tienen ficha correcta (V01 a V12). Las 4 sin respuesta se tratan aparte (sección 7).

En palabras simples

Es como un examen: el buscador responde con una lista. Hit@k pregunta «¿estaba la respuesta correcta entre las primeras k líneas?». MRR da nota completa si estaba primera, la mitad si estaba segunda, un tercio si tercera… y luego promedia todas las consultas.

$$\text{Hit@k} = \frac{1}{n} \sum_i 1[r_i \le k]$$

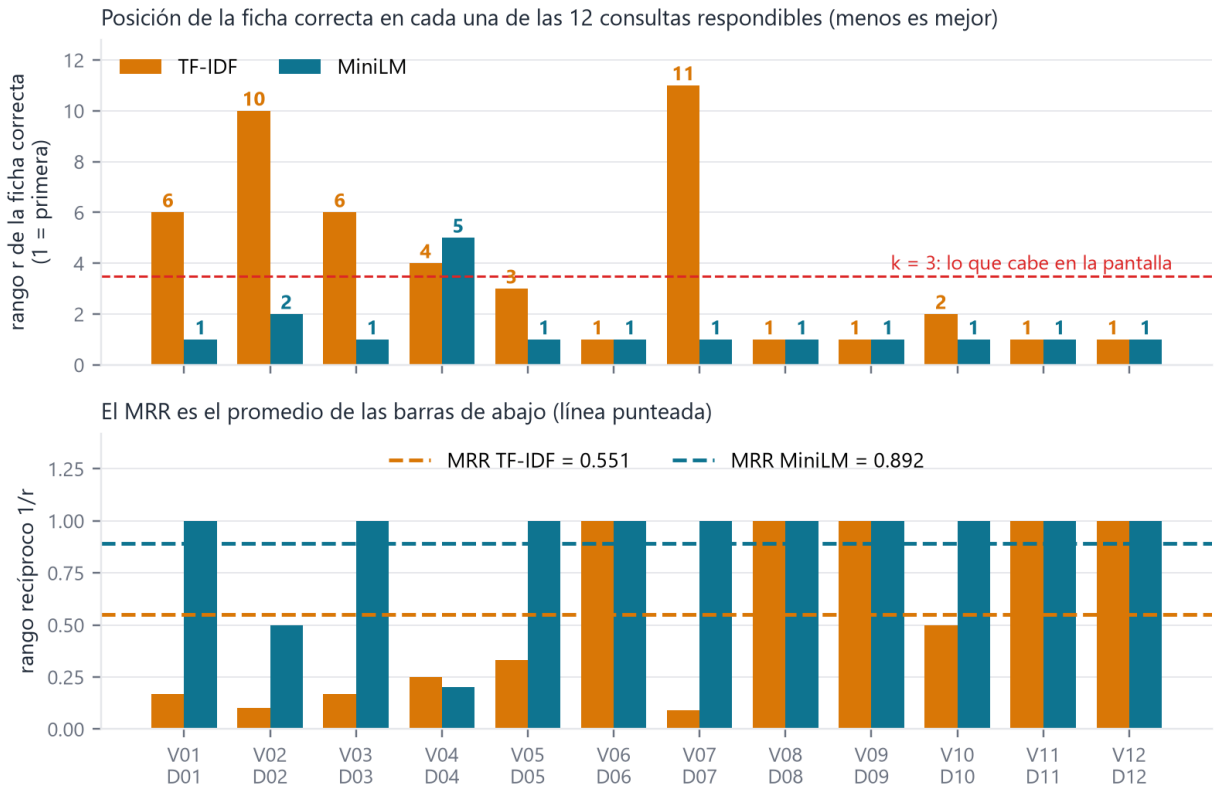
$$\text{MRR} = \frac{1}{n} \sum_i \frac{1}{r_i}$$

n = 12 consultas con respuesta

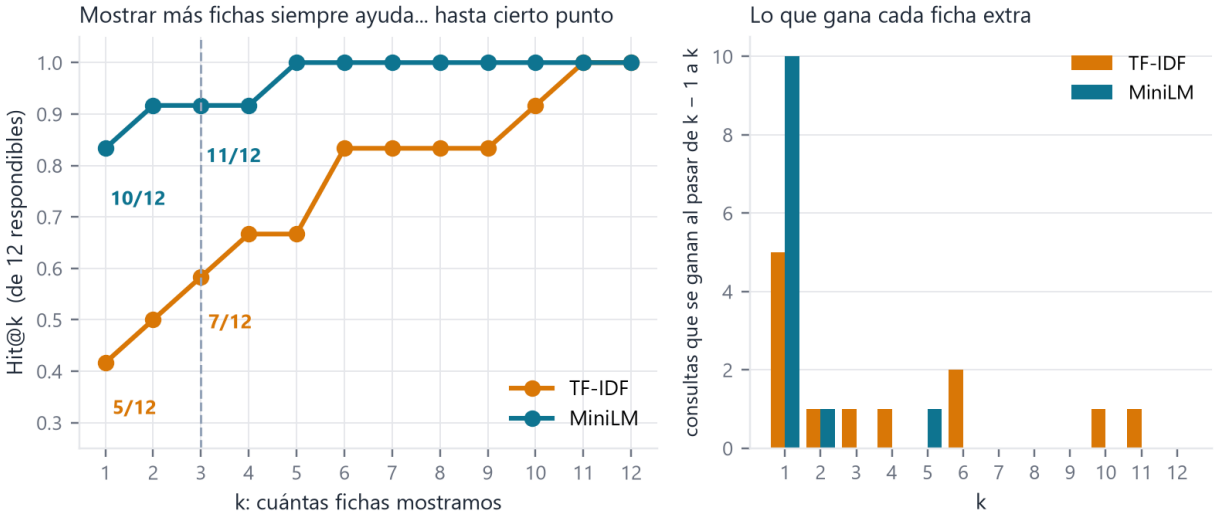
Con los números de la clase

- Hit@3: TF-IDF 7/12 = 0.583; MiniLM 11/12 = 0.917. MRR: 0.551 y 0.892 (diapositiva 38)
- Hit@1: TF-IDF 5/12; MiniLM 10/12. Pasar de k = 1 a k = 3 suma 2 consultas a TF-IDF y 1 a MiniLM (diapositiva 44)
- MiniLM llega a 12/12 recién con k = 5 (V04 está en el lugar 5); TF-IDF, con k = 11 (V07 está en el lugar 11) — nuestro cálculo
- V04 «¿Me conceden más días automáticamente si pido prórroga?»: TF-IDF la pone 4.ª y MiniLM 5.ª; con k = 3 ninguna la recupera

Cuidado. Son solo 12 consultas: una sola que cambie mueve Hit@k en 0.083 (1/12). El promedio favorable a MiniLM debe acompañarse de revisar los errores (diapositiva 38). Y k se elige con validación, no con la prueba.



Nuestro cálculo con las 12 consultas respondibles: rango de la ficha correcta (arriba) y rango recíproco con el MRR (abajo).



Nuestro cálculo: Hit@k para todos los k de 1 a 12. La línea punteada marca k = 3, el valor de las diapositivas.

7 Errores y límites: códigos casi iguales, información insuficiente y preguntas sin respuesta

Un puntaje alto no garantiza una respuesta correcta. Tres situaciones lo muestran: dos fichas casi idénticas que difieren en un código, una ficha relacionada pero que no contiene el dato, y preguntas que ninguna ficha responde.

1 **Códigos exactos.** D11 (proyecto A17, 12 de noviembre) y D12 (A71, 19 de noviembre) comparten casi todas las palabras: solo cambian «a17» frente a «a71» y la fecha. Confundirlas entrega una fecha equivocada (diapositiva 40). En V11 y V12 ambas recetas ponen la ficha correcta primero.

2 **Relacionada pero insuficiente.** V14 «¿Cuál es el precio total en pesos?»: ambas recetas ponen D05 primero porque habla de pagos y cuotas, pero no informa el valor de las cuotas ni el total (diapositiva 41). Un ranking siempre tiene un primer lugar.

3 **Corte de aceptación.** Se acepta una consulta si su coseno máximo alcanza un corte c. Con c = 0.3 se aceptan 9 de 12 respondibles y 0 de 4 sin respuesta; con c = 0.5, 3 de 12 y 0 de 4 (diapositiva 42). Con 0.7 y 0.9 no se acepta ninguna (programa). Cada corte rechaza consultas que sí tenían respuesta.

4 **Aceptar, recuperar y responder.** Son tres etapas con criterios distintos: **aceptar** (el puntaje alcanza el corte), **recuperar** (la ficha pertinente está entre las k primeras) y **responder** (la respuesta usa fielmente información suficiente). Encontrar un vecino no es contestar bien (diapositiva 43).

En palabras simples

Piensa en un bibliotecario que siempre te trae el libro «más cercano» al tema: pediste el **precio** y te trae el libro de **pagos**. Es el libro correcto del estante, pero la cifra no está. Y como un GPS, siempre propone una ruta, aunque la calle que buscas no exista. Por eso hace falta un corte, y mirar qué responde de verdad.

aceptar si $\max_j \cos(q, d_j) \geq c$

recuperar si $r \leq k$

responder: requiere revisar el contenido

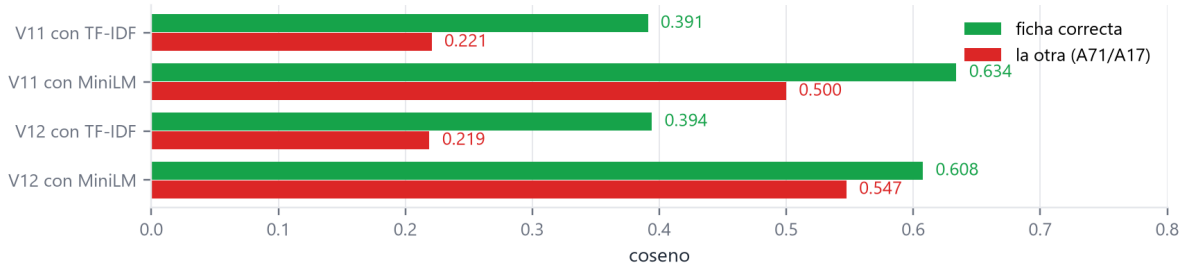
Con los números de la clase

- V11: ficha correcta con TF-IDF 0.391 frente a 0.221; con MiniLM 0.634 frente a 0.500. V12: TF-IDF 0.394 y 0.219; MiniLM 0.608 y 0.547 (nuestro cálculo)
- El margen de MiniLM en V12 es solo 0.060; y el coseno entre D11 y D12 vale 0.891, el par de fichas más parecido de las 12 (TF-IDF: 0.888)
- V14: coseno máximo 0.266 con D05 (en clase: «0,6… 0,26, algo de ese estilo»); las consultas sin respuesta V13, V14, V15 y V16 llegan a 0.276 como máximo; V02, V06 y V10 (con respuesta) solo a 0.236, 0.262 y 0.280
- Con solo 4 consultas sin respuesta es poco para generalizar (diapositiva 42)

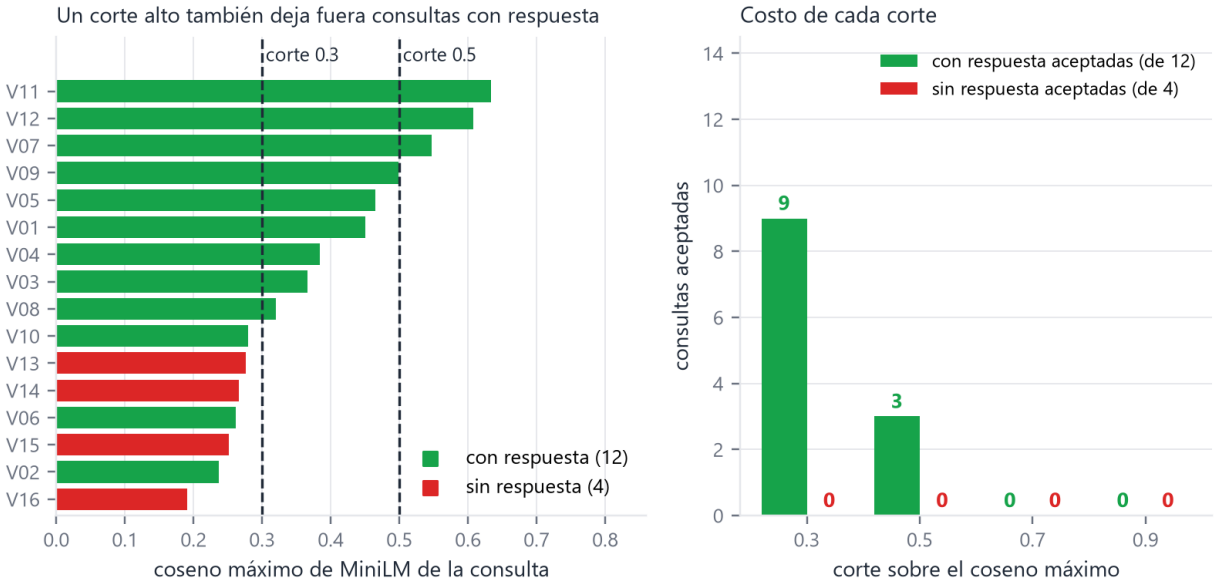
Cuidado. Los cortes 0.3, 0.5, 0.7 y 0.9 son ilustrativos: el coseno no es una probabilidad. Elegir c implica aceptar el costo de rechazar consultas respondibles frente al riesgo de aceptar información insuficiente.

D11 y D12: casi la misma frase; cambia solo el código del proyecto

D11	El proyecto	A17	se entrega el	12 de noviembre	de 2026 a las 18:00. Incluye un informe PDF…
D12	El proyecto	A71	se entrega el	19 de noviembre	de 2026 a las 18:00. Incluye un informe PDF…



Diapositiva 40 con nuestro cálculo: las dos fichas casi idénticas y los cosenos de V11 y V12 con la ficha correcta y con la otra.



Diapositiva 42 con nuestro cálculo: el coseno máximo de cada consulta (izquierda) y cuántas consultas se aceptan con cada corte (derecha).

8 Mirar el espacio con PCA y reutilizar los embeddings

El PCA dibuja las 384 coordenadas en un plano para explorar, pero la búsqueda sigue usando las 384. Y el mismo embedding puede alimentar un clasificador, un agrupamiento o una búsqueda de vecinos.

1. **PCA de las fichas.** Resume las 12 fichas centradas en dos ejes: PC1 explica 20.0 % de la variación y PC2 14.2 %; juntos 34.3 % (diapositiva 45). Se pierde casi dos tercios de la variación.
2. **Qué se ve.** D11 y D12 aparecen casi juntas: sus textos son muy parecidos, pero no idénticos (no están en el mismo punto). Las consultas, proyectadas con la misma base, caen cerca de su ficha correcta en varios casos y lejos en otros.
3. **El ranking no se calcula ahí.** El ranking se calcula en el espacio original de 384 coordenadas; el plano ayuda a explorar, la calidad se juzga con consultas y relevancia (diapositiva 45).
4. **Otros usos.** Clasificación (aprender etiquetas desde las coordenadas, como spam), agrupamiento (revisar la coherencia y estabilidad de los grupos) y búsqueda de vecinos. Cambiar la tarea cambia qué resultado hay que evaluar (diapositiva 46).
5. **Qué revisar al cambiar la aplicación.** Otro codificador (recalcular fichas y consultas en el mismo espacio), otra división de las fichas, otro dominio de consultas, otro puntaje o corte: volver a medir recuperación y aceptación (diapositiva 47).

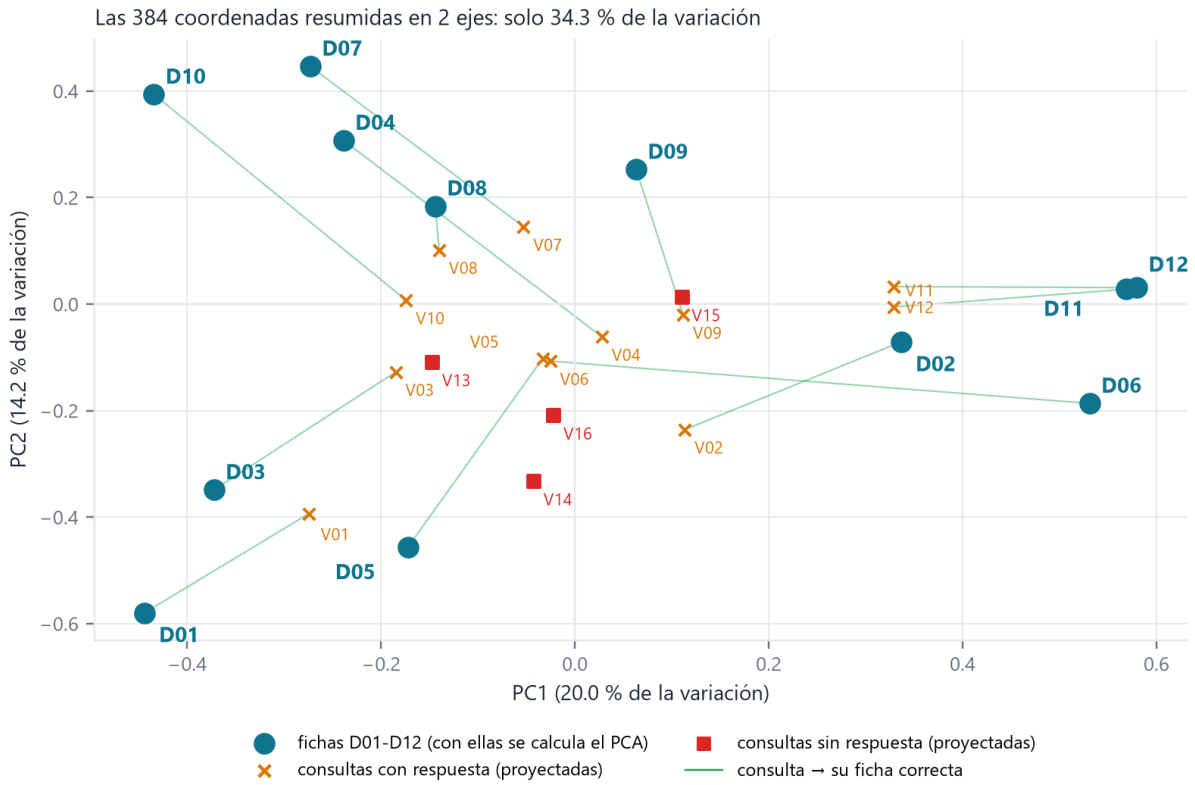
En palabras simples

El PCA es una **foto aérea** de una ciudad de 384 calles: ves qué barrios quedan juntos, pero se pierde mucho (dos edificios de distinta altura parecen iguales). Para buscar la dirección exacta no usas la foto, usas el mapa completo.

Con los números de la clase

- PC1 20.0 %, PC2 14.2 %, suma 34.3 % (diapositiva 45; reproducido)
- D11 y D12 están a la derecha del plano y muy cerca: coseno 0.891 en 384 dimensiones
- Resumen de la clase: el embedding convierte algo no matemático (texto) en un vector; después se aplican las mismas redes y métricas que ya conocemos

Cuidado. Los ejes del PCA no tienen nombre y la cercanía en el dibujo no es un ranking. Con 34 % de variación, el plano omite otras diferencias.



Diapositiva 45 con nuestro cálculo: las 12 fichas (PCA ajustado solo con ellas) y las 16 consultas de validación proyectadas con los mismos ejes.

Repaso, alertas del material y criterio de dominio

Lo que debes poder explicar sin apuntes

Alertas del material

Qué conviene saber al leer las diapositivas y la transcripción

- **La transcripción tenía errores de reconocimiento de voz** («reenerales» por redes neuronales; «toncodes» y «AutonCoders» por autoencoders; «Empery» por embeddings; «Mini LEM», «MIMLM» y «MiniLemme» por MiniLM; «TF y DF» por TF-IDF; «pichas» por fichas; «octogonales» por ortogonales; «Ábula Libre» por Aula Abierta; «PSA» por PCA). Se corrigieron en 91 líneas; el original se conserva en `VideosClases/originales_sin_corregir/`.
- **Dos cifras dichas en voz alta no coincidían con las diapositivas:** «el rango de V04 era 3» (es 5, diapositivas 36 y 39) y «con 3 candidatos pasé de 11 a 12» (es de 10 a 11, diapositiva 44). En la transcripción están corregidas.
- **El «0,6, si mal recuerdo, 0,26»** para el coseno de V14 con D05: el valor es 0.266.
- **La grabación empieza unos 5 minutos tarde y tiene un recreo** (1:10:26 a 1:28:13): lo que falta se cubre con las diapositivas.
- **«Las 16 consultas de evaluación»** que menciona el profesor son las 16 de **validación**; las 16 de prueba se reservan y aquí no se evalúan.
- **MRR** se dice «Mean Reciprocal Rank» (en la grabación sale «Grant»). **R** y Python dan lo mismo en esta clase; las cifras de las diapositivas son las de Python.

Preguntas de repaso (intenta responder antes de leer)

#	Pregunta	Respuesta corta
1	q = (1, 1) y un texto repetido cuatro veces b = (4, 4): ¿qué producto interno y qué coseno tienen? ¿Y con a = (2, 0)?	$q^T b = 8$ y coseno 1; $q^T a = 2$ y coseno 0.7071. El coseno quita el efecto del largo.
2	¿Por qué «clave» y «contraseña» son perpendiculares en un conteo?	Cada palabra activa una columna distinta: (1, 0, 0) y (0, 1, 0). El producto interno es 0 y el coseno 0.
3	Si «a17» está en 1 de las 12 fichas, ¿cuál es su IDF?	ln(13/2) + 1 = 2.8718.
4	Con vectores normalizados, ¿cómo se obtiene el coseno?	Sumando los productos de las coordenadas correspondientes (384 en MiniLM).
5	¿Qué forma tiene $S = Q D^T$ y qué representa cada casilla?	16 × 12: el coseno de una consulta con una ficha.
6	Rangos de 3 consultas: 1, 2 y 5. ¿Hit@3 y MRR?	Hit@3 = 2/3 ≈ 0.667; MRR = (1 + 0.5 + 0.2)/3 ≈ 0.567.
7	¿Qué métrica no cambia al subir k y por qué?	El MRR: usa el ranking completo (el rango r), no solo las k primeras.
8	¿Por qué «precio total en pesos» recupera D05 y aun así no se responde?	D05 habla de pagos y cuotas, pero no informa el monto; recuperar no es responder.
9	¿Qué porcentaje de la variación muestra el plano PCA y por qué importa?	34.3 %: el dibujo omite casi dos tercios; el ranking usa las 384 coordenadas.

Criterio de dominio

- ☐ Convierto textos cortos en vectores de conteo y explico por qué los sinónimos quedan perpendiculares
- ☐ Calculo a mano un IDF, un producto interno, una norma y un coseno
- ☐ Explico por qué el coseno compara direcciones y la distancia no
- ☐ Ordeno 12 fichas por puntaje, encuentro el rango r y calculo Hit@k y MRR
- ☐ Elijo k y un corte de aceptación explicando el costo de cada uno
- ☐ Explico por qué recuperar una ficha no es responder, y por qué dos códigos casi iguales son un riesgo

Cifras de las diapositivas frente a nuestra reproducción (programa del profesor)

Cifra	Diapositivas	Reproducido	¿Igual?
Error de destilación (maestro [0.2, 0.8], estudiante [0.4, 0.6])	0.04	0.04	sí
Distancia $\|q - a\|$ y $\|q - b\|$	1.414 y 4.243	1.414 y 4.243	sí
Producto interno $q^T a$, $q^T b$ y $q^T(2b)$	2, 8 y 16	2, 8 y 16	sí
Normas $\|q\|$, $\|a\|$, $\|b\|$	√2, 2, √32	1.4142, 2.0000, 5.6569	sí
Coseno de q con A y con B (también en el programa)	0.7071 y 1	0.7071 y 1	sí
V01 · D01: primeros tres productos	−0.00114; 0.00082; −0.00218	−0.00114; 0.00082; −0.00218	sí
V01 · D01: coordenadas 1 a 3 de V01 y de D01	0.04347, 0.02170, 0.02971 y −0.02631, 0.03797, −0.07323	0.04347, 0.02170, 0.02971 y −0.02631, 0.03797, −0.07323	sí
V01 · D01: suma de las otras 381 coordenadas	0.45262	0.45262	sí
V01 · D01: coseno (suma de 384 productos)	≈ 0.45013 (0.450)	0.45013; programa: 0.45013	sí
Matriz 16 × 12 (V01: D01, D02, D03, D12)	0.450; −0.150; 0.078; −0.128	0.450; −0.150; 0.078; −0.128	sí
Matriz (V02 y V03 con D01, D02, D03, D12)	V02: 0.131; 0.147; −0.022; 0.098 · V03: 0.052; 0.056; 0.366; 0.048 (la lámina alinea los dos últimos en la fila siguiente)	V02: 0.131; 0.147; −0.022; 0.098 · V03: 0.052; 0.056; 0.366; 0.048	sí

Cifra	Diapositivas	Reproducido	¿Igual?
V01 con TF-IDF: tres primeros (D03, D09, D04)	0.162; 0.160; 0.156	0.162; 0.160; 0.156 (D03, D09, D04)	sí
V01 con TF-IDF: lugar de D01 y puntaje	lugar 6; puntaje 0	lugar 6; puntaje 0	sí
V01 con MiniLM: D01, D03, D05	0.450; 0.078; 0.066	0.450; 0.078; 0.066 (D01, D03, D05)	sí
V02 con MiniLM: posiciones 1, 2 y 3	D06; D02; D01	D06; D02; D01	sí
Rangos MiniLM de V01, V02, V04	1; 2; 5	1; 2; 5	sí
Hit@3 de V01, V02, V04	2/3 ≈ 0.667	2/3 = 0.667	sí
MRR de V01, V02, V04	≈ 0.567	0.567	sí
Hit@3 en las 12 respondibles (TF-IDF; MiniLM)	7/12 = 0.583; 11/12 = 0.917	7/12 = 0.583; 11/12 = 0.917	sí
MRR en las 12 respondibles (TF-IDF; MiniLM)	0.551; 0.892	0.551; 0.892	sí
Hit@1 (TF-IDF; MiniLM)	5/12; 10/12	5/12; 10/12	sí
Programa (K = 3): Hit@3 y MRR de cada receta	0.583333 / 0.550631; 0.916667 / 0.891667	0.583333 / 0.550631; 0.916667 / 0.891667	sí
A17 / A71 (V11, V12): rango de la ficha correcta	1 en TF-IDF y 1 en MiniLM	V11: 1 y 1; V12: 1 y 1	sí
«Precio total» (V14): ficha en primer lugar en ambas recetas	D05 en ambas	TF-IDF: D05; MiniLM: D05	sí
Cortes 0.3 y 0.5: respondibles / sin respuesta aceptadas (el programa agrega 0.7 y 0.9)	0.3: 9/12 y 0/4 · 0.5: 3/12 y 0/4	0.3: 9/12 y 0/4; 0.5: 3/12 y 0/4; 0.7: 0/12 y 0/4; 0.9: 0/12 y 0/4	sí
PCA de las 12 fichas: PC1, PC2 y suma	20.0 %; 14.2 %; 34.3 %	20.0 %; 14.2 %; 34.3 %	sí
Programa: 16 × 12 puntajes MiniLM y rangos de las 12 respondibles	—	máxima diferencia 0.0e+00; rangos idénticos	sí

No reproducible con el programa: la forma exacta de los vectores 'ejemplo' de las diapositivas 31 (16 de 384 coordenadas, solo colores); el entrenamiento de MiniLM, que aquí se usa ya calculado (vectores.csv); el desempeño en las 16 consultas de prueba, que el profesor reserva (no se evaluó).